

Torre del Caribe

Guía técnica

Cómo hicimos el proyecto, fórmula por fórmula, con su fundamento y sus ejemplos resueltos a mano

Licenciatura en Ciencias de Datos para Negocios · 5° semestre, 2026-2

Problema Prototípico: *Turismo inteligente sustentable para México* (Quintana Roo)

Responsable técnico: **Brandon Uriel García Sánchez**

Equipo: Maribel Mondragón Mercado · Jesús Ramírez Isidro · Enrique González Ortega

Versión del 2 de octubre de 2026

Índice general

Cómo leer esta guía	1
I El proyecto y sus preguntas incómodas	3
1. El problema y la respuesta	4
1.1. La pregunta del Problema Prototípico	4
1.2. La respuesta en una página	4
1.3. Tres módulos que no se enciman	5
1.4. Cómo se pasan la estafeta	6
1.5. Las siete preguntas secundarias y quién las responde	6
1.6. Las 12 fases	7
2. Cómo construimos el proyecto	8
2.1. Cómo usamos la inteligencia artificial	8
2.2. Por qué hay tantos archivos de código	8
2.3. Notebooks, pruebas y reproducibilidad	11
2.4. El entorno de cómputo	12
3. Los datos: de dónde sale cada cifra	13
3.1. La regla: solo fuentes oficiales, descargadas con código	13
3.2. Las fuentes, una por una	13
3.3. Lo que no existe (huecos declarados)	16
II Las materias, una por una	17
4. Grandes volúmenes de datos	18
4.1. La arquitectura medallón: Bronze, Silver y Gold	18
4.2. Spark: qué es y qué hace exactamente aquí	19
4.3. Reglas de limpieza: cero no es lo mismo que hueco	20

4.4. Cuando dos fuentes cuentan lo mismo (conciliación)	22
4.5. El almacén DuckDB y el modelo estrella	22
4.6. Streaming: la Torre en vivo con Spark Structured Streaming	23
4.7. Privacidad	24
5. Planteamiento: el problema medido	25
5.1. Concentración: cuotas e índice de Herfindahl-Hirschman	25
5.2. ¿Por qué estos cinco lugares? La tabla de criterios	27
5.3. Variables, actores y relaciones	28
6. Minería de datos: encontrar patrones	29
6.1. El índice de presión turística (IPT)	29
6.2. Agrupamiento de los centros turísticos del país (Ward)	32
6.3. La forma del año (estacionalidad)	33
6.4. Clima raro con Isolation Forest (detección de anomalías)	35
6.5. Minería de texto de las reseñas	37
6.6. NLP de lugares: qué hacer, dónde comer y dónde dormir	39
7. Aprendizaje de máquina: predecir	41
7.1. Clasificación: ¿qué estado tendrá cada lugar el mes siguiente?	41
7.2. Pronóstico de visitantes: series de tiempo	44
8. Procesos estocásticos: la incertidumbre	50
8.1. Cadena de Markov semanal del norte	50
8.2. Tormentas: definición y distancia	52
8.3. Poisson: la probabilidad de tormenta en cada mes	53
8.4. Monte Carlo: escenarios malo, probable y bueno	53
8.5. Sensibilidad: ¿qué variable mueve más?	55
9. Investigación de Operaciones: repartir el presupuesto	57
9.1. La pregunta	57
9.2. Los parámetros: cuánto rinde un peso en cada canal	57
9.3. El modelo completo	58

9.4. Cómo lo resuelve la computadora	59
9.5. El resultado, a mano	60
9.6. ¿Cuánto cuesta cada regla? Dualidad y precios sombra	61
9.7. Sensibilidad: ¿y si los supuestos están mal?	63
9.8. La etapa 2 en la práctica: el motor de la Torre	63
10. Mercadotecnia digital: la campaña	65
10.1. El marco: segmentar, elegir y posicionar	65
10.2. Segmentar: lo que dicen los datos	65
10.3. Elegir: dos viajeras ideales (buyer persona)	66
10.4. Posicionar: la marca	66
10.5. Los mensajes: cada promesa con su dato	67
10.6. Los medios y el calendario	67
10.7. Cómo se mide: los indicadores	68
10.8. La regla anti-colapso	68
III Cierre	70
11. Integración, página y servidor	71
11.1. La estafeta, con archivos	71
11.2. La página web	71
11.3. El servidor que calcula en vivo (Fase 9)	72
11.4. Página final y cierre (Fases 10 y 11)	72
12. Lo que no se pudo medir y lo que se supuso	73
12.1. Huecos (datos que no existen)	73
12.2. Supuestos (lo que se dio por cierto)	74
12.3. Lo que los modelos no pueden afirmar	74
13. Preguntas difíciles y su respuesta	75
13.1. Sobre el proyecto y los datos	75
13.2. Sobre los métodos	75
13.3. Sobre la optimización y la campaña	76

A. Glosario

78

Cómo leer esta guía

En esta guía explicamos **todo** lo que hace Torre del Caribe: de dónde sale cada dato, qué hace cada archivo de código, qué método usamos, **de dónde viene cada fórmula** (no solo cuál es), cómo la resolvimos a mano con números reales del proyecto, qué supusimos, qué alternativas descartamos y por qué. La escribimos para que cualquier integrante del equipo pueda defender cada pieza frente a un profesor sin abrir el código, y para mostrar el razonamiento, no solo el resultado.

El orden de cada método

Cada método de la guía sigue el mismo recorrido, y cada parte tiene su propia caja de color:

Parte	Qué contesta
Pregunta	Qué duda del problema resuelve este método y a qué decisión de la campaña alimenta.
La idea	La intuición sin fórmulas: qué hace el método con palabras de todos los días.
El fundamento	De dónde sale la fórmula: qué propiedad matemática o estadística la justifica.
A mano	Un ejemplo con números reales del proyecto, paso por paso, que coincide con lo que da el código.
Supuestos y límites	Qué dimos por cierto y qué no puede afirmar el método.
Por qué así	Qué alternativa consideramos y con qué evidencia la descartamos.
Código	El archivo y la función donde vive.
Si nos preguntan	Nuestra respuesta corta para el profesor.

Tres convenciones

- **Medido** es lo que sale directo de una fuente oficial. **Estimado** es lo que sale de un modelo; en las tablas del proyecto lleva el sufijo `_est` y siempre va acompañado de su error.
- **Hueco** es un dato que no existe. Nunca lo rellenamos con ceros ni con promedios: lo declaramos y decimos qué no se puede afirmar por su culpa.
- **Recalculamos las cifras** el 2 de octubre de 2026 con los datos del proyecto. Las principales

las vigila la prueba automática `tests/test_guias.py`: si una fuente se vuelve a descargar y una cifra cambia, la prueba falla y obliga a corregir esta guía.

Cómo está organizada

- **Parte I** contesta las preguntas que un profesor hace primero: qué problema resolvimos, cómo construimos el proyecto (incluido el uso de inteligencia artificial), por qué hay tantos archivos y de dónde sale cada dato.
- **Parte II** recorre las materias (UCA) una por una: grandes volúmenes de datos, planteamiento, minería, aprendizaje de máquina, procesos estocásticos, investigación de operaciones y mercadotecnia digital.
- **Parte III** explica cómo se integran, qué no pudimos medir y las preguntas difíciles con su respuesta.

PARTE I

El proyecto y sus preguntas incómodas

El problema y la respuesta

1.1 La pregunta del Problema Prototípico

El Problema Prototípico de la UNRC pide responder:

¿Cómo diseñar una campaña publicitaria basada en Ciencia de Datos que permita promover estratégicamente un destino turístico del estado seleccionado, atraer segmentos de visitantes de manera responsable y contribuir a una distribución más equilibrada de los flujos turísticos, aprovechando la capacidad disponible y reduciendo los impactos económicos, sociales y ambientales asociados con la saturación turística?

La pregunta tiene cuatro exigencias que el proyecto atiende por separado, y conviene tenerlas presentes porque cada módulo responde a una:

1. **Promover estratégicamente:** saber *dónde* hay espacio y *cuándo* conviene ir (Radar y Pronóstico).
2. **De manera responsable:** no llevar gente a donde ya está lleno ni con mal clima (reglas del presupuesto y la Torre en vivo).
3. **Distribución más equilibrada:** medir cuánto está concentrado el turismo y mover visitantes del norte al sur (planteamiento y campaña).
4. **Aprovechar la capacidad disponible:** medir la capacidad y no rebasarla (capacidad probada, Monte Carlo y optimización).

1.2 La respuesta en una página

Diagnóstico con datos. El norte de Quintana Roo (Cancún, la Riviera Maya, Tulum) concentra casi todo: Cancún recibe el **92.5 %** de los pasajeros de avión del estado y, en 2026, la franja de Tulum a Xcalak tiene sargazo récord (56 de 140 playas en rojo en agosto) y Tulum perdió el 31.3 % de sus visitas a la zona arqueológica entre enero y julio. El sur tiene espacio: los cinco lugares de la campaña tienen el **12.3 %** de la población del estado pero reciben el **1.4 %** de los pasajeros de avión.

Los cinco lugares (elegidos con una tabla de criterios, capítulo 5): Chetumal; la Bahía de Calderitas y Oxtankah; la Ruta arqueológica del sur (Kohunlich, Dzibanché e Ichkabal); Maya Ka'an con Kantemó; y la Laguna Milagros con Xul-Ha. Cancún, la Riviera Maya y Tulum aparecen **solo**

como referencia etiquetada: sirven para medir de dónde se redistribuye, pero la campaña no los promueve.

La campaña se llama “**El sur tiene espacio**”. Invita al sur con tres reglas que la hacen responsable: nunca anuncia un lugar en su temporada alta, se pausa sola con mal clima o si llega más gente de la esperada, y a quien iba al norte le ofrece el lugar del sur con más espacio.

1.3 Tres módulos que no se enciman

El sistema responde tres preguntas con horizontes distintos. La regla de diseño fue que **ninguna técnica contestara la pregunta de otro módulo**, para que no hubiera dos respuestas distintas a lo mismo.

Módulo	Pregunta	Horizonte	Técnicas
A1 Radar	¿Dónde hay presión y dónde hay espacio?	Hoy (meses y semanas)	Índice de presión, clustering, clasificador, cadena de Markov
A3 Pronóstico	¿Cuándo conviene ir y cuánto invertir?	1 a 12 meses	Forma del año, 5 modelos de series de tiempo, intervalo conformal, Poisson, Monte Carlo, optimización
A5 Torre en vivo	¿Qué hace la campaña esta semana?	Semana a semana	Spark Structured Streaming, Isolation Forest, motor de reglas
Campaña	¿A quién, con qué mensaje y por qué canal?	Todo el plan	Minería de texto, buyer persona, indicadores

Por qué no se enciman. El Radar predice un *estado* (una categoría: tranquilo, concurrido o saturado) a un mes; el Pronóstico predice un *nivel* (cuántos visitantes) a 1–12 meses. La cadena de Markov trabaja en *semanas* (1 a 8) y el Monte Carlo en *meses* (1 a 12). La Torre en vivo no entrena modelos propios: observa la semana real y ejecuta reglas que el presupuesto dejó previstas.

1.4 Cómo se pasan la estafeta

La integración (criterio 8 de la rúbrica, 10 %) consiste en que la salida de un módulo es la entrada del siguiente:

1. El **Pronóstico** produce, para cada lugar y mes, la *forma del año*, los escenarios malo/probable/bueno y el riesgo de rebasar la capacidad. Con eso marca la **temporada alta** (`gold/pronostico_calendario.parquet`).
2. El **presupuesto** (investigación de operaciones) toma esa tabla: prohíbe gastar en temporada alta y no deja rebasar la capacidad. Produce cuántos pesos van a cada lugar, mes y canal (`gold/presupuesto_plan.parquet`).
3. El **Radar** aporta los cortes semanales con los que se sabe si el norte está saturado ($p50 = 71.16 \%$, $p90 = 85.92 \%$).
4. La **Torre en vivo** gasta cada semana el dinero del plan, pero lo pausa si hay tormenta, clima raro o llegó más gente de la esperada; si el norte se satura, enciende “¿Ibas al norte?” (`gold/envivo_decisiones.parquet`).
5. La **campana** pone el mensaje y el público, y sus indicadores se miden con lo que registra la Torre (`gold/campana.json`).

1.5 Las siete preguntas secundarias y quién las responde

Pregunta del Problema Prototípico	Módulo	Capítulo
1. Patrones temporales, espaciales y de comportamiento de la concentración	Planteamiento, Pronóstico, campaña	5, 6, 10
2. Variables relacionadas con la saturación	Radar (índice y clasificador)	6, 7
3. Demanda futura con incertidumbre	Pronóstico	7, 8
4. Escenarios de redistribución sin perder actividad económica	Presupuesto	9
5. Características para recomendar destinos alternativos	Campaña y planeador	6, 10
6. Impacto en comunidades y destinos saturados	Radar (presión por habitante) y Torre	6, 9
7. Evaluar si la propuesta es viable, sustentable y efectiva	Indicadores y escenarios	9, 10

1.6 Las 12 fases

Trabajamos en fases, una a la vez, y cada decisión de cada fase está en el documento 3 (*Las decisiones del proyecto*).

Fase	Qué hicimos	Capítulo aquí
0	Plan, reglas, entorno con Spark	2
1	Descargar 14 fuentes oficiales (Bronze)	3
2	Limpiar y ordenar (Silver, Gold, almacén DuckDB, diccionario)	4
3	Elegir y medir los cinco lugares; planteamiento con datos	5
4	El Radar	6, 7, 8
5	El Pronóstico y el planeador de viaje	6, 7, 8
6	Repartir el presupuesto	9
7	La Torre en vivo	4, 6, 9
8	La campaña	10
9	Servidor que conecta la página con los modelos	11
10	Página final auditada	11
11	Cierre y coloquio	11

Cómo construimos el proyecto

2.1 Cómo usamos la inteligencia artificial

Lo que pasó, tal cual. Para programar usamos **Claude Code**, un asistente de programación con inteligencia artificial (de la empresa Anthropic), como herramienta de trabajo. Por eso el historial del repositorio marca muchos cambios con Co-Authored-By: Claude: git registra que el asistente participó en ese cambio. La página se rediseñó con otra herramienta de la misma empresa, Claude Design.

Cómo trabajamos, y cómo se puede demostrar con los archivos. Nos pusimos reglas desde el primer día: no inventar datos, ir una fase a la vez, documentar cada ecuación y decidir siempre entre opciones con evidencia. El protocolo fue el mismo en todas las fases:

1. Planteábamos qué había que decidir y **con qué cifra real**.
2. Poníamos sobre la mesa **2 o 3 opciones** con pros y contras.
3. **Elegíamos** y lo dejábamos escrito. Hay más de 40 registros de decisión y 25 notas, cada una con las opciones descartadas y la evidencia (están resumidas en *Las decisiones, fase por fase*).
4. Programábamos **una pieza pequeña** (una función o un notebook corto) comentada en español.
5. Corríamos la pieza, la revisábamos con datos reales y la dejábamos con pruebas automáticas.

Si nos preguntan

Lo declaramos antes de que pregunten: *“Usamos un asistente de programación con inteligencia artificial como herramienta. Las reglas, las decisiones y la revisión son del equipo y están documentadas; cada cifra se puede rastrear a su fuente oficial y podemos explicar cada método.”* Conviene revisar antes la política del profesor y de la UNRC sobre el uso de inteligencia artificial. Lo que hace defendible el proyecto no es esconder la herramienta, sino poder explicar cada pieza: para eso es esta guía.

2.2 Por qué hay tantos archivos de código

La regla: una pieza = un archivo. Cada archivo hace una sola cosa y empieza con un encabezado obligatorio que dice qué hace, por qué así (con la alternativa descartada), de qué datos sale y

a qué decisión de la campaña alimenta. Así cada pieza se puede probar sola, explicar sola y reemplazar sin romper las demás. Si todo estuviera en un solo notebook, no se podría probar por partes ni reutilizar una función en la página.

El paquete `backend/torre/` tiene **56 archivos** en 7 carpetas:

Carpeta	Archivos	Para qué sirve	Fases
<code>base/</code>	23	Descargar las fuentes (Bronze), limpiarlas con Spark (Silver), almacén DuckDB y diccionario	0, 1, 2
<code>radar/</code>	7	Planteamiento, criterios de las regiones, índice de presión, clasificador, Markov, clustering	3, 4
<code>pronostico/</code>	7	Series de tiempo, forma del año, modelos, rango del 90 %, escenarios, calendario	5
<code>campana/</code>	9	Presupuesto (IO), minería de texto, marca, lugares (NLP), fotos, idiomas	6, 8
<code>envivo/</code>	3	Señales semanales, motor de reglas, reproducción con Spark Streaming	7
<code>api/</code>	2	Datos de la página y servidor FastAPI	9
<code>documento/</code>	5	Gráficas, PDF, capturas y auditoría de la página, y la carpeta Entregable	10, 11

2.2.1 El mapa completo, archivo por archivo

Archivo	Qué hace
base/ — datos crudos y limpios	
<code>entorno.py</code>	Apunta Java 17 y Hadoop solo dentro del proceso y crea la sesión de Spark (<code>local[*]</code> , 4 GB).
<code>manifiesto.py</code>	Registra cada archivo crudo con su huella SHA-256, tamaño, URL, fecha y número de registros.
<code>ingesta_siturq.py</code>	Descarga los indicadores de SITUR-Q por su API pública.
<code>ingesta_datatur.py</code>	Descarga de DataTur la ocupación semanal y mensual, nacionalidades, INAH, AFAC, cruceros y el Compendio.
<code>ingesta_abiertas.py</code>	Descarga DENUE, Censo, clima, huracanes, FRED, Rest-Mex, geografía y ENDUTIH.
<code>ingesta_benchmarks.py</code>	Abre con un navegador automatizado las tablas de costos de anuncios y guarda captura como evidencia.
<code>evidencia_sargazo.py</code>	Guarda como evidencia las publicaciones públicas sobre sargazo en la bahía.
<code>ingesta_fotos.py</code>	Fotos con licencia libre de Wikimedia Commons.

Archivo	Qué hace
ubicaciones.py	Comprueba que cada pueblo y zona esté en Quintana Roo y en su municipio.
<i>Limpieza, un archivo por fuente (12 archivos <code>silver_*.py</code>):</i>	
silver_siturq.py	SITUR-Q en formato largo; Tren Maya sumado por estación; ceros imposibles = hueco.
silver_datatur_ocupacion.py	166 Excel de ocupación en una tabla; gana la versión más reciente de cada semana.
silver_denue.py	6.1 millones de negocios con su categoría turística (PySpark).
silver_inah.py	Visitantes por zona y mes; quita un bloque duplicado; marca el papel de cada zona.
silver_iter.py	Censo 2020 por localidad; datos reservados por el INEGI quedan vacíos.
silver_clima.py	Clima diario 1950–2026 y horario 2019–2026, con hora local.
silver_huracanes.py	HURDAT2 con la distancia de cada punto a Chetumal y la regla de tormenta.
silver_fred.py	Pesos por dólar diario y mensual sin rellenar feriados; inflación de EE. UU.
silver_nacionalidad.py	Extranjeros por aeropuerto, país y sexo.
silver_afac.py	Pasajeros por aerolínea; resuelve 300 llaves repetidas.
silver_cruceros.py	Cruceros por puerto y conciliación con SITUR-Q.
silver_restmex.py	207,873 reseñas; Spark lee el CSV directo.
almacen.py	Almacén DuckDB: vistas de Silver y Gold y el modelo estrella.
diccionario.py	Genera el diccionario de datos desde el almacén.
radar/ — dónde hay presión	
planteamiento.py	Variables, actores, cuotas y HHI (Fase 3).
criterios.py	Tabla de criterios de las regiones.
panel.py	Panel lugar × mes con todas las variables de presión.
indice.py	Índice de presión, estados y sensibilidad.
prediccion.py	Índice comparable, tres clasificadores con origen móvil, sesgo y predicción.
markov.py	Cadena de Markov semanal del norte y su validación.
clustering.py	Agrupamiento Ward de 55 centros del país.
pronostico/ — cuándo conviene ir	
series.py	Series a pronosticar y meses que no entrenan.
forma.py	Forma del año, fuerza de la temporada y segunda opinión con STL.
modelos.py	Cinco modelos y el origen móvil.
intervalos.py	Rango del 90 % (conformal) y su cobertura real.
seleccion.py	Elección del modelo y pronóstico final de 12 meses.
escenarios.py	Poisson de tormentas, Monte Carlo y sensibilidad.

Archivo	Qué hace
calendario.py	Temporada alta y recomendaciones del planeador.
campana/ — la campaña	
presupuesto.py	Modelo de optimización de dos etapas (PuLP/CBC).
texto.py	Minería de las reseñas: temas, Apriori y palabras.
marca.py	Personas, marca, anuncios, medios, calendario e indicadores.
lugares.py	NLP por léxico sobre el DENUÉ: qué hacer, comer y dormir.
vitrina.py, estrellas.py	Experiencias, rutas y estrellas oficiales de hoteles.
fotos_lugares.py, aportes.py, idiomas.py	Fotos comprobadas, aportes del equipo y los 10 idiomas.
envivo/ — la Torre	
senales.py	Las cuatro señales semanales (con Isolation Forest y ventana deslizante en Spark).
motor.py	Reglas de pausa y de “¿Ibas al norte?”.
torre.py	La reproducción con Spark Structured Streaming.
api/ y documento/	
datos_pagina.py, servidor.py	Datos de la página y servidor FastAPI.
figuras.py, pdf.py, capturas.py, auditoria.py	Gráficas, PDF, capturas de la página y auditoría de accesibilidad.
entregable.py	Arma la carpeta Entregable/: las guías, los cuatro notebooks autosuficientes (con el código de estos módulos dentro), los datos y la página.

2.3 Notebooks, pruebas y reproducibilidad

Notebooks. Hay seis notebooks narrados (01_planteamiento, 02_radar, 03_pronostico, 05_optimizacion, 06_torre_en_vivo y 07_campana; el 04 del plan quedó dentro del 03). No contienen la lógica: **llaman a las funciones del paquete** y cuentan la historia con texto, tablas y gráficas. Cada uno se construye y se ejecuta completo con su script `_construir_*.py`; si una celda falla, el notebook no se guarda.

Los cuatro notebooks de la entrega. Para los profesores, la carpeta `Entregable/` junta esos seis en **cuatro notebooks autosuficientes**: (1) los datos y la arquitectura, (2) dónde y cuándo (planteamiento, Radar y Pronóstico), (3) el presupuesto y la Torre en vivo, y (4) la campaña. No dependen de archivos `.py`: cada celda que empieza con `\%\%modulo` trae completo un archivo del paquete, y al correrla queda registrada como ese módulo. Así el notebook usa exactamente el mismo código y da las mismas cifras (por ejemplo, 956.8 visitantes y 239 lotes de Spark). Se generan con `torre.documento.entregable`, que además los ejecuta de principio a fin dentro de la carpeta.

Pruebas automáticas (279). Hay dos tipos:

- **De contrato:** revisan la forma de los datos (no hay duplicados, las columnas existen, una tabla tiene las semanas que debe).
- **De realidad:** revisan una cifra conocida. Por ejemplo, que Tulum haya tenido 1,031,443 visitantes en 2025, que la tasa de tormentas de agosto sea 13.9 % o que el modelo de presupuesto dé 956.8 visitantes.

Las pruebas `test_documentos.py` y `test_guias.py` recalculan las cifras que aparecen en los documentos y en esta guía.

Reproducibilidad. Todo lo aleatorio usa semilla fija (`random_state=0` en los modelos, semilla 2026 en el Monte Carlo), así que correr de nuevo da exactamente lo mismo. La auditoría del 29 de septiembre volvió a correr el Radar desde cero y las 8 tablas salieron idénticas.

2.4 El entorno de cómputo

- Python 3.11 en un entorno propio (`.venv`); todas las versiones fijas en `requirements.txt`.
- **PySpark 3.5.6 con Java 17.** La máquina tenía Java 8, y Spark 3.5 necesita Java 17. Se instaló Java 17 sin cambiar el de Windows: `entorno.py` lo apunta solo dentro del proceso del proyecto.
- **winutils y hadoop.dll 3.3.6:** sin ellos, Spark no puede escribir archivos en Windows.
- **Ruta corta de Windows:** la carpeta del proyecto tiene espacios ("PP 5to semestre") y los scripts de Spark la cortaban; se usa el nombre corto que Windows asigna sin espacios.

Alternativa descartada: Spark dentro de Docker. Funciona, pero es más pesado de arrancar y de explicar en el coloquio.

Los datos: de dónde sale cada cifra

3.1 La regla: solo fuentes oficiales, descargadas con código

Todas las fuentes se descargan con programas (nunca a mano), a `datos/bronze/<fuente>/<fecha>/`, **sin modificarlas**. Cada archivo queda registrado en `datos/bronze/MANIFIESTO.csv` con su huella SHA-256, su tamaño, su dirección de origen, la fecha de descarga y su número de registros. Resultado de la Fase 1: **353 archivos, 8,134,802 registros y 824 MB**.

Dos razones para hacerlo así:

- **Reproducible:** cualquiera puede volver a correr la descarga y obtener lo mismo, o ver qué cambió.
- **Rastreable:** cualquier cifra del proyecto se puede seguir hasta el archivo oficial del que salió (`docs/trazabilidad.md`).

Lo que **no** se usa: TripAdvisor y Google Maps, porque sus términos prohíben extraer sus datos; el semáforo de sargazo del estado, porque solo se publica en Facebook, cuyos términos también lo prohíben.

3.2 Las fuentes, una por una

D1 · SITUR-Q (sistema estatal de información turística)

- **Qué es:** el sistema del gobierno de Quintana Roo; publica indicadores por destino y mes.
- **Cómo se descargó:** su página consulta una API con una llave pública incrustada. Al principio rechazaba las peticiones (“Origin not allowed”); se resolvió enviando los mismos encabezados que envía el navegador.
- **Qué trae:** ocupación hotelera, cuartos y hoteles, Tren Maya (subidas y bajadas por estación), cruceristas, cruces desde Belice, llegadas por avión, visitas a zonas y afluencia. 6,607 registros.
- **Hallazgos:** *no publica ocupación hotelera de 2025–2026 para ningún destino* (viene en ceros); las llegadas por avión de 2025 vienen en cero en los cuatro aeropuertos; el indicador “Turista – Afluencia” devolvió error 500 en las 120 consultas. Todo eso se declaró como hueco.

- **Para qué:** Radar del sur, pronóstico de Chetumal (cruces de Belice), conciliación con DataTur.

D2 · DataTur, ocupación hotelera (SECTUR)

- **Qué es:** el monitoreo hotelero federal. 135 archivos semanales y 31 mensuales.
- **Qué trae:** cuartos disponibles, cuartos ocupados y ocupación de 66 centros del país; los 7 de Quintana Roo (Cancún, Riviera Maya, Playa del Carmen, Playacar, Akumal, Cozumel e Isla Mujeres) tienen **239 semanas**, de enero de 2022 a julio de 2026 (cada archivo trae también los dos años anteriores).
- **Hallazgo:** hubo 2,804 cifras corregidas entre una publicación y otra; se conserva la más reciente.
- **Para qué:** la única ocupación medida de 2025–2026; Radar del norte, cadena de Markov y Torre en vivo.

D3 · DataTur, llegadas por nacionalidad (Unidad de Política Migratoria)

521,363 renglones de 2012 a julio de 2026: extranjeros que llegan en avión, por aeropuerto, país y sexo. Solo cuenta extranjeros (no hay país “México”). Para la campaña: de dónde viene el visitante que aterriza en Cancún y cuántos llegan a Chetumal (250 en 2025).

D4 · DataTur, INAH, AFAC, cruceros y Compendio

- **BdINAH:** visitantes por zona arqueológica, mes y tipo (nacional o extranjero), 2016–2026. Es la serie **medida** que sí llega a 2026 en el sur, y la base del pronóstico.
- **AFAC:** pasajeros por aerolínea en el país. **Cruceros:** arribos y pasajeros por puerto.
- **Compendio 2024:** cuartos-noche por categoría de hotel (estrellas) en 70 centros.
- En total, 390,228 registros.

D5 · Rest-Mex 2025 (licencia CC-BY-4.0)

208,051 reseñas de turistas en México con calificación de 1 a 5. En Quintana Roo, 85,993 (85,987 sin duplicados), solo de Tulum, Isla Mujeres y Bacalar. Para la minería de texto de la campaña.

D6 · DINUE del INEGI (los 32 estados)

6,138,075 negocios con giro, tamaño y coordenadas. Se procesó el país completo, y no solo Quintana Roo, por dos razones: la rúbrica pide volumen real, y el total nacional da contexto

(14.3 % de los negocios del país son turísticos; en Quintana Roo, 19.7 %). Para la oferta turística, los criterios y el planeador.

D7 · Censo 2020, ITER del INEGI

Población y viviendas de 2,243 localidades de Quintana Roo. Se usa **por localidad**, no por municipio, porque cuatro de los cinco lugares están en el mismo municipio (Othón P. Blanco) y con la cifra municipal tendrían el mismo denominador.

D8 · Open-Meteo (reanálisis ERA5)

Clima de 8 puntos: diario desde 1950 (224,232 días) y horario desde 2019 (542,784 horas), sin huecos. Un *reanálisis* es un modelo meteorológico que combina observaciones reales; no es una estación, y así lo declaramos. Para la regresión con clima y para detectar clima raro.

D9 · HURDAT2 de la NOAA

Todas las tormentas del Atlántico de 1851 a 2025: 55,524 posiciones de 1,988 tormentas, cada seis horas. Para la probabilidad de tormenta.

D10 · FRED (Reserva Federal de St. Louis)

Pesos por dólar de cada día hábil desde 1993 (8,575 días) e inflación de EE. UU. Para la sensibilidad al tipo de cambio y para pasar a pesos los costos de los anuncios.

D11 a D15

ENDUTIH 2025 (uso de internet y aplicaciones, PDF oficial del INEGI), los polígonos de los municipios, los costos por clic y conversiones de anuncios de viajes (WordStream y LocaliQ, promedios de EE. UU. usados como supuesto etiquetado) y las fotos con licencia libre de Wikimedia Commons.

3.3 Lo que no existe (huecos declarados)

Hueco	Qué no se puede afirmar por su culpa
Ocupación hotelera del sur 2025–2026	Cuántos cuartos se llenan hoy en Chetumal; por eso el sur se mide con llegadas reales
Estado de origen, edad e ingreso del visitante nacional	Una persona nacional más detallada
Conversión de Facebook para turismo	El rendimiento exacto de Facebook; se prueba con 3 valores
Tormentas de 2026	Si hubo tormentas este año; la Torre dice “sin dato”
Reseñas de los cinco lugares	Qué opinan los turistas del sur; las reseñas son de destinos llenos
Derrama económica por lugar	Cuánto dinero deja la campaña; la de SITUR-Q no trae unidad y termina en 2024

PARTE II

Las materias, una por una

Grandes volúmenes de datos

Criterio 2 de la rúbrica (12 %): integra diversas fuentes; estructura, documenta, transforma y almacena considerando calidad y arquitectura.

4.1 La arquitectura medallón: Bronze, Silver y Gold

La idea, sin fórmulas

Pensemos en una planta potabilizadora. El agua cruda (Bronze) se guarda tal como llega, para poder volver a ella. Se filtra y se limpia (Silver). Y al final se embotella lista para beber (Gold). Si alguien duda del agua embotellada, se puede revisar cada paso hasta la toma original.

Capa	Carpeta	Contenido y regla
Bronze	datos/bronze/	Los archivos tal como los publica la fuente (zip, Excel, JSON, CSV, texto). Nunca se modifican; cada uno tiene su huella SHA-256.
Silver	datos/silver/	Una tabla limpia por fuente, en Parquet, con nombres en español, tipos correctos y banderas de calidad (<code>_flag</code>). La escribe Spark.
Gold	datos/gold/	Salidas de los modelos y el modelo estrella; lo que usan la página y los documentos.

Por qué así. Si una cifra de Gold parece rara, se puede repetir el camino desde el archivo crudo, que no se tocó. **Alternativa descartada:** limpiar mientras se descarga. Así Bronze dejaría de ser idéntico a la fuente y ya no habría contra qué comparar.

4.1.1 La huella SHA-256

La idea, sin fórmulas

Una huella SHA-256 es como la huella digital de un archivo: una cadena de 64 caracteres que se calcula con todo su contenido. Si cambia un solo byte del archivo, la huella cambia por completo. No se puede “fabricar” otro archivo con la misma huella.

La prueba `tests/test_ingesta.py` vuelve a calcular las 353 huellas y falla si alguna no coincide con el manifiesto. Así se demuestra que Bronze no se alteró.

4.2 Spark: qué es y qué hace exactamente aquí

La idea, sin fórmulas

Limpiar una lista de 6 millones de negocios es como corregir 6 millones de exámenes. Una persona sola tardaría mucho; doce personas, cada una con un montón, terminan mucho antes. Spark reparte la tabla en montones (*particiones*) y pone a trabajar a todos los núcleos de la computadora a la vez.

4.2.1 Cinco ideas que hay que poder explicar

1. **Driver y ejecutores.** El *driver* es el programa que planea el trabajo; los *ejecutores* lo hacen. Aquí Spark corre en **modo local** (`local[*]`): el driver y los ejecutores viven en la misma computadora y usan sus 12 núcleos, con 4 GB de memoria. Es el mismo programa que correría en un clúster de muchas computadoras; solo cambia la dirección del “maestro”.
2. **DataFrame y particiones.** Un DataFrame de Spark es una tabla repartida en particiones. Cada partición la procesa un núcleo. Se programa parecido a pandas (`select`, `withColumn`, `groupBy`).
3. **Evaluación perezosa.** Las *transformaciones* (`withColumn`, `filter`) no se ejecutan al escribirlas: Spark arma un plan (un grafo acíclico de pasos) y lo optimiza completo. Solo cuando se pide una *acción* (`count`, `write`) se ejecuta. Así puede, por ejemplo, filtrar antes de leer columnas que no se van a usar.
4. **Barajeo (shuffle).** Algunas operaciones necesitan juntar renglones de distintas particiones: quitar duplicados por `id` obliga a mandar todos los renglones con el mismo `id` al mismo núcleo. Es la parte cara del trabajo y por eso se hace una sola vez.
5. **Parquet particionado.** Spark escribe cada tabla en formato **Parquet**: guarda por columnas (leer una columna no obliga a leer las demás) y comprime. Además la parte en carpetas por una columna, por ejemplo `cve_ent=23/` para Quintana Roo. Leer solo Quintana Roo no obliga a leer los otros 31 estados (*partition pruning*).

4.2.2 El trabajo más grande: los 6.1 millones de negocios del DENUE

```
crudo = (spark.read.option("header", True).option("encoding", "ISO-8859-1")
        .csv("temporal/*.csv"))           # 33 CSV como UNA sola tabla
silver = (crudo.select(*COLUMNAS)         # sin datos personales
        .dropDuplicates(["id"])           # un negocio, una fila (barajeo)
        .withColumn("scian_3", F.substring("codigo_act", 1, 3))
        .withColumn("categoria_turistica", categoria)      # 721 alojamiento, 722 alimentos...
        .withColumn("coordenadas_flag",
                    ~(lat.between(14, 33) & lon.between(-119, -86)) | lat.isNull())
        .withColumn("es_qroo", F.col("cve_ent") == "23"))
silver.write.mode("overwrite").partitionBy("cve_ent").parquet("datos/silver/denue")
```

Qué pasa en cada línea:

- **Lectura:** los 33 archivos (el Estado de México viene en dos partes) se leen como una sola tabla, con la codificación ISO-8859-1 que usa el INEGI.
- **Privacidad:** se seleccionan solo las columnas necesarias; la razón social, el teléfono y el correo nunca entran a Silver.
- **Duplicados:** `dropDuplicates(["id"])`. Resultado: 0 duplicados.
- **Categoría turística:** con los primeros dígitos del código SCIAN (721 alojamiento, 722 alimentos y bebidas, 5615 agencias de viajes, 487 transporte turístico, 712 museos y sitios, 713 esparcimiento).
- **Bandera de calidad:** las coordenadas fuera de México se *marcan*, no se borran (resultado: ninguna fuera).
- **Escritura:** Parquet partido por estado. Tarda cerca de minuto y medio.

4.2.3 Dónde se usa Spark y dónde no

- **Sí:** las 12 limpiezas `silver_*.py`, la ventana deslizante de la Torre (`envivo/senales.py`) y la reproducción con Structured Streaming (`envivo/torre.py`).
- **No:** Spark no lee Excel, así que pandas abre los Excel de DataTur e INAH y Spark hace la unión, la deduplicación y la escritura. Los modelos (scikit-learn, statsmodels, PuLP) trabajan sobre tablas de Gold que ya caben en memoria: no tendría sentido repartirlas.

Si nos preguntan

“¿De verdad se necesitaba Spark?” Con honestidad: 8.1 millones de registros caben en una laptop y pandas podría con casi todo. Spark se usó porque la rúbrica pide una arquitectura de grandes volúmenes, porque el DENUe nacional y el clima por hora ya son pesados, y porque el mismo código escala sin cambios a un clúster si mañana entran más años o más estados. El valor está en la arquitectura y el rastreo, no en el tamaño.

4.3 Reglas de limpieza: cero no es lo mismo que hueco

La regla más importante de Silver: **un cero físicamente imposible es un hueco**, y un cero posible se conserva.

Caso	Por qué	Regla
Ocupación con 0 cuartos disponibles	No se pueden ocupar cuartos que no existen	Hueco
Los 4 aeropuertos en 0 todo 2025	Cancún no pudo recibir cero pasajeros (su ocupación semanal promedió 72.2 %): la fuente dejó de publicar	Hueco
Afluencia y derrama en 0	Un destino no recibe cero turistas en un mes	Hueco
Cruceistas en 0 en 2020	Real: los puertos cerraron por la pandemia	Se conserva
Zona arqueológica con 0 visitantes	Suele ser un cierre por obras	Se conserva y se marca
Feriado sin tipo de cambio	No hubo cotización ese día	Vacío; no se copia el día anterior

4.3.1 Ocupación: sumar antes de dividir

La ocupación de un periodo **nunca** se calcula promediando porcentajes:

$$O = \frac{\sum_{\text{meses}} \text{cuartos-noche ocupados}}{\sum_{\text{meses}} \text{cuartos-noche disponibles}} \times 100.$$

Fundamento. Un promedio simple de porcentajes le da el mismo peso a un mes con 50,000 cuartos-noche que a uno con 80,000. El cociente de sumas es el promedio *ponderado* correcto: cada cuarto-noche cuenta una vez.

A mano, con números reales · ocupación de Chetumal en 2024

$$O = \frac{458,696}{791,016} \times 100 = 57.99 \approx 58.0\%.$$

De cada 10 cuartos, 4 se quedaron vacíos: capacidad ociosa, justo lo que la campaña puede aprovechar.

Un error real que lo demuestra. SITUR-Q publica tres renglones por mes para la ocupación (disponibles, ocupados y porcentaje). La primera versión del panel del Radar los sumaba, y la “ocupación” llegaba a 2,560,068. Ahora se recalcula $\text{ocupados} \div \text{disponibles}$, y la prueba `testocupacion_no_suma_filas` lo vigila.

4.4 Cuando dos fuentes cuentan lo mismo (conciliación)

El incidente de Big Data del Problema Prototípico pregunta qué hacer con “fuentes que no coinciden”. El proyecto tiene dos casos medidos:

$$\Delta\% = \left(\frac{S}{D} - 1 \right) \times 100, \quad S = \text{SITUR-Q (estatal)}, \quad D = \text{DataTur (federal)}.$$

A mano, con números reales · cruceristas en 2025

Cozumel: $\left(\frac{4,915,242}{4,724,255} - 1 \right) \times 100 = (1.0404 - 1) \times 100 = +4.04\%$.

Mahahual: $\left(\frac{2,641,695}{2,379,422} - 1 \right) \times 100 = +11.02\%$. En Mahahual SITUR-Q cuenta siempre más: entre 11 % y 35 % según el año.

En la ocupación pasa lo mismo: DataTur marca menos que SITUR-Q (Cancún -1.6 puntos, Cozumel -14.5 , Isla Mujeres -19.3), aunque las dos se mueven juntas (correlación entre 0.68 y 0.97).

La regla del proyecto tiene tres partes:

- cada lugar usa **una sola fuente en toda su historia**, así sus cambios en el tiempo son reales;
- la diferencia se **declara** y no se “ajusta”;
- si la diferencia va en sentido conservador, la conclusión no cambia. Aquí el norte se ve *menos* lleno con DataTur, así que “el sur tiene espacio” se sostiene aún con más fuerza.

4.5 El almacén DuckDB y el modelo estrella

DuckDB es una base de datos analítica que vive en un solo archivo (`datos/gold/torre.duckdb`) y lee los Parquet de Silver y Gold **sin copiarlos**. Responde en milisegundos sin levantar Spark. Tiene una vista por cada tabla (14 de Silver y 39 de Gold) y un **modelo estrella**.

Qué es un modelo estrella (Kimball): una tabla de *hechos* en el centro, con las medidas, y tablas de *dimensiones* alrededor, con las descripciones. Su ventaja es que cualquier pregunta se contesta con el mismo patrón: hechos unidos con dimensiones, filtrados y agrupados.

Tabla	Tipo	Contenido
dim_lugar	Dimensión	15 lugares con su papel: 5 promovidos, 3 de referencia y 7 de comparación
dim_tiempo	Dimensión	Un renglón por mes, de 2012 a 2027
hechos_mes	Hechos	3,287 renglones: lugar × mes × variable, con su fuente

El **grano** (qué representa un renglón de hechos) es “una medida de un lugar en un mes”. Un hueco **no tiene renglón**: nunca se guarda un cero inventado. Ejemplo de consulta:

```
SELECT anio, SUM(valor) FROM hechos_mes JOIN dim_tiempo USING (periodo)
WHERE lugar = 'Chetumal' AND variable = 'llegadas_extranjeros_avion'
GROUP BY anio;      -- 2025: 250 extranjeros (Cancún: 9,408,423)
```

El **diccionario de datos** (docs/datos/DICCIONARIO.md) se **genera solo** desde el almacén: 56 tablas, cada columna con su tipo, su porcentaje de vacíos, un ejemplo real y su significado. Si una columna de Silver no tiene significado escrito, el programa se detiene. Así el diccionario no puede quedar desactualizado (en la revisión del 2 de octubre esa regla detectó 12 tablas sin descripción).

Alternativa descartada: PostgreSQL. Exige instalar y levantar un servidor, y el proyecto debe correr sin internet en cualquier computadora.

4.6 Streaming: la Torre en vivo con Spark Structured Streaming

La idea, sin fórmulas

Una banda transportadora: cada semana llega una caja con los datos de esa semana. La Torre abre una caja a la vez, en el orden en que llegaron, decide qué hacer con la campaña y pasa a la siguiente.

Cómo funciona (envivo/torre.py):

1. Cada una de las 239 semanas reales (enero de 2022 a julio de 2026) se escribe como un archivo JSON en una carpeta, con hora de llegada creciente.
2. Spark **escucha** la carpeta con `readStream`. La opción `maxFilesPerTrigger=1` hace que cada *micro-lote* sea exactamente un archivo, es decir, una semana. `trigger(availableNow=True)` procesa todo lo que hay y se detiene.
3. En cada micro-lote, la función `foreachBatch` le pasa la semana al motor de reglas, que decide qué anuncio se enciende o se pausa y lleva la cuenta del dinero guardado.
4. Un **punto de control** (*checkpoint*) registra qué archivos ya se procesaron: si el programa se cae, no procesa dos veces la misma semana.
5. Al final se comprueba que llegaron **239 lotes, en orden**.

Por qué así. El incidente de Big Data pide una arquitectura de *baja latencia* para ajustar la campaña *durante* su ejecución. Esta es exactamente la arquitectura que recibiría datos reales cada semana: una carpeta a la que llega un archivo nuevo. Cambiar la fuente por una real no cambia el motor de reglas. En la página se muestra como “reproducción de datos históricos reales”, porque GitHub Pages no puede transmitir en vivo.

4.6.1 La ventana deslizante

El promedio de ocupación de las últimas cuatro semanas lo calcula Spark con una *ventana* sobre cada centro:

$$\bar{o}_w = \frac{1}{4} \sum_{k=0}^3 o_{w-k}.$$

La ventana “se desliza”: cada semana entra la nueva y sale la de hace cuatro. Suaviza una semana atípica sin perder la tendencia reciente.

4.7 Privacidad

No se guarda ningún dato personal. El DENUe entra sin razón social, teléfono ni correo; las reseñas de Rest-Mex no tienen identificadores; las nacionalidades y los visitantes vienen agregados por mes. Ninguna tabla permite identificar a una persona.

Planteamiento: el problema medido

Criterio 1 de la rúbrica (8 %): delimita el problema, identifica variables, actores y relaciones.

5.1 Concentración: cuotas e índice de Herfindahl-Hirschman

Pregunta. Si el problema es la concentración, hay que medirla. ¿Qué parte de los visitantes, cuartos y negocios del estado está en los cinco lugares, y qué tan concentrada está cada dimensión?

La idea, sin fórmulas

Imaginemos un pastel repartido entre varias personas. Si una se lleva casi todo, el reparto está concentrado. El índice de Herfindahl-Hirschman resume en un número qué tan desigual es el reparto: vale casi 1 si uno se lleva todo, y vale poco si todos reciben parecido.

5.1.1 Las fórmulas y su fundamento

Para una dimensión (llegadas en avión, cuartos, visitantes, negocios o población) repartida entre N unidades con valores $x_1, \dots, x_N$:

$$s_i = \frac{x_i}{\sum_{j=1}^N x_j} \quad (\text{cuota de la unidad } i; \text{ las cuotas suman } 1)$$

$$HHI = \sum_{i=1}^N s_i^2 \quad (\text{índice de Herfindahl-Hirschman})$$

$$HHI^* = \frac{HHI - 1/N}{1 - 1/N} \quad (\text{normalizado, entre } 0 \text{ y } 1)$$

$$\rho = \frac{s_5^{\text{dimensión}}}{s_5^{\text{población}}} \quad (\text{razón contra la población})$$

Por qué el cuadrado. Elevar las cuotas al cuadrado hace que las unidades grandes pesen mucho más que las chicas: una cuota de 0.9 aporta 0.81, y nueve cuotas de 0.01 juntas apenas 0.0009. Así el índice “ve” la dominancia. Es el índice que usan las autoridades de competencia para medir si un mercado está concentrado.

Por qué normalizarlo. El mínimo del HHI depende de N : si todos pesan igual, $s_i = 1/N$ y $HHI = N \cdot (1/N)^2 = 1/N$. Con 4 aeropuertos el mínimo es 0.25, con 11 municipios es 0.09. Para comparar

dimensiones con distinto N se resta ese mínimo y se divide entre el rango posible, de modo que 0 = reparto parejo y 1 = todo en una unidad.

Qué dice ρ . Compara la parte que los cinco lugares tienen de algo con la parte que tienen de la gente. Si $\rho = 1$, tienen de visitantes lo mismo que de habitantes; si $\rho < 1$, reciben menos de lo que “les tocaría” por su población. Ojo: ρ es una comparación, no una meta. Nada dice que el turismo deba repartirse según la población.

A mano, con números reales · llegadas en avión, 2024

Aeropuerto	Pasajeros	Cuota s_i	s_i^2
Cancún	14,769,302	0.92544	0.856433
Tulum	620,384	0.03887	0.001511
Cozumel	352,067	0.02206	0.000487
Chetumal	217,524	0.01363	0.000186
Total	15,959,277	1	0.858617

$$HHI^* = \frac{0.8586 - 0.25}{1 - 0.25} = \frac{0.6086}{0.75} = 0.811.$$

Casi todo el tráfico aéreo entra por una sola puerta. Los cinco lugares (solo Chetumal tiene aeropuerto) tienen el 1.4 % de los pasajeros y el 12.3 % de la población: $\rho = 1.4/12.3 = 0.11$, la novena parte de lo que les tocaría por su gente.

Dimensión	HHI^*	Cuota de los 5	ρ
Llegadas en avión (2024)	0.811	1.4 %	0.11
Cuartos de hotel (jul-2026)	0.219	1.7 %	0.14
Visitantes INAH (2025)	0.276	4.1 %	0.33
Negocios turísticos (DENUE)	0.133	14.4 %	1.17
Población (2020)	0.225	12.3 %	1.00

La lectura central del proyecto: los negocios están donde está la gente ($\rho = 1.17$), pero los visitantes no (ρ entre 0.11 y 0.33). El sur tiene la infraestructura de una región habitada y recibe una fracción de los visitantes. Eso es capacidad ociosa.

Supuestos y límites

- Las unidades no se enciman. En los cuartos de SITUR-Q se suman destinos y zonas, no los “miembros”: una zona no es la suma de sus miembros publicados (la Riviera Maya tenía 59,632 cuartos en julio de 2026 contra 22,923 de Playa del Carmen y Tulum juntos). Sumar miembros habría perdido 36,709 cuartos.
- Cada dimensión usa su último periodo completo: avión 2024 (2025 viene en cero),




Figura 5.1: Parte de cada dimensión que tienen los cinco lugares (notebook 01).

cuartos julio de 2026, INAH 2025.

Dónde está en el código

backend/torre/radar/planteamiento.py: cuotas_y_hhi(), concentracion(), comprobar_zonas(). Notebook 01_planteamiento.

5.2 ¿Por qué estos cinco lugares? La tabla de criterios

Pregunta. ¿Qué lugares puede promover una campaña responsable en 2026? Usamos cinco criterios: sin sargazo en rojo, sin cierres recientes, sin saturación, sin fragilidad grave y con datos para medirlos.

5.2.1 Las medidas

- **Visitantes por residente:** $R_d = \frac{V_{d,2025}}{P_d}$, con la población **por localidad** del Censo. Mide la presión sobre la comunidad: mil visitantes pesan más en Nicolás Bravo que en Chetumal.
- **Variación de un sitio:** $\Delta\% = \left(\frac{V_{2026}^{ene-jul}}{V_{2025}^{ene-jul}} - 1 \right) \times 100$. Se comparan los mismos meses para que la temporada no distorsione.
- **Meses seguidos abierta:** se cuenta hacia atrás desde el último mes con dato hasta el último mes en cero. Nuestra regla: pasa si son al menos 12 y no hubo cierres en 2026.

A mano, con números reales**Tulum, enero a julio:**

$$\Delta\% = \left(\frac{476,247}{692,946} - 1 \right) \times 100 = (0.6873 - 1) \times 100 = -31.3\%.$$

Presión por residente en la Ruta del sur (Kohunlich + Dzibanché + Ichkabal, entre los pueblos de acceso):

$$R = \frac{21,850 + 6,592 + 38,186}{3,699 + 1,436 + 963} = \frac{66,628}{6,098} = 10.93, \quad R_{\text{Tulum}} = \frac{1,031,443}{33,374} = 30.91.$$

La ruta recibe un tercio de la presión de Tulum: no es poco, y por eso la campaña también le pone tope.

Tulum contra la Ruta en 2025: $1,031,443/66,628 = 15.5$ veces más visitantes.

Dzibanché: último mes en cero, enero de 2025; de febrero de 2025 a julio de 2026 son $11 + 7 = 18 \geq 12$: pasa. Muyil reabrió en febrero de 2026: solo 6 meses, no pasaría.

Por qué por localidad. Cuatro de los cinco lugares están en el municipio Othón P. Blanco (233,648 habitantes). Con la cifra municipal, Chetumal, Calderitas, la Laguna y la Ruta tendrían el mismo denominador y no se podrían comparar.

Hallazgo honesto: Kohunlich (+13.5 %) y Dzibanché (+69.2 %) crecen en 2026, pero la Ruta completa bajó 8.2 % porque Ichkabal cayó 27.5 %. Por eso nunca se destacan solo las zonas que suben: sería escoger datos a conveniencia.

Dónde está en el código

`backend/torre/radar/criterios.py` □ `gold/criterios_regiones.parquet`.

5.3 Variables, actores y relaciones

El notebook `01_planteamiento` ordena el problema en tres listas, cada elemento con su cifra:

- **17 variables** con su fuente, su periodo y su porcentaje de huecos: 9 miden presión (llegadas por tren, crucero, frontera y avión; visitantes INAH; ocupación), 3 capacidad (cuartos, hoteles, negocios), 2 comunidad (población, servicios de vivienda) y 3 son huecos declarados (afluencia y las dos derramas).
- **Actores:** comunidades de los cinco lugares (229,247 habitantes), negocios turísticos en sus localidades (1,966), Tren Maya (58,086 personas bajaron en Chetumal y Maya Ka'an en 2025), frontera con Belice (653,306 cruces en 2025), INAH (77,645 visitantes en las 4 zonas), y las fuentes SITUR-Q y DataTur.
- **Relación central:** la concentración medida con el HHI (arriba).

Minería de datos: encontrar patrones

Criterio 3 de la rúbrica (12 %): identifica patrones, tendencias y relaciones con técnicas pertinentes y los interpreta en función del problema.

6.1 El índice de presión turística (IPT)

Pregunta. ¿Qué lugar está más presionado, si cada uno se mide con cosas distintas? Chetumal tiene Tren Maya y cruces de Belice; la Ruta tiene visitantes a zonas arqueológicas; Cancún tiene ocupación hotelera semanal. Hace falta una sola escala de 0 a 1.

La idea, sin fórmulas

Es como calificar a alumnos de grupos distintos con exámenes distintos. Primero se pasa cada examen a la misma escala (de 0 a 1, donde 0 es la peor calificación de todo el estado y 1 la mejor) y luego se promedian los exámenes que cada alumno presentó. Al final se dice quién está en la mitad baja, quién en el 10 % más alto y quién en medio.

6.1.1 Los datos: el panel mensual

Una tabla de 15 lugares $\times$ 55 meses (enero de 2022 a julio de 2026) = 825 renglones, con: personas que bajan del Tren Maya, cruceristas y visitantes INAH **por cada mil habitantes**, llegadas por cuarto de hotel y ocupación. Los diez destinos del resto del estado dan la escala común: sin ellos, “tranquilo” no significaría nada.

Un hallazgo al armarlo: la serie “zonas arqueológicas” de SITUR-Q es el mismo dato del INAH sumado por destino (Chetumal 2025: 39,459 = Oxtankah 11,017 + Kohunlich 21,850 + Dzibanché 6,592). Usar las dos habría contado dos veces a los mismos visitantes; se usa solo el INAH, zona por zona.

6.1.2 Las fórmulas y su fundamento

Paso 1, llevar todo a la misma escala (mín-máx).

$$z_{k,d,t} = \frac{x_{k,d,t} - \text{mín}_k}{\text{máx}_k - \text{mín}_k},$$

donde mín_k y máx_k son el mínimo y el máximo del componente k **en todos los lugares y meses juntos**. *Fundamento:* la transformación es lineal, así que conserva el orden y las proporciones;

el 0 y el 1 tienen significado (“lo más bajo” y “lo más alto registrado en el estado”). *Alternativa:* estandarizar ($z = (x - \bar{x})/\sigma$) da números sin límite y negativos, más difíciles de explicar; usar percentiles pierde las proporciones (un lugar el doble de lleno no saldría el doble).

Paso 2, promediar con pesos iguales lo que el lugar tiene.

$$IPT_{d,t} = \frac{1}{|A_{d,t}|} \sum_{k \in A_{d,t}} z_{k,d,t},$$

con $A_{d,t}$ = componentes con dato. Un componente entra al índice solo si lo tienen al menos dos lugares (si no, ese lugar se compararía contra sí mismo; así salió Belice, que solo tiene Chetumal).

Paso 3, clasificar con percentiles comunes. u_{50} y u_{90} son los percentiles 50 y 90 del índice de todos los lugares y meses:

$$\text{estado} = \begin{cases} \text{tranquilo} & IPT < u_{50} \\ \text{concurrido} & u_{50} \leq IPT \leq u_{90} \\ \text{saturado} & IPT > u_{90} \end{cases}$$

Fundamento: un percentil es una posición relativa. “Saturado” significa “en el 10 % más presionado de todo lo observado en el estado”, la misma vara para el norte y el sur.

A mano, con números reales · Cancún, julio de 2026 (888,797 habitantes)

Componente	x	mín	máx	z
Tren Maya (22,316 personas)	25.1081 por mil	0	505.2287	0.0497
INAH, El Rey (854)	0.9608 por mil	0	6,451.8787	0.0001
Llegadas por cuarto	0.4709	0	432.0230	0.0011
Ocupación (DataTur)	68.78 %	17.97	88.40	0.7214

Por ejemplo: $z_{\text{tren}} = \frac{25.1081 - 0}{505.2287 - 0} = 0.0497$ y $z_{\text{ocupación}} = \frac{68.78 - 17.97}{88.40 - 17.97} = \frac{50.81}{70.43} = 0.7214$.

$$IPT = \frac{0.0497 + 0.0001 + 0.0011 + 0.7214}{4} = \frac{0.7723}{4} = 0.1931.$$

6.1.3 La prueba de validez que falló, y por qué se cuenta

La primera versión (solo con SITUR-Q) calificaba a Cancún “tranquilo” en julio de 2026, con 0.025. La razón: SITUR-Q dejó de publicar la ocupación en 2025, y sin ella Cancún solo tenía componentes casi en cero. Para ese mes, DataTur marcaba 68.8 %. **Un índice que dice que Cancún está tranquilo en julio no es válido.** Comparamos cuatro variantes con el IPT promedio de 2025–2026:

Variante	Cancún	Isla M.	Chetumal	Ruta	Problema
A. Mín-máx, solo SITUR-Q	0.02	—	0.39	0.14	El norte “desaparece”
B. + ocupación DataTur	0.28	0.45	0.39	0.14	Chetumal arriba de Cancún
C. Percentil + DataTur	0.44	0.25	0.48	0.71	La Ruta arriba de Cancún
D. B sin componentes de un solo lugar	0.28	0.45	0.05	0.14	Quiebre de 2025

Elegimos la **D**: la ocupación de los 4 lugares que mide DataTur viene de DataTur en toda su historia, y sale Belice (solo Chetumal lo tiene).

6.1.4 Dos índices, y por qué Cancún sale distinto en cada uno

- **Índice base**: usa todas las medidas que existan cada mes. Cortes $u_{50} = 0.258$, $u_{90} = 0.766$. Con él, Cancún (0.193) es *tranquilo*.
- **El quiebre de 2025**: SITUR-Q dejó de publicar la ocupación del sur y Chetumal “cayó” de 0.54 a 0.05 sin que llegara menos gente. Fue un cambio en los datos, no en la realidad. Un modelo entrenado con eso aprendería cambios falsos.
- **Índice comparable** (el que publica el Radar): cada lugar usa solo las medidas que tiene hoy, y solo en los meses en que las tiene todas. Así un cambio de estado es siempre real. Cortes $u_{50} = 0.186$, $u_{90} = 0.756$. Con él, Cancún (el mismo 0.193) es *concurrido*.

Julio de 2026, índice comparable: concurridos Mahahual (0.731), Isla Mujeres (0.510), Bacalar (0.314), Holbox (0.228), Cancún (0.193) y Cozumel (0.191); tranquilos Playa del Carmen (0.160), Tulum (0.145) y los cinco lugares de la campaña (Ruta 0.129, Chetumal 0.025, Oxtankah 0.020, Maya Ka’an 0.009). La Laguna Milagros no tiene ninguna serie: “sin dato oficial”, nunca “tranquila”.

6.1.5 Sensibilidad: ¿y si los pesos no fueran iguales?

Cada peso se movió a 0.5 y a 1.5 (con los demás en 1) y se contó cuántos lugar-mes cambian de estado: entre el 0.6 % y el 6.0 %. Lo que más mueve el resultado es la ocupación. Conclusión: la elección de pesos iguales no decide el resultado; el estado de casi todos los lugares es el mismo con cualquier peso razonable.

Dónde está en el código

```
radar/panel.py (panel), radar/indice.py (minmax, ipt, estados, sensibilidad), radar/prediccion.py (indice_comparable).
```




Figura 6.1: El Radar: índice comparable de cada lugar (notebook 02).

Si nos preguntan

“¿Por qué pesos iguales?” Porque no hay un dato que diga que el tren pesa más que los cruceros, y unos pesos inventados serían difíciles de defender. Además, la sensibilidad muestra que con pesos de 0.5 a 1.5 el estado cambia en 6 % de los casos como máximo.

6.2 Agrupamiento de los centros turísticos del país (Ward)

Pregunta. ¿A qué se parece el norte de Quintana Roo dentro del país? Si está en el grupo de los destinos más llenos de México, la saturación no es una impresión.

La idea, sin fórmulas

Cada centro turístico tiene una “huella” de 12 números: qué tan lleno está cada mes del año. El agrupamiento junta los centros cuyas huellas se parecen. Empieza con cada centro solo y va uniando, de dos en dos, los grupos que menos “desordenan” el conjunto, hasta formar un árbol.

Fórmulas. El perfil del centro c es su ocupación de cada mes del año, sumando cuartos de todos los años, y la distancia entre dos centros es la euclidiana:

$$p_{c,m} = 100 \cdot \frac{\sum_{\text{años}} \text{ocupados}_{c,m}}{\sum_{\text{años}} \text{disponibles}_{c,m}}, \quad d(c, c') = \sqrt{\sum_m (p_{c,m} - p_{c',m})^2}.$$

En cada paso, Ward une los grupos A, B con el menor aumento de la varianza dentro de los grupos:

$$\Delta(A, B) = \frac{|A| |B|}{|A| + |B|} \|\bar{p}_A - \bar{p}_B\|^2.$$

Fundamento: la suma de cuadrados dentro de los grupos es lo que se quiere mínima (grupos compactos); unir A y B la aumenta exactamente en $\Delta(A, B)$, así que Ward elige en cada paso la unión más “barata”.

¿Cuántos grupos? Con la silueta de cada centro, $s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$, donde $a(i)$ es su distancia media a los de su grupo y $b(i)$ al grupo más cercano. Va de -1 (mal asignado) a 1 (perfecto). Se elige el número de grupos con la mayor silueta promedio:

k	2	3	4	5	6	7	8
Silueta	0.450	0.380	0.365	0.300	0.283	0.317	0.306

A mano, con números reales · silueta de Cancún

$a = 43.84$ (distancia media a los otros 22 de su grupo), $b = 116.21$ (a los 32 del otro): $s = \frac{116.21 - 43.84}{116.21} = \frac{72.37}{116.21} = 0.623$. Cancún está bien asignado.

Resultado ($k = 2$): grupo 1, playas y destinos muy ocupados (23 centros, 64.5 %: Cancún, Riviera Maya, Playacar, Akumal, Playa del Carmen, Los Cabos); grupo 2, el resto del país (32 centros, 41.1 %, con Cozumel e Isla Mujeres). Solo entran centros con sus 55 meses completos; los incompletos no se rellenan, se excluyen.

Dónde está en el código

```
radar/clustering.py (perfiles, agrupar): scipy.cluster.hierarchy.linkage(method="ward") y sklearn.metrics.silhouette_score.
```

6.3 La forma del año (estacionalidad)

Pregunta. ¿Qué meses se llenan y cuáles se vacían en cada lugar? Es la base de la temporada alta, del pronóstico y del calendario de la campaña.

La idea, sin fórmulas

Para saber si enero es “alto”, se compara enero con el promedio de su propio año: si un año tuvo 5,000 visitantes al mes en promedio y enero tuvo 8,000, enero fue 1.6 veces un mes normal. Se repite con varios años y se promedia.

6.3.1 Las fórmulas

Descomposición clásica **multiplicativa**, solo con años completos:

$$r_{a,m} = \frac{y_{a,m}}{\bar{y}_a}, \quad \bar{y}_a = \frac{1}{12} \sum_{m=1}^{12} y_{a,m} \quad (\text{razón del mes contra su año})$$

$$\tilde{S}_m = \frac{1}{|A|} \sum_{a \in A} r_{a,m}, \quad S_m = \frac{\tilde{S}_m}{\frac{1}{12} \sum_k \tilde{S}_k} \quad (\text{índice del mes, reescalado a promedio 1})$$

Fundamento: el modelo supone $y_{a,m} = \text{nivel}_a \times S_m \times \text{ruido}$. Al dividir entre el promedio del año se elimina el nivel, y al promediar varios años se cancela el ruido. Queda la forma.

¿Multiplicativa o aditiva? Aditiva diría “enero tiene 2,000 visitantes más”; multiplicativa, “enero tiene 61 % más”. Kohunlich reabrió en 2025 con la mitad de su nivel de 2019: “+2,000” ya no vale, pero “+61 %” sí. La temporada escala con el nivel, así que es multiplicativa.

Fuerza de la temporada (Wang, Smith y Hyndman, 2006), en logaritmos, con $s = \ln S_m$ y $e = \ln r_{a,m} - \ln S_m$:

$$F_S = \max\left(0, 1 - \frac{\text{Var}(e)}{\text{Var}(s + e)}\right).$$

Fundamento: $s + e$ es toda la variación de un mes a otro; e es la parte que la temporada no explica. Si la temporada lo explica todo, $\text{Var}(e) = 0$ y $F_S = 1$; si no explica nada, $F_S = 0$.

A mano, con números reales · Ruta arqueológica del sur

Una razón. En 2019, Kohunlich + Dzibanché sumaron 64,139 visitantes: $\bar{y}_{2019} = 64,139/12 = 5,344.92$. En enero hubo 7,935: $r_{2019,1} = 7,935/5,344.92 = 1.4846$.

El índice de enero. Las seis razones de enero (2016–2019, 2022, 2023): 1.5459, 1.7075, 1.8266, 1.4846, 1.2540 y 1.8173. Suman 9.6359: $\tilde{S}_1 = 9.6359/6 = 1.606$. El promedio de los 12 índices es 1.0000, así que $S_1 = 1.606$: en enero llega 61 % más gente que en un mes promedio. En septiembre, $S_9 = 0.496$: la mitad.


La fuerza. $\text{Var}(e) = 0.03152$ y $\text{Var}(s + e) = 0.15230$:

$$F_S = 1 - \frac{0.03152}{0.15230} = 1 - 0.2070 = 0.793.$$

El 79 % de la variación de un mes a otro en la Ruta es temporada.

Serie	F_S	Mes más alto	Mes más bajo
Ruta arqueológica del sur	0.793	enero (1.606)	septiembre (0.496)
Bahía Calderitas–Oxtankah	0.684	diciembre (1.402)	septiembre (0.647)
Chetumal (cruces de Belice)	0.655	diciembre (1.172)	febrero (0.865)
Cancún (referencia)	0.714	marzo (1.084)	septiembre (0.867)

¿Por qué no STL? STL (descomposición con regresión local, el método del plan) necesita una serie continua, y estas tienen huecos: pandemia, cierres por obras. STL solo podría usar el tramo continuo más largo y tirar los años posteriores. Se usó como **segunda opinión** en ese tramo: su índice coincide con el de este método entre 0.85 y 0.97.



Fuente: INAH (BdINAH), SITUR-Q (frontera México-Belice) y SECTUR-Datatur; solo años completos sin cierres ni pandemia (zonas: 2016–2019, 2022 y 2023 o 2025; Belice: 2019 y 2023–2025; Cancún: 2022–2025). Cálculo del proyecto.

Figura 6.2: La forma del año de cada serie (notebook 03).

Dónde está en el código

```
pronostico/forma.py: razones, indice_estacional, fuerza_estacional, segunda_opinion_stl.
```

6.4 Clima raro con Isolation Forest (detección de anomalías)

Pregunta. ¿Esta semana tuvo un clima tan raro que conviene pausar el anuncio? Se necesita detectar “lo raro” sin que alguien defina a mano qué es raro.

La idea, sin fórmulas

Imaginemos que separamos puntos en un plano con cortes al azar. Un punto que está lejos de todos se queda solo con muy pocos cortes; un punto en medio de la multitud necesita muchísimos. Isolation Forest hace eso con cientos de árboles de cortes al azar y mide cuántos cortes tarda, en promedio, en aislar cada semana. Las semanas raras se aíslan rápido.

6.4.1 Las fórmulas y su fundamento

$$s(x) = 2^{-\frac{E[h(x)]}{c(n)}}, \quad c(n) = 2H(n-1) - \frac{2(n-1)}{n}, \quad H(k) \approx \ln k + 0.5772.$$

- $h(x)$: número de cortes hasta aislar la semana x en un árbol; $E[h(x)]$, su promedio en los 300 árboles.
- $c(n)$: el número *promedio* de cortes que necesita una semana cualquiera en un árbol de n datos. Viene de la teoría de árboles binarios de búsqueda: es la longitud media de una búsqueda sin éxito. Sirve para normalizar.
- Si $E[h(x)] \approx c(n)$, entonces $s \approx 2^{-1} = 0.5$ (normal). Si $E[h(x)] \ll c(n)$, $s \rightarrow 1$ (muy rara).
- Cada árbol se entrena con una submuestra de hasta 256 semanas: con pocas semanas por árbol, las anomalías se separan mejor (el artículo original lo demuestra).

Variables: lluvia de la semana, lluvia del peor día, viento máximo, temperatura máxima y la época del año como seno y coseno de la semana. La época entra para que un aguacero de septiembre no salga raro solo por ser septiembre.

A mano, con números reales · Chetumal, semana del 14 de octubre de 2024 (tormenta Nadine)

Llovieron 148.7 mm (65.4 mm el peor día). Había 260 semanas de entrenamiento, así que cada árbol usa $n = 256$:

$$c(256) = 2(\ln 255 + 0.5772) - \frac{2 \cdot 255}{256} = 2(5.5413 + 0.5772) - 1.9922 = 12.237 - 1.992 = 10.245.$$

El bosque da $s = 0.712$. El corte (percentil 95 de las semanas de entrenamiento) es 0.543: como $0.712 > 0.543$, la semana es **rara**. ¿Cuántos cortes tardó en aislarse?

$$E[h] = -c(n) \log_2 s = -10.245 \times \log_2 0.712 = -10.245 \times (-0.489) = 5.0,$$

contra unos 10 de una semana normal.

Lo que decidimos

El corte automático del método (`contamination="auto"`, que marca raro si $s > 0.5$) señalaba **47 %** de las semanas de Chetumal: con pocas semanas el bosque no distinguía, y desde 2022 llueve más y hace más calor que en 2019–2021. Elegimos “más raro que el 95 % de las semanas que el bosque ya conoce”, con un bosque por año entrenado con todos los años anteriores (ventana creciente). Resultado: 21 semanas raras en Chetumal y 17 en Kohunlich. Descartados: el percentil 99 (casi nunca pausaba) y quitar la señal.

Validación independiente: el bosque marcó como raras las tres semanas en que pasaron tormentas (Lisa en 2022, Nadine y Sara en 2024) **sin saber** que hubo tormenta. Es evidencia de que “raro” significa algo real.

Dónde está en el código

```
envivo/senales.py: clima_semanal, anomalias_clima (sklearn.ensemble.IsolationForest
(n_estimators=300, random_state=0)).
```

6.5 Minería de texto de las reseñas

Pregunta. ¿Qué molesta y qué enamora al turista? Es lo que define la promesa de la campaña y sus palabras.

Datos: 85,987 reseñas de Quintana Roo (Rest-Mex 2025, sin duplicados): Tulum, Isla Mujeres y Bacalar. **Ninguna es de los cinco lugares**, así que sirven para saber qué molesta en los destinos llenos, no para opinar del sur. 3,597 son malas (1–2 estrellas) y 60,082 de 5 estrellas.

6.5.1 Temas con un léxico a la vista y riesgo relativo

Cada tema es una lista de raíces de palabras que cuentan solo al inicio de una palabra. Por ejemplo, “ruido” incluye *ruido*, *ruidos*, *escándalo*, *música alta*, *fiesta*; “calma” incluye *tranquil*-, *paz*, *relaj*-, *silencio*.

El **riesgo relativo** es la medida que usa la epidemiología para comparar el riesgo en un grupo con el riesgo general:

$$RR_a = \frac{P(\text{mala} \mid \text{la reseña toca el tema } a)}{P(\text{mala})}.$$

$RR = 1$: el tema no cambia nada. $RR = 2$: una reseña que lo toca es mala el doble de seguido.

A mano, con números reales · ruido

$P(\text{mala}) = 3,597/85,987 = 0.04183$. Reseñas que hablan de ruido: 2,038, de las cuales 235 son malas: $P(\text{mala} \mid \text{ruido}) = 235/2,038 = 0.11531$. Entonces

$$RR_{\text{ruido}} = \frac{0.11531}{0.04183} = 2.76.$$

Tema	RR	Lectura
Ruido	2.76	Aleja
Suciedad	1.89	Aleja
Precio	1.66	Aleja
Multitudes	1.52	Aleja
Servicio	1.18	Neutro
Comida	0.81	Protege un poco
Naturaleza	0.73	Protege
Cultura	0.48	Protege
Calma	0.41	Protege

Por qué léxico y no un modelo de temas (LDA): con LDA, cada tema es una lista de palabras que hay que interpretar (“adivinar” qué significa). Con un léxico, cada tema se define antes y se defiende palabra por palabra. Para una campaña que tiene que explicar por qué promete calma, lo segundo es más defendible.

6.5.2 Reglas de asociación (algoritmo Apriori)

Cada reseña es una “canasta” con sus temas y su calificación. Apriori encuentra combinaciones frecuentes:

$$\text{soporte}(A) = \frac{\#\{\text{reseñas con } A\}}{N}, \quad \text{confianza}(A \Rightarrow B) = \frac{\text{sop}(A \cup B)}{\text{sop}(A)}, \quad \text{lift} = \frac{\text{confianza}}{\text{sop}(B)}.$$

El truco de Apriori: si una combinación es rara, todas las combinaciones más grandes que la contienen también lo son (propiedad antimonótona). Así no tiene que revisar todas las combinaciones posibles. Se usó soporte mínimo de 0.1 % y combinaciones de hasta 3 elementos.

A mano, con números reales · ruido + servicio $\Rightarrow$ reseña mala

1,204 reseñas tocan ruido y servicio a la vez; 142 de ellas son malas.

$$\text{soporte} = \frac{142}{85,987} = 0.00165, \quad \text{confianza} = \frac{142}{1,204} = 0.1179, \quad \text{lift} = \frac{0.1179}{0.04183} = 2.82.$$

Una reseña que habla de ruido y de mal servicio es mala 2.8 veces más seguido de lo normal. Otras: suciedad + multitudes (lift 2.59), suciedad + precio (2.54). Hacia 5 estrellas: comida + servicio (1.12), calma + naturaleza (1.10).

6.5.3 El lenguaje del turista (log-odds con prior de Dirichlet)

Pregunta: ¿qué palabras usan más las reseñas de 5 estrellas que las malas? Contar no basta: las palabras raras dan cocientes enormes por azar. El método de Monroe, Colaresi y Quinn (2008)

agrega un “colchón” α_w proporcional a lo común que es la palabra:

$$\delta_w = \ln \frac{y_w^A + \alpha_w}{n_A + \alpha_0 - y_w^A - \alpha_w} - \ln \frac{y_w^B + \alpha_w}{n_B + \alpha_0 - y_w^B - \alpha_w}, \quad z_w = \frac{\delta_w}{\sqrt{\frac{1}{y_w^A + \alpha_w} + \frac{1}{y_w^B + \alpha_w}}},$$

con A = reseñas de 5 estrellas, B = reseñas malas, y = veces que aparece la palabra, n = total de palabras, $\alpha_w = 0.01 \times (\text{veces en todo el corpus})$ y $\alpha_0 = \sum_w \alpha_w$. z es como un puntaje de cuántas desviaciones estándar se aleja la palabra de lo esperado.

A mano, con números reales · la palabra “excelente”

$y^A = 18,952$, $y^B = 144$, $\alpha = 190.96$, $n_A = 1,879,868$, $n_B = 162,035$, $\alpha_0 = 20,419.0$.

$$\begin{aligned} \delta &= \ln \frac{18,952 + 190.96}{1,879,868 + 20,419.0 - 18,952 - 190.96} - \ln \frac{144 + 190.96}{162,035 + 20,419.0 - 144 - 190.96} \\ &= \ln \frac{19,142.96}{1,881,144.04} - \ln \frac{334.96}{182,119.04} = -4.5878 - (-6.2985) = 1.7107, \\ z &= \frac{1.7107}{\sqrt{1/19,142.96 + 1/334.96}} = \frac{1.7107}{0.05512} = 31.04. \end{aligned}$$

“Excelente” es una de las palabras que más distinguen a las reseñas de 5 estrellas. En el otro extremo, “sucio” tiene $z = -18.76$.

Palabras de 5 estrellas: *excelente, increíble, hermoso, deliciosa, amable, ruinas, ambiente*. Malas: *peor, horrible, dinero, caro, sucio, grosero*. Con ellas se escribieron los mensajes (capítulo 10).

Dónde está en el código

`campana/texto.py: marcar_aspectos, aspectos, reglas_asociacion (mlxtend.apriori), palabras_que_distiungen. Notebook 07_campana.`

6.6 NLP de lugares: qué hacer, dónde comer y dónde dormir

Pregunta: de los negocios del DENU, ¿cuáles recomendar de día, tarde y noche en cada lugar?

Método: un clasificador por léxico que lee el **nombre** del negocio y, si el nombre no dice nada, su giro oficial (SCIAN). No se entrenó un modelo estadístico porque no hay etiquetas con qué entrenarlo; un léxico es lo honesto y se puede explicar regla por regla. Las reglas salieron de errores reales:

- La raíz cuenta solo al inicio de una palabra: “MICHELADAS” contiene “HELAD” y salía como heladería; “BARBACOA” contiene “BAR”.
- El nombre gana al giro: “HOTEL COSTA AZUL” tenía giro de casa de huéspedes.
- Se excluye lo que no le sirve a un visitante: cooperativas escolares, gimnasios, moteles, banquetes.

Precisión medida: dos muestras al azar revisadas a mano, 38 de 40 y, tras corregir, **39 de 40** en una muestra nueva. **No hicimos scraping** de Google Maps (lo prohíben sus términos): cada tarjeta es un enlace público.

Dónde está en el código

`campana/lugares.py`: clasificar, recomendaciones.

Aprendizaje de máquina: predecir

Criterio 4 de la rúbrica (12 %): construye, valida, compara e interpreta modelos con métricas adecuadas y justifica la selección.

El proyecto tiene dos problemas de aprendizaje de máquina, y es importante no confundirlos:

	Clasificación (Radar)	Regresión de series de tiempo (Pronóstico)
Qué predice	Un <i>estado</i> : tranquilo, concurrido o saturado	Un <i>número</i> : cuántos visitantes
Horizonte	El mes siguiente	1 a 12 meses
Modelos	Logística, Random Forest, Gradient Boosting	Línea base, Holt-Winters (2), regresión con clima, Gradient Boosting
Contra qué se compara	"Igual que este mes"	"El mismo mes del año pasado"
Métrica	Aciertos, cambios anticipados, F1	MAE, MAPE, cobertura del rango

7.1 Clasificación: ¿qué estado tendrá cada lugar el mes siguiente?

7.1.1 El planteamiento

Unidad: un lugar en un mes. **Objetivo** (y): el estado del índice comparable el mes siguiente.

Rasgos (x , lo que el modelo ve):

- el índice de este mes y de los dos anteriores (IPT_t , IPT_{t-1} , IPT_{t-2}) y el cambio ($IPT_t - IPT_{t-1}$);
- el mes del año como un punto en un círculo, $(\sin \frac{2\pi m}{12}, \cos \frac{2\pi m}{12})$. *Por qué un círculo:* si el mes fuera el número 1 a 12, el modelo creería que diciembre (12) está lejos de enero (1); en el círculo quedan juntos;
- si es uno de los cinco lugares (1 o 0).

Datos: 468 casos para el modelo final (234 tranquilos, 185 concurridos, 49 saturados).

7.1.2 Los modelos y su fundamento

Línea base, persistencia: $\hat{y}_{t+1} = y_t$ (“igual que este mes”). Un modelo que no le gane a esto no sirve.

Regresión logística multiclase. Para cada clase k calcula un puntaje lineal y los convierte en probabilidades con la función *softmax*:

$$z_k = b_k + \beta_k^\top \mathbf{x}, \quad P(y = k \mid \mathbf{x}) = \frac{e^{z_k}}{\sum_j e^{z_j}}.$$

Fundamento: el softmax garantiza probabilidades positivas que suman 1, y cada β dice cuánto empuja un rasgo hacia una clase. Los β se estiman por **máxima verosimilitud**: se buscan los que hacen más probables los estados que de verdad ocurrieron (equivale a minimizar la entropía cruzada). Detalles: los rasgos se *estandarizan* $((x - \bar{x})/\sigma)$ para que los β sean comparables, y se usan *pesos de clase balanceados*, porque “saturado” es raro (49 de 468) y sin pesos el modelo casi nunca lo predeciría.

Random Forest: 400 árboles de decisión; cada uno se entrena con una muestra al azar de los casos (con reemplazo) y mira un subconjunto al azar de rasgos en cada corte. La predicción promedia las probabilidades de los 400. *Fundamento:* promediar muchos árboles distintos reduce la varianza de un árbol solo.

Gradient Boosting: suma árboles pequeños, $F_M(\mathbf{x}) = \sum_{m=1}^M \nu h_m(\mathbf{x})$; cada árbol nuevo h_m se ajusta a los errores que dejaron los anteriores (al gradiente de la pérdida). 100 árboles con tasa $\nu = 0.1$.

A mano, con números reales · Mahahual, predicción de agosto de 2026 con la regresión logística

1. Estandarizar. El índice de julio fue 0.731; la media de entrenamiento es 0.2762 y la desviación 0.2799:

$$x^{\text{std}} = \frac{0.731 - 0.2762}{0.2799} = 1.625.$$

Así con los siete rasgos: (1.625, 1.362, 1.623, 0.871, -0.803, -1.158, -0.657).

2. Puntaje de “saturado”. Coeficientes $\beta = (1.462, 1.291, 1.560, 0.567, -0.158, 1.195, -0.016)$ y $b = -3.255$:

$$\begin{aligned} z_{\text{sat}} &= -3.255 + 1.462(1.625) + 1.291(1.362) + 1.560(1.623) + 0.567(0.871) \\ &\quad + (-0.158)(-0.803) + 1.195(-1.158) + (-0.016)(-0.657) \\ &= -3.255 + 2.376 + 1.758 + 2.532 + 0.494 + 0.127 - 1.384 + 0.011 = 2.659. \end{aligned}$$

Igual se obtienen $z_{\text{conc}} = 3.068$ y $z_{\text{tranq}} = -5.728$.

3. Softmax. Restando el mayor (3.068) para no desbordar:

$$e^0 = 1, \quad e^{2.659-3.068} = e^{-0.409} = 0.664, \quad e^{-5.728-3.068} = e^{-8.796} = 0.00015;$$

$$P(\text{concurrido}) = \frac{1}{1.664} = 0.601, \quad P(\text{saturado}) = \frac{0.664}{1.664} = 0.399, \quad P(\text{tranquilo}) \approx 0.$$

El modelo dice: Mahahual sigue concurrido, con 40 % de probabilidad de saturarse. Es lo que muestra la página.

Qué rasgo pesa más (promedio de $|\beta|$ en las tres clases): el índice del mes (1.07), el de dos meses antes (1.04), el del mes anterior (0.95), la temporada como coseno (0.80), el cambio (0.40), ser uno de los cinco (0.35).

7.1.3 Cómo se validó: origen móvil

Por qué no revolver al azar. La forma escolar de validar (separar 80 % para entrenar y 20 % al azar para probar) aquí sería trampa: el modelo podría entrenar con agosto y probarse con julio, es decir, **ver el futuro**. En series de tiempo se valida como se usaría de verdad.

Origen móvil: para cada uno de los 12 meses de prueba (agosto de 2025 a julio de 2026), se reentrena cada modelo con todo lo anterior y se predice solo ese mes. Son 12 reentrenamientos, 156 predicciones y 30 cambios reales de estado.

7.1.4 Las métricas

Para cada clase: precisión $P_k = \frac{VP_k}{VP_k + FP_k}$ (de lo que predijo k , cuánto era k), sensibilidad $R_k = \frac{VP_k}{VP_k + FN_k}$ (de lo que era k , cuánto encontró) y $F1_k = \frac{2P_kR_k}{P_k + R_k}$ (su media armónica, que castiga si una de las dos es baja). $F1_{\text{macro}} = \frac{1}{3} \sum_k F1_k$ da el mismo peso a las tres clases, aunque “saturado” sea rara. Además: **cambios anticipados** (aciertos en los meses en que el estado cambió), que es lo que le importa a la regla anti-colapso.

A mano, con números reales · matriz de confusión y F1 de la logística

Real \ predicho	tranquilo	concurrido	saturado
tranquilo	75	12	0
concurrido	10	50	2
saturado	0	2	5

- Tranquilo: $P = 75/85 = 0.882$, $R = 75/87 = 0.862$, $F1 = \frac{2(0.882)(0.862)}{0.882+0.862} = 0.872$.
- Concurrido: $P = 50/64 = 0.781$, $R = 50/62 = 0.806$, $F1 = 0.794$. Saturado: $P = R = 5/7 = 0.714$, $F1 = 0.714$.
- $F1_{\text{macro}} = (0.872 + 0.794 + 0.714)/3 = 0.793$. Aciertos: $75 + 50 + 5 = 130$ de 156.

Modelo	Aciertos	Cambios (de 30)	Falsas alarmas	F1 macro
Persistencia	126	0	0	0.774
Regresión logística (elegida)	130	8	4	0.793
Random Forest	130	6	2	0.766
Gradient Boosting	128	7	5	0.731

Lo que decidimos

El modelo que más acierta y, a igualdad, el que más cambios anticipa (la regla anti-colapso necesita anticipar). Antes de la auditoría ese criterio daba Random Forest; al agregar “llegadas por cuarto”, la logística empató en aciertos y anticipó más cambios. Se respeta el criterio, no el nombre del modelo: el código elige solo.

Supuestos y límites

- **Lectura honesta:** el estado se repite el 81 % de los meses, así que el modelo agrega poco (+4 aciertos); su valor está en los 8 cambios que anticipa.
- **Sesgo:** en los cinco lugares hubo solo 2 cambios en 48 casos y el modelo no anticipó ninguno. La afirmación correcta es “anticipa cambios en los lugares de referencia”; en el sur casi no hubo cambios con qué probarlo.

Dónde está en el código

radar/prediccion.py: tabla_de_aprendizaje, modelos, origen_movil, sesgo, predecir_mes_siguiente.

7.2 Pronóstico de visitantes: series de tiempo

7.2.1 De dónde salen las series

Serie	Fuente y camino	Meses	Entrenan
Visitantes a Oxtankah (Bahía)	DataTur BdINAH.zip □ silver/inah □ pronostico/series.py	127	90
Kohunlich + Dzibanché + Ichkabal (Ruta)	DataTur BdINAH.zip □ silver/inah	127	91
Cruces desde Belice (Chetumal)	API de SITUR-Q □ silver/siturq	90	62
Ocupación de Cancún (referencia)	DataTur semanal □ silver/datatur_ocupacion	55	55

Por qué estas: el sur no tiene ocupación oficial en 2025–2026; se pronostica solo lo **medido** que llega a 2026. Maya Ka'an y la Laguna no tienen serie mensual propia: hueco declarado.

7.2.2 Meses que no entrenan

Un mes cerrado no es “cero demanda”. Si el modelo aprendiera de esos ceros, creería que en abril puede haber 0 visitantes por temporada. Reglas (decisión “Hueco + forma del año”):

- **Cierre:** la zona reportó 0 visitantes.
- **Mes parcial:** el mes justo antes de cerrar o después de reabrir (abrió a medias).
- **Pandemia:** INAH, de marzo de 2020 a diciembre de 2021; Belice, de marzo de 2020 a junio de 2022 (de marzo a junio de 2022 los cruces apenas iban en 65–82 % de 2019).
- Una región toma el motivo más fuerte de sus zonas. Ejemplo, Ruta: diciembre de 2024 cierre; enero de 2025 cierre (Dzibanché seguía cerrada aunque Kohunlich abrió); febrero de 2025 parcial; marzo de 2025 ya entrena.

Esos meses no entrenan, pero su valor se conserva. Cada reapertura inicia un **tramo** con su propio nivel.

7.2.3 Los cinco modelos

Notación: y_t = valor del mes t ; o = origen (último mes conocido); h = meses hacia adelante; S_m = forma del año calculada **solo con años anteriores al origen**.

1. Línea base (ingenuo estacional). $\hat{y}_{o+h}$ = el último valor del mismo mes del año. Es la vara.

2 y 3. Holt-Winters con la forma del año fija.

La idea, sin fórmulas

Se le quita la temporada a la serie (se divide cada mes entre su índice), así queda el “nivel” de fondo. Ese nivel se actualiza cada mes mezclando el dato nuevo con lo que ya se creía, y para pronosticar se le vuelve a poner la temporada.

$$z_t = \frac{y_t}{S_{m(t)}}, \quad \ell_t = \alpha z_t + (1 - \alpha)\ell_{t-1}, \quad \hat{y}_{o+h} = \ell_o S_{m(o+h)}.$$

$\alpha \in (0, 1)$ dice cuánto se cree en el dato nuevo: cerca de 1, el nivel sigue cada dato; cerca de 0, cambia lento. Se estima minimizando el error de pronóstico a un paso dentro del tramo (stats-models). La variante **con tendencia amortiguada** agrega una pendiente $b_t = \beta(\ell_t - \ell_{t-1}) + (1 -$

$\beta)\phi b_{t-1}$ que se va apagando ($\phi < 1$). Por qué la forma fija: el Holt-Winters clásico estima la temporada él mismo y necesita al menos 24 meses seguidos; desde las reaperturas solo hay 17 a 20.

A mano, con números reales · Ruta, origen julio de 2026, sin tendencia

statsmodels estimó $\alpha = 0.1183$. Julio tuvo 5,057 visitantes y su índice es 0.953: $z = 5,057/0.953 = 5,306.6$. El nivel de junio era 5,332.5:

$$\ell_{\text{jul}} = 0.1183 \times 5,306.6 + 0.8817 \times 5,332.5 = 627.8 + 4,701.7 = 5,329.4.$$

Enero de 2027: $\hat{y} = 5,329.4 \times S_1 = 5,329.4 \times 1.606 = 8,559$ visitantes. El código da 8,559.

4. Regresión con clima (mínimos cuadrados sobre el logaritmo):

$$\ln y_t = \tau_{k(t)} + \mu_{m(t)} + \beta \frac{L_t - \bar{L}_{m(t)}}{100} + \gamma T_t + \varepsilon_t.$$

τ_k = nivel del tramo k ; μ_m = efecto del mes (enero es la referencia, $\mu_1 = 0$); $L_t - \bar{L}_m$ = lluvia del mes menos la normal (en cientos de mm); $T_t = 1$ si empezó una tormenta que afecta al sur. *Fundamento*: en logaritmos, los efectos se vuelven porcentajes: $e^{\mu_{12}}$ es “cuántas veces enero” es diciembre. Los coeficientes se estiman por mínimos cuadrados ordinarios, $\hat{\theta} = (X^\top X)^{-1} X^\top y$ (numpy `lstsq`). Para el futuro el clima no se conoce, así que se usa el normal: lluvia anómala = 0 y tormenta = su frecuencia histórica en ese mes:

$$\hat{y}_{o+h} = \exp(\hat{\tau}_K + \hat{\mu}_m + \hat{\gamma} \hat{p}_m).$$

A mano, con números reales · Bahía, diciembre de 2026

Con 90 meses que entrenan hay tres tramos: antes de 2020 ($\hat{\tau} = 7.0975$, un enero típico de $e^{7.0975} = 1,209$ visitantes), después de la pandemia (6.8559, 949) y desde la reapertura de 2024 (7.0382, 1,139). Diciembre: $\hat{\mu}_{12} = 0.1404$, o sea $e^{0.1404} = 1.151$ veces un enero; nunca hubo tormenta en diciembre ($\hat{p} = 0$):

$$\hat{y} = e^{7.0382+0.1404} = e^{7.1786} = 1,311 \text{ visitantes.}$$

El código da 1,311.13. El coeficiente de la lluvia, $\hat{\beta} = -0.115$, dice que cada 100 mm sobre lo normal se asocian a $e^{-0.115} - 1 = -10.9\%$ visitantes ($p = 0.027$).

5. Gradient Boosting con rezagos. 150 árboles (tasa 0.05, hojas de al menos 20 casos) que aprenden de todos los pares pasados (origen → destino), con: meses hacia adelante, mes del año, logaritmo del último valor, del promedio de los últimos 3 meses y del mismo mes del año anterior.

7.2.4 Cómo se midió el error: origen móvil

Para cada mes del pasado (desde enero de 2019 en el INAH) se pronostican los 12 siguientes **usando solo lo que se sabía entonces**, incluida la forma del año, y se compara con lo que pasó. Para que la comparación sea justa, solo cuentan los pares que los cinco modelos pudieron pronosticar: 366 en la Bahía, 378 en la Ruta, 366 en Belice y 438 en Cancún.

$$MAE = \frac{1}{n} \sum |y - \hat{y}|, \quad MAPE = \frac{100}{n} \sum \left| \frac{y - \hat{y}}{y} \right|, \quad \text{error relativo} = \frac{MAE_{\text{modelo}}}{MAE_{\text{línea base}}}.$$

El error relativo menor que 1 significa que el modelo le gana a “el mismo mes del año pasado”.

A mano, con números reales · el error de un pronóstico

Bahía, origen enero de 2019, destino febrero: pronóstico 1,058.48, real 925. $e = |\ln(1,058.48/925)| = |\ln 1.1443| = 0.1348$: el pronóstico se pasó 14.4 %.

7.2.5 El rango del 90 %: intervalo conformal

La idea, sin fórmulas

Se revisan los errores que el modelo cometió en el pasado en pronósticos parecidos. Si 9 de cada 10 fueron menores que cierto tamaño, lo razonable es decir que el próximo pronóstico tampoco se equivocará más que eso, con 90 % de confianza. No se supone que los errores sigan una curva normal: se usan los errores reales.

$$\hat{q} = e_{(k)}, \quad k = \lceil (n+1) \cdot 0.9 \rceil, \quad \text{rango} = [\hat{y} e^{-\hat{q}}, \hat{y} e^{\hat{q}}].$$

$e_{(k)}$ es el k -ésimo error más chico de los n errores de calibración (del mismo modelo y del mismo tramo de horizonte: 1–3, 4–6 o 7–12 meses) cuyo mes ya había pasado en el origen.

Fundamento (la garantía): si los errores futuros son intercambiables con los pasados (vienen “del mismo tipo de mes”), el nuevo error cae por debajo del k -ésimo con probabilidad al menos $k/(n+1)$. El +1 y el techo son la corrección de muestra finita que vuelve la garantía exacta. Se trabaja con errores en logaritmo porque los errores son proporcionales al nivel.

A mano, con números reales · Bahía, diciembre de 2026 (5 meses adelante)

Hay $n = 105$ errores de calibración: $k = \lceil 106 \times 0.9 \rceil = \lceil 95.4 \rceil = 96$, y el 96.º más chico es $\hat{q} = 0.3132$. Garantía: $96/106 = 90.6\%$. Con el pronóstico de 1,311.13:

$$\text{mínimo} = 1,311.13 \times e^{-0.3132} = 1,311.13 \times 0.7311 = 959,$$

$$\text{máximo} = 1,311.13 \times e^{0.3132} = 1,311.13 \times 1.3678 = 1,793.$$

Diciembre de 2025 tuvo 1,224: dentro del rango.

Cobertura real: se midió cuántas veces el dato cayó dentro del rango, y se reporta aunque salga peor.

7.2.6 La elección y los resultados


Lo que decidimos

“Menor error con rango $\geq 80\%$ ”: por serie, el modelo de menor error entre los que tienen un rango que se cumple al menos 80 de cada 100 veces. Descartados: el menor error sin importar el rango (en la Ruta elegiría un modelo cuyo rango acierta 72 de cada 100) y un solo modelo para todo (en Cancún la regresión comete 58 % más error que la línea base).

Serie	Modelo	MAPE	vs base	Cobertura	Rango típico
Bahía	Regresión con clima	15.7 %	0.898	91.3 %	$\pm 43\%$
	Holt-Winters sin tendencia	19.4 %	1.078	96.5 %	$\pm 63\%$
	Holt-Winters con tendencia	27.6 %	1.524	87.8 %	$\pm 108\%$
	Gradient Boosting	28.7 %	1.405	85.8 %	$\pm 83\%$
	Línea base	19.8 %	1.000	85.4 %	$\pm 77\%$
Ruta	Regresión con clima	21.6 %	0.737	80.3 %	$\pm 51\%$
	Holt-Winters sin tendencia	20.1 %	0.639	72.3 %	$\pm 45\%$
	Línea base	27.9 %	1.000	74.3 %	$\pm 63\%$
Belice	Regresión con clima	11.0 %	0.820	94.1 %	$\pm 26\%$
Cancún	Línea base	3.8 %	1.000	89.3 %	$\pm 10\%$

Supuestos y límites

- **La Ruta no llega a 90 % con ningún modelo:** en 2023 las visitas cayeron 10.7 % (de 46,295 a 41,322) sin aviso en la historia, y ese año la cobertura fue de 67 %. La garantía conformal supone que el futuro se parece al pasado; 2023 rompió ese supuesto.
- **El clima casi no mejora el pronóstico:** la misma regresión sin lluvia ni tormentas da errores casi iguales (0.906, 0.842 y 0.721). Lo que gana es la estructura: nivel por tramo y efecto del mes. Al pronosticar se usa el clima normal, porque el futuro no se conoce.
- **La tendencia falla en tramos cortos:** Holt-Winters con tendencia llegó a pronosticar –240 visitantes en la Bahía porque aprendió la tendencia en plena reapertura.
- **En Cancún, repetir el año anterior es lo mejor** (3.8 % de error): su ocupación cambia poco de un año a otro.



Fuente: INAH (BdINAH) y SITUR-Q (frontera México-Belice). Pronóstico del proyecto con regresión con clima (modelo elegido en el origen móvil); rango del 90 % conformal. Los huecos de la línea gris son meses de cierre o mes parcial.

Figura 7.1: Pronóstico de los próximos 12 meses con su rango del 90 % (notebook 03).

Dónde está en el código

`pronostico/series.py`, `modelos.py` (cinco modelos y `origen_movil`), `intervalos.py` (`cantil_conformal`, `cobertura`), `seleccion.py`.

Si nos preguntan

“¿Por qué no usaste ARIMA o Prophet?” Porque las series tienen huecos largos (pandemia y cierres por obras) y tramos cortos desde las reaperturas, y esos métodos necesitan series continuas largas. Elegimos modelos que funcionan por tramos y con la temporada estimada aparte, y los comparamos contra una línea base con validación honesta.

Procesos estocásticos: la incertidumbre

Criterio 5 de la rúbrica (10 %): incorpora la incertidumbre, genera escenarios pertinentes y analiza sus implicaciones para decidir.

Un proceso estocástico es algo que evoluciona con azar. El proyecto modela tres: cómo cambia de estado la ocupación del norte semana a semana (Markov), cuántas tormentas llegan cada mes (Poisson) y cuántos visitantes podrían llegar en los próximos 12 meses (Monte Carlo).

8.1 Cadena de Markov semanal del norte

Pregunta. Si Cancún está concurrido esta semana, ¿qué probabilidad hay de que se sature en las próximas semanas? Cuando el norte se va a saturar es el momento de ofrecer el sur a quien iba allá.

La idea, sin fórmulas

Una cadena de Markov es un juego de tablero donde la siguiente casilla depende solo de la casilla donde estás, no de cómo llegaste. Aquí las casillas son tranquilo, concurrido y saturado, y las probabilidades de moverse se cuentan con lo que pasó en 239 semanas reales.

8.1.1 Los datos y los estados

7 centros de DataTur (Cancún, Riviera Maya, Playa del Carmen, Playacar, Akumal, Cozumel e Isla Mujeres) $\times$ 239 semanas. Cada semana se clasifica con los percentiles comunes de la ocupación de todas las semanas de los 7 centros: $u_{50} = 71.16\%$ y $u_{90} = 85.92\%$.

8.1.2 Las fórmulas y su fundamento

Propiedad de Markov: $P(X_{t+1} = j \mid X_t = i, X_{t-1}, \dots) = P(X_{t+1} = j \mid X_t = i) = p_{ij}$.

Estimación por máxima verosimilitud: con n_{ij} = veces que un centro pasó de i a j entre dos semanas seguidas,

$$\hat{p}_{ij} = \frac{n_{ij}}{\sum_j n_{ij}}.$$

Fundamento: la probabilidad de haber observado todas las transiciones es $\prod_{i,j} p_{ij}^{n_{ij}}$; si se maximiza respetando que cada renglón sume 1, sale exactamente "contar y dividir".

Varias semanas adelante (ecuación de Chapman-Kolmogorov): la matriz a k semanas es la potencia P^k , y si hoy el estado es i , $\pi_{t+k} = \pi_t P^k$ con $\pi_t = 1$ en i .

A largo plazo: la distribución estacionaria π cumple $\pi = \pi P$ y $\sum \pi = 1$ (es el vector propio de $P^\top$ con valor propio 1). Dice qué parte del tiempo pasa el sistema en cada estado.

Cuánto dura un estado: el número de semanas seguidas en el estado i es geométrico, con media $1/(1 - p_{ii})$.

A mano, con números reales · conteos, matriz y predicciones

	Conteos n_{ij}			Probabilidades $\hat{p}_{ij}$		
Esta semana	tranq.	conc.	sat.	tranq.	conc.	sat.
tranquilo	765	65	0	0.922	0.078	0.000
concurrido	67	555	46	0.100	0.831	0.069
saturado	2	44	122	0.012	0.262	0.726

Un renglón: $765/(765 + 65 + 0) = 765/830 = 0.922$.

Dos semanas adelante desde concurrido, probabilidad de estar saturado:

$$p_{c,s}^{(2)} = p_{c,t} p_{t,s} + p_{c,c} p_{c,s} + p_{c,s} p_{s,s} = 0.100(0) + 0.831(0.069) + 0.069(0.726) = 0.057 + 0.050 = 0.107.$$

Desde tranquilo, a 8 semanas (P^8): 5.4 %.

Largo plazo: resolviendo $\pi = \pi P$ se obtiene $\pi = (0.513, 0.389, 0.098)$: el norte pasa el 9.8 % de las semanas saturado. Comprobación: $\pi P = \pi$.

Duración: una racha saturada dura en promedio $1/(1 - 0.726) = 3.65$ semanas.

8.1.3 ¿Sirve? El puntaje de Brier

Para evaluar *probabilidades* (no solo aciertos) se usa el puntaje de Brier:

$$B = \frac{1}{N} \sum_{n=1}^N \sum_j (p_{n,j} - \mathbb{I}[y_n = j])^2.$$

Es el error cuadrático entre la probabilidad dada y lo que pasó (1 en el estado real, 0 en los demás). 0 es perfecto; más bajo es mejor. Se probó en las últimas 52 semanas, estimando P en cada semana solo con las transiciones anteriores:

Horizonte	Brier Markov	Brier persistencia	Brier frecuencia simple
1 semana	0.200	0.225	0.544
4 semanas	0.389	0.484	0.549
8 semanas	0.490	0.676	0.555

La cadena da **mejores probabilidades** en los tres horizontes. Si solo se toma su estado más probable, no le gana a la persistencia a 4 y 8 semanas: su valor está en la probabilidad (“14 % de riesgo de saturarse”), no en una etiqueta.

Supuestos y límites

- La siguiente semana depende solo de esta semana (propiedad de Markov).
- La matriz es la misma para los 7 centros y en el tiempo (homogénea): dos centros en el mismo estado tienen el mismo riesgo. Es una simplificación declarada.
- El sur no tiene datos semanales: la cadena cubre solo el norte, que es la referencia.

Dónde está en el código

radar/markov.py: estados, transiciones, matriz, estacionaria, a_k_semanas, backtest.

8.2 Tormentas: definición y distancia

Lo que decidimos

Una tormenta **afecta al sur** si un punto de su trayectoria pasa a ≤ 200 km de Chetumal, con viento ≥ 34 nudos (tormenta tropical o huracán) y es de 1966 en adelante (era satelital). Alternativas medidas: 100 km daba 13 eventos (muy pocos para estimar una tasa por mes); 300 km daba 59 (mete tormentas que no traen viento fuerte al sur); desde 1851 la tasa sale baja porque antes de los satélites se perdían tormentas en el mar.

La distancia sobre la Tierra se calcula con la fórmula de **haversine** (radio $R = 6,371$ km), que da la distancia por la superficie de una esfera entre dos puntos con latitud φ y longitud λ en radianes:

$$d = 2R \arcsin \sqrt{\sin^2 \frac{\Delta\varphi}{2} + \cos \varphi_1 \cos \varphi_2 \sin^2 \frac{\Delta\lambda}{2}}.$$

A mano, con números reales · huracán Carmen, 2 de septiembre de 1974

Chetumal está en $(18.5^\circ, -88.3^\circ)$ y Carmen pasó por $(18.6^\circ, -88.2^\circ)$: $\Delta\varphi = \Delta\lambda = 0.1^\circ = 0.0017453$ rad.

$$\begin{aligned} a &= \sin^2(0.00087266) + \cos 18.5^\circ \cos 18.6^\circ \sin^2(0.00087266) \\ &= 7.6154 \times 10^{-7} + 0.94832 \times 0.94777 \times 7.6154 \times 10^{-7} = 1.4460 \times 10^{-6}, \\ d &= 2 \times 6,371 \times \arcsin \sqrt{1.4460 \times 10^{-6}} = 2 \times 6,371 \times 0.0012025 = 15.3 \text{ km}. \end{aligned}$$

A 15.3 km, con 125 nudos, en 1974: **es evento**. En total, **31 eventos en 60 temporadas** (1966–2025).

8.3 Poisson: la probabilidad de tormenta en cada mes

La idea, sin fórmulas

Las tormentas son eventos raros que llegan sin aviso y uno no depende del otro. La distribución de Poisson es la que describe cuántos eventos así ocurren en un periodo, y solo necesita un número: cuántos llegan en promedio.

$$N_m \sim \text{Poisson}(\lambda_m), \quad P(N_m = k) = \frac{e^{-\lambda_m} \lambda_m^k}{k!},$$

$$\hat{\lambda}_m = \frac{\text{\#eventos que empezaron en el mes } m}{60}, \quad P(N_m \geq 1) = 1 - e^{-\hat{\lambda}_m}.$$

Fundamento: si un mes se divide en muchos instantes muy cortos y en cada uno puede empezar una tormenta con probabilidad muy pequeña e independiente, el número total sigue una binomial que, en el límite, es una Poisson. El estimador de máxima verosimilitud de λ es el promedio de eventos por temporada. La probabilidad de “al menos una” es 1 menos la de “ninguna”, y $P(N = 0) = e^{-\lambda}$.

A mano, con números reales · agosto y el año completo

Agosto tuvo 9 eventos en 60 temporadas: $\hat{\lambda}_8 = 9/60 = 0.15$,

$$P(N_8 \geq 1) = 1 - e^{-0.15} = 1 - 0.8607 = 0.139 = 13.9\%.$$

Septiembre: $8/60 = 0.1333$, $P = 12.5\%$. Al menos una en el año (la suma de Poisson independientes es Poisson): $1 - e^{-31/60} = 1 - e^{-0.5167} = 1 - 0.5965 = 40.3\%$.


Mes	may	jun	jul	ago	sep	oct	nov	dic-abr
Eventos	1	3	1	9	8	6	3	0
$P(N \geq 1)$	1.7 %	4.9 %	1.7 %	13.9 %	12.5 %	9.5 %	4.9 %	0 %

8.4 Monte Carlo: escenarios malo, probable y bueno

Pregunta (incidente de estocásticos): ¿y si el año sale mejor o peor de lo pronosticado? ¿Qué tan probable es rebasar lo que un lugar ha podido recibir?

La idea, sin fórmulas

En lugar de un solo pronóstico, la computadora imagina 10,000 años posibles. En cada uno toma el pronóstico, le aplica un año de errores reales del pasado y le sortea tormentas. Con



Fuente: Open-Meteo (reanálisis ERA5), lluvia diaria en Chetumal 1991–2020; NOAA HURDAT2, tormentas a 200 km o menos de Chetumal con viento de 34 nudos o más, 1966–2025 (31 en total). El número blanco dentro de cada barra guinda = tormentas de ese mes. Datos limpios del proyecto.

Figura 8.1: Lluvia y tormentas por mes en Chetumal: la temporada de lluvias coincide con la de tormentas.

los 10,000 años se ve qué tan malo puede ser un año malo y qué tan probable es pasarse de la capacidad.

Para cada futuro $r = 1, \dots, 10,000$ y cada mes $j = 1, \dots, 12$:

$$D_j^{(r)} = \hat{y}_j \cdot e^{\epsilon_j^{(r)}} \cdot \left(1 - \delta \mathbb{I}[N_j^{(r)} \geq 1]\right).$$

- $\hat{y}_j$: el pronóstico del modelo elegido.
- $\epsilon_j^{(r)} = \ln(\text{real}/\text{pronóstico})$: se copian los **12 errores de un mismo origen** del pasado, sorteado al azar. *Por qué en bloque*: los meses flojos vienen juntos (si un año sale bajo, sale bajo varios meses). Sortear cada mes por separado haría los años demasiado parejos y subestimaría el riesgo.
- $N_j^{(r)} \sim \text{Poisson}(\hat{\lambda}_{m(j)})$: las tormentas sorteadas.
- $\delta \in \{0, 0.25, 0.50\}$: cuánto quita una tormenta. **Es un supuesto**: solo hubo 3 meses con tormenta entre los meses que entrenan (Earl 2016, Franklin 2017, Lisa 2022), muy pocos para medirlo. Por eso se prueban tres valores.

Escenarios: malo, probable y bueno = percentiles 10, 50 y 90 de los 10,000 valores de cada mes.

Riesgo de capacidad: $\hat{p}_j = \frac{1}{R} \sum_r \mathbb{I}[D_j^{(r)} > C]$, con C = la capacidad probada (el mes más alto que el lugar ya recibió).

¿Por qué 10,000? Un riesgo estimado con R simulaciones tiene error estándar $\sqrt{p(1-p)/R}$. Con el riesgo de la Ruta en enero ($p = 0.3035$): $\sqrt{0.3035 \times 0.6965/10,000} = 0.0046$, menos de medio punto porcentual. Más simulaciones no cambiarían ninguna decisión.


A mano, con números reales · el mecanismo, Bahía en agosto de 2026

El pronóstico es 879 visitantes. Si un futuro sortea un error de -0.20 y una tormenta con $\delta = 0.5$: $879 \times e^{-0.20} \times 0.5 = 879 \times 0.8187 \times 0.5 = 360$. Si sortea $+0.10$ y no hay tormenta: $879 \times e^{0.10} = 879 \times 1.105 = 971$. Con los 10,000 futuros, los percentiles 10, 50 y 90 son **684 / 930 / 1,202**.

Por qué el probable (930) no es el pronóstico (879): los errores reales de la Bahía tienen sesgo (el modelo se quedó corto 6 % en la mediana), y el Monte Carlo lo hereda. Es más honesto que suponer errores centrados en cero.

Lugar (año)	Malo / probable / bueno, sin golpe	Con golpe de 50 %	Riesgo de capacidad
Ruta del sur	55,811 / 62,212 / 73,884	54,751 / 61,440 / 72,628	30.9 % (cap. 10,465)
Bahía	10,106 / 11,217 / 13,085	9,915 / 11,019 / 12,777	24.2 % (cap. 1,639)
Chetumal (Belice)	551,986 / 620,304 / 671,956	535,346 / 606,138 / 660,162	38.3 % (cap. 65,792)

Lectura para decidir: (1) las tormentas pesan en el mes, no en el año: con el golpe más duro el escenario probable del año baja solo 1–2 %; la reserva para tormentas es por mes (agosto a octubre), no un recorte anual. (2) El riesgo de capacidad está en los meses pico: diciembre de 2026 en Chetumal (29 %) y en la Bahía (14 %), enero de 2027 en la Ruta (30 %). Empujar la campaña en esos meses podría llevar a esos lugares a recibir más de lo que nunca han recibido.

Escenarios sin campaña para los próximos 12 meses

Fuente: Monte Carlo del proyecto (10,000 futuros; percentiles 10, 50 y 90) sobre el pronóstico del modelo elegido. Capacidad probada = el mes más alto que cada lugar ya recibió. En gris: meses con 9 % o más de probabilidad de tormenta (NOAA HURDAT2, 1966–2025). Sin efecto de tormenta en visitantes (supuesto 0 %).

Figura 8.2: Escenarios sin campaña para los próximos 12 meses (notebook 03).

8.5 Sensibilidad: ¿qué variable mueve más?

Se agrega una variable v a la misma regresión, $\ln y_t = \tau_{k(t)} + \mu_{m(t)} + \theta v_t$; el efecto en porcentaje es $e^{\hat{\theta}} - 1$ y el valor p dice qué tan probable sería ver un efecto así de grande si en realidad no hubiera ninguno (por debajo de 0.05 se considera que hay evidencia).

Lugar	+100 mm de lluvia sobre lo normal	+1 peso por dólar
Bahía	− 9.7 % ($p = 0.039$)	−0.2 % ($p = 0.92$)
Ruta	−0.6 % ($p = 0.92$)	+6.8 % ($p = 0.011$)
Chetumal (Belice)	− 4.7 % ($p = 0.031$)	+1.2 % ($p = 0.36$)

A mano, con números reales · lluvia en la Bahía

$\hat{\theta} = -0.1017$: $e^{-0.1017} - 1 = 0.9033 - 1 = -9.7\%$ visitantes por cada 100 mm sobre lo normal.

Son **asociaciones**, no causas probadas. La hipótesis de que un peso barato atrae más cruces desde Belice no se sostiene con estos datos ($p = 0.36$).

Dónde está en el código

pronostico/escenarios.py: poisson_tormentas, errores_por_origen, simular, escenarios, capacidad_probada, sensibilidad. Haversine en base/silver_huracanes.py (km_haversine).

Investigación de Operaciones: repartir el presupuesto

Criterio 6 de la rúbrica (12 %): formula variables de decisión, función objetivo y restricciones; la solución es justificable.

9.1 La pregunta

¿Cuánto dinero de la campaña va a cada lugar del sur, en qué mes y por qué canal, para traer el mayor número de visitantes **sin anunciar donde ya está lleno** y **sin rebasar la capacidad** de nadie? Responde al incidente de investigación de operaciones: qué es “óptimo”, qué priorizar si los objetivos chocan, qué restricciones son indispensables y qué pasa si se cambian.

9.2 Los parámetros: cuánto rinde un peso en cada canal

9.2.1 El embudo de un anuncio

La idea, sin fórmulas

Un anuncio funciona como un embudo: muchas personas lo ven (impresiones), algunas le dan clic, y de esas, algunas planean el viaje (conversión). Se paga por clic. Lo que importa es cuántas conversiones trae cada peso.

$$\begin{aligned} \text{clics} &= \frac{\text{pesos}}{\text{costo por clic}}, & \text{conversiones} &= \text{clics} \times \text{tasa de conversión}, \\ r_c &= \frac{\text{conversiones}}{\text{peso}} = \frac{\text{conversión}_c}{\text{costo por clic}_c (\text{dólares}) \times \text{pesos por dólar}}. \end{aligned}$$

Datos (categoría *Travel*, WordStream 2025; promedios de anunciantes de EE. UU., usados como supuesto etiquetado): Google, clic de \$2.12 dólares y conversión de 5.75 %; Facebook, clic de \$0.51. El dólar es el promedio de agosto de 2026 en FRED: 17.0609 pesos (21 días con dato).

A mano, con números reales · conversiones por peso

Google: $r = \frac{0.0575}{2.12 \times 17.0609} = \frac{0.0575}{36.169} = 0.001590$, es decir, **1.59 visitantes por cada \$1,000**.

Facebook: $r = \frac{0.0575}{0.51 \times 17.0609} = \frac{0.0575}{8.701} = 0.006608$, es decir, **6.61 por cada \$1,000**.

Facebook rinde cuatro veces más por peso porque su clic es cuatro veces más barato (con la misma conversión supuesta).

Hueco declarado: la conversión de Facebook para turismo *no está publicada*. El caso base usa la de Google Travel (5.75 %) y la sensibilidad prueba 3 % y 6.38 % (la mediana de Facebook en todas las industrias). **Supuesto:** cada conversión cuenta como un visitante. Es una cota alta: si llegan menos, la capacidad queda aún más protegida.

9.3 El modelo completo

9.3.1 Conjuntos y variables

- Meses m : de octubre de 2026 a junio de 2027, los 9 que tienen calendario y escenarios para los tres lugares. Después no hay pronóstico, y no se extrapola.
- Lugares l : Chetumal, Bahía, Ruta. Canales c : Google, Facebook.
- Escenarios s : malo, probable y bueno (percentiles 10, 50 y 90 del Monte Carlo), con pesos $p_s = 0.3, 0.4, 0.3$ (regla de Swanson para resumir una distribución con tres percentiles).

Variables de decisión:

- **Etapla 1** (se decide hoy, “aquí y ahora”): $x_{m,l,c} \geq 0$, pesos en el mes m , lugar l , canal c .
- **Etapla 2** (recurso, se decide cuando se ve el escenario): $y_{s,m,l} \in \{0, 1\}$, si el anuncio sigue encendido; $w_{s,m,l} \geq 0$, los visitantes que sí llegan.

Visitantes que trae la campaña: $v_{m,l} = \sum_c r_c x_{m,l,c}$.

9.3.2 Función objetivo

$$\text{máx} \sum_s p_s \sum_{m,l} w_{s,m,l}$$

Los visitantes **esperados**: el promedio, ponderado por la probabilidad de cada escenario, de los visitantes que sí llegan.

9.3.3 Restricciones

$$\sum_{m,l,c} x_{m,l,c} \leq B = 250,000 \times \frac{9}{12} = 187,500 \quad \text{presupuesto (prorratedo)} \quad (9.1)$$

$$x_{m,l,c} = 0 \quad \text{si } (m, l) \text{ es temporada alta} \quad \text{cero anuncio en temporada alta} \quad (9.2)$$

$$D_{m,l}^{p50} + v_{m,l} \leq C_l \quad \text{capacidad probada} \quad (9.3)$$

$$\sum_{m,c} x_{m,l,c} \geq 0.15 B \quad \forall l \quad \text{piso de equidad} \quad (9.4)$$

$$\sum_{m,l} x_{m,l,c} \leq 0.70 B \quad \forall c \quad \text{tope por canal} \quad (9.5)$$

$$D_{s,m,l} + v_{m,l} \leq C_l + M_{s,m,l} (1 - y_{s,m,l}) \quad \text{recurso: pausa si se rebasa} \quad (9.6)$$

$$w_{s,m,l} \leq v_{m,l}, \quad w_{s,m,l} \leq U y_{s,m,l} \quad \text{solo cuenta lo que llega} \quad (9.7)$$

con $U = \max_c r_c \cdot B$ (lo más que podría traer una celda) y $M_{s,m,l} = \max(D_{s,m,l} + U - C_l, 0)$.

9.3.4 Qué significa cada pieza

La “M grande”. La restricción de recurso tiene dos modos. Si el anuncio sigue ($y = 1$), el término $M(1 - y)$ vale 0 y la capacidad debe respetarse en ese escenario. Si se pausa ($y = 0$), el término suma M , que es justo lo necesario para que la restricción ya no obligue; pero entonces $w \leq U \cdot 0 = 0$: esos visitantes se pierden. El valor de M es el más chico que logra eso, porque una M demasiado grande vuelve lento al solucionador.

Por qué “estocástico de dos etapas”. La decisión de hoy (x) se toma sin saber qué escenario va a ocurrir; la reacción (y) depende del escenario. Al maximizar el promedio sobre escenarios, el modelo aprende, desde hoy, a no gastar en meses donde un año bueno llenaría el lugar: ese dinero se perdería con probabilidad $p_{\text{bueno}} = 0.3$. Con tres escenarios, el problema se escribe como un solo modelo grande (el *equivalente determinista*).

9.4 Cómo lo resuelve la computadora

PuLP escribe el modelo y **CBC** lo resuelve. Tiene 54 variables x , 81 binarias y y 81 variables w .

- **Programación lineal y simplex.** Si todas las variables fueran continuas, las restricciones lineales formarían un poliedro convexo, y el óptimo de un objetivo lineal siempre está en una esquina. El método simplex salta de esquina en esquina, mejorando cada vez, hasta que ninguna vecina mejora.
- **Ramificación y acotamiento.** Como y solo puede valer 0 o 1, CBC resuelve primero la versión con y continua (una cota optimista). Si alguna y sale fraccionaria, crea dos subproblemas ($y = 0$ y $y = 1$) y descarta las ramas cuya cota no puede superar la mejor solución entera encontrada.
- Tarda **0.3 segundos**.

9.4.1 Desempate en dos pasos (optimización lexicográfica)

Como todos los lugares convierten igual (no hay dato de respuesta por lugar), hay muchísimas soluciones con el mismo máximo de visitantes. El solucionador entregaba una esquina cualquiera: todo el dinero de cada lugar en un solo mes (los \$131,250 de la Ruta, en junio).

Lo que decidimos

Desempatar **proporcional al espacio libre**. Paso 1: el máximo de visitantes z^* . Paso 2: exigir al menos z^* y, entre esas soluciones, quedarse con la que reparte cada canal en proporción al espacio libre de cada mes:

$$\min \sum_{m,l,c} \left| x_{m,l,c} - \pi_{m,l} \sum_{m',l'} x_{m',l',c} \right|, \quad \pi_{m,l} = \frac{\text{libre}_{m,l}}{\sum_{\text{permitidas}} \text{libre}}, \quad \text{libre} = 1 - \frac{D^{p50}}{C}.$$

Descartados: un tope de 25 % por mes (una regla nueva) y dejarlo concentrado.

Cómo se vuelve lineal el valor absoluto: se agrega una variable $d \geq 0$ con $d \geq x - \text{meta}$ y $d \geq \text{meta} - x$, y se minimiza d . En el óptimo, d es exactamente $|x - \text{meta}|$.

9.5 El resultado, a mano

A mano, con números reales · el máximo de visitantes

Facebook rinde más por peso, así que se lleva su tope (70 %); Google, el resto:

$$z^* = 0.70 \times 187,500 \times 0.006608 + 0.30 \times 187,500 \times 0.001590 = 867.3 + 89.4 = 956.8 \text{ visitantes.}$$

En el embudo: \$131,250 en Facebook compran $131,250/8.70 = 15,084$ clics y $15,084 \times 0.0575 = 867$ visitantes; \$56,250 en Google compran 1,555 clics y 89 visitantes. Unos **\$196 por visitante**.

A mano, con números reales · el reparto proporcional, Ruta en octubre de 2026

Libre = $1 - 3,688/10,465 = 0.6476$. Hay 20 combinaciones de mes y lugar permitidas (las 7 restantes son temporada alta) y sus espacios libres suman 8.0004: $\pi = 0.6476/8.0004 = 0.0809$. Facebook: $0.0809 \times 131,250 = 10,624$ pesos. Google: $0.0809 \times 56,250 = 4,553$ pesos. El código da lo mismo.

Reparto final: Ruta 41.5 % (\$77,790), Bahía 36.9 % (\$69,175), Chetumal 21.6 % (\$40,535). Diciembre sin anuncio en los tres lugares (temporada alta).




Figura 9.1: Reparto del presupuesto por mes y lugar.

9.6 ¿Cuánto cuesta cada regla? Dualidad y precios sombra

9.6.1 Costo de cada regla

Se resuelve el modelo sin la regla y se compara:

Regla	Visitantes que cuesta	%
Cero anuncio en temporada alta	0	0 %
Tope de capacidad probada	0	0 %
Piso de equidad de 15 %	0	0 %
Tope de 70 % por canal	282	29.5 %

9.6.2 Precios sombra

Qué son. Todo programa lineal tiene un problema “dual”. Su solución da, para cada restricción, un **precio sombra** $\lambda_i = \partial z^* / \partial b_i$: cuánto mejoraría el objetivo si la restricción se aflojara una unidad. Se calculan con las y fijas en su solución (para que el modelo sea lineal).

Holgura complementaria: si una restricción no está “apretada” (le sobra holgura), su precio sombra es 0. Por eso los precios sombra explican la tabla de arriba:

- **Presupuesto:** 0.00159 visitantes por peso (1.59 por cada \$1,000). Un peso extra iría a Google, porque Facebook ya está en su tope.
- **Tope de Facebook:** $0.006608 - 0.001590 = 0.005019$ por peso. Cada peso que pasa de Google a Facebook suma 0.005 visitantes. Quitar el tope suma $0.30 \times 187,500 \times 0.005019 = 282.3$, exactamente el costo de la tabla.

- **Equidad:** precio sombra 0. Aunque en la solución del paso 1 el piso de Chetumal queda justo en 15 %, aflojarlo no trae ningún visitante: todos los lugares convierten igual, así que mover un peso de Chetumal a otro lugar no cambia el total. (Es un caso *degenerado*: la restricción está apretada pero no estorba.) En el reparto final, cada lugar recibe más del 15 %.
- **Capacidad:** no estorba. La campaña es chica frente al espacio que hay, y resolver sin esa regla da los mismos 957 visitantes.

9.6.3 Frontera de Pareto: visitantes contra espacio libre

Qué es. Cuando hay dos objetivos que chocan (más visitantes contra menos presión), no hay un solo óptimo: hay una *frontera* de soluciones donde no se puede mejorar uno sin empeorar el otro. Se traza con el método de la ε -restricción: se pide que ningún mes con anuncio pase de ε veces su capacidad en el escenario probable ($D^{p50} + v \leq \varepsilon C$) y se maximizan los visitantes, para varios valores de ε .

ε	100 %	90	80	70	60	50	45	40	35	30
Visitantes	957	957	957	957	957	957	957	957	537	0

Hasta 40 % no se pierde ningún visitante: la campaña puede prometer que ningún mes con anuncio pasará del 40 % de su capacidad probada.




Figura 9.2: Frontera de Pareto.

9.7 Sensibilidad: ¿y si los supuestos están mal?

Si cambia...	Visitantes
Nada (caso base)	957
Conversión de Facebook de 3 %	542
Conversión de Facebook de 6.38 % (mediana de industrias)	1,052
Clic de Facebook a \$0.42 dólares (LocaliQ 2026)	1,143
Golpe de tormenta de 25 % o 50 %	957
Presupuesto de \$500,000 al año	1,914
Presupuesto de \$1,000,000 al año	3,827

Los visitantes son proporcionales al presupuesto porque el modelo es lineal y la capacidad no se alcanza; el reparto entre lugares y canales casi no cambia en ningún caso. La recomendación es estable.

9.8 La etapa 2 en la práctica: el motor de la Torre

Cada semana, para cada lugar, el motor (`envivo/motor.py`) decide: temporada alta (no se gasta), fuera del plan, **pausado** (tormenta cerca, clima raro o llegó más gente de la esperada) o **encendido**. El dinero pausado pasa a la siguiente semana permitida:

$$b = \frac{\text{pesos del mes}}{\text{\#lunes del mes}}, \quad g_w = (b + A_{w-1}) \mathbb{I}[\text{encendido}],$$

$$A_w = \begin{cases} A_{w-1} + b & \text{si se pausa} \\ 0 & \text{si se enciende (se gasta todo)} \\ A_{w-1} & \text{en temporada alta o fuera del plan} \end{cases}$$

A mano, con números reales · el arrastre del dinero

Octubre tiene 4 lunes; con \$4,000 en el mes, $b = \$1,000$. Semana 1 pausada: $A = 1,000$. Semana 2 encendida: se gastan $1,000 + 1,000 = \$2,000$ y $A = 0$.

En las 239 semanas reales: 48 pausas de lugar-semana, todo el dinero pausado se gastó después, y “¿Ibas al norte?” se encendió 6 semanas.

Dónde está en el código

`campana/presupuesto.py`: `benchmarks`, `canales`, `resolver`, `precios_sombra`, `costo_de_regla`, `s, pareto`, `sensibilidad`. Notebook 05_optimizacion.

Si nos preguntan

“¿Qué es lo estocástico de su modelo de optimización?” La segunda etapa: la decisión de pausar depende de cuál de los tres escenarios ocurra, cada uno con su probabilidad, y el objetivo es el valor esperado. *“¿Cuánto cuesta la regla ambiental?”* A este presupuesto, nada: su precio sombra es 0 porque tiene holgura.

Mercadotecnia digital: la campaña

Criterio 7 de la rúbrica (8 %): estrategia integral sustentada en datos; plan mercadológico, branding, buyer persona y medios digitales.

10.1 El marco: segmentar, elegir y posicionar

La campaña sigue el esquema clásico de mercadotecnia **STP**:

1. **Segmentar**: dividir a los visitantes posibles en grupos con datos (de dónde vienen, cuándo viajan, cómo se informan).
2. **Elegir** (*targeting*): a qué grupos hablarles.
3. **Posicionar**: qué lugar quiere ocupar la marca en su mente frente a las alternativas.

La diferencia con una campaña común es que cada paso sale de una cifra, y cada rasgo dice si es dato, cálculo o supuesto.

10.2 Segmentar: lo que dicen los datos

- **Quién visita el sur** (INAH 2025): Oxtankah, 94.8 % nacionales; la Ruta, 63.3 % nacionales y 36.7 % extranjeros.
- **Quién llega al estado en avión** (Unidad de Política Migratoria, 2025): 9,408,423 extranjeros a Cancún; Estados Unidos 56.3 % y Canadá 17.1 %; 53.4 % mujeres; más llegadas en marzo, menos en septiembre.
- **El hallazgo que define todo**: al aeropuerto de Chetumal llegaron **250** extranjeros en 2025. El extranjero no llega al sur por avión: entra por Cancún y baja por carretera, en Tren Maya, desde Belice o en crucero.
- **Cómo se informan** (ENDUTIH 2025, INEGI): 92.1 % de la población de Quintana Roo usa internet (tercer lugar nacional); de quienes tienen teléfono inteligente, 90.6 % usa mensajería y 80.4 % redes sociales.
- **Qué valoran y qué los aleja** (85,987 reseñas, capítulo 6): el ruido (2.76×), la suciedad (1.89×), el precio (1.66×) y las multitudes (1.52×) hundieron una reseña; la calma (0.41×) y la cultura (0.48×) la protegen.

10.3 Elegir: dos viajeras ideales (buyer persona)

Lo que decidimos

Dos personas: “La que vuelve al sur” (nacional) y “La que baja del norte” (Estados Unidos o Canadá, ya en Cancún o la Riviera). Descartadas: solo la nacional (deja fuera al extranjero que ya está a 334 km) y solo la extranjera (la Bahía es 95 % nacional).

Persona	Rasgo	Valor y fuente	Tipo
La que vuelve al sur	Origen	Nacional: 94.8 % de Oxtankah y 63.3 % de la Ruta (INAH 2025)	dato
	Cuándo viaja	De diciembre a abril; la campaña la invita en los meses con espacio (forma del año)	derivado
	Qué valora	Calma (0.41×) y cultura (0.48×) en las reseñas	derivado
	Qué la aleja	Ruido, suciedad, precio y multitudes	derivado
	Cómo se informa	Mensajería 90.6 %, redes 80.4 % (ENDUTIH 2025)	dato
	Estado de origen, edad, ingreso	No hay dato oficial por destino	hueco
La que baja del norte	Origen	De 9,408,423 extranjeros en Cancún: EE. UU. 56.3 %, Canadá 17.1 %	dato
	Sexo	53.4 % mujeres	dato
	Por qué no llega sola	250 extranjeros en el aeropuerto de Chetumal	dato
	Cuándo está	Más en marzo, menos en septiembre; Cancún en temporada alta de noviembre a abril	dato
	Cómo se informa	Busca en Google y usa redes desde el destino	supuesto
	Idioma	Inglés y español	derivado

10.4 Posicionar: la marca

- **Nombre:** “El sur tiene espacio” (“The south has room”). Dice el dato (capacidad ociosa) y la promesa (sin multitudes) a la vez.
- **Lema:** “Pirámides, bahía y sabor del sur, con espacio para disfrutarlos”.
- **Personalidad** (combinamos los tres tonos, porque para nosotros es un orgullo ser mexicanos): cercana y tranquila; orgullosa de lo maya y lo mexicano; con espíritu de aventura.

- **Propuesta de valor:** el Caribe mexicano que todavía tiene espacio: zonas mayas con 15.5 veces menos visitantes que Tulum (INAH 2025), una bahía tranquila y la comida del sur.
- **Posicionamiento:** para quien quiere el Caribe mexicano sin multitudes, el sur de Quintana Roo es la opción cultural y tranquila; a diferencia de Tulum o Cancún, aquí hay espacio, y la campaña lo cuida.
- **Elementos visuales:** el sistema “Sur mexicano” (rosa, amarillo, turquesa y añil en bloques; letras Bricolage y Figtree; greca maya; fotos reales con coordenada comprobada).

10.5 Los mensajes: cada promesa con su dato

Reglas: cada anuncio lleva el dato que lo respalda; **sin precios ni horas de viaje** (no hay dato oficial); el lenguaje sale de las reseñas de 5 estrellas; el largo se revisa contra los límites de cada plataforma (Google: título ≤ 30 caracteres y descripción ≤ 90 ; Meta: título ≤ 40 y texto ≤ 125).

Persona	Canal	Mensaje y respaldo
Vuelve	Google (es)	“Pirámides mayas con espacio”. <i>Respaldo:</i> Tulum 1,031,443 visitantes; Ruta 66,628 (15.5 veces menos).
Vuelve	Facebook (es)	“La bahía que te esperaba”. <i>Respaldo:</i> Oxtankah, 11,017 visitantes en 2025, 94.8 % mexicanos.
Vuelve	WhatsApp	“¿Y si este puente nos vamos al sur?”. <i>Respaldo:</i> 90.6 % usa mensajería; sin costo.
Baja	Google (en)	“Mayan pyramids, with room”. <i>Respaldo:</i> el mismo 15.5; Cancún en temporada alta.
Baja	Facebook (en)	“Your Caribbean trip, one stop south”. <i>Respaldo:</i> Tren Maya con estación en Chetumal; solo se muestra si la Torre marca el norte lleno.

10.6 Los medios y el calendario

Medio	Peso	Justificación con datos
Facebook / Instagram	70 %	6.61 visitantes por cada \$1,000; 80.4 % usa redes. Tope de 70 % para no depender de una plataforma
Google búsqueda	30 %	Llega a quien ya busca viajar; conversión medida de 5.75 % en viajes
WhatsApp (orgánico)	sin costo	90.6 % usa mensajería; el botón de compartir viaja entre familia y amigos
La página	destino	Planeador por lugar y mes en 9 idiomas, sin llamadas a otros sitios

Calendario: los 9 meses del plan (octubre de 2026 a junio de 2027) con el dinero de la Fase 6. “La que baja del norte” se activa solo en los meses en que Cancún está en temporada alta y el sur tiene espacio; además, la Torre la enciende por semana cuando el norte se satura.

10.7 Cómo se mide: los indicadores

El embudo con números (con las tasas de referencia de viajes, y con el reparto de la Fase 6):

A mano, con números reales · impresiones, clics y visitantes esperados

Facebook: $131,250 \text{ pesos} \div 8.70 \text{ pesos por clic} = 15,084 \text{ clics}$. Con una tasa de clics de 2.76 %, eso supone $15,084 / 0.0276 = 546,535 \text{ impresiones}$, y con conversión de 5.75 %, 867 visitantes.

Google: $56,250 \div 36.17 = 1,555 \text{ clics}$; con tasa de clics de 8.73 %, 17,814 impresiones; 89 visitantes.

Son estimaciones con promedios de EE. UU.: las metas reales se fijan con el primer mes de campaña.

Indicador	Fórmula	Meta
Alcance	Personas únicas que vieron un anuncio	Se fija con el primer mes real
Interacción (CTR)	$\text{clics} \div \text{impresiones}$	Google $\geq 8.73 \%$; Facebook $\geq 2.76 \%$
Conversión	$\text{planes de viaje} \div \text{clics}$	$\geq 5.75 \%$
Costo por visitante	$\text{pesos gastados} \div \text{conversiones}$	$\leq \$196$
Afluencia	visitantes reales – escenario probable	+957 en 9 meses
Presupuesto	$\text{pesos gastados} \div \text{pesos planeados}$	100 % (lo pausado se gasta después)
Económico	ocupación hotelera de Chetumal	Hueco: no se publica desde 2025
Social	visitantes por cada mil habitantes (Radar)	Nunca “saturado”
Ambiental	semanas con anuncio en temporada alta o con mal clima	0
Capacidad	$(\text{esperados} + \text{campaña}) \div \text{capacidad probada}$	$\leq 40 \%$ en meses con anuncio

10.8 La regla anti-colapso

El incidente de mercadotecnia pregunta qué hacer si la afluencia rebasa la capacidad. La campaña tiene la respuesta programada, no solo escrita:

1. Nunca anuncia un lugar en su temporada alta (restricción del presupuesto).

2. No permite que los visitantes esperados más los de la campaña pasen de la capacidad probada.
3. La Torre pausa el anuncio si hay tormenta, clima raro o llegó más gente de la esperada.
4. A quien iba al norte lleno le ofrece el lugar del sur con más espacio, nunca otro lugar lleno.

Dónde está en el código

`campana/marca.py` (personas, marca, mensajes, revisar_largos, medios, calendario, kpis) y `campana/texto.py`. Notebook 07_campana.

PARTE III

Cierre

Integración, página y servidor

Criterio 8 de la rúbrica (10 %): articula los seis componentes; los resultados de cada uno alimentan las decisiones de los demás.

11.1 La estafeta, con archivos

Paso	Sale de	Archivo	Lo usa
1	Forma del año y Monte Carlo (Fase 5)	<code>pronostico_calendario, pronostico_escenarios</code>	El presupuesto: temporada alta y capacidad
2	Presupuesto (Fase 6)	<code>presupuesto_plan</code>	La Torre: cuánto gastar cada semana
3	Radar (Fase 4)	cortes p50/p90 de la ocupación semanal	La Torre: cuándo el norte está saturado
4	Torre (Fase 7)	<code>envivo_decisiones</code>	La campaña: indicador ambiental y “¿Ibas al norte?”
5	Campaña (Fase 8)	<code>campana.json</code>	La página y el coloquio

11.2 La página web

La página (<https://catoxp.github.io/torre-del-caribe-unrc-2026/>) es HTML, CSS y JavaScript sin framework, y **funciona sin internet**: no llama a ningún otro sitio. Todas sus cifras salen de un solo archivo generado, `frontend/datos/pagina.js`, que escribe `api/datos_pagina.py` con los datos de Silver y Gold. La parte del viajero (planeador, qué hacer, lugares) está en 10 idiomas; la parte de los datos (Radar, presupuesto, Torre, campaña) va en español.

11.3 El servidor que calcula en vivo (Fase 9)

El plan pedía que el backend *calcule*, no que sirva archivos fijos. El servidor **FastAPI** (`api/servidor.py`) corre en la computadora del proyecto (`127.0.0.1:8000`) y tiene 8 servicios:

- `/api/optimizar`: resuelve en vivo el modelo de la Fase 6 con los supuestos que manda la página. Tarda 0.3 segundos (el plan pedía menos de 2).
- `/api/stream`: transmite la Torre semana a semana (*Server-Sent Events*).
- `/api/consulta`: una consulta SQL de **solo lectura** al almacén DuckDB; rechaza cualquier intento de leer archivos o cambiar datos.
- Además: radar, pronóstico, escenarios, campaña y salud.

Con el servidor, la página muestra “Pruébalo tú” (mover el presupuesto y ver el reparto) y “Escuchar en vivo”. En GitHub Pages la página sigue estática.

11.4 Página final y cierre (Fases 10 y 11)

- **Auditoría de accesibilidad** con axe-core (normas WCAG 2.1, niveles A y AA) en cuatro vistas (computadora y celular, de día y de noche): de 67 fallas a 0. No hubo prueba con personas; lo declaramos.
- **Trazabilidad** (`docs/trazabilidad.md`), **mapa del informe técnico** (`docs/informe/MAPA_INFORME.md`) y **guion del coloquio** de 15 minutos con los cuatro integrantes (`docs/coloquio/GUION_COLOQUIO.md`).
- La carpeta `Entregable/` reúne estas guías, el documento ejecutivo, cuatro notebooks autosuficientes ya ejecutados (con el código del proyecto dentro de sus celdas), los datos limpios y los resultados, y la página.

Lo que no se pudo medir y lo que se supuso

Un proyecto serio dice qué no sabe. Esta lista reúne todo lo que se declaró a lo largo de las fases.

12.1 Huecos (datos que no existen)

Hueco	Por qué no existe	Cómo se trató
Ocupación hotelera del sur 2025–2026	SITUR-Q la publica en ceros	El sur se mide con llegadas reales; la página dice “sin dato oficial”
Estado de origen, edad e ingreso del visitante nacional	No se publica por destino	La persona nacional no los incluye
Conversión de Facebook para turismo	Los estudios no incluyen la categoría	Barrido de tres valores
Tormentas de 2026	HURDAT2 se publica al año siguiente	La Torre dice “sin dato de tormentas” y no pausa por eso
Reseñas de los cinco lugares	Rest-Mex no los cubre	Las reseñas se usan para saber qué molesta en los destinos llenos
Derrama por lugar	La de SITUR-Q no trae unidad y termina en 2024	El objetivo del presupuesto son visitantes, no pesos
Serie de Maya Ka’an y la Laguna	No hay serie mensual propia	Sin pronóstico; en la parte del viajero usamos Cancún y la Riviera como referencia
Prueba con personas	Decisión del equipo	Auditoría automática; lo declaramos

12.2 Supuestos (lo que se dio por cierto)

Supuesto	Dónde	Cómo se protegió
Costos por clic y conversiones de EE. UU.	Presupuesto	Se etiquetan como supuesto y se prueba la sensibilidad
Cada conversión es un visitante	Presupuesto	Es una cota alta: protege la capacidad
Golpe de una tormenta (0, 25 o 50 %)	Monte Carlo	Se prueban los tres valores; el año cambia 1–2 %
Capacidad = el mes más alto ya recibido	Monte Carlo y presupuesto	Se dice que no es la capacidad física oficial
El futuro se parece al pasado	Rango conformal	Se mide la cobertura real; en la Ruta 2023 falló y se dice
La misma matriz de Markov para 7 centros	Radar semanal	Lo declaramos como simplificación
El dato mensual se conoce al mes siguiente	Torre	En la realidad tarda 1–2 meses; lo declaramos
Pesos iguales en el índice	Radar	Sensibilidad: cambia el estado de 0.6–6.0 % de los casos

12.3 Lo que los modelos no pueden afirmar

- Que el clasificador anticipe saturaciones *del sur*: en los cinco lugares casi no hubo cambios con qué probarlo.
- Que el clima *cause* cambios en los visitantes: las sensibilidades son asociaciones.
- El rendimiento real de la campaña: los indicadores tienen metas, pero solo se medirán cuando corra.

Preguntas difíciles y su respuesta

13.1 Sobre el proyecto y los datos

¿Inventaste algún dato?

No. Lo que no existe es hueco; lo estimado lleva `_est`; cada cifra se rastrea hasta su archivo oficial en `docs/trazabilidad.md`, y las pruebas recalculan las cifras de los documentos.

¿Por qué aparece Claude?

Porque usé un asistente de programación con inteligencia artificial. Las decisiones son mías y están documentadas con mis palabras; puedo explicar cada método (capítulo 2).

¿Por qué el sur y no Bacalar o Tulum?

Sargazo récord en la franja de Tulum a Xcalak, crisis de Tulum (-31.3% de visitas en enero-julio de 2026) y la laguna de Bacalar en deterioro. El sur tiene capacidad ociosa: el 12.3% de la población y el 1.4% de los pasajeros de avión.

¿Por qué tantos archivos?

Una pieza por archivo, para probar y explicar cada una por separado; los notebooks narran y usan esas piezas.

¿De verdad necesitabas Spark?

Pandas podría con casi todo. Se usó por la arquitectura que pide la rúbrica, porque el DENU nacional y el clima por hora ya son pesados, y porque el mismo código escala a un clúster.

¿Qué haces si dos fuentes no coinciden?

Una fuente por lugar en toda su historia, declaramos la diferencia, y se revisa en qué sentido va (aquí, conservador).

13.2 Sobre los métodos

¿Por qué no promediaste porcentajes de ocupación?

Porque los meses con pocos cuartos pesarían igual que los grandes; se suman cuartos y luego se divide.

¿Por qué pesos iguales en el índice?

No hay dato que diga qué componente pesa más, y la sensibilidad muestra que el estado cambia en 6% de los casos como máximo con pesos de 0.5 a 1.5 .

¿Por qué validaste con origen móvil y no 80/20 al azar?

Porque en series de tiempo revolver al azar deja que el modelo vea el futuro; el origen móvil

solo usa el pasado, como en la vida real.

¿Tu clasificador sirve?

Le gana a “igual que este mes” por 4 aciertos de 156 y anticipa 8 de 30 cambios. En el sur casi no hubo cambios con qué probarlo, y así lo digo.

¿Por qué no ARIMA o Prophet?

Las series tienen huecos largos y tramos cortos desde las reaperturas; esos métodos necesitan series continuas largas.

¿Qué garantiza el rango del 90 %?

Si los errores futuros se parecen a los pasados, el dato cae dentro al menos 90 de cada 100 veces. Medí la cobertura real: 80–94 %; la Ruta falló en 2023 y lo declaro.

¿Por qué Poisson para las tormentas?

Son eventos raros e independientes en un periodo: es la distribución natural para contarlos.

¿Por qué copias errores de un mismo origen en el Monte Carlo?

Porque los meses flojos vienen juntos; sortear cada mes por separado haría los años demasiado parejos.

¿Qué es el golpe de tormenta de 50 %?

Un supuesto: solo hubo 3 meses con tormenta para medirlo; por eso se prueba con 0, 25 y 50 %.

¿Por qué Isolation Forest?

Detecta lo raro sin que alguien defina “raro”. Lo validé: marcó las 3 semanas de tormenta sin saberlo.

¿Por qué léxico y no LDA en las reseñas?

Porque cada tema se define y se defiende palabra por palabra.

13.3 Sobre la optimización y la campaña

¿Qué es lo estocástico de su modelo de optimización?

La segunda etapa: la pausa depende del escenario, y el objetivo es el valor esperado sobre los escenarios.

¿Qué significa el precio sombra?

Cuánto mejora el objetivo si se afloja una restricción una unidad. El del presupuesto es 1.59 visitantes por cada \$1,000.

¿Cuánto cuesta la regla ambiental?

A este presupuesto, nada. Lo único que cuesta es el tope por canal (29.5 %).

¿Por qué 70 % en Facebook?

Rinde 6.61 visitantes por cada \$1,000 contra 1.59 de Google; sin tope se iría el 100 %.

¿De dónde sale la capacidad?

Es la capacidad probada: el mes más alto que cada lugar ya recibió; no es la capacidad física

oficial.

¿De dónde salen las personas?

INAH (nacional/extranjero), Unidad de Política Migratoria (país, sexo, mes) y ENDUTIH; declaramos los huecos.

¿Qué pasa si la campaña funciona demasiado bien?

La capacidad y la temporada alta son restricciones del modelo, y la Torre pausa cada semana. Además, se puede prometer no pasar del 40 % de la capacidad sin perder visitantes.

¿Probaron la página con personas?

No; lo declaramos. Hicimos una auditoría automática con axe-core: 0 fallas en 4 vistas.

Glosario

Apriori Algoritmo que encuentra combinaciones frecuentes en canastas; usa que lo raro contiene solo cosas raras.

Bronze, Silver, Gold Capas de datos: crudo, limpio, resultados.

Brier Error cuadrático entre una probabilidad y lo que pasó; mide la calidad de las probabilidades.

Cadena de Markov Proceso donde el siguiente estado depende solo del estado actual.

Capacidad probada El mes más alto que un lugar ya recibió.

Clustering (agrupamiento) Juntar elementos parecidos sin etiquetas previas.

Cobertura Porcentaje de veces que el dato real cayó dentro del rango pronosticado.

DataFrame Tabla de datos; en Spark, repartida en particiones.

Dualidad, precio sombra Cuánto mejora el objetivo al aflojar una restricción una unidad.

Evaluación perezosa Spark arma el plan completo antes de ejecutar.

F1 Media armónica de precisión y sensibilidad.

Frontera de Pareto Soluciones donde no se mejora un objetivo sin empeorar otro.

Hueco Dato que no existe; lo declaramos y no lo rellenamos.

Intervalo conformal Rango construido con los errores reales del pasado, con garantía de cobertura.

Isolation Forest Detecta anomalías midiendo qué tan fácil es aislar un dato con cortes al azar.

Lift Cuántas veces más probable es la consecuencia cuando aparece la causa.

Máxima verosimilitud Elegir los parámetros que hacen más probable lo observado.

Monte Carlo Simular muchos futuros posibles para estudiar su distribución.

Origen móvil Validar un pronóstico usando, en cada momento del pasado, solo lo que se sabía entonces.

Parquet Formato de tabla por columnas, comprimido.

Percentil Valor que deja abajo a cierto porcentaje de los datos.

Persistencia El modelo más simple: “igual que este mes”.

Poisson Distribución para contar eventos raros e independientes.

Riesgo relativo Cuántas veces más probable es algo en un grupo que en general.

Softmax Función que convierte puntajes en probabilidades que suman 1.

Spark Structured Streaming Procesar datos conforme llegan, en micro-lotes.

_est, _flag Sufijos de lo estimado y de las banderas de calidad.