

Torre del Caribe

Guía sencilla

Qué hicimos, cómo y por qué, explicado sin tecnicismos y con números reales

Licenciatura en Ciencias de Datos para Negocios · 5° semestre, 2026-2

Problema Prototípico: *Turismo inteligente sustentable para México* (Quintana Roo)

Responsable técnico: **Brandon Uriel García Sánchez**

Equipo: Maribel Mondragón Mercado · Jesús Ramírez Isidro · Enrique González Ortega

Versión del 2 de octubre de 2026

Índice general

Cómo leer esta guía	1
I La idea	3
1. La idea en pocas páginas	4
1.1. El problema: un estado lleno de un lado y vacío del otro	4
1.2. La cifra que lo resume todo	4
1.3. Los cinco lugares de la campaña	5
1.4. La respuesta: una campaña con tres pantallas	5
1.5. Cómo se pasan la información	6
1.6. Cómo se trabajó: 12 fases, una a la vez	6
2. Las preguntas incómodas, primero	8
2.1. ¿Por qué aparece “Claude” en el historial?	8
2.2. ¿Por qué hay tantos archivos de código?	9
2.3. ¿Y los notebooks? ¿Y las pruebas?	10
2.4. ¿Dónde está cada materia (UCA)?	10
3. Los datos: de dónde sale cada número	12
3.1. La regla de oro: no inventar	12
3.2. Las fuentes, una por una	12
3.3. Los huecos: lo que no existe	14
3.4. Cero no es lo mismo que “sin dato”	14
3.5. Cuando dos fuentes no coinciden	15
3.6. Privacidad	15
II Cómo se hizo, paso a paso	16
4. Grandes volúmenes: tres cajas y Spark	17

4.1. El problema	17
4.2. Las tres cajas	17
4.3. La huella digital de cada archivo	18
4.4. Spark: muchas manos al mismo tiempo	18
4.5. Reglas de limpieza que salieron de los datos	19
4.6. El almacén: una biblioteca con fichero	19
4.7. Datos que llegan cada semana: la Torre con Spark Streaming	20
5. Minería: encontrar patrones	21
5.1. ¿Qué tan concentrado está el turismo?	21
5.2. ¿Qué meses se llenan? La forma del año	22
5.3. ¿Qué lugar está más presionado? El índice de presión	23
5.4. ¿A qué se parece el norte en el país? Agrupamiento	24
5.5. ¿Qué semanas tienen clima raro? Isolation Forest	25
5.6. ¿Qué molesta y qué enamora al turista? Las reseñas	25
5.7. ¿Qué recomendar cerca? Clasificar negocios por su nombre	26
6. Aprendizaje de máquina: predecir	27
6.1. Qué significa que una computadora “aprenda”	27
6.2. El Radar: ¿cómo estará el lugar el mes que entra?	27
6.3. El Pronóstico: ¿cuánta gente llegará?	29
7. Procesos estocásticos: las probabilidades	32
7.1. Tormentas: ¿qué tan probable es una cada mes?	32
7.2. ¿Se va a llenar el norte? Cadena de Markov	33
7.3. Monte Carlo: 10,000 años posibles	34
7.4. Lo que estas probabilidades le dicen a la campaña	35
8. Investigación de Operaciones: repartir el dinero	36
8.1. El problema, como una receta	36
8.2. Cuánto rinde un peso en cada red	36
8.3. Las cuatro reglas de cuidado	37
8.4. Lo “estocástico”: decidir hoy sin saber cómo saldrá el año	37

8.5. Cómo lo resuelve la computadora	38
8.6. El resultado	38
8.7. ¿Cuánto cuesta cuidar?	39
8.8. ¿Hasta dónde se puede apretar?	39
8.9. ¿Y si los supuestos están mal?	40
9. La Torre: la campaña semana a semana	41
9.1. La idea	41
9.2. Las cuatro señales	41
9.3. Lo que decidimos	42
9.4. El dinero que no se pierde	42
9.5. Lo que pasó al reproducir 239 semanas reales	42
9.6. Lo que declaramos	43
10. Mercadotecnia: la campaña “El sur tiene espacio”	44
10.1. El método: segmentar, elegir y posicionar	44
10.2. Lo que dicen los datos sobre quién viaja	44
10.3. Las dos viajeras ideales	45
10.4. La marca	45
10.5. Los anuncios: cada promesa con su dato	46
10.6. Los medios y el calendario	46
10.7. Cómo se sabe si funciona: los indicadores	47
10.8. La regla anti-colapso	47
11. La página web: donde todo se junta	48
11.1. Cómo está ordenada	48
11.2. El planeador: la redistribución que se ve	48
11.3. Qué hacer, dónde comer y dónde dormir	49
11.4. Las fotos: todas comprobadas	49
11.5. Día y noche, y 9 idiomas	50
11.6. Una página que calcula	50
11.7. Accesible para todos	50

III Para defenderlo	51
12.Lo que no se sabe y lo que salió mal	52
12.1.Lo que no se pudo medir (huecos)	52
12.2.Los supuestos (y cómo los probamos)	52
12.3.Los límites de los modelos	53
12.4.Los errores que encontramos y corregimos	53
13.Para explicarlo en el coloquio	55
13.1.En un minuto	55
13.2.En cinco minutos: la historia en orden	55
13.3.Si solo se recuerdan cinco cifras	55
13.4.Preguntas probables y respuestas cortas	56
13.5.Palabras que conviene saber explicar	57

Cómo leer esta guía

En esta guía contamos el proyecto **Torre del Caribe** de principio a fin, para cualquier persona que quiera entenderlo: un integrante del equipo, un profesor que pregunta “¿y esto de dónde salió?” o nosotros mismos dentro de un mes, cuando ya no recordemos los detalles. Es la versión **sin fórmulas difíciles** de la *Guía técnica*. Dice lo mismo y con las mismas cifras, pero explica cada paso con palabras de todos los días, con comparaciones y con cuentas que se pueden hacer en una calculadora.

Tres reglas de esta guía

1. **Cada cifra es real.** Todos los números salen de fuentes oficiales (INEGI, SECTUR, el gobierno de Quintana Roo, la NOAA) o de un cálculo del proyecto que se puede repetir. Una prueba automática (`tests/test_guias.py`) revisa que las cifras clave de esta guía sigan coincidiendo con los datos.
2. **Cada paso dice por qué.** No basta con decir “usamos tal cosa”. Siempre explicamos qué otras opciones había y por qué elegimos esa.
3. **Lo que no se sabe, se dice.** Cuando un dato no existe, la guía lo llama *hueco* y no lo rellena.

Las cajas de colores

La idea, sin fórmulas

La idea de cada paso, explicada con una comparación de la vida diaria.

Un ejemplo con números reales

Una cuenta hecha con números reales del proyecto, paso a paso, para ver que no hay magia.

Por qué así y no de otra forma

Las otras opciones que había, y la razón por la que elegimos esta.

Si nos preguntan

Una pregunta que probablemente nos hará un profesor en el coloquio, con nuestra respuesta corta y defendible.

Lo que salió mal y cómo lo corregimos

Algo que salió mal durante el proyecto, cómo lo descubrimos y cómo lo corregimos. Estas cajas son importantes: muestran que revisamos las cifras en lugar de aceptarlas a ciegas.

Cómo está organizada

- **Parte I, La idea** (capítulos 1 a 3): el problema, las preguntas incómodas (¿por qué aparece Claude?, ¿por qué tantos archivos?) y de dónde salen los datos.
- **Parte II, Cómo lo hicimos** (capítulos 4 a 11): una materia por capítulo, en el orden en que los datos viajan por el proyecto: guardarlos, encontrar patrones, predecir, medir la incertidumbre, repartir el dinero, vigilar cada semana, diseñar la campaña y mostrarla en la página.
- **Parte III, Para defenderlo** (capítulos 12 y 13): lo que no pudimos medir, los errores que corregimos y cómo explicar el proyecto en uno y en cinco minutos.

La fórmula exacta de cada tema está en la *Guía técnica*, con el mismo nombre. Qué decidimos, cuándo y entre qué opciones está en *Las decisiones, fase por fase*.

PARTE I

La idea

La idea en pocas páginas

1.1 El problema: un estado lleno de un lado y vacío del otro

Quintana Roo tiene el Caribe más visitado de México, pero los visitantes no se reparten parejo. Casi todos llegan al norte: Cancún, la Riviera Maya y Tulum. El sur, con Chetumal, la bahía, las pirámides en la selva y los pueblos mayas, recibe muy poca gente aunque tiene espacio.

En 2026 el desequilibrio se volvió un problema visible:

- **Sargazo récord:** más de 104,700 toneladas recogidas y 56 de 140 playas del estado en rojo en agosto.
- **Tulum en crisis:** las ventas cayeron hasta 60 % y cerraron negocios. Las visitas a su zona arqueológica bajaron 31.3 % de enero a julio de 2026 contra el mismo periodo de 2025 (INAH).
- **Cozumel saturado por cruceros,** Isla Mujeres con carencias de agua y drenaje, Holbox con basura acumulada.

El *Problema Prototípico* de la UNRC pide justo esto: diseñar una campaña de publicidad basada en datos que atraiga visitantes a un destino **de forma responsable**, que reparta mejor a los turistas y que aproveche el espacio que sobra sin crear una nueva saturación.

1.2 La cifra que lo resume todo

Un ejemplo con números reales · cuánto tiene el sur y cuánto recibe

Los cinco lugares de la campaña tienen:

- el **12.3 %** de la gente del estado (Censo 2020) y el **14.4 %** de sus negocios turísticos (DENUE);
- pero solo el **1.4 %** de los pasajeros de avión, el **1.7 %** de los cuartos de hotel y el **4.1 %** de los visitantes a zonas arqueológicas.

En palabras sencillas: **los negocios siguen a la gente que vive ahí, pero los turistas no.** El sur tiene la infraestructura de una región que podría recibir más visitantes, y no los recibe.

Otra forma de verlo: en 2025, la zona arqueológica de Tulum recibió **1,031,443** visitantes; las tres zonas de la Ruta de las pirámides del sur (Kohunlich, Dzibanché e Ichkabal) recibieron **66,628**.

Tulum recibe **15.5 veces** más gente. Y en Chetumal, en 2024, de cada 10 cuartos de hotel solo se ocuparon unos 6: se usaron 458,696 noches de 791,016 disponibles, el 58.0 %.

1.3 Los cinco lugares de la campaña

Lugar	Qué es y su cifra principal
Chetumal	La capital del estado, frente a la bahía, con el Museo de la Cultura Maya. 169,028 habitantes. En 2024 tuvo 58.0 % de ocupación hotelera: 4 de cada 10 cuartos vacíos. Recibe gente por la frontera con Belice (49,097 cruces en junio de 2026) y por el Tren Maya.
Bahía de Calderitas y Oxtankah	Un pueblo de pescadores a 7.7 km de Chetumal y la zona arqueológica de Oxtankah, la ciudad maya más grande de la bahía. Oxtankah recibió 11,017 visitantes en 2025, el 94.8 % mexicanos.
Ruta de las pirámides	Kohunlich, Dzibanché e Ichkabal, tierra adentro y sin sargazo. 66,628 visitantes en 2025, unas 183 personas al día entre las tres.
Maya Ka'an y Kantemó	Felipe Carrillo Puerto, Tihosuco, Señor, Chunhuhub y Kantemó: turismo comunitario maya, con estación del Tren Maya. 44,388 habitantes.
Laguna Milagros y Xul-Ha	Una laguna dulce cerca de Chetumal, del mismo sistema que Bacalar. Es el lugar con menos datos (ninguna serie turística propia), así que se promueve con límite estricto.

¿Y el norte? Cancún, la Riviera Maya y Tulum **no se promueven**. Aparecen solo como *referencia*: son el punto de comparación (sin ellos no se puede medir que el sur “tiene espacio”) y son de donde viene buena parte del público de la campaña. En la página, Cancún y la Riviera Maya salen en el planeador con la etiqueta “Referencia: la campaña no lo promueve”, y si su mes está lleno, la página recomienda un lugar del sur.

Por qué así y no de otra forma

Al principio elegimos 8 lugares. Después decidimos quitar todo lo que tuviera sargazo, cierres o relación con Tulum, y salieron tres: **Cobá** (está en el municipio de Tulum), **Muyil** (cerrada de junio de 2024 a febrero de 2026 y pegada a Tulum) y **la Ribera del Río Hondo** (ninguna fuente oficial publica sus visitantes). También descartamos Chacchoben (el 92 % de sus visitantes llega en crucero por Mahahual, que tiene sargazo) y Bacalar (su laguna está en deterioro ecológico).

1.4 La respuesta: una campaña con tres pantallas

La propuesta se llama “**El sur tiene espacio**”. Invita a la gente al sur, pero con reglas de cuidado: nunca anuncia un lugar en su temporada alta, se pausa sola si hay mal clima o si llega más gente de la esperada, y a quien iba al norte lleno le ofrece el sur.

Para tomar esas decisiones, el sistema funciona como la torre de control de un aeropuerto, con tres pantallas que responden tres preguntas distintas y nunca se enciman:

Pantalla	Pregunta	Ejemplo de respuesta real
El Radar	¿Dónde hay espacio <i>hoy</i> ?	En julio de 2026 los cinco lugares del sur están tranquilos; Cancún, concurrido.
El Pronóstico	¿Cuándo conviene ir en los próximos 12 meses?	En enero la Ruta recibe 61 % más gente que un mes normal; en septiembre, la mitad. Mejor ir en noviembre.
La Torre	¿Qué hace la campaña <i>esta semana</i> ?	Esta semana pasa una tormenta: el anuncio de ese lugar se pausa y el dinero se guarda para la siguiente semana buena.

La idea, sin fórmulas

Pensemos en un viaje en carretera. El Radar es mirar por la ventana: cómo está el tráfico ahora. El Pronóstico es revisar el calendario de puentes y vacaciones: cuándo va a haber tráfico. La Torre es el copiloto que, en el camino, dice “hay un choque adelante, mejor tomemos otra ruta”.

1.5 Cómo se pasan la información

Las tres pantallas trabajan en cadena:

1. **El Pronóstico arma el plan:** cuántos visitantes se esperan cada mes y en qué meses hay riesgo de llenarse. Con eso se decide cuánto dinero va a cada lugar, cada mes y cada red social.
2. **El Radar dice el estado:** tranquilo, concurrido o saturado, y qué tan probable es que cambie.
3. **La Torre ejecuta:** cada semana compara lo que pasó con lo esperado y, si hace falta, pausa un anuncio o enciende otro.
4. **La campaña** pone el mensaje, el público y el canal de cada anuncio.

1.6 Cómo se trabajó: 12 fases, una a la vez

Hicimos el proyecto en 12 fases (0 a 11). No abríamos una fase sin terminar y revisar la anterior.

Fase	Nombre	Qué hicimos
0	Cimientos	El plan, las reglas y la computadora lista para procesar millones de datos
1	Descarga	353 archivos oficiales, 8,134,802 registros
2	Limpieza	Los datos limpios, ordenados y consultables (56 tablas documentadas)
3	Planteamiento	Elegir y medir los 5 lugares; medir la desigualdad
4	Radar	Índice de presión, estados y predicción del mes siguiente
5	Pronóstico	Visitantes de los próximos 12 meses, tormentas y escenarios
6	Presupuesto	El reparto óptimo del dinero de la campaña
7	Torre en vivo	La campaña semana a semana
8	Campaña	Viajeras ideales, marca, mensajes, medios e indicadores
9	Servidor	La página calcula en vivo con los modelos
10	Página final	Revisión de accesibilidad
11	Cierre	Trazabilidad, mapa del informe y guion del coloquio

Las preguntas incómodas, primero

Antes de explicar los modelos, respondemos las preguntas que un profesor hará al ver la carpeta del proyecto. Son las que más preocupan, y tienen respuestas claras.

2.1 ¿Por qué aparece “Claude” en el historial?

Porque programamos el proyecto con la ayuda de **Claude Code**, un asistente de programación con inteligencia artificial, como herramienta. Por eso muchos cambios guardados en el historial (los *commits* de git) dicen “Co-Authored-By: Claude”.

Cómo trabajamos. Las reglas, las decisiones de fondo y la revisión de los resultados son del equipo. Nos pusimos reglas desde el primer día (no inventar datos, ir fase por fase, explicar cada decisión con una cifra real) y seguimos siempre el mismo método:

1. planteábamos qué había que decidir, con la cifra real que lo motivaba;
2. poníamos sobre la mesa 2 o 3 opciones con sus pros y contras;
3. **elegíamos una;**
4. la decisión quedaba escrita en una nota, con lo que descartamos y por qué.

Hay 25 notas de decisión y más de 40 decisiones registradas. Algunos ejemplos de lo que decidimos:

- enfocarnos en solo 5 lugares y sacar todo lo que tuviera sargazo o relación con Tulum;
- tratar los ceros imposibles como dato faltante y no como cero;
- el criterio para elegir el modelo del Radar: “el que más acierta y más cambios anticipa”;
- repartir el dinero en proporción al espacio libre;
- el corte de “clima raro”, cuando el método automático marcaba casi la mitad de las semanas;
- el nombre y el tono de la campaña, que combina los tres tonos porque para nosotros es un orgullo ser mexicanos.

Y cuando algo salió mal, lo detectamos y lo corregimos: por ejemplo, las fotos de comida no eran de Quintana Roo (eran de Mérida y Campeche) y las retiramos.

Si nos preguntan

“¿Esto lo hicieron ustedes o la IA?” Nuestra respuesta: “Usamos un asistente de programación con IA como herramienta, igual que se usa una calculadora o una librería. Las reglas, las decisiones y la revisión son nuestras y están documentadas con fecha; podemos explicar cada parte y por qué la elegimos.” Conviene decirlo antes de que lo pregunten, y revisar qué dice el profesor o la UNRC sobre el uso de IA.

2.2 ¿Por qué hay tantos archivos de código?

Porque cada archivo hace **una sola cosa**, como los cajones de un taller: en uno están los desarmadores, en otro las llaves. Si algo falla, se sabe en qué cajón buscar, y cada pieza se puede probar sola.

Son **56 archivos** de Python en 7 cajones (carpetas) dentro de `backend/torre/`:

Cajón	Archivos	Qué guarda, con ejemplos
base	23	Descargar los datos oficiales (<code>ingesta_datatur.py</code>), limpiarlos uno por uno por fuente (<code>silver_inah.py</code> , <code>silver_denue.py</code> ...: 12 archivos de limpieza, porque hay 12 fuentes con reglas distintas) y armar el almacén.
radar	7	Medir dónde hay presión: el índice, la predicción, Markov, el agrupamiento.
pronostico	7	La forma del año, los 5 modelos, el rango del 90 %, las tormentas y los escenarios.
campana	9	El reparto del presupuesto, las reseñas, la marca, los lugares para recomendar, las fotos.
envivo	3	La Torre: las señales de cada semana, las reglas y la reproducción con Spark.
api	2	Lo que alimenta la página y el servidor que calcula en vivo.
documento	5	Los PDF, las gráficas, las capturas de la página, la revisión de accesibilidad y la carpeta Entregable.

Por qué así y no de otra forma

Se podía escribir todo en un solo archivo enorme o en un notebook gigante. Se descartó porque un archivo de miles de líneas no se puede revisar ni probar por partes, y un error en un lugar rompe todo lo demás. Con archivos chicos, cada uno tiene un encabezado que dice: quién lo escribió, qué hace, por qué así, de qué datos sale y **a qué decisión de la campaña alimenta**. Si un archivo no podía decir a qué decisión alimenta, no se escribía.

2.3 ¿Y los notebooks? ¿Y las pruebas?

Los **notebooks** (6) cuentan la historia paso a paso, con texto, tablas y gráficas. No repiten el código: llaman a las funciones de los cajones. Es como un libro de recetas que dice “usa la batidora” en lugar de explicar cómo se fabrica una batidora.

Notebook	Qué cuenta
01_planteamiento	Variables, actores y la desigualdad entre norte y sur
02_radar	El índice de presión, los estados y la predicción
03_pronostico	La forma del año, los modelos, las tormentas y los escenarios
05_optimizacion	El reparto del presupuesto
06_torre_en_vivo	La campaña semana a semana
07_campana	Las reseñas, las viajeras ideales y la marca

(No hay notebook 04 porque los escenarios quedaron dentro del 03.)

Lo que se entrega a los profesores es más sencillo: la carpeta `Entregable` junta esos seis en **cuatro notebooks** que funcionan solos, sin archivos `.py`:

Notebook de la entrega	Materias
1. Datos y arquitectura	Grandes volúmenes de datos
2. Dónde y cuándo	Planteamiento, minería, aprendizaje de máquina y estocásticos
3. Presupuesto y Torre en vivo	Investigación de Operaciones y Spark Streaming
4. Campaña	Mercadotecnia digital y minería de texto

Cada uno trae dentro el código que usa: las celdas que empiezan con `%%modulo` son los “cajones” del proyecto, copiados completos. Así se puede leer todo en un solo lugar y las cifras salen idénticas.

Las **pruebas** (279) son pequeños programas que revisan solos que todo siga correcto. Hay dos tipos:

- de **forma**: que una tabla tenga las columnas que debe, que no haya renglones repetidos;
- de **realidad**: que una cifra conocida salga igual. Por ejemplo, que la zona de Tulum tenga 1,031,443 visitantes en 2025, o que la ocupación de Bacalar en enero de 2024 sea 66.5 %.

Si alguien vuelve a descargar los datos y una cifra cambia, la prueba falla y avisa. Se corren con un comando: `.venv\Scripts\python -m pytest tests`.

2.4 ¿Dónde está cada materia (UCA)?

El proyecto integra las seis materias del semestre. Ninguna está aislada: el resultado de una alimenta a la siguiente.

Materia	Qué hicimos, en una frase	Dónde está
Grandes volúmenes de datos	Se juntaron 8.1 millones de registros oficiales en tres cajas (bronce, plata y oro) y se limpiaron con Spark; la Torre reproduce 239 semanas con Spark Streaming.	base/, envivo/torre.py · capítulo 4
Minería de datos	Se encontraron patrones: qué tan concentrado está el turismo, qué meses se llenan, qué semanas tienen clima raro y qué molesta a los turistas en sus reseñas.	radar/indice.py, pronostico/forma.py, campana/texto.py · capítulo 5
Aprendizaje de máquina	Modelos que predicen el estado del mes siguiente y los visitantes de los próximos 12 meses, comparados contra reglas simples.	radar/prediccion.py, pronostico/modelos.p y · capítulo 6
Procesos estocásticos	Probabilidades: de tormenta cada mes, de que el norte se sature y 10,000 años simulados para los escenarios.	radar/markov.py, pron ostico/escenarios.py · capítulo 7
Investigación de Operaciones	Un modelo matemático que reparte el dinero de la campaña de la mejor forma posible respetando reglas de cuidado.	campana/presupuesto. py · capítulo 8
Mercadotecnia digital	Las viajeras ideales, la marca, los anuncios, los medios y cómo se mide si la campaña funciona.	campana/marca.py · capítulo 10

Los datos: de dónde sale cada número

3.1 La regla de oro: no inventar

Todo sale de **fuentes oficiales o abiertas**, descargadas **con programas** (no a mano) y guardadas sin tocar. Si un dato no existe, **no se inventa, no se rellena con un promedio y no se “simula para probar”**: se dice “sin dato” y se explica por qué.

Por qué así y no de otra forma

Descargar a mano desde una página (copiar y pegar, o “exportar a Excel”) es más rápido la primera vez, pero no se puede repetir ni comprobar. Con un programa, cualquiera puede volver a descargar todo con un comando y obtener lo mismo. Además, el programa anota de dónde vino cada archivo, cuándo y cuántos registros tiene.

También hay una regla de lo que **no** se usa: nada copiado de Google Maps ni de TripAdvisor, porque sus términos de uso prohíben extraer sus datos con programas.

3.2 Las fuentes, una por una

Se descargaron **353 archivos con 8,134,802 registros** (824 MB). Estas son las fuentes, de la más grande a la más chica:

Fuente (quién la publica)	Registros	Qué es y para qué se usó
DENUE (INEGI)	6,138,075	Todos los negocios del país, con su giro y su ubicación. Para saber cuántos hoteles, restaurantes y museos hay en cada lugar, y qué recomendar en la página.
Clima (Open-Meteo)	767,016	El clima de cada día desde 1950 y de cada hora desde 2019, en 8 puntos. Para ver si la lluvia aleja visitantes y detectar semanas de clima raro.
Nacionalidades (SECTUR)	521,364	Cuántos extranjeros llegan en avión a cada aeropuerto y de qué país. Para conocer a la viajera extranjera.
Compendio 2024 (SECTUR)	295,191	Estadísticas generales del turismo; de aquí salen las estrellas oficiales de los hoteles.
Rest-Mex 2025 (concurso académico)	208,051	Opiniones de turistas con su calificación de 1 a 5. Para saber qué molesta y qué enamora.
INAH (SECTUR)	71,562	Visitantes por mes a cada zona arqueológica y museo. La serie más importante del sur.
Huracanes HURDAT2 (NOAA)	57,512	La trayectoria de todas las tormentas del Atlántico desde 1851.
Ocupación hotelera (SECTUR)	34,164	La ocupación de cada semana de 7 centros del norte. La única ocupación medida en 2025–2026.
Vuelos AFAC	19,578	Pasajeros nacionales por aerolínea.
Tipo de cambio (FRED)	9,531	Pesos por dólar cada día, y la inflación de Estados Unidos.
SITUR-Q (gobierno del estado)	6,607	Tren Maya, cruces desde Belice, cruceros, cuartos de hotel y ocupación hasta 2024.
Cruceros (SECTUR)	3,897	Pasajeros de crucero por puerto.
Censo 2020 (INEGI)	2,243	La población de cada pueblo de Quintana Roo.
Uso de internet ENDUTIH (INEGI)	PDF	Cuánta gente usa redes y mensajería.
Mapa del estado (GeoJSON)	11	Los 11 municipios, para comprobar que cada lugar y cada foto están donde dicen.

Además: los **costos de anuncios** de Google y Facebook (WordStream y LocaliQ, guardados con captura de pantalla como evidencia) y las **fotos** de Wikimedia Commons, con licencia libre y crédito a su autor.

Lo que salió mal y cómo lo corregimos

El conteo del DENUE estaba inflado. La primera cuenta decía 6,139,989 negocios. Al limpiarlos, Spark contó 6,138,075, y un segundo programa independiente le dio la razón. La diferencia era de 1,914: cada uno de los 33 archivos comprimidos del DENUE trae, además de los negocios, un diccionario de datos de 58 renglones, y el conteo los sumaba como si fueran negocios ($33 \times 58 = 1,914$). Se corrigió el programa y los documentos. Con el Censo pasó lo mismo: decía 2,257 pueblos y son 2,243.

3.3 Los huecos: lo que no existe

El hallazgo más importante de la descarga fue un hueco: **el gobierno del estado dejó de publicar la ocupación hotelera en 2025, para todos los destinos**, incluso Cancún. Para 2025 y 2026 la única ocupación medida es la semanal de SECTUR, y solo para 7 centros del norte.

Consecuencia: la ocupación del sur en 2025–2026 se muestra como “sin dato oficial”. No se calcula con un modelo, porque sería poner una cifra inventada donde nadie midió. En su lugar, el sur se mide con lo que *sí* llega hasta 2026: la gente que baja del Tren Maya, los cruces desde Belice y los visitantes a las zonas arqueológicas.

Otros huecos declarados:

- De qué estado del país viene el turista mexicano, su edad y su ingreso.
- Cuánta gente compra un viaje después de ver un anuncio de turismo en Facebook.
- Reseñas de los cinco lugares: Rest-Mex solo trae Tulum, Isla Mujeres y Bacalar.
- Las tormentas de 2026 (la NOAA todavía no las publica).
- Visitantes de Maya Ka'an y de la Laguna Milagros: ninguna fuente los cuenta.

3.4 Cero no es lo mismo que “sin dato”

Un ejemplo con números reales · los aeropuertos en 2025

En los datos del gobierno, los cuatro aeropuertos del estado (Cancún, Cozumel, Chetumal y Tulum) dicen “0 pasajeros” todos los meses de 2025. Si se tomara como cero, la página diría “nadie llegó en avión en 2025”. Pero ese mismo año la ocupación semanal de Cancún promedió 72.2 %: es imposible que nadie haya volado. Lo que pasó es que **dejaron de publicar**.

Regla: si en un mes *todos* los aeropuertos marcan cero, ese mes es hueco. Si al menos uno trae dato, los ceros se respetan (podría ser un aeropuerto cerrado de verdad). Con esta regla, 114 renglones pasaron a ser hueco, y la página usa 2024 como último año completo del avión, y lo dice.

Lo mismo con otras cosas: una ocupación con 0 cuartos disponibles es imposible (hueco); en cambio, una zona arqueológica con 0 visitantes *sí* puede ser real, porque estaba cerrada, y se conserva marcada.

3.5 Cuando dos fuentes no coinciden

Un ejemplo con números reales · Isla Mujeres

Las noticias de 2026 decían que Isla Mujeres estaba al 93.5 % y al 95 % de ocupación. La fuente oficial (SECTUR) registra **74.7 %** en febrero y **43.2 %** en abril. Además, SECTUR y el gobierno del estado no miden igual: en Isla Mujeres hay 19.3 puntos de diferencia en promedio.

Reglas que fijamos:

1. El dato oficial va antes que la nota de prensa.
2. Cada lugar usa **una sola fuente** en toda su historia, y declaramos la diferencia con la otra. Así un cambio en el tiempo es real y no un salto entre fuentes.

Con los cruceros pasa algo parecido: en Mahahual, el gobierno del estado cuenta siempre entre 11 % y 35 % más cruceristas que SECTUR. Usamos una y declaramos la diferencia.

3.6 Privacidad

No se guarda ningún dato personal. Del DENUÉ se quitan la razón social, el teléfono y el correo de cada negocio, porque ningún modelo los necesita. Las reseñas de Rest-Mex no traen nombres, y las llegadas de extranjeros vienen sumadas por país, no por persona.

PARTE II

Cómo se hizo, paso a paso

Grandes volúmenes: tres cajas y Spark

Materia: Grandes volúmenes de datos. Pregunta: ¿cómo se guardan, se limpian y se juntan millones de datos de fuentes que no se parecen entre sí?

4.1 El problema

Las fuentes llegan en formatos distintos: archivos Excel con notas al pie (SECTUR), archivos de texto con un formato propio (las tormentas de la NOAA), respuestas de una página web (SITUR-Q), CSV comprimidos con acentos raros (el DENUÉ). Algunas son historia (el Censo de 2020) y otras cambian cada semana (la ocupación). Hay que juntarlas sin perder nada y sin mezclar lo crudo con lo limpio.

4.2 Las tres cajas

La idea, sin fórmulas

Es como el agua que pasa por un filtro de tres etapas. La primera caja guarda el agua tal como llegó del río; la segunda, el agua filtrada; la tercera, el agua lista para servir. Si algo sale mal en el filtro, siempre se puede volver al agua original.

1. **Caja de bronce** (datos/bronze/): los 353 archivos tal como llegaron. **Nunca se tocan.**
2. **Caja de plata** (datos/silver/): los datos limpios, con nombres de columna en español, tipos correctos y marcas de calidad. Hay un archivo de limpieza por fuente (12), porque cada una tiene sus propias trampas.
3. **Caja de oro** (datos/gold/): lo que usan los modelos y la página: la tabla central de hechos y los resultados de cada fase.

Por qué así y no de otra forma

Si se limpiara al descargar, el original se perdería, y si la regla de limpieza estaba mal, no habría forma de rehacerla. Con tres cajas, cualquier limpieza se puede repetir desde cero. Esta forma de organizar se llama *arquitectura medallón* y es la que usan las empresas que manejan muchos datos.

4.3 La huella digital de cada archivo

Cada archivo de la caja de bronce tiene una **huella** (SHA-256): un código de 64 letras y números que se calcula con su contenido. Si alguien cambia una sola coma del archivo, la huella cambia por completo. Una prueba automática recalcula las 353 huellas y avisa si alguna no coincide. Así se demuestra que los datos crudos son los mismos que se descargaron.

Todo queda anotado en un **manifiesto** (`datos/bronze/MANIFIESTO.csv`): el nombre del archivo, su huella, su tamaño, de qué dirección vino, cuándo se bajó y cuántos registros tiene.

4.4 Spark: muchas manos al mismo tiempo

La idea, sin fórmulas

Revisar 6.1 millones de negocios es como calificar 6.1 millones de exámenes. Una persona sola tardaría muchísimo. Doce personas, cada una con un montón, terminan mucho antes. Spark hace eso: parte la tabla en montones (*particiones*) y pone a trabajar a todos los núcleos de la computadora a la vez.

Cinco ideas de Spark que conviene poder explicar:

1. **Un jefe y varios trabajadores.** Un programa planea el trabajo y los trabajadores lo hacen. Aquí todo corre en una sola computadora, con sus 12 núcleos. Es el mismo programa que correría en un centro de datos con cientos de computadoras: solo cambia la dirección del jefe.
2. **Tablas repartidas.** Cada pedazo de la tabla lo procesa un núcleo distinto.
3. **Primero el plan, luego el trabajo.** Spark no ejecuta cada instrucción en cuanto se escribe: arma el plan completo y lo optimiza. Por ejemplo, si al final solo se necesitan 10 columnas, no lee las otras.
4. **Juntar lo repartido cuesta.** Quitar negocios repetidos obliga a juntar en el mismo núcleo todos los renglones con la misma clave. Es la parte más cara y por eso se hace una sola vez.
5. **Parquet por carpetas.** Spark guarda cada tabla en formato Parquet, que se lee por columnas y viene comprimido, y la reparte en carpetas (por ejemplo, una por estado). Para leer solo Quintana Roo no hace falta abrir los otros 31 estados.

Un ejemplo con números reales · el DENUE completo

Spark leyó los 33 archivos del DENUE (el Estado de México viene en dos partes) en cerca de un minuto y medio y:

- contó 6,138,075 negocios, con 0 repetidos y 0 coordenadas fuera de México;

- quitó la razón social, el teléfono y el correo;
- marcó cuáles son turísticos según su giro oficial (hoteles, restaurantes, agencias de viajes, transporte turístico, museos y esparcimiento): 875,667 en el país, **13,663 en Quintana Roo**.

Si nos preguntan

“¿Para qué Spark si cabe en su computadora?” Porque el incidente de Big Data pide una arquitectura que siga funcionando cuando los datos *no* quepan. El código de Spark es el mismo para 6 millones que para 600 millones de registros: solo se agregan computadoras. Además, el DENU nacional (574 MB comprimido) ya es pesado para leerlo de golpe con herramientas comunes.

4.5 Reglas de limpieza que salieron de los datos

Cada regla se comprobó con números antes de aplicarla:

- **Tren Maya:** algunos destinos traen dos renglones por mes (uno por estación) y **se suman**. Se comprobó que la suma cuadra exacto con el total que publica el gobierno. En enero de 2025: Chetumal ($24 + 3,478$) + Bacalar ($213 + 3,369$) = 7,084, igual que el total de la zona.
- **Ceros imposibles = hueco** (capítulo anterior).
- **Una versión por periodo:** SECTUR corrige sus cifras preliminares, y un mismo periodo aparece en varios archivos. Gana el más reciente. Hubo 2,804 cifras semanales corregidas.
- **Repetidos:** el INAH traía repetido el bloque de extranjeros de septiembre de 2025, una copia con cifras y otra en ceros. Se conserva la de cifras. Si algún día aparecen dos cifras distintas para lo mismo, el programa se detiene en lugar de escoger una.
- **Feriados sin tipo de cambio:** se quedan vacíos. Copiar el día anterior inventaría una cotización que no existió.

4.6 El almacén: una biblioteca con fichero

Al final, todo se puede consultar en **DuckDB**, una base de datos que vive en un solo archivo (datos/gold/torre.duckdb). Lee las tablas de las cajas de plata y oro sin copiarlas y responde en milisegundos, sin servidor y sin internet.

La tabla central (*hechos*) tiene un renglón por lugar, mes y variable, con su fuente: 3,287 renglones de 15 lugares y 192 meses. **Un hueco no tiene renglón**; nunca se rellena con cero. A los lados están las tablas de lugares y de fechas. Esta forma se llama *modelo estrella*: la tabla de hechos en el centro y las descripciones alrededor.

Además se genera solo un **diccionario de datos** de 56 tablas: cada columna con su tipo, su porcentaje de vacíos, un ejemplo real y su significado. Si una columna no tiene significado escrito, el programa se detiene.

4.7 Datos que llegan cada semana: la Torre con Spark Streaming

El incidente de Big Data pide una arquitectura de **baja latencia**: que la campaña se ajuste *mientras* corre. Para eso, la Torre usa **Spark Structured Streaming**, la parte de Spark que procesa datos conforme van llegando.

La idea, sin fórmulas

Es como ver una película cuadro por cuadro. Cada semana real (de enero de 2022 a julio de 2026) se guarda como un archivo, y Spark los lee de uno en uno, en orden, como si fueran llegando. En cada uno decide si pausa un anuncio.

Se reprodujeron **239 semanas en 239 lotes**, en orden. Spark anota en una bitácora (*checkpoint*) cuál fue el último archivo leído: si el proceso se cae, sigue donde se quedó sin repetir ni saltarse semanas. Y si mañana llegara una fuente semanal real del sur, se cambia la carpeta y las reglas siguen igual.

Minería: encontrar patrones

Materia: Minería de datos. Pregunta: ¿qué patrones de tiempo, de lugar y de comportamiento explican dónde se concentra la gente?

La minería de datos busca lo que no se ve a simple vista. En este proyecto buscamos seis patrones; cada uno alimenta una decisión de la campaña.

5.1 ¿Qué tan concentrado está el turismo?

La idea, sin fórmulas

Imaginemos un pastel repartido entre varias personas. Si una se lleva casi todo, el reparto está concentrado. Hay un número, el **índice de Herfindahl-Hirschman**, que resume qué tan desigual es el reparto: vale 0 si todos reciben lo mismo y 1 si uno se lleva todo. Es el que usan las autoridades de competencia para ver si un mercado está acaparado.

Un ejemplo con números reales · los pasajeros de avión en 2024

De 15,959,277 pasajeros que llegaron en avión al estado, Cancún recibió 14,769,302: el **92.5 %**. Tulum, 3.9 %; Cozumel, 2.2 %; Chetumal, 1.4 %.

El índice eleva al cuadrado la parte de cada aeropuerto y las suma: $0.9254^2 + 0.0389^2 + 0.0221^2 + 0.0136^2 = 0.8586$. Con cuatro aeropuertos, lo más parejo posible sería que cada uno tuviera la cuarta parte, y el índice valdría 0.25. Se ajusta para que ese caso valga 0:

$$\frac{0.8586 - 0.25}{1 - 0.25} = \frac{0.6086}{0.75} = \mathbf{0.811}.$$

Un 0.811 en una escala de 0 a 1: casi todo entra por una sola puerta.

Qué se mide	Concentración (0 a 1)	Parte de los 5 lugares
Pasajeros de avión (2024)	0.811	1.4 %
Cuartos de hotel (julio de 2026)	0.219	1.7 %
Visitantes a zonas arqueológicas (2025)	0.276	4.1 %
Negocios turísticos (DENUE)	0.133	14.4 %
Población (Censo 2020)	0.225	12.3 %

Lectura: los negocios están donde vive la gente (14.4 % contra 12.3 %), pero los visitantes no

(entre 1.4 % y 4.1 %). **Para la campaña:** el sur tiene capacidad ociosa; promoverlo no crea una saturación nueva, aprovecha lo que ya existe.

5.2 ¿Qué meses se llenan? La forma del año

La idea, sin fórmulas

Para saber si enero es un mes “alto”, se compara enero con el promedio de su propio año. Si un año tuvo 5,000 visitantes al mes en promedio y enero tuvo 8,000, enero fue 1.6 veces un mes normal. Se hace lo mismo con varios años y se promedia. El resultado es la **forma del año**: un número por mes, donde 1 es un mes normal.

Un ejemplo con números reales · enero en la Ruta de las pirámides

En 2019, Kohunlich y Dzibanché recibieron 64,139 visitantes: $64,139 \div 12 = 5,344.9$ al mes en promedio. En enero llegaron 7,935: $7,935 \div 5,344.9 = 1.48$. Enero de 2019 fue 1.48 veces un mes normal.

Con los seis años completos que hay (2016 a 2019, 2022 y 2023), las razones de enero fueron 1.55, 1.71, 1.83, 1.48, 1.25 y 1.82. Su promedio es **1.606**: en enero llega **61 % más** gente que en un mes promedio. En septiembre, el número es 0.496: **la mitad**.

Lugar	Mes más lleno	Mes más vacío
Ruta de las pirámides	enero (1.61)	septiembre (0.50)
Bahía Calderitas–Oxtankah	diciembre (1.40)	septiembre (0.65)
Chetumal (cruces de Belice)	diciembre (1.17)	febrero (0.87)
Cancún (referencia)	marzo (1.08)	septiembre (0.87)

Qué tanto pesa la temporada: en la Ruta, el 79 % de lo que sube y baja un mes a otro se explica por la temporada; el resto es azar. Es una temporada fuerte y predecible.

Dos hallazgos: (1) las zonas del sur suben y bajan al mismo tiempo que Cancún, pero Chetumal con Belice no; (2) septiembre es el mes más vacío casi en todos lados y coincide con el pico de tormentas.

Por qué así y no de otra forma

Multiplicar en lugar de sumar. Se podía decir “enero tiene 2,000 visitantes más” o “enero tiene 61 % más”. Kohunlich reabrió en 2025 con la mitad de la gente que tenía en 2019: “2,000 más” ya no tiene sentido, pero “61 % más” sí. Por eso la forma del año se calcula en proporciones.

Solo años completos. El método más conocido (STL) necesita una serie sin huecos, y estas los tienen: la pandemia y los cierres por obras. Con STL se habrían tirado años enteros. Se

usó como segunda opinión donde sí se puede, y coincide entre 85 % y 97 %.

Para la campaña: no se anuncia un lugar en sus meses más llenos y se empuja en sus meses con espacio.

5.3 ¿Qué lugar está más presionado? El índice de presión

Cada lugar se mide con cosas distintas: Chetumal tiene Tren Maya, la Ruta tiene visitantes a sus zonas, Cancún tiene ocupación hotelera. Para compararlos se necesita una sola escala.

La idea, sin fórmulas

Es como calificar a alumnos de grupos distintos con exámenes distintos. Primero se pasa cada examen a una escala de 0 a 1 (0 = la calificación más baja de todo el estado, 1 = la más alta) y luego se promedian los exámenes que presentó cada alumno. Así sale el **índice de presión turística**: 0 es lo más tranquilo y 1 lo más presionado que se ha visto en el estado.

Un ejemplo con números reales · Cancún, julio de 2026

Cancún tiene cuatro medidas ese mes. Cada una se pasa a la escala de 0 a 1 dividiendo lo que tuvo entre el rango de todo el estado:

- Ocupación hotelera: tuvo 68.78 %; en el estado va de 17.97 % a 88.40 %. Escala: $(68.78 - 17.97) \div (88.40 - 17.97) = 50.81 \div 70.43 = 0.721$.
- Gente que bajó del Tren Maya por cada mil habitantes: 25.1; el máximo del estado es 505.2. Escala: 0.050.
- Visitantes a sus zonas arqueológicas por cada mil habitantes: casi nada frente al máximo. Escala: 0.0001.
- Llegadas por cuarto de hotel: 0.47 frente a un máximo de 432. Escala: 0.001.

Promedio: $(0.721 + 0.050 + 0.0001 + 0.001) \div 4 = 0.772 \div 4 = \mathbf{0.193}$.

Después se ordenan todos los lugares y meses del estado y se ponen dos cortes: la mitad más baja es **tranquilo**, el 10 % más alto es **saturado** y lo de en medio es **concurrido**. Con los cortes del índice que publica el Radar (0.186 y 0.756), Cancún, con 0.193, queda **concurrido** en julio de 2026.

Julio de 2026: los cinco lugares de la campaña están **tranquilos** (la Ruta con 0.129, Chetumal 0.025, Oxtankah 0.020 y Maya Ka'an 0.009). Están concurridos Mahahual (0.731, por los cruces), Isla Mujeres, Bacalar, Holbox, Cancún y Cozumel. La Laguna Milagros no tiene ninguna medida: sale "sin dato oficial", nunca "tranquila".

Por qué así y no de otra forma

Pesos iguales. Ninguna fuente dice que el tren pese más que los cruceros. Unos pesos inventados serían difíciles de defender. Para comprobar que no cambia el resultado, se movió cada peso a la mitad y al 150 %: el estado cambia en 6 % de los casos como máximo.

Cortes comunes para todo el estado. Si cada lugar se comparara solo contra sí mismo, todos saldrían “saturados” una parte del tiempo, aunque nunca se llenen. Con la misma vara, el norte y el sur se pueden comparar.

Lo que salió mal y cómo lo corregimos

El índice que decía que Cancún estaba tranquilo. La primera versión usaba solo los datos del gobierno del estado. Como el estado dejó de publicar la ocupación en 2025, Cancún se quedó solo con medidas casi en cero y salió “tranquilo” en julio de 2026, con 0.025. SECTUR decía que ese mes tenía 68.8 % de ocupación. Un índice que dice que Cancún está tranquilo en julio no sirve. Comparamos cuatro arreglos con datos y elegimos el que usa la ocupación de SECTUR para los cuatro lugares del norte que mide, y deja fuera las medidas que solo tiene un lugar (como Belice, que solo tiene Chetumal y se comparaba contra sí mismo).

5.4 ¿A qué se parece el norte en el país? Agrupamiento

Cada centro turístico del país tiene una “huella” de 12 números: qué tan lleno está cada mes del año. Un método de **agrupamiento** (el de Ward) junta los centros con huellas parecidas: empieza con cada centro solo y va uniendo los más parecidos, de dos en dos, como un árbol genealógico al revés.

¿Cuántos grupos? Se mide qué tan bien acomodado está cada centro en su grupo (la *silueta*: de -1, mal acomodado, a 1, perfecto) y se eligen los grupos con el mejor promedio. Con 55 centros, lo mejor fueron **2 grupos** (silueta 0.450):

- **Grupo 1**, playas muy llenas (64.5 % de ocupación en promedio): Cancún, Riviera Maya, Playacar, Akumal, Playa del Carmen, Los Cabos.
- **Grupo 2**, el resto del país (41.1 %), incluidos Cozumel e Isla Mujeres.

Para la campaña: la saturación del norte no es una impresión; está entre los destinos más llenos de México.

5.5 ¿Qué semanas tienen clima raro? Isolation Forest

La idea, sin fórmulas

Imaginemos puntos en una hoja que separamos con cortes de tijera al azar. Un punto que está lejos de todos queda solo con muy pocos cortes; uno en medio de la multitud necesita muchísimos. **Isolation Forest** hace eso con 300 “árboles” de cortes al azar y mide cuántos cortes tarda en aislar cada semana. Las semanas raras se aíslan rápido.

Cada semana se describe con su lluvia, la lluvia del peor día, el viento, el calor y la época del año (para que un aguacero de septiembre no salga raro solo por ser septiembre). El método da un puntaje de 0 a 1: cerca de 0.5 es normal; cerca de 1, muy raro.

Un ejemplo con números reales · Chetumal, semana de la tormenta Nadine (octubre de 2024)

Llovieron 148.7 mm en la semana, 65.4 mm el peor día. El bosque tardó unos 5 cortes en aislarla, cuando una semana normal tarda unos 10. Su puntaje fue **0.712**; el corte para “raro” era 0.543. Como $0.712 > 0.543$, la semana es rara.

La prueba de que funciona: el bosque marcó como raras las tres semanas en que pasaron tormentas (Lisa en 2022, Nadine y Sara en 2024) **sin saber que hubo tormenta**. Nadie se lo dijo.

Para la campaña: una semana rara pausa el anuncio de ese lugar (capítulo 9).

5.6 ¿Qué molesta y qué enamora al turista? Las reseñas

Se analizaron **85,987 opiniones** de turistas en Quintana Roo (Tulum, Isla Mujeres y Bacalar; ninguna de los cinco lugares, así que sirven para saber qué molesta en los lugares llenos, no para opinar del sur).

Temas con una lista de palabras a la vista. Cada tema es una lista de palabras que se puede leer: “ruido” incluye *ruido, escándalo, música alta, fiesta*; “calma” incluye *tranquilo, paz, relajado, silencio*. Se eligió así, y no con un modelo automático de temas, porque cada tema se puede defender palabra por palabra.

Un ejemplo con números reales · el ruido

De las 85,987 reseñas, 3,597 son malas (1 o 2 estrellas): $3,597 \div 85,987 = 4.18\%$.

De las 2,038 que hablan de ruido, 235 son malas: $235 \div 2,038 = 11.53\%$.

$11.53 \div 4.18 = \mathbf{2.76}$. Una reseña que habla de ruido es mala **2.76 veces** más seguido de lo normal. A esto se le llama *riesgo relativo*, y es la misma medida que usan los médicos para comparar riesgos.

Tema	Riesgo relativo	Qué significa
Ruido	2.76	Hunde la reseña
Suciedad	1.89	Hunde
Precio	1.66	Hunde
Multitudes	1.52	Hunde
Servicio	1.18	Casi neutro
Naturaleza	0.73	Protege
Cultura	0.48	Protege
Calma	0.41	Protege mucho

Combinaciones (método Apriori, que busca qué temas aparecen juntos): una reseña que habla de ruido y de mal servicio es mala 2.82 veces más seguido de lo normal.

Las palabras del turista: las reseñas de 5 estrellas dicen *excelente, increíble, hermoso, deliciosa, amable, ruinas, ambiente*; las malas dicen *peor, horrible, dinero, caro, sucia, grosero*.

La conclusión que define la campaña: lo que hunde una reseña (ruido, suciedad, multitudes) es lo que sobra en los lugares llenos, y lo que la protege (calma y cultura) es justo lo que el sur ofrece. Esa es la promesa de la marca.

5.7 ¿Qué recomendar cerca? Clasificar negocios por su nombre

Para que la página recomiende qué hacer, dónde comer y dónde dormir, se clasificaron los negocios del DENU de las localidades de los cinco lugares leyendo su **nombre** (y, si el nombre no dice nada, su giro oficial). Lo hicimos con una lista de raíces de palabras, porque no había ejemplos etiquetados para entrenar un modelo.

Las reglas salieron de errores reales: “MICHELADAS” contiene “HELAD” y salía como heladería; “BARBACOA” contiene “BAR”. Por eso una raíz cuenta solo al inicio de una palabra. Al revisar a mano dos muestras al azar de 40 negocios, la segunda acertó **39 de 40**. De 2,042 negocios turísticos, 1,587 quedaron clasificados.

Aprendizaje de máquina: predecir

Materia: Aprendizaje de máquina. Pregunta: ¿cómo estará cada lugar el mes que entra, y cuánta gente llegará en los próximos 12 meses?

6.1 Qué significa que una computadora “aprenda”

Un modelo de aprendizaje de máquina es una receta que se ajusta sola con ejemplos del pasado. Se le muestran muchos casos (“este mes el índice era tal y el mes siguiente el lugar estuvo concurrido”) y busca la regla que mejor los explica. Después se le da un caso nuevo y responde con esa regla.

El proyecto tiene **dos** problemas de predicción distintos, y conviene no confundirlos:

	El Radar	El Pronóstico
Qué predice	Una <i>palabra</i> : tranquilo, concurrido o saturado	Un <i>número</i> : cuántos visitantes
Para cuándo	El mes siguiente	De 1 a 12 meses
Contra qué se compara	“Igual que este mes”	“Lo mismo que el mismo mes del año pasado”

Por qué así y no de otra forma

Siempre contra una regla simple. Un modelo complicado que no le gana a una regla de sentido común no sirve. Por eso cada modelo se compara contra la regla más simple posible, y se dice cuánto le gana (o si no le gana).

6.2 El Radar: ¿cómo estará el lugar el mes que entra?

Qué ve el modelo: el índice de presión de este mes y de los dos anteriores, cuánto cambió, la época del año y si es uno de los cinco lugares. **Qué responde:** la probabilidad de cada estado el mes siguiente.

Comparamos tres modelos:

- **Regresión logística:** le da a cada estado un puntaje que suma lo que empuja cada dato, y convierte los puntajes en probabilidades que suman 100 %.

- **Random Forest:** 400 árboles de decisión, cada uno entrenado con una muestra distinta; el resultado es el promedio de sus votos.
- **Gradient Boosting:** árboles pequeños en fila, donde cada uno corrige los errores del anterior.

Un ejemplo con números reales · Mahahual, agosto de 2026

Mahahual tuvo en julio un índice de 0.731, muy alto por los cruceros. La regresión logística calcula un puntaje para cada estado y los convierte en probabilidades:

- concurrido: **60.1 %**;
- saturado: **39.9 %**;
- tranquilo: casi 0.

La página dice: Mahahual seguirá concurrido, con 4 de 10 probabilidades de saturarse. (Mahahual no se promueve; sirve para ver que el modelo detecta presión donde la hay.)

6.2.1 Cómo se probó: viajar al pasado

La idea, sin fórmulas

La forma escolar de probar un modelo es apartar al azar una parte de los datos. Aquí sería trampa: el modelo podría aprender con agosto y probarse con julio, es decir, *ver el futuro*. Lo honesto es “viajar al pasado”: pararse en agosto de 2025, entrenar solo con lo que se sabía hasta entonces, predecir septiembre y comparar con lo que pasó. Luego pararse en septiembre, y así hasta julio de 2026.

Fueron 12 meses de prueba, 156 predicciones y 30 cambios reales de estado.

Modelo	Aciertos (de 156)	Cambios anticipados (de 30)	Falsas alarmas
“Igual que este mes”	126	0	0
Regresión logística	130	8	4
Random Forest	130	6	2
Gradient Boosting	128	7	5

Nuestro criterio: el que más acierta y, si empatan, el que más cambios anticipa, porque la regla anti-colapso necesita *anticipar*. Ganó la regresión logística.

Si nos preguntan

“Su modelo apenas le gana a la regla simple, ¿para qué sirve?” Es cierto, y se dice: el estado se repite 8 de cada 10 meses, así que “igual que este mes” acierta mucho. El modelo gana 4 aciertos, pero su valor está en otra parte: anticipa 8 de los 30 cambios, y la regla simple

no anticipa ninguno. Además, en los cinco lugares casi no hubo cambios (2 en 48 casos), así que **no se puede afirmar que el modelo anticipe saturaciones en el sur**; anticipa cambios en los lugares de referencia. Decirlo así es más fuerte que exagerar.

6.3 El Pronóstico: ¿cuánta gente llegará?

6.3.1 Qué se pronostica y qué no

Solo se pronostica lo que está **medido** y llega hasta 2026:

- visitantes a Oxtankah (Bahía) y a las tres zonas de la Ruta, desde 2016 (INAH);
- cruces desde Belice por Chetumal, desde 2019 (gobierno del estado);
- la ocupación de Cancún y de la Riviera Maya, como referencia.

Maya Ka'an y la Laguna Milagros no tienen ninguna serie de visitantes: no se pronostican, y se dice.

Por qué así y no de otra forma

Los meses cerrados no enseñan. Si una zona estuvo cerrada por obras y marcó 0 visitantes, un modelo que aprenda de ese cero creería que en ese mes puede no llegar nadie “por temporada”. Por eso los meses de cierre, los meses a medias (justo antes de cerrar o después de reabrir) y la pandemia se marcan y **no entrenan**, aunque su valor se conserva. Además, las zonas reabrieron con menos gente que antes (Kohunlich tuvo 21,850 visitantes en 2025 contra 42,813 en 2019), así que el nivel se toma de los meses después de la reapertura.

6.3.2 Cinco formas de predecir

1. **La regla simple:** lo mismo que el mismo mes del año pasado.
2. **Holt-Winters sin tendencia:** se le quita la temporada a la serie, se sigue su “nivel de fondo” mezclando cada dato nuevo con lo que ya se creía, y se le vuelve a poner la temporada.
3. **Holt-Winters con tendencia:** igual, más una pendiente que se va apagando.
4. **Regresión con clima:** el nivel de cada etapa (antes de la pandemia, después, desde la reapertura), el efecto de cada mes, la lluvia fuera de lo normal y las tormentas.
5. **Gradient Boosting:** árboles que aprenden de los últimos meses y del mismo mes del año anterior.

Un ejemplo con números reales · la Ruta en enero de 2027, con Holt-Winters

El “nivel de fondo” de la Ruta (sin temporada) era de unos 5,332 visitantes al mes. En julio de 2026 llegaron 5,057, y como julio es un mes casi normal (0.953), sin temporada eso equivale a 5,307. El modelo cree un 11.8 % en el dato nuevo y un 88.2 % en lo que ya sabía:

$$0.118 \times 5,307 + 0.882 \times 5,332 \approx 5,329.$$

Para enero se le vuelve a poner la temporada: $5,329 \times 1.606 = \mathbf{8,559}$ visitantes.

Un ejemplo con números reales · la Bahía en diciembre de 2026, con la regresión

Desde que Oxtankah reabrió en 2024, un enero típico tiene unos 1,139 visitantes. Diciembre trae 15.1 % más que enero, y nunca ha habido tormenta en diciembre. Pronóstico: $1,139 \times 1.151 \approx \mathbf{1,311}$ visitantes.

6.3.3 El rango: “muy probablemente entre tanto y tanto”

Un pronóstico solo, sin rango, engaña: parece más seguro de lo que es. Cada pronóstico lleva un **rango del 90 %**.

La idea, sin fórmulas

Se revisan los errores que el modelo cometió en el pasado en pronósticos parecidos. Si 9 de cada 10 fueron menores que cierto tamaño, lo razonable es decir que el próximo tampoco se equivocará más que eso. No se supone ninguna curva: se usan los errores reales. Este método se llama *conformal*.

Un ejemplo con números reales · otra vez la Bahía en diciembre de 2026

De 105 errores pasados de pronósticos a 4–6 meses, el que deja abajo al 90 % equivale a equivocarse unos 37 % hacia arriba o 27 % hacia abajo. Entonces:

- mínimo: $1,311 \times 0.731 = 959$;
- máximo: $1,311 \times 1.368 = 1,793$.

Se esperan **1,311 visitantes, muy probablemente entre 959 y 1,793**. Diciembre de 2025 tuvo 1,224: dentro del rango.

¿Se cumple de verdad? Se midió en el pasado cuántas veces el dato real cayó dentro del rango, y se reporta aunque salga mal: en la Bahía, 91 de cada 100 veces; en Belice, 94; en la Ruta, solo 80.

6.3.4 Cuál elegimos

Nuestra regla: “menor error con rango $\geq 80\%$ ”. De los modelos cuyo rango se cumple al menos 80 de cada 100 veces, el que menos se equivoca.

Lugar	Modelo elegido	Error típico	Rango cumplido
Bahía	Regresión con clima	15.7 %	91.3 %
Ruta	Regresión con clima	21.6 %	80.3 %
Chetumal (Belice)	Regresión con clima	11.0 %	94.1 %
Cancún (referencia)	La regla simple	3.8 %	89.3 %

Por qué así y no de otra forma

Por qué no el de menor error, sin más. En la Ruta, el de menor error (Holt-Winters sin tendencia) tiene un rango que solo atrapa el dato real 72 de cada 100 veces: un rango “del 90 %” que falla tanto engaña al que planea. **Por qué no un solo modelo para todo.** En Cancún, la regresión se equivoca 58 % más que repetir el año anterior; la ocupación de Cancún cambia muy poco de un año a otro.

6.3.5 Lo que declaramos

- **La Ruta falló en 2023:** las visitas cayeron 10.7 % sin ningún aviso en la historia, y ese año el rango solo se cumplió 67 de cada 100 veces. En 2025–2026 vuelve a cumplirse.
- **El clima casi no mejora el pronóstico:** sin lluvia ni tormentas, la regresión se equivoca casi igual. Lo que funciona es separar las etapas y el efecto de cada mes. Aun así, el clima sí se asocia: en la Bahía, cada 100 mm de lluvia sobre lo normal van con 10.9 % menos visitantes.
- **La tendencia engaña en tramos cortos:** Holt-Winters con tendencia llegó a pronosticar –240 visitantes (¡negativo!) en la Bahía, porque aprendió la “tendencia” en plena reapertura.

Para la campaña: el Pronóstico define la temporada alta de cada lugar y cuánta gente se espera; con eso el modelo del dinero decide en qué meses anunciar (capítulo 8).

Procesos estocásticos: las probabilidades

Materia: Procesos estocásticos. Pregunta: ¿y si el año sale mejor o peor de lo pronosticado? ¿Qué tan probable es una tormenta, o que un lugar se llene?

“Estocástico” quiere decir “con azar”. Un pronóstico dice lo más probable; los procesos estocásticos dicen **qué tan probable es cada cosa**. El proyecto usa tres.

7.1 Tormentas: ¿qué tan probable es una cada mes?

7.1.1 Primero, qué cuenta como tormenta “del sur”

Una tormenta afecta al sur si pasó a **200 km o menos de Chetumal**, con viento de tormenta tropical o huracán (34 nudos o más), **de 1966 en adelante**.

Por qué así y no de otra forma

200 km cubre Chetumal, la bahía, la Ruta y Maya Ka'an sin contar tormentas que solo pasan por Honduras o el norte de Yucatán. Con 100 km quedaban 13 tormentas en 60 años, muy pocas para calcular algo por mes; con 300 km, 59, muchas que no traen viento fuerte al sur. **Desde 1966** porque es la era de los satélites: antes, muchas tormentas en el mar no se registraban, y contarlas haría ver el riesgo más bajo de lo que es.

Con esa regla hay **31 tormentas en 60 años**, la mayoría de agosto a octubre (23 de 31). Entre ellas, Carmen en 1974, que pasó a 15.3 km de Chetumal con 125 nudos, y Dean en 2007. La distancia se calcula sobre la superficie de la Tierra (que es redonda), con la fórmula de *haversine*.

7.1.2 La probabilidad de cada mes

La idea, sin fórmulas

Las tormentas son eventos raros que llegan sin aviso y una no depende de la otra. Para eventos así, las matemáticas tienen una regla conocida, la **distribución de Poisson**, que solo necesita un dato: cuántos llegan en promedio. Con eso dice la probabilidad de que llegue al menos uno.

Un ejemplo con números reales · agosto

En agosto hubo 9 tormentas en 60 años: $9 \div 60 = 0.15$ tormentas por agosto, en promedio. La probabilidad de que no llegue ninguna es $e^{-0.15} = 0.861$ (la regla de Poisson), así que la de que llegue al menos una es $1 - 0.861 = 0.139$: **13.9 %**.

En el año completo, 31 tormentas en 60 años: probabilidad de al menos una, **40.3 %**.

Mes	may	jun	jul	ago	sep	oct	nov	dic a abr
Probabilidad	1.7 %	4.9 %	1.7 %	13.9 %	12.5 %	9.5 %	4.9 %	0 %

Para la campaña: de agosto a octubre se reserva dinero por si una tormenta obliga a pausar.

7.2 ¿Se va a llenar el norte? Cadena de Markov

La idea, sin fórmulas

Una cadena de Markov es como un juego de tablero en el que la siguiente casilla depende solo de la casilla donde estás, no de cómo llegaste. Aquí las casillas son *tranquilo*, *concurrido* y *saturado*, y las probabilidades de moverse se cuentan con lo que pasó en 239 semanas reales de 7 centros del norte.

Un ejemplo con números reales · contar y dividir

De todas las veces que un centro del norte estuvo tranquilo una semana (830 veces), la semana siguiente siguió tranquilo 765 veces: $765 \div 830 = 92.2 \%$. Así se llena una tabla de 3 por 3:

Esta semana \ la que sigue	tranquilo	concurrido	saturado
tranquilo	92.2 %	7.8 %	0 %
concurrido	10.0 %	83.1 %	6.9 %
saturado	1.2 %	26.2 %	72.6 %

Si esta semana Cancún está concurrido, hay **6.9 %** de probabilidad de que la siguiente esté saturado.

¿Y dentro de dos semanas? Hay dos caminos para llegar a saturado: seguir concurrido y luego saturarse ($0.831 \times 0.069 = 0.057$), o saturarse ya y seguir saturado ($0.069 \times 0.726 = 0.050$). Suma: **10.7 %**.

Otras lecturas de la misma tabla:

- **A la larga**, el norte pasa el 9.8 % de las semanas saturado.
- **Una racha saturada dura** en promedio 3.65 semanas.

¿Sirve? Se probó en las últimas 52 semanas, comparando sus probabilidades contra “igual que esta semana”. Para medir qué tan buenas son unas probabilidades se usa el *puntaje de Brier* (como un examen donde se castiga más equivocarse con mucha seguridad). Markov sacó mejor puntaje a 1, 4 y 8 semanas.

Para la campaña: cuando el norte se va a saturar es el momento de ofrecerle el sur a quien iba allá. Solo cubre el norte, porque el sur no tiene ningún dato semanal.

7.3 Monte Carlo: 10,000 años posibles

La idea, sin fórmulas

En lugar de un solo pronóstico, la computadora imagina **10,000 años posibles**. En cada uno toma el pronóstico, le aplica un año de errores reales del pasado (elegido al azar) y le sorteas tormentas con las probabilidades de arriba. Con los 10,000 años se ve qué tan malo puede ser un año malo y qué tan probable es pasarse de lo que un lugar ha recibido.

Un ejemplo con números reales · la Bahía en agosto de 2026

El pronóstico es de 879 visitantes.

- En un año imaginado, el error sorteado es de -18% y además cae una tormenta que (supuesto) quita la mitad: $879 \times 0.82 \times 0.5 = 360$ visitantes.
- En otro, el error es de $+10.5\%$ y no hay tormenta: $879 \times 1.105 = 971$.

Con los 10,000 años se ordenan los resultados. El que deja abajo al 10% es el **escenario malo** (684); el de en medio, el **probable** (930); el que deja abajo al 90% , el **bueno** (1,202).

Lugar (año completo)	Malo / probable / bueno	Riesgo de pasarse
Ruta de las pirámides	55,811 / 62,212 / 73,884	30.9 %
Bahía Calderitas–Oxtankah	10,106 / 11,217 / 13,085	24.2 %
Chetumal (cruces de Belice)	551,986 / 620,304 / 671,956	38.3 %

El **riesgo de pasarse** es la parte de los 10,000 años en que algún mes rebasa la **capacidad probada**: el mes más lleno que ese lugar ha recibido en su historia (la Ruta, 10,465 visitantes en enero de 2018).

Por qué así y no de otra forma

Errores de un año completo, no mes por mes. Los meses flojos vienen juntos: si un año sale bajo, sale bajo varios meses. Sortear cada mes por separado haría los años demasiado parejos y escondería el riesgo. **El golpe de una tormenta es un supuesto:** solo hubo 3 meses con tormenta entre los meses con datos útiles, muy pocos para medir cuánto quita.

Por eso lo probamos con 0 %, 25 % y 50 % (lo que llamamos “supuesto con barrido”). **¿Por qué 10,000?** Con 10,000 años, un riesgo como el de la Ruta en enero (30 %) tiene un margen de error de menos de medio punto. Más simulaciones no cambiarían ninguna decisión.

7.4 Lo que estas probabilidades le dicen a la campaña

1. **Las tormentas pesan en el mes, no en el año.** Con el golpe más duro (50 %), el escenario probable del año baja apenas 1 a 2 %. Pesa más la incertidumbre del propio pronóstico. Por eso la reserva para tormentas es por mes, no un recorte del año.
2. **El riesgo de llenarse está en los meses pico:** diciembre de 2026 en Chetumal (29 %) y en la Bahía (14 %), enero de 2027 en la Ruta (30 %). Si la campaña empujara en esos meses, podría llevar a esos lugares a recibir más de lo que nunca han recibido. Por eso **no se anuncia en temporada alta**.
3. **Qué mueve más a los visitantes:** la lluvia (en la Bahía, -9.7% por cada 100 mm sobre lo normal) y el tipo de cambio (en la Ruta, $+6.8\%$ por cada peso más por dólar). Son asociaciones, no causas probadas. La idea de que un peso barato atrae más cruces desde Belice **no** se sostiene con los datos.

Investigación de Operaciones: repartir el dinero

Materia: Investigación de Operaciones. Pregunta: ¿cuánto dinero va a cada lugar, en qué mes y por qué red social, para traer a la mayor cantidad de gente sin llenar ningún lugar?

8.1 El problema, como una receta

Todo problema de optimización tiene tres ingredientes:

1. **Lo que se decide** (las *variables*): cuántos pesos poner en cada mes, en cada lugar y en cada canal. Son 9 meses (octubre de 2026 a junio de 2027) $\times$ 3 lugares (Chetumal, Bahía y Ruta) $\times$ 2 canales (Google y Facebook) = **54 cantidades**.
2. **Lo que se quiere lograr** (el *objetivo*): el mayor número de visitantes esperados hacia el sur.
3. **Las reglas que no se pueden romper** (las *restricciones*).

La computadora busca, entre todas las formas posibles de repartir el dinero, la que logra el objetivo sin romper ninguna regla.

Por qué así y no de otra forma

¿**Por qué visitantes y no dinero que deja el turismo (derrama)**? La derrama que publica el gobierno no dice en qué unidad está y termina en marzo de 2024; habría que inventar cuánto gasta cada turista. ¿**Por qué no “visitantes menos un castigo por presión”**? Habría que inventar cuánto pesa el castigo. Elegimos **visitantes al sur**, y la presión la controlamos con reglas duras.

8.2 Cuánto rinde un peso en cada red

La idea, sin fórmulas

Un anuncio funciona como un embudo: mucha gente lo ve, algunos le dan clic y, de esos, algunos planean el viaje. Se paga por cada clic. Lo que importa es cuántos viajeros trae cada peso.

Un ejemplo con números reales · Google contra Facebook

Con los costos publicados para anuncios de viajes (promedios de Estados Unidos, usados como supuesto) y el dólar a 17.06 pesos:

- **Google:** un clic cuesta 2.12 dólares, es decir, $2.12 \times 17.06 = 36.17$ pesos. De cada 100 clics, 5.75 planean el viaje. Con \$1,000 se compran $1,000 \div 36.17 = 27.6$ clics y llegan $27.6 \times 0.0575 = 1.59$ visitantes.
- **Facebook:** un clic cuesta 0.51 dólares, 8.70 pesos. Con \$1,000 se compran 114.9 clics y llegan **6.61** visitantes.

Facebook rinde cuatro veces más por peso porque su clic es cuatro veces más barato.

Un hueco importante: nadie publica cuántas personas planean un viaje después de dar clic en un anuncio de turismo en Facebook. El caso base usa la cifra de Google (5.75 %) y se prueba qué pasa con 3 % y con 6.38 %.

8.3 Las cuatro reglas de cuidado

Regla	Por qué existe
Cero anuncio en temporada alta	Anunciar un lugar cuando ya se llena sería crear la saturación que la campaña quiere evitar.
Tope de capacidad probada	Los visitantes esperados más los de la campaña no pueden pasar del mes más lleno que el lugar ha recibido en su historia.
Mínimo de 15 % por lugar	Para que el dinero no se vaya todo a un solo lugar y los tres reciban algo (equidad entre comunidades).
Tope de 70 % por canal	Para no depender de una sola plataforma: si Facebook cambia sus precios o sus reglas, la campaña no se cae.

8.4 Lo “estocástico”: decidir hoy sin saber cómo saldrá el año

El dinero se decide hoy, pero el año puede salir malo, probable o bueno (los escenarios del Monte Carlo). Si sale bueno y un lugar se llena, el anuncio de ese mes **se pausa** y esos visitantes se pierden. El modelo considera los tres escenarios a la vez (con probabilidades de 30 %, 40 % y 30 %) y aprende, desde hoy, a no gastar en meses donde un año bueno llenaría el lugar. A esto se le llama **programación estocástica de dos etapas**: la primera etapa es el plan; la segunda, la reacción cuando se sabe qué pasó.

8.5 Cómo lo resuelve la computadora

La idea, sin fórmulas

Imaginemos todas las formas posibles de repartir el dinero como el interior de un diamante con muchas caras. Las reglas son las paredes. La mejor solución siempre está en una de las esquinas. El método **simplex** camina de esquina en esquina por las orillas, siempre hacia una mejor, hasta que ya no hay esquina vecina que mejore. Como pausar o no pausar es un sí o no (no se puede pausar “a medias”), se agrega otro método, **ramificación y acotamiento**, que prueba las dos opciones y descarta los caminos que no pueden ganar.

El programa PuLP escribe el modelo y el programa CBC lo resuelve en **0.3 segundos**.

8.6 El resultado

Un ejemplo con números reales · el máximo de visitantes, a mano

De los \$250,000 al año, a los 9 meses del plan les tocan $250,000 \times 9/12 = \$187,500$.

Como Facebook rinde más, se lleva su tope de 70 %: \$131,250. Google, el resto: \$56,250.

- Facebook: $131,250 \div 8.70 = 15,084$ clics; $15,084 \times 0.0575 = 867$ visitantes.
- Google: $56,250 \div 36.17 = 1,555$ clics; $1,555 \times 0.0575 = 89$ visitantes.

Total: **957 visitantes**, a unos **\$196** cada uno ($187,500 \div 957$).

Reparto por lugar: la Ruta, 41.5 % (\$77,790); la Bahía, 36.9 % (\$69,175); Chetumal, 21.6 % (\$40,535). **Meses sin anuncio:** diciembre en los tres lugares, enero en la Ruta y la Bahía, marzo en la Ruta y abril en la Bahía. Todos son de temporada alta: de 27 combinaciones de mes y lugar, 20 quedan permitidas.

Lo que salió mal y cómo lo corregimos

El primer resultado mandaba todo a un solo mes. Como no hay dato de que un lugar responda mejor que otro a los anuncios, había muchísimas formas de repartir que daban los mismos 957 visitantes, y la computadora entregaba una cualquiera: los \$131,250 de la Ruta, todos en junio. Matemáticamente era óptimo; en la práctica, absurdo. Decidimos desempatar **en proporción al espacio libre de cada mes:** primero se calcula el máximo de visitantes, y luego, entre las soluciones que lo logran, se elige la que reparte el dinero según cuánto espacio sobra.

Ejemplo: en octubre de 2026 se esperan 3,688 visitantes en la Ruta, que ha llegado a recibir 10,465. Le sobra el 64.8 % de espacio. Sumando el espacio de las 20 combinaciones permitidas, a la Ruta en octubre le toca el 8.1 % del dinero de cada canal: \$10,624 de Facebook y

\$4,553 de Google.

8.7 ¿Cuánto cuesta cuidar?

Para saber cuánto cuesta cada regla, se resuelve el modelo sin ella y se compara:

Regla	Visitantes que cuesta
Cero anuncio en temporada alta	0
Tope de capacidad probada	0
Mínimo de 15 % por lugar	0
Tope de 70 % por canal	282 (29.5 %)

El hallazgo más bonito del proyecto: las reglas de cuidado ambiental y de equidad **no le cuestan ni un visitante** a la campaña. La campaña es chica frente al espacio que tiene el sur. La única regla que cuesta es el tope por canal, y se mantiene por prudencia.

Precios sombra: la teoría de la optimización da, para cada regla, cuánto mejoraría el resultado si se aflojara un poquito. Si al presupuesto se le agregan \$1,000, llegan 1.59 visitantes más (iría a Google, porque Facebook ya está en su tope). Si a Facebook se le permiten \$1,000 más (quitándoselos a Google), llegan 5.02 más. Las reglas que no estorban tienen precio sombra cero.

8.8 ¿Hasta dónde se puede apretar?

Si se exige que ningún mes con anuncio pase de cierto porcentaje de su capacidad probada:

Límite	100 % a 40 %	35 %	30 %
Visitantes	957	537	0

La campaña puede prometer que **ningún mes con anuncio pasará del 40 % de lo que el lugar ya ha recibido**, sin perder un solo visitante. A esto se le llama *frontera de Pareto*: la línea donde ya no se puede mejorar una cosa sin empeorar la otra.

8.9 ¿Y si los supuestos están mal?

Si cambia...	Visitantes
Nada (caso base)	957
Facebook convierte solo 3 %	542
Facebook convierte 6.38 %	1,052
El clic de Facebook cuesta 0.42 dólares	1,143
Una tormenta quita 25 % o 50 %	957 (los meses con riesgo ya están fuera)
\$500,000 al año	1,914
\$1,000,000 al año	3,827

El número de visitantes cambia, pero **el reparto entre lugares y canales casi no cambia**. La recomendación es estable aunque los supuestos se muevan.

CAPÍTULO 9

La Torre: la campaña semana a semana

Materias: Grandes volúmenes (datos que llegan) y Mercadotecnia (qué hacer si la afluencia rebasa la capacidad). Pregunta: ¿qué hace la campaña esta semana?

9.1 La idea

El plan de dinero se arma por mes, pero el mundo cambia cada semana: pasa una tormenta, llueve fuera de lo normal, llega más gente de la esperada o el norte se llena. La Torre vigila esas señales cada semana y, si hace falta, **pausa** un anuncio o **enciende** otro, con reglas fijadas de antemano.

La idea, sin fórmulas

Es el copiloto del viaje. El plan dice “vamos por la carretera federal”, pero si el copiloto ve un choque adelante, cambia de ruta sin tener que rehacer todo el viaje. Las reglas para cambiar de ruta se acordaron antes de salir.

9.2 Las cuatro señales

Señal	De dónde sale	Qué provoca
Tormenta cerca	Trayectorias de la NOAA, con la regla de 200 km	Pausa el anuncio de ese lugar esa semana
Clima raro	Isolation Forest sobre la lluvia, el viento y el calor de la semana	Pausa
Llegó más gente de la esperada	El dato real del mes contra el rango del 90 % del Pronóstico	Pausa
El norte se llenó	Ocupación semanal de Cancún y la Riviera Maya (SECTUR)	Enciende “¿Ibas al norte?”

Si llega **menos** gente de la esperada, no se pausa nada: eso es espacio, justo lo que la campaña busca llenar.

9.3 Lo que decidimos

- **Qué hacer en el sur con una mala semana:** “pausar esa semana y guardar el dinero”. El dinero no se pierde: pasa a la siguiente semana permitida del mismo lugar. Se descartó bajar el anuncio a la mitad (se seguiría anunciando con mal clima) y solo avisar (no cuidaría nada).
- **Qué hacer si el norte se llena:** encender el anuncio “¿Ibas al norte?”, que invita al lugar del sur con más espacio ese mes. “Lleno” es el mismo corte que ya usa el Radar: 85.92 % de ocupación.
- **Cómo mostrarlo:** como una reproducción grabada en la página (GitHub Pages no puede transmitir en vivo) y, en la computadora del proyecto, en vivo con el servidor.
- **Qué es “clima raro”:** más raro que el 95 % de las semanas que el modelo ya conoce.

Lo que salió mal y cómo lo corregimos

El modelo de clima raro marcaba casi la mitad de las semanas. El corte automático de Isolation Forest señalaba como raras el **47 %** de las semanas de Chetumal, lo que habría pausado media campaña. Dos causas: con pocas semanas, el modelo no distinguía bien, y desde 2022 llueve más y hace más calor que en 2019–2021, así que todo lo reciente le parecía raro. Cambiamos a un modelo por año que aprende de todos los años anteriores, y elegimos el corte del 95 %. Quedaron **21 semanas raras en Chetumal** y 17 en Kohunlich, entre 7 % y 9 % de las semanas.

9.4 El dinero que no se pierde

Un ejemplo con números reales · una pausa

Si un mes tiene 4 lunes y \$4,000 de presupuesto, cada semana le tocan \$1,000. Si la primera semana se pausa, esos \$1,000 se guardan. La segunda semana, si todo está bien, se gastan \$2,000: los suyos y los guardados.

9.5 Lo que pasó al reproducir 239 semanas reales

Se revivieron **239 semanas reales**, del 3 de enero de 2022 al 27 de julio de 2026, como si llegaran una por una, con Spark Structured Streaming (capítulo 4). El plan de dinero se aplicó a esos años para ver qué habría pasado.

Lugar	Encendido	Pausado	Temporada alta	Fuera del plan
Chetumal	145	19	18	57
Bahía Calderitas–Oxtankah	106	14	62	57
Ruta de las pirámides	104	15	63	57

(“Fuera del plan” son julio, agosto y septiembre: el plan solo cubre de octubre a junio. En esas semanas la Torre vigila pero no gasta.)

- **48 pausas** en total. Algunas tuvieron más de un motivo: 44 por clima raro, 9 por tormenta cerca (Lisa en 2022, Nadine y Sara en 2024) y 5 porque llegó más gente de la esperada a Chetumal en mayo de 2025.
- **No se perdió dinero:** los \$876,901 planeados en las semanas con plan se gastaron todos.
- **“¿Ibas al norte?” se encendió 6 semanas**, todas hacia la Bahía. El norte casi nunca se satura en una semana suelta (Cancún 1 semana, la Riviera Maya 9): su señal fuerte es la temporada, no la semana.
- **La prueba de independencia:** el modelo de clima raro marcó las tres semanas de tormenta sin saber que hubo tormenta.

Si nos preguntan

“¿Esto es en tiempo real?” Es una **reproducción de datos reales**: las semanas pasadas se procesan en orden, una por una, con la misma tecnología que procesaría datos que llegan en vivo. Si mañana existiera una fuente semanal del sur, se cambia la carpeta de entrada y las reglas siguen iguales. En la página se dice así: “reproducción de datos históricos reales”.

9.6 Lo que declaramos

- El sur no tiene ningún dato oficial semanal; la Torre del sur usa el clima, las tormentas y el dato mensual.
- Las tormentas de 2026 todavía no se publican: esas semanas dicen “sin dato”, no “sin tormenta”.
- Se supone que el dato del mes se conoce al empezar el mes siguiente; en la realidad tarda uno o dos meses.

Mercadotecnia: la campaña “El sur tiene espacio”

Materia: Mercadotecnia digital. Pregunta: ¿a quién le habla la campaña, con qué palabras, por qué medio, cuándo y cómo se sabe si funciona?

10.1 El método: segmentar, elegir y posicionar

La campaña sigue los tres pasos clásicos de la mercadotecnia:

1. **Segmentar:** dividir a los posibles visitantes en grupos, con datos.
2. **Elegir:** a qué grupos hablarles.
3. **Posicionar:** qué lugar quiere ocupar la marca en la mente de esos grupos.

La diferencia con una campaña común es que **cada paso sale de una cifra**, y cada rasgo dice si es un dato medido, un cálculo o un supuesto.

10.2 Lo que dicen los datos sobre quién viaja

- **Quién visita el sur** (INAH 2025): en Oxtankah, el 94.8 % son mexicanos; en la Ruta, el 63.3 %.
- **Quién llega al estado en avión:** 9,408,423 extranjeros a Cancún en 2025; 56.3 % de Estados Unidos y 17.1 % de Canadá; 53.4 % mujeres.
- **El dato que lo define todo:** al aeropuerto de Chetumal llegaron **250 extranjeros** en todo 2025. El extranjero no llega al sur en avión: entra por Cancún y baja por carretera, en Tren Maya, desde Belice o en crucero. Por eso el anuncio tiene que encontrarlo *antes* de viajar o *cuando ya está en Cancún*.
- **Cómo se informan** (ENDUTIH 2025): el 92.1 % de la gente de Quintana Roo usa internet; de quienes tienen teléfono inteligente, 90.6 % usa mensajería y 80.4 % redes sociales.
- **Qué los aleja y qué los atrae** (85,987 reseñas, capítulo 5): el ruido, la suciedad, el precio y las multitudes hunden una reseña; la calma y la cultura la protegen.

10.3 Las dos viajeras ideales

Una *buyer persona* es el retrato de un cliente típico, construido con datos. Elegimos **dos**:

La que vuelve al sur (nacional)

- **Origen:** mexicana. Es el 94.8 % de quien visita Oxtankah (*dato, INAH*).
- **Cuándo viaja:** de diciembre a abril; la campaña la invita en los meses con espacio (*derivado de la forma del año*).
- **Qué valora:** calma y cultura (*derivado de las reseñas*).
- **Qué la aleja:** ruido, suciedad, precio y multitudes (*derivado*).
- **Cómo se informa:** mensajería y redes sociales (*dato, ENDUTIH*).
- **De qué estado viene, su edad, su ingreso:** *hueco*; no hay dato oficial por destino.

La que baja del norte (Estados Unidos o Canadá)

- **Origen:** de los 9.4 millones de extranjeros en Cancún, 56.3 % de Estados Unidos y 17.1 % de Canadá (*dato*).
- **Sexo:** 53.4 % mujeres (*dato*).
- **Por qué no llega sola:** solo 250 extranjeros aterrizaron en Chetumal (*dato*).
- **Cuándo está:** más en marzo, menos en septiembre; Cancún en temporada alta de noviembre a abril (*dato*).
- **Cómo se informa:** busca en Google y usa redes desde el destino (*supuesto: no hay encuesta propia*).

Por qué así y no de otra forma

Solo la nacional dejaría fuera al extranjero que ya está a 334 km, en Cancún. **Solo la extranjera** ignoraría que la Bahía es 95 % mexicana. Con dos, cada una recibe su mensaje y su canal.

10.4 La marca

- **Nombre:** “El sur tiene espacio” (en inglés, “The south has room”). Dice el dato (capacidad que sobra) y la promesa (sin multitudes) a la vez. Descartamos “Sur sin prisa” (no dice dónde) y “Del Caribe al sur” (solo le habla a la extranjera).
- **Lema:** “Pirámides, bahía y sabor del sur, con espacio para disfrutarlos”.
- **Personalidad:** combinamos los tres tonos que consideramos, porque para nosotros es

un orgullo ser mexicanos: cercana y tranquila, orgullosa de lo maya y lo mexicano, y con espíritu de aventura.

- **Propuesta de valor:** el Caribe mexicano que todavía tiene espacio: pirámides con 15.5 veces menos visitantes que Tulum, una bahía tranquila y la comida del sur.
- **Lo visual:** el sistema “Sur mexicano”: rosa mexicano, amarillo cempasúchil, turquesa y añil en bloques, la greca maya y fotos reales comprobadas.

10.5 Los anuncios: cada promesa con su dato

Reglas: cada anuncio lleva el dato que lo respalda; **no se prometen precios ni tiempos de viaje** (no hay dato oficial); las palabras salen de las reseñas de 5 estrellas; y el largo se revisa contra los límites de cada plataforma.

Para	Dónde	Anuncio y su respaldo
Nacional	Google	“Pirámides mayas con espacio”. Tulum: 1,031,443 visitantes; la Ruta: 66,628.
Nacional	Facebook	“La bahía que te esperaba”. Oxtankah: 11,017 visitantes en 2025, 94.8 % mexicanos.
Nacional	WhatsApp	“¿Y si este puente nos vamos al sur?”. 90.6 % usa mensajería; no cuesta.
Extranjera	Google (inglés)	“Mayan pyramids, with room”. El mismo 15.5; Cancún en temporada alta.
Extranjera	Facebook (inglés)	“Your Caribbean trip, one stop south”. Solo se muestra cuando la Torre marca el norte lleno.

10.6 Los medios y el calendario

- **Facebook e Instagram, 70 %:** trae 6.61 visitantes por cada \$1,000 y el 80.4 % usa redes. Con tope para no depender de una sola plataforma.
- **Google, 30 %:** llega a quien ya está buscando viajar.
- **WhatsApp, sin costo:** el botón de compartir viaja entre familia y amigos.
- **La página:** el destino de todos los anuncios, con el planeador por lugar y mes en 9 idiomas (el décimo, el maya yucateco, espera la revisión de una persona hablante antes de publicarse).

Calendario: los 9 meses del plan (octubre de 2026 a junio de 2027), con el dinero de la Fase 6. “La que baja del norte” se activa solo en los meses en que Cancún está en temporada alta y el sur tiene espacio, y además la Torre la enciende por semana cuando el norte se llena.

10.7 Cómo se sabe si funciona: los indicadores

Indicador	Cómo se calcula	Meta
Alcance	Personas que vieron un anuncio	Se fija con el primer mes real
Interacción	Clics entre veces que se vio	Google 8.73 % o más; Facebook 2.76 % o más
Conversión	Viajes planeados entre clics	5.75 % o más
Costo por visitante	Pesos gastados entre visitantes	\$196 o menos
Afluencia	Visitantes reales menos el escenario probable	957 más en 9 meses
Presupuesto	Pesos gastados entre pesos planeados	100 % (lo pausado se gasta después)
Económico	Ocupación hotelera de Chetumal	Hueco: no se publica desde 2025
Social	Visitantes por cada mil habitantes (Radar)	Nunca “saturado”
Ambiental	Semanas con anuncio en temporada alta o con mal clima	0
Capacidad	Esperados más campaña entre capacidad probada	40 % o menos

10.8 La regla anti-colapso

El incidente de mercadotecnia pregunta qué hacer si llega más gente de la que un lugar soporta. La campaña tiene la respuesta **programada**, no solo escrita:

1. Nunca anuncia un lugar en su temporada alta (regla del presupuesto).
2. No permite que los visitantes esperados más los de la campaña pasen de la capacidad probada.
3. La Torre pausa el anuncio si hay tormenta, clima raro o llegó más gente de la esperada.
4. A quien iba al norte lleno le ofrece el lugar del sur con más espacio, nunca otro lugar lleno.

La página web: donde todo se junta

La página es la cara del proyecto: es donde la campaña llega al viajero y donde el jurado puede ver los modelos funcionando. Está publicada en `catexp.github.io/torre-del-caribe-unrc-2026`.

11.1 Cómo está ordenada

Decidimos que la página empezara por el viaje y dejara los datos al final. Quedó así:

Para el viajero (arriba)	Los datos (al final)
1. Portada con el planeador: se elige lugar y mes, y la foto cambia con el lugar	6. "Los datos": el problema, el Radar, cómo llega la gente
2. "Así va a estar": temporada, gente esperada, clima, riesgo de tormenta y una recomendación	7. El Pronóstico, los escenarios y el reparto del dinero
3. Qué hacer de día, de tarde y de noche; dónde comer y dónde dormir	8. La Torre semana a semana y la campaña
4. Los lugares, en un mapa 3D	9. Las 12 fases, las fuentes y quiénes somos
5. Experiencias, rutas de 2 y 3 días y preguntas frecuentes	

11.2 El planeador: la redistribución que se ve

Un ejemplo con números reales · la Ruta en enero de 2027

Quien elige la Ruta de las pirámides en enero de 2027 ve que es **temporada alta**: llega 61 % más gente que en un mes promedio y hay 30 % de riesgo de pasar del mes más lleno de su historia. Se esperan unos 8,993 visitantes (entre 5,716 y 14,149). La página le recomienda **Chetumal** ese mes (tranquilo) o **la Ruta en noviembre**.

Cuándo es temporada alta: si el mes tiene 20 % más gente que un mes normal (forma del año de 1.20 o más) o si hay 10 % o más de riesgo de pasar la capacidad probada. Para Cancún y la Riviera Maya, que cambian poco en el año, se usa el corte del Radar (71.2 % de ocupación): así Cancún queda en temporada alta de noviembre a abril.

Qué mes recomienda: el más tranquilo del mismo lugar que no sea temporada alta, que esté fuera de la temporada de tormentas y que llueva menos que un mes típico.

Lo que salió mal y cómo lo corregimos

El mes recomendado era el más lluvioso. Sin la condición de lluvia, el planeador casi siempre recomendaba **junio**: es tranquilo, pero es el mes más lluvioso en Chetumal (195 mm). Sería un mal consejo. Se agregó la condición, y ahora recomienda noviembre para la Ruta, mayo para la Bahía y febrero para Chetumal.

Cancún y la Riviera Maya aparecen bajo “¿Ibas al norte?” con la etiqueta “Referencia: la campaña no lo promueve”. Si su mes está lleno, la página **siempre** recomienda un lugar del sur, con un aviso que no se pierde al bajar. Nunca recomienda ir al norte.

11.3 Qué hacer, dónde comer y dónde dormir

Los negocios salen del DENUÉ (oficiales, con nombre y coordenadas), ordenados por cercanía y clasificados por su nombre (capítulo 5). Cada tarjeta tiene dos botones que abren Google Maps en otra pestaña: “Cómo llegar” y “Reseñas”. La página **no copia ni descarga nada de Google**: es un enlace público, como compartir una dirección.

Por qué así y no de otra forma

Al principio pensamos en recomendar los lugares con Google Maps y *webscraping*. El *scraping* (extraer datos de una página con un programa) de Google Maps lo prohíben sus términos de uso y la regla 4 del proyecto. La API oficial de Google pide una tarjeta de crédito, deja de funcionar sin internet y su llave quedaría expuesta en un repositorio público. Con el DENUÉ y un enlace, la página sigue funcionando sin internet hasta que alguien da clic.

11.4 Las fotos: todas comprobadas

Lo que salió mal y cómo lo corregimos

Las fotos de comida no eran de Quintana Roo. Habíamos hecho una galería de 24 platillos con fotos de Wikimedia Commons. Solo revisamos que no mencionaran lugares excluidos, pero eran de Mérida, Campeche y otros lugares. Cuando lo detectamos, retiramos la galería completa, y desde entonces **toda foto debe tener coordenada GPS dentro del municipio de su lugar**; si no la tiene, el programa se detiene. Hoy hay 28 fotos de los cinco lugares, cada una con su crédito y su licencia.

11.5 Día y noche, y 9 idiomas

Un botón cambia la página a modo noche (con una animación de sol que se vuelve luna) y otro cambia el idioma: español, inglés, francés, alemán, italiano, portugués, japonés, coreano y chino. El maya yucateco está preparado, pero no se publica hasta que lo revise una persona hablante. La parte de “Los datos” queda en español.

11.6 Una página que calcula

El plan pedía una web real con un sistema que **calcula**, no una página con números fijos. Hay dos formas de verla:

- **En internet** (GitHub Pages): la página muestra los resultados ya calculados y no hace ninguna llamada a otros sitios.
- **En la computadora del proyecto**, con el servidor encendido, aparecen dos controles más: “Pruébalo tú”, donde se mueve el presupuesto, la conversión o los topes, y el servidor **resuelve el modelo de optimización en vivo** (tardó 274 milésimas de segundo); y “Escuchar en vivo”, donde la Torre avanza semana a semana. El servidor se enciende con el comando `python -m torre.api.servidor`.

El servidor (FastAPI) tiene 8 direcciones de consulta. La consulta a la base de datos es **de solo lectura**: rechaza cualquier intento de cambiar datos o leer archivos (probamos 6 intentos).

11.7 Accesible para todos

Se revisó la página con **axe-core**, la herramienta estándar para revisar accesibilidad (normas WCAG 2.1 AA), en cuatro vistas: escritorio y celular, de día y de noche. La primera revisión encontró **67** fallas, la mayoría textos con poco contraste. Las corregimos hasta **0**. Además, la página se puede recorrer completa con el teclado.

Lo que no hicimos: el plan pedía probar la página con personas reales. Decidimos quedarnos con la revisión automática y declarar que no hubo prueba con personas.

PARTE III

Para defenderlo

Lo que no se sabe y lo que salió mal

Un proyecto de datos convence más cuando dice con claridad dónde termina lo que sabe. Este capítulo junta los huecos, los supuestos y los errores que corregimos. Es material para el coloquio: si un profesor encuentra un límite, lo mejor es que ya esté escrito aquí.

12.1 Lo que no se pudo medir (huecos)

Qué falta	Qué hicimos en su lugar
Ocupación hotelera del sur desde 2025	Se mide con lo que sí llega a 2026 (Tren Maya, Belice, INAH) y se muestra “sin dato oficial”
Visitantes de Maya Ka’an y de la Laguna Milagros	No se pronostican; en el Radar, “sin dato oficial”
De qué estado viene el turista mexicano, su edad y su ingreso	Se marca como hueco en la viajera ideal
Conversión de Facebook para turismo	Se prueba con tres valores (3 %, 5.75 % y 6.38 %)
Reseñas de los cinco lugares	Se usan las de los lugares llenos para saber qué molesta; en la página, un botón a Google
Fotos de platillos tomadas en el sur	Se muestran fotos reales de restaurantes; las de platillos las aportará el equipo
Estrellas oficiales de los hoteles del sur	Solo existen para 70 centros del país, ninguno del sur
Tormentas de 2026	“Sin dato”, nunca “sin tormenta”
Prueba de la página con personas	Declaramos que no se hizo

12.2 Los supuestos (y cómo los probamos)

Un supuesto es un número que no se pudo medir y se tuvo que fijar. Cada uno está marcado y se probó con varios valores:

- **Presupuesto de \$250,000 al año:** no hay un presupuesto real. Se probó con \$500,000 y \$1,000,000: los visitantes crecen en proporción y el reparto casi no cambia.
- **Costos de anuncios:** son promedios de anunciantes de Estados Unidos.
- **Cuánto quita una tormenta:** 0 %, 25 % o 50 %; el año casi no cambia.
- **Cada viaje planeado es un visitante más:** es una cota alta; si llegan menos, la capacidad

queda aún más protegida.

12.3 Los límites de los modelos

- El Radar apenas le gana a “igual que este mes” (130 contra 126 de 156) y en los cinco lugares casi no hubo cambios con qué probarlo.
- El rango del 90 % de la Ruta se cumple 80 de cada 100 veces, no 90, por la caída inesperada de 2023.
- El clima casi no mejora el pronóstico.
- Markov y la ocupación semanal solo cubren el norte.
- SECTUR mide menos ocupación que el gobierno del estado (hasta 19 puntos en Isla Mujeres). Como el norte se ve *menos* lleno de lo que diría el estado, el error juega en contra de la conclusión “el sur tiene espacio”, no a favor: la conclusión se sostiene igual.

12.4 Los errores que encontramos y corregimos

Estos errores son parte del valor del proyecto: muestran que revisamos las cifras en lugar de aceptarlas a ciegas.

1. **El conteo del DENUÉ** sumaba los diccionarios de datos como negocios (1,914 de más). Lo detectó Spark al contar diferente; un tercer lector lo confirmó.
2. **El Censo** contaba un catálogo como pueblos: 2,257 en lugar de 2,243.
3. **La “ocupación” de 2,560,068**: el panel del Radar sumaba tres renglones distintos (cuartos disponibles, ocupados y porcentaje). Ahora se calcula ocupados entre disponibles, y una prueba lo vigila.
4. **Visitantes contados dos veces**: la serie de “zonas arqueológicas” del gobierno del estado es el mismo dato del INAH sumado. Se usa solo el INAH.
5. **Cancún “tranquilo” en julio**: el índice falló la prueba de validez y se corrigió con datos (capítulo 5).
6. **Afluencia que parecía llegar a junio de 2024**: unos ceros lo hacían ver así; en realidad termina en marzo.
7. **Una línea del archivo de huracanes sin hemisferio**: la primera exploración la saltaba sin avisar. El código final se detiene si no entiende una línea, y esa latitud se dejó vacía, sin adivinar.
8. **Clima raro en el 47 % de las semanas**: se cambió el corte (capítulo 9).
9. **Todo el dinero de la Ruta en junio**: se agregó el desempate proporcional (capítulo 8).

10. **Junio como mes recomendado:** se agregó la condición de lluvia (capítulo 11).
11. **Fotos de Mérida y Campeche:** las retiramos y exigimos coordenada comprobada (capítulo 11).
12. **Un dominio inventado** en las maquetas de los anuncios: se cambió por la dirección real de la página.
13. **La página tenía 67 fallas de accesibilidad:** las corregimos hasta 0.
14. **Una imagen borrada:** la portada del documento ejecutivo desapareció del disco; se restauró y se agregó una prueba que revisa que todas las imágenes existan.

Para explicarlo en el coloquio

13.1 En un minuto

Quintana Roo está lleno de un lado y vacío del otro. Los cinco lugares del sur tienen el 12.3 % de la gente del estado, pero reciben el 1.4 % de los pasajeros de avión, y Tulum recibe 15.5 veces más visitantes que las pirámides del sur. Nuestra campaña, “El sur tiene espacio”, invita a la gente al sur sin llenarlo: con datos oficiales medimos dónde hay espacio hoy, pronosticamos cuándo conviene ir y repartimos el presupuesto con un modelo de optimización que nunca anuncia un lugar en temporada alta. Cada semana, una torre de control pausa los anuncios si hay mal clima o llega más gente de la esperada. Con \$187,500 en 9 meses esperamos 957 visitantes más, a \$196 cada uno, y las reglas de cuidado no cuestan ni un visitante.

13.2 En cinco minutos: la historia en orden

1. **El problema** (capítulo 1): sargazo, Tulum en crisis, el norte lleno; la cifra 12.3 % contra 1.4 %.
2. **Los datos** (capítulos 3 y 4): 8.1 millones de registros oficiales, tres cajas, Spark; lo que no existe se dice.
3. **Dónde y cuándo** (capítulos 5 a 7): el índice de presión (los cinco lugares tranquilos), la forma del año (enero 61 % arriba en la Ruta), el pronóstico con su rango y las tormentas (agosto, 13.9 %).
4. **Cuánto y cómo se cuida** (capítulos 8 y 9): 957 visitantes, las reglas que cuestan cero, la Torre con 48 pausas sin perder dinero.
5. **La campaña** (capítulo 10): dos viajeras, la marca, los anuncios con su dato y los 10 indicadores.

13.3 Si solo se recuerdan cinco cifras

1. **12.3 % contra 1.4 %:** la gente del sur contra los pasajeros de avión que recibe.
2. **15.5 veces:** Tulum recibe 15.5 veces más visitantes que las pirámides del sur.

3. **957 visitantes por \$187,500:** lo que trae la campaña en 9 meses, a \$196 cada uno.
4. **0 visitantes:** lo que cuestan las reglas de cuidado ambiental y de equidad.
5. **250 extranjeros:** los que llegaron en avión a Chetumal en 2025, contra 9.4 millones a Cancún.

13.4 Preguntas probables y respuestas cortas

Si nos preguntan

“¿De dónde sacaste los datos?” De 15 fuentes oficiales o abiertas (INEGI, SECTUR, el gobierno del estado, la NOAA, el INAH por medio de SECTUR), descargadas con programas y guardadas sin modificar, cada archivo con su huella digital. Nada de Google Maps ni TripAdvisor.

Si nos preguntan

“¿Por qué Spark?” Porque la arquitectura tiene que seguir funcionando cuando los datos no quepan en una computadora: el mismo código procesa 6 millones o 600 millones de registros. Se usó para limpiar los 6.1 millones de negocios del país y para reproducir 239 semanas como si llegaran en vivo.

Si nos preguntan

“¿Por qué no estimaste la ocupación del sur?” Porque nadie la midió desde 2025. Un modelo daría un número que parece dato pero es inventado. Preferimos medir el sur con lo que sí se mide (tren, frontera, zonas arqueológicas) y decir “sin dato oficial”.

Si nos preguntan

“¿Cómo saben que su pronóstico funciona?” Lo probamos “viajando al pasado”: en cada mes pronosticamos los 12 siguientes solo con lo que se sabía entonces y lo comparamos con lo que pasó. El rango del 90 % se cumplió 91 de cada 100 veces en la Bahía, 94 en Belice y 80 en la Ruta, y decimos por qué la Ruta falla.

Si nos preguntan

“¿Qué es lo óptimo?” Traer la mayor cantidad de visitantes con el presupuesto, sin romper cuatro reglas: no anunciar en temporada alta, no pasar la capacidad probada, al menos 15 % por lugar y máximo 70 % por canal. Y lo comprobamos: las reglas de cuidado cuestan cero visitantes.

Si nos preguntan

“¿Qué pasa si la campaña funciona demasiado bien?” La regla anti-colapso está programada: la Torre pausa el anuncio si llega más gente de la esperada, y el plan garantiza que ningún mes con anuncio pase del 40 % de la capacidad probada.

Si nos preguntan

“¿Por qué aparece Claude?” Usamos un asistente de programación con IA como herramienta. Las reglas, las decisiones y la revisión son nuestras y están documentadas con fecha en 25 notas de decisión.

13.5 Palabras que conviene saber explicar

Palabra	Qué significa, en una frase
Bronce, plata y oro	Las tres cajas: lo crudo, lo limpio y lo listo para usar.
Hueco	Un dato que no existe; lo declaramos y no lo rellenamos.
Índice de presión	Un número de 0 a 1 que resume qué tan presionado está un lugar frente a todo el estado.
Forma del año	Cuántas veces un mes normal recibe cada mes (1.61 = 61 % más).
Capacidad probada	El mes más lleno que un lugar ha recibido en su historia.
Origen móvil	Probar un modelo “viajando al pasado”, sin dejarlo ver el futuro.
Rango del 90 %	Entre qué valores caerá el dato real 9 de cada 10 veces.
Poisson	La regla para contar eventos raros que llegan sin aviso, como las tormentas.
Markov	Un modelo donde la siguiente semana depende solo de esta semana.
Monte Carlo	Imaginar miles de futuros posibles con azar para ver qué tan malo puede ser uno malo.
Simplex	El método que camina de esquina en esquina hasta encontrar el mejor reparto.
Precio sombra	Cuánto mejoraría el resultado si una regla se aflojara un poco.
Isolation Forest	Un método que detecta lo raro midiendo qué tan rápido se puede separar del resto.
Riesgo relativo	Cuántas veces más seguido pasa algo en un grupo que en general (ruido: 2.76).
Buyer persona	El retrato con datos de un cliente típico.
Spark Streaming	Procesar datos conforme llegan, en lotes pequeños y en orden.