

Torre del Caribe

Las decisiones, fase por fase

Qué elegimos en cada una de las 12 fases, entre qué opciones, con qué evidencia y qué consecuencia tuvo

Licenciatura en Ciencias de Datos para Negocios · 5° semestre, 2026-2

Problema Prototípico: *Turismo inteligente sustentable para México* (Quintana Roo)

Responsable técnico: **Brandon Uriel García Sánchez**

Equipo: Maribel Mondragón Mercado · Jesús Ramírez Isidro · Enrique González Ortega

Versión del 2 de octubre de 2026

Índice general

Cómo leer este documento	1
I Antes de los modelos	3
1. Fase 0: el plan, las reglas y la computadora	4
2. Fase 1: descargar los datos oficiales (Bronze)	7
3. Fase 2: limpiar y ordenar los datos (Silver y Gold)	10
4. Fase 3: elegir y medir los cinco lugares	14
II Los modelos	17
5. Fase 4: el Radar, ¿dónde hay espacio?	18
6. Fase 5: el Pronóstico, ¿cuándo conviene ir?	22
7. Fase 6: repartir el presupuesto	26
8. Fase 7: la Torre en vivo	28
III La campaña y el cierre	30
9. Fase 8: la campaña “El sur tiene espacio”	31
10. Fases 9, 10 y 11: servidor, página final y cierre	34
10.1. Fase 9: el servidor que conecta la página con los modelos	34
10.2. Fase 10: la página final	35
10.3. Fase 11: cierre y coloquio	35
11. La página web, en paralelo a todas las fases	38

12.Lo que estas decisiones tienen en común	41
12.1.1. Ninguna cifra se inventó	41
12.2.2. Cada modelo se comparó contra una regla simple	41
12.3.3. Fijamos los criterios antes de ver al ganador	41
12.4.4. Cuando algo falló, se contó	42
12.5.5. La redistribución tiene reglas que no se pueden romper	42

Cómo leer este documento

Este documento reúne **todas las decisiones de fondo** que tomamos en el proyecto Torre del Caribe, del 26 de septiembre al 3 de octubre de 2026, en el orden de las 12 fases (0 a 11). Nos sirve para tres cosas:

1. **Defender el proyecto:** ante la pregunta “¿por qué lo hicieron así?”, aquí está la respuesta, con la cifra que la motivó y las opciones que descartamos.
2. **Que cualquier integrante lo entienda:** cualquiera del equipo puede saber qué decidimos, cuándo y por qué.
3. **Mostrar el método:** no programamos el proyecto “de golpe”. Cada punto importante lo decidimos con opciones a la vista.

Cómo tomamos cada decisión

Desde el inicio nos pusimos una regla de trabajo: nada de cajas negras. Cada paso tenía que poder explicarse y defenderse con datos reales, no con suposiciones. De ahí salió el mismo protocolo para cada decisión:

1. Planteamos qué había que decidir y **con qué cifra real**.
2. Pusimos sobre la mesa **2 o 3 opciones**, con sus pros y contras.
3. **Elegimos una** y escribimos por qué.
4. La decisión quedó en una nota (`docs/decisiones/NN-nombre.md`) con las opciones descartadas, la evidencia (cifra, archivo y función) y la consecuencia.

Las decisiones *técnicas* menores (por ejemplo, qué librería usar para leer un Excel) las tomamos con su razón escrita, sin abrir una discusión de opciones. Aquí se marcan como “decisión técnica”.

Cómo está escrita cada decisión

Fase · número · nombre corto · fecha

La pregunta: qué había que decidir y por qué importaba.

Las opciones: cada una con lo que tenía a favor y en contra. La elegida va marcada.

Lo que decidimos: la opción elegida y la razón.

Evidencia: la cifra real que sostiene la decisión.

Consecuencia: qué cambió en el proyecto.

Al final de cada fase hay una caja de **errores encontrados y corregidos**. No los escondemos: son la prueba de que revisamos las cifras en lugar de aceptarlas a ciegas.

Las 12 fases de un vistazo

Fase	Nombre	Qué resolvió	Fechas	Notas
0	Cimientos	El plan, las reglas y la computadora lista	26–27 sep	00, 02
1	Descarga	353 archivos oficiales, 8,134,802 registros	27–28 sep	03
2	Limpieza	14 fuentes limpias, almacén y diccionario	28 sep – 2 oct	04, 10, 18
3	Planteamiento	Los 5 lugares y la desigualdad medida	28 sep	01, 05
4	Radar	Índice de presión, estados y predicción	28–29 sep	08, 09
5	Pronóstico	12 meses, tormentas y escenarios	30 sep – 1 oct	11, 12, 15
6	Presupuesto	El reparto óptimo del dinero	2 oct	19
7	Torre en vivo	La campaña semana a semana	2 oct	20
8	Campaña	Personas, marca, mensajes, medios, indicadores	2 oct	21
9	Servidor	La página calcula en vivo	2 oct	22
10	Página final	Accesibilidad (sin prueba con personas)	2 oct	23
11	Cierre	Trazabilidad, guías, entrega y coloquio	2–3 oct	24
—	La página web	En paralelo a todas las fases	28 sep – 2 oct	06, 07, 12–17

Fuentes de este documento: las 25 notas de decisión (00 a 24) y la bitácora de decisiones cerradas del proyecto. Para las fórmulas de cada modelo, ver la *Guía técnica*; para la explicación sin fórmulas, la *Guía sencilla*.

PARTE I

Antes de los modelos

CAPÍTULO 1

Fase 0: el plan, las reglas y la computadora

Fechas: 26 y 27 de septiembre de 2026. **Notas:** 00-fundacion.md, 02-entorno.md.

Qué buscábamos: decidir qué proyecto hacer, con qué reglas y cómo trabajar, y dejar la computadora lista para procesar millones de datos con Spark.

0.1 · El estado · 26-sep-2026

La pregunta: el Problema Prototípico pide elegir un estado de México.

Lo que decidimos: Quintana Roo.

Por qué: es el estado más visitado del Caribe mexicano, con un problema de saturación visible en 2026 (sargazo, Tulum, Cozumel) y con fuentes oficiales abundantes (SITUR-Q, DataTur, INAH).

0.2 · Empezar desde cero · 26-sep-2026

La pregunta: ya existía un proyecto anterior (el paquete `cauce`, con modelos, personas y cifras). ¿Lo reutilizábamos?

Lo que decidimos: empezar desde cero. Revisamos los flujos del proyecto anterior y no nos convencieron.

Descartado: portar el paquete anterior y reentrenar sus modelos.

Consecuencia: no usamos ninguna cifra, modelo ni flujo del proyecto anterior. Diseñamos y validamos cada técnica de nuevo, fase por fase.

0.3 · Qué sistema construir: la fusión de tres alternativas · 27-sep-2026

La pregunta: antes de programar, armamos cinco alternativas que cumplieran toda la rúbrica y **cuyos datos ya estuvieran verificados**, para no descubrir a medio camino que una no era posible:

Alternativa	Idea central
A1 Radar	Medir dónde hay presión y dónde hay espacio hoy
A2 Voz del viajero	Construir la campaña desde las reseñas de los turistas
A3 Pronóstico	Predecir cuándo conviene ir y cuánto invertir
A4 Portafolio	Tratar los destinos como un portafolio de inversión
A5 Tiempo casi real	Ajustar la campaña semana a semana mientras corre

Lo que decidimos: fusionar **A1, A3 y A5**, con la condición de que no se enciman y funcionen juntas en la página.

Cómo evitamos que se enciman: cada módulo responde una sola pregunta en un solo horizonte de tiempo: el Radar, *dónde* hoy (semanas); el Pronóstico, *cuándo* y *cuánto* (1 a 12 meses); la Torre, *qué hacer esta semana*. Markov trabaja solo en semanas y Monte Carlo solo en meses; el clasificador predice un estado y el pronóstico un número; hay un solo modelo de optimización con dos etapas, y la Torre no entrena modelos propios.

Descartado: A2 y A4 como ejes. La minería de texto de A2 la conservamos para construir a las viajeras ideales.

Evidencia de que había datos: DataTur publica 135 archivos semanales de ocupación con 7 centros de Quintana Roo; SITUR-Q responde 45 indicadores por su API; la NOAA tiene las tormentas desde 1851.

0.4 · Cómo trabajar · 26-sep-2026

Lo que decidimos: trabajar sin cajas negras. Cada decisión se explica con datos reales, no con suposiciones, y cada paso se programa en piezas pequeñas que podemos correr y revisar.

Consecuencia: un protocolo de cinco pasos (cifra real, opciones, elección, pieza pequeña, nota escrita), una fase a la vez, y unas reglas de oro: no inventar datos, toda cifra rastreable, lo estimado se marca con `_est`, nada de *scraping* prohibido, y si falta un dato, nos detenemos y lo declaramos.

0.5 · Ecuaciones y “cómo lo resolvimos” · 27-sep-2026

Lo que decidimos: como es un proyecto escolar, cada modelo tenía que llevar sus ecuaciones y cómo las resolvimos.

Consecuencia: documentamos cada modelo con cinco partes: la ecuación, sus supuestos, el método de resolución paso a paso, un ejemplo resuelto a mano con números reales y dónde está en el código. Todo está en la *Guía técnica* y en los notebooks.

0.6 · Herramientas de trabajo · 27-sep-2026

Lo que decidimos: repositorio **git** (historial de cada cambio) y **Graphify**, un mapa de conocimiento que conecta reglas, fuentes, módulos y regiones. La carpeta del proyecto anterior quedó **fuera** del mapa.

Más tarde (30-sep-2026): hicimos **público** el repositorio y publicamos la página en GitHub Pages. Los datos crudos nunca se suben.

0.7 · La computadora: Spark en Windows · 27-sep-2026

La pregunta: la máquina solo tenía Java 1.8. PySpark 4, lo que instala pip por defecto, exige Java 17. Y en Windows, Spark no escribe Parquet sin dos archivos de Hadoop (`winutils.exe` y `hadoop.dll`).

Opción	A favor	En contra
Entorno propio: PySpark 3.5.6 + Java 17 + Hadoop 3.3.6 (elegida)	Versiones compatibles y verificadas; Java 17 solo dentro del proyecto	Hay que instalar Java 17
Spark dentro de Docker	Funciona igual en cualquier computadora	Pesado de arrancar y de explicar el día del coloquio
Cambiar el Java de todo Windows	Simple	Podía romper otros programas que usan Java 8

Evidencia: la prueba de humo (`tests/test_entorno.py`) leyó un CSV de 3 filas con Spark, escribió Parquet, lo volvió a leer y la suma dio $1 + 2 + 3 = 6$, la esperada. Guardamos los dos archivos de Hadoop con su huella SHA-256.

0.8 · No promover destinos de playa en 2026 · 27-sep-2026

La pregunta: ¿qué tipo de destino promover?

Evidencia: sargazo récord (más de 104,700 toneladas; 56 de 140 playas en rojo en agosto, y la franja más afectada va de Tulum a Xcalak); crisis de Tulum (ventas hasta -60% , cierres); Cozumel declarado lleno por cruceros; Isla Mujeres con carencias de agua y drenaje; Holbox con más de 90,000 toneladas de basura acumulada.

Consecuencia: la campaña deja de ser de playa. Se vuelve una ruta de cultura, bahía, laguna y comunidad en el sur, que confirmamos con una tabla de criterios calculada con datos en la Fase 3.

0.9 · Un documento ejecutivo para el equipo · 28-sep-2026

Lo que decidimos: al cerrar cada fase agregamos un capítulo en lenguaje no técnico, con el estilo de la UNRC, que sirve de base para redactar el informe en limpio. Se genera como PDF con un comando.

CAPÍTULO 2

Fase 1: descargar los datos oficiales (Bronze)

Fechas: 27 y 28 de septiembre de 2026. **Nota:** 03-ingesta.md.

Qué buscábamos: bajar todas las fuentes del inventario con código reproducible, sin modificarlas, y contar sus registros reales para saber con qué se cuenta y qué falta.

1.1 · Cómo descargar · 27-sep-2026

Opción	Por qué sí o por qué no
Programas de descarga con manifiesto SHA-256 (elegida)	Cualquiera puede volver a bajar todo con un comando; cada archivo queda con su huella, tamaño, URL, fecha y número de registros
Exportar a mano desde las páginas	Más rápido la primera vez, pero no se puede repetir ni comprobar

Consecuencia: datos/bronze/MANIFIESTO.csv y una prueba que recalcula las 353 huellas.

1.2 · El DENUÉ: ¿solo Quintana Roo o el país? · 27-sep-2026

Elegida: los 32 estados (6,138,075 negocios, 574 MB).

Por qué: el criterio 2 de la rúbrica (12 %) pide volumen real y fuentes heterogéneas, y el total nacional da contexto (qué parte de los negocios turísticos del país está en Quintana Roo). **Descartado:** solo Quintana Roo (5.9 MB), que no justificaría Spark.

1.3 · ¿Limpiar al descargar? · 27-sep-2026

Elegida: no. La caja de bronce es idéntica a la fuente; la limpieza va en la caja de plata (Fase 2).

Descartado: limpiar al vuelo, porque se pierde el original y una regla equivocada no se podría rehacer.

1.4 · Costos de anuncios (fuente D13) · 28-sep-2026

La pregunta: el modelo de presupuesto necesita cuánto cuesta un clic y cuántos convierten en Google y Facebook.

Elegida: leer las tablas originales de WordStream y LocaliQ con un navegador automati-

zados (Playwright) y guardar captura de página completa como evidencia: 386 filas de 23 industrias.

Descartado: copiar cifras de resúmenes en internet. **Evidencia de por qué:** un resumen decía que la tasa de clics de *Travel* en Google era 8.24 %; la tabla oficial dice **8.73 %**.

Hueco encontrado: las tablas de conversión de Facebook **no traen la categoría Travel**. Se decidió cómo tratarlo en la Fase 6.

1.5 · El sargazo en la Bahía de Chetumal · 28-sep-2026

La pregunta: dos de los lugares (Chetumal y Calderitas) están frente a la bahía. ¿Hay sargazo?

Lo que se encontró: el semáforo oficial diario solo se publica en Facebook, cuyos términos prohíben extraerlo con programas. **Elegido:** guardar como evidencia (HTML y captura) las publicaciones públicas de ECOSUR y la prensa.

Evidencia: ECOSUR confirma sargazo en los canales de entrada a la bahía (Canal de Zaragoza y río Bacalar Chico), pero no hay reporte en la costa de Chetumal ni de Calderitas.

Consecuencia: siguen como destinos, *con vigilancia*; si se confirma sargazo en su costa, la Torre pausa su promoción.

Resultado de la fase

353 archivos, 8,134,802 registros, 824 MB de 15 fuentes. Las más grandes: DENUÉ (6,138,075), clima (767,016), nacionalidades (521,364), Compendio 2024 (295,191), Rest-Mex (208,051) e INAH (71,562).

El hallazgo que cambió el plan

El plan suponía que el hueco de ocupación hotelera era solo del sur. Al descargar se vio que **SITUR-Q no publica ocupación de 2025–2026 para ningún destino**, ni siquiera Cancún. Para esos años, la única ocupación medida es la semanal de DataTur, y solo para 7 centros del norte. Además: la afluencia y la derrama de SITUR-Q terminan en marzo de 2024, y el indicador “Turista - Afluencia” devolvió error 500 en sus 120 consultas (se guardó como hueco con el error exacto).

Consecuencia: la Fase 3 tuvo que decidir cómo medir el sur sin ocupación (decisión 3.4).

Lo que salió mal y cómo lo corregimos

- **DENUÉ inflado:** el conteo decía 6,139,989; Spark contó 6,138,075 y un lector independiente le dio la razón. Cada uno de los 33 zips trae un diccionario de 58 líneas que se sumaba como negocios ($33 \times 58 = 1,914$).

- **Censo inflado dos veces:** 2,547 → 2,257 (diccionario) → **2,243** (un catálogo de 14 filas). Ahora solo se cuenta la carpeta de datos.
- **SITUR-Q rechazaba las peticiones** ("Origin not allowed"): se envían los mismos encabezados que el navegador.
- **El Estado de México viene en dos partes:** el programa busca las partes y revisa que cada descarga sea un zip real.
- **Open-Meteo respondía "demasiadas peticiones":** se pide un año por consulta, con espera y reintento. Dos archivos duplicados del primer intento se borraron del disco y del manifiesto.

Los archivos descargados nunca estuvieron mal: solo los conteos, y los corregimos en todos los documentos.

CAPÍTULO 3

Fase 2: limpiar y ordenar los datos (Silver y Gold)

Fechas: del 28 de septiembre al 2 de octubre de 2026. **Notas:** 04-silver.md, 10-silver-fase5.md, 18-cierre-fase-2.md.

Qué buscábamos: convertir 14 fuentes distintas en tablas limpias, con las mismas reglas, documentadas y consultables.

Por qué duró tanto: decidimos construir la página en paralelo y abrir las Fases 3 y 4 con las fuentes que ya estaban limpias. Las demás las limpiamos justo antes de la fase que las usaba: clima, huracanes y tipo de cambio antes del Pronóstico; nacionalidades, vuelos, cruceros y reseñas antes de la campaña. Una auditoría (29-sep) lo hizo visible y cerramos la fase el 2 de octubre.

2.1 · La página, en paralelo · 28-sep-2026

Elegida: construir la página web desde la Fase 2, junto con los datos. **Descartado:** esperar al final. **Consecuencia:** la página creció con cada fase (ver el capítulo 11).

2.2 · Qué es "oferta turística" · 28-sep-2026

Elegida: los giros SCIAN característicos del turismo según SECTUR e INEGI: alojamiento (721), alimentos y bebidas (722), agencias de viajes (5615), transporte turístico (487), museos y sitios (712) y esparcimiento (713).

Resultado: 875,667 negocios turísticos en el país (14.3 %) y **13,663 en Quintana Roo** (19.7 % de sus 69,260).

2.3 · Tren Maya con dos renglones por mes · 28-sep-2026

Elegida: sumar las estaciones de cada destino. **Evidencia:** la suma cuadra exacto con el total de la zona. Enero de 2025, Gran Costa Maya: 7,084 = Chetumal (24 + 3,478) + Bacalar (213 + 3,369).

2.4 · Los ceros imposibles · 28-sep-2026

La pregunta: SITUR-Q trae ceros donde no puede haber cero.

Caso	Regla	Por qué
Ocupación con 0 cuartos disponibles	Hueco (693 filas)	Físicamente imposible
Afluencia y derrama en 0	Hueco	Un destino no recibe cero turistas ni cero pesos
Los 4 aeropuertos en 0 todo 2025	Hueco si <i>todos</i> marcan 0 ese mes (114 filas)	Cancún promedió 72.2 % de ocupación en 2025: es la fuente la que dejó de publicar
Zona arqueológica con 0	Se conserva, marcada	Suele ser un cierre real (Muyil, 2024–2026)
Cruce de 2020 en 0	Se conserva	Puertos cerrados por la pandemia

Descartado: conservar los ceros. La página habría dicho “0 pasajeros en avión en 2025”.

Consecuencia: la página usa 2024 como último año completo del avión (15,959,277 pasajeros) y lo dice.

2.5 · Qué tormenta “afecta al sur” · 30-sep-2026

Opción	Eventos	Por año	Problema
200 km · □ 34 nudos · desde 1966 (elegida)	31 en 60 años	0.517	—
100 km · □ 34 nudos · desde 1966	13	0.217	Muy pocos para una tasa por mes
300 km · □ 34 nudos · desde 1966	59	0.983	Mete tormentas sin viento fuerte en el sur
200 km · □ 34 nudos · desde 1851	82 en 175	0.469	Antes de los satélites se perdían tormentas

Evidencia: 23 de los 31 eventos caen de agosto a octubre; entre ellos Carmen (1974, a 15.3 km de Chetumal con 125 nudos) y Dean (2007). Guardamos los 55,524 puntos de trayectoria con su distancia, para poder cambiar el radio sin volver al texto crudo.

2.6 · Clima: dos tablas y hora local · 30-sep-2026

Decisión técnica: una tabla diaria (1950–2026, para medir la temporada de lluvias) y una horaria (2019–2026, para la Torre). El crudo horario viene en UTC; se pasa a hora local restando 5 horas (Quintana Roo usa UTC–5 fijo desde 2015). 0 huecos en los 128 archivos.

Hueco declarado: no hay punto de clima propio para la Laguna Milagros ni para Calderitas; se usa Chetumal (a 7.7 km de Calderitas y 18.9 km de Xul-Ha), y se dice.

2.7 · Feriados sin tipo de cambio · 30-sep-2026

Elegida: se quedan vacíos (336 días), con su bandera. El promedio del mes se saca solo con los días observados y se guarda cuántos fueron (agosto de 2026: 21 días, 17.0609 pesos por dólar).

Descartado: copiar el día anterior, porque inventa una cotización que no existió; y usar el último dato del mes, porque depende de un solo día.

2.8 · AFAC: dos aerolíneas con la misma etiqueta · 2-oct-2026

La pregunta: el archivo de vuelos traía 300 llaves repetidas: 98 renglones idénticos (se deja uno), 177 con una cifra y una copia en cero (se conserva la cifra) y **25 con dos cifras distintas**, todas de “Virgin America (Alaska Airlines)”, de 2016 a enero de 2018.

Opción	Por qué sí o por qué no
Sumarlas (elegida)	Son dos aerolíneas que se fusionaron en 2018 bajo una sola etiqueta; en juego hay 369,311 pasajeros de 1,042 millones (0.035 %)
Dos renglones marcados	Obliga a recordarlo en cada suma
Dejar AFAC fuera	Se pierde una fuente por 25 renglones

Regla de paro: si aparece otra etiqueta con dos cifras, el proceso se detiene.

2.9 · Dónde consultar los datos: el almacén · 2-oct-2026

Elegida: DuckDB, una base en un solo archivo que lee los Parquet sin copiarlos, con un **modelo estrella**: la tabla de hechos (lugar × mes × variable, 3,287 renglones) y las dimensiones de lugares (15) y meses (192). **Un hueco no tiene renglón.**

Descartado: PostgreSQL, porque exige un servidor y el proyecto debe correr sin internet en cualquier computadora.

Consecuencia: un diccionario de datos generado solo, de **56 tablas**. Si una columna no tiene significado escrito, el programa se detiene.

2.10 · Cuando dos fuentes no coinciden

Isla Mujeres: las noticias decían 93.5 % y 95 % de ocupación en 2026; DataTur registra 74.7 % (febrero) y 43.2 % (abril). **Regla:** el dato oficial va antes que la nota de prensa.

Cruceros: en Mahahual, SITUR-Q cuenta siempre entre 11 % y 35 % más que DataTur; en Cozumel casi coinciden (2025: $4,915,242 \div 4,724,255 - 1 = +4.0 \%$). **Regla:** una fuente por lugar, y declaramos la diferencia.

Hallazgo para la campaña

Al aeropuerto de Chetumal llegaron **250 extranjeros** en todo 2025; a Cancún, 9,408,423. El viajero extranjero no llega al sur en avión: el anuncio tiene que alcanzarlo antes del viaje o cuando ya está en Cancún. Esto decidió las personas de la Fase 8.

Lo que salió mal y cómo lo corregimos

- **Afluencia y derrama** parecían llegar a junio de 2024 por unos ceros; terminan en marzo de 2024.
- **Huracanes:** dos líneas mal escritas en el archivo oficial. Una (1975) no dice si la latitud es norte o sur: se dejó vacía, sin adivinar. La primera exploración saltaba esa línea sin avisar (55,523 puntos); el código final se detiene si no entiende una línea (55,524).
- **INAH:** el bloque de extranjeros de septiembre de 2025 venía dos veces, una con cifras y otra en ceros.
- **DataTur:** un mismo centro contaba dos veces por las marcas de nota ("ISLA MUJERES /4") y las notas al pie se leían como centros.
- **Windows:** la ruta de la carpeta tiene espacios y Spark la cortaba; se usa la ruta corta.
- **Revisión del 2 de octubre:** el diccionario se detuvo porque 12 tablas nuevas no tenían descripción.

CAPÍTULO 4

Fase 3: elegir y medir los cinco lugares

Fecha: 28 de septiembre de 2026. **Notas:** 01-regiones.md, 05-planteamiento.md.

Qué buscábamos: decidir qué lugares promueve la campaña con criterios medidos, y plantear el problema (variables, actores y relaciones) con cifras.

3.1 · De 8 regiones a 5 · 27 y 28-sep-2026

Primera versión (27-sep): buscamos al menos 6 regiones sin los problemas de 2026, y elegimos 8 destinos (Chetumal, Calderitas–Oxtankah, la Ruta arqueológica, Maya Ka'an + Kantemó, Cobá + Punta Laguna, Muyil, Laguna Milagros–Xul-Ha y Ribera del Río Hondo) más Cancún y Riviera Maya como emisoras.

Revisión (28-sep): decidimos no meter nada con sargazo, cierres o relación con Tulum, y enfocarnos en 5.

Región retirada	Motivo
Cobá + Punta Laguna	Municipio de Tulum. Tenía buenos datos (74.4 % de capacidad probada sin usar), pero su imagen va ligada a Tulum
Muyil	Cerrada del 4 de junio de 2024 al 10 de febrero de 2026 (INAH) y colinda con Tulum
Ribera del Río Hondo	Ninguna serie turística propia
Chacchoben	El 92 % de sus visitantes llega en crucero por Mahahual (franja de sargazo)
Kantunilkin–Chiquilá	Evidencia débil; es la puerta de Holbox

Las 5: Chetumal · Bahía Calderitas–Oxtankah · Ruta arqueológica del sur (Kohunlich, Dzibanché, Ichkabal) · Maya Ka'an + Kantemó · Laguna Milagros–Xul-Ha. La quinta salió de las que quedaban: la Laguna no tiene sargazo ni cierres y está en el mismo municipio que Chetumal.

Evidencia (INAH): la zona de Tulum cayó 31.3 % en enero–julio de 2026 (de 692,946 a 476,247); la Ruta recibe 15.5 veces menos visitantes que Tulum (66,628 contra 1,031,443 en 2025).

3.2 · El norte: ¿quitarlo o dejarlo como referencia? · 28-sep-2026

Elegida: Cancún, Riviera Maya y Tulum **solo como referencia**, nunca como destino promovido.

Descartado: quitarlos por completo. **Por qué:** la única ocupación hotelera medida en 2025–2026 es la del norte (DataTur), y sin ella no se puede medir de dónde se redistribuye ni comparar escenarios (criterios 6 y 9 de la rúbrica).

3.3 · La población: ¿por municipio o por localidad? · 28-sep-2026

Elegida: por localidad (Censo 2020). **Por qué:** 4 de los 5 lugares están en Othón P. Blanco (233,648 habitantes); con la cifra municipal tendrían el mismo denominador y no se podrían comparar.

Región	Localidades	Población
Chetumal	Chetumal	169,028
Bahía	Calderitas	5,551
Laguna Milagros	Xul-Ha y Huay-Pix	4,182
Ruta arqueológica	Nicolás Bravo, Morocoy, Francisco Villa	6,098
Maya Ka'an + Kantemó	Felipe Carrillo Puerto, Tihosuco, Chunhuhub, Señor, Kantemó	44,388

Riesgo declarado: la lista es un criterio del proyecto, no una delimitación oficial. El código se detiene si una clave no corresponde al nombre esperado (hay un “Xul-Ha” en Puerto Morelos).

3.4 · El sur sin ocupación hotelera · 28-sep-2026

Opción	Por qué sí o por qué no
Medir la presión de llegada y mostrar “sin dato oficial” (elegida)	Usa solo lo medido hasta 2026: Tren Maya (3,843 bajaron en Chetumal en julio de 2026), cruces de Belice (49,097 en junio), INAH y cuartos
Estimar la ocupación con un modelo (_est)	Sería una cifra estimada donde nadie midió; con solo 36 meses de Chetumal, además, poco confiable

3.5 · El criterio de cierres · 28-sep-2026

La pregunta: las zonas del sur también cerraron por obras en 2024 (Oxtankah de octubre de 2023 a octubre de 2024, Kohunlich de marzo a diciembre de 2024, Dzibanché de febrero de 2024 a enero de 2025). Muyil salió por cierre: hacía falta una regla igual para todas.

Elegida: una zona pasa si lleva **al menos 12 meses seguidos abierta** y no tuvo cierres en 2026. Pasan Oxtankah (21 meses), Kohunlich (19) y Dzibanché (18); Muyil (6) no.

Descartado: “ningún cierre desde 2024”, que habría sacado a la Ruta y a la Bahía y dejado solo 3 regiones.

3.6 · Cómo se suman los cuartos del estado · 28-sep-2026

Hallazgo: en SITUR-Q una zona no es la suma de sus miembros. En julio de 2026 la Riviera Maya tenía 59,632 cuartos, contra 22,923 de Playa del Carmen + Tulum: **36,709 de diferencia** (lugares que no se publican por separado).

Elegida: el total estatal suma destinos + zonas (**140,664 cuartos**). **Descartado:** destinos + miembros, que perdería esos 36,709 cuartos.

Resultado: el problema medido

La tabla de criterios (sargazo, cierres, ocupación, presión por residente, oferta, servicios y series disponibles): las 5 regiones pasan. Donde hay dato, sus hoteles se llenaron mucho menos en 2024 (Chetumal 58 %, Maya Ka'an 39 %) que los del norte (74–77 %).

La relación central, con cuotas y el índice de Herfindahl-Hirschman:

Dimensión	Concentración	Parte de los 5	Contra su población
Llegadas en avión (2024)	0.811	1.4 %	0.11
Cuartos de hotel (jul-2026)	0.219	1.7 %	0.14
Visitantes INAH (2025)	0.276	4.1 %	0.33
Negocios turísticos	0.133	14.4 %	1.17
Población (2020)	0.225	12.3 %	1.00

Lectura: los negocios siguen a la población; los visitantes, no. Es capacidad ociosa.

Un hallazgo que no se escondió

Kohunlich (+13.5 %) y Dzibanché (+69.2 %) crecen en 2026, pero la Ruta completa bajó 8.2 % porque Ichkabal cayó 27.5 %. **Decisión:** no destacar en la portada solo las zonas que suben, porque sería escoger datos a conveniencia.

PARTE II

Los modelos

CAPÍTULO 5

Fase 4: el Radar, ¿dónde hay espacio?

Fechas: 28 y 29 de septiembre de 2026. **Notas:** 08-radar.md, 09-auditoria-fases-1-4.md.

Qué buscábamos: un índice de presión de 0 a 1 por lugar y mes, un estado en palabras (tranquilo, concurrido, saturado) y una predicción del estado futuro.

4.1 · Los pesos del índice · 28-sep-2026

Evidencia que motivó la pregunta: el sur solo tiene 4 series mensuales en 2025–2026; el norte tiene además la ocupación semanal.

Opción	Por qué sí o por qué no
Pesos iguales con sensibilidad de $\pm 50\%$ (elegida)	Fácil de defender; no premia al norte por tener más series
Componentes principales	Pesos “objetivos”, pero difíciles de explicar e inestables con 19 meses del sur
Criterio del equipo	Subjetivo; cada número habría que justificarlo

Resultado: moviendo cada peso a 0.5 y 1.5, cambia de estado entre el 0.6 % y el 6.0 % de los lugar-mes.

4.2 · Los cortes entre estados · 28-sep-2026

Elegida: percentiles comunes a todo el estado: debajo de la mediana, tranquilo; arriba del percentil 90, saturado.

Descartados: terciles de cada lugar (todo lugar saldría “saturado” un tercio del tiempo aunque nunca se llene: Cozumel promedia 53 %) y grupos k-means (los grupos pueden no significar nada y cambian al agregar datos).

4.3 · Predecir con aprendizaje de máquina · 28-sep-2026

Lo que decidimos: con los datos que tenemos, inferir los estados futuros con aprendizaje de máquina.

Consecuencia: un clasificador del estado del mes siguiente (logística, Random Forest y Gradient Boosting) y una cadena de Markov. El Radar predice *estados*; los *niveles* son de la Fase 5.

4.4 · La escala de las variables · 29-sep-2026

Evidencia presentada: en mín-máx, el mes típico de visitantes INAH por mil habitantes cae en 0.02, el del Tren Maya en 0.06, el de cruceros en 0.11, el de ocupación en 0.70 y el de Belice en 0.74.

Elegida: mín-máx con mínimo y máximo comunes. **Descartados:** percentil común (pierde las proporciones) y mín-máx sobre logaritmo (más difícil de explicar).

4.5 · La prueba de validez que falló: opción D · 29-sep-2026

Lo que pasó: con solo SITUR-Q, Cancún salía “tranquilo” en julio de 2026 (0.025), porque SITUR-Q dejó de publicar su ocupación; DataTur marcaba 68.8 %. Además, Chetumal (0.57) salía más presionado que Cancún (0.27) en 2024 por los cruces de Belice.

Variante	Cancún	Isla M.	Chetumal	Ruta	Problema
A. Mín-máx, solo SITUR-Q	0.02	—	0.39	0.14	El norte “desaparece”
B. + ocupación DataTur	0.28	0.45	0.39	0.14	Chetumal arriba de Cancún
C. Percentil + DataTur	0.44	0.25	0.48	0.71	La Ruta arriba de Cancún
D. B sin componentes de un solo lugar	0.28	0.45	0.05	0.14	Quiebre de 2025

Elegimos la D. La ocupación de los 4 lugares que mide DataTur viene de DataTur en toda su historia, y un componente entra solo si lo tienen al menos 2 lugares (sale Belice, que solo tiene Chetumal).

4.6 · Qué índice se usa para predecir y cuál se publica · 29-sep-2026

El problema: en 2025 Chetumal “cayó” de 0.54 a 0.05 porque perdió la ocupación, no porque llegara menos gente. Un modelo aprendería ese cambio de datos como si fuera presión.

Elegida: el **índice comparable:** cada lugar usa solo las medidas que tiene hoy, y solo en los meses en que las tiene todas. Se usa para predecir y para publicar (un solo índice: con dos, Cancún salía “tranquilo” en uno y “concurrido” en el otro el mismo mes).

Descartados: entrenar solo con 2025–2026 (19 meses por lugar) y entrenar todo con una bandera “tiene ocupación” (el modelo aprendería el cambio de datos).

4.7 · Cómo elegir el modelo · 29-sep-2026

Nuestro criterio: el que más acierta y, a igualdad, el que más cambios anticipa, porque la regla anti-colapso necesita anticipar.

Descartado: elegir por F1-macro, la métrica del plan.

Resultado vigente (tras la auditoría): la regresión logística, con 130 de 156 aciertos y 8 de 30 cambios anticipados, contra 130 y 6 de Random Forest y 126 y 0 de “igual que este mes”. Antes de la auditoría, el mismo criterio daba Random Forest: **se respeta el criterio, no el nombre del modelo**, y el código elige solo.

Lectura honesta: el estado se repite el 81 % de los meses, así que el modelo agrega poco; su valor está en los cambios que anticipa. En los 5 lugares hubo solo 2 cambios en 48 casos y no anticipó ninguno: no se puede afirmar que anticipe saturaciones del sur.

4.8 · Markov: ¿semanal o mensual? · 29-sep-2026

Elegida: semanal, solo el norte (7 centros de DataTur, 239 semanas, 1,666 transiciones). Es lo que marca el plan (Markov en semanas, el Pronóstico en meses) y sirve a la campaña: cuando el norte se va a saturar, es el momento de ofrecer el sur.

Descartados: mensual para todos (repetía al clasificador y se encimaba con la Fase 5) y los dos.

Resultado: mejor puntaje de Brier que la persistencia a 1, 4 y 8 semanas (0.200 contra 0.225; 0.389 contra 0.484; 0.490 contra 0.676).

La auditoría del 29 de septiembre

Antes de seguir, auditamos las Fases 1 a 4 contra el plan. Revisamos punto por punto, volvimos a correr todo desde cero (las 8 tablas del Radar salieron idénticas) y una prueba nueva comprobó 20 cifras de los documentos contra el código. Faltaban tres puntos del plan:

4.9 · Lo que faltaba y lo que decidimos · 29-sep-2026

Hallazgo	Decisión y resultado
El índice no tenía “llegadas por cuarto” ni “densidad de oferta”	Se agregan llegadas por cuarto (tren + cruceros). La densidad no entra: es un solo corte en el tiempo y no señala meses. Vimos que con cruceros el componente queda dominado por los puertos (Mahahual: 432 por cuarto al mes) y decidimos mantener tren + cruceros, declarándolo
Faltaba el agrupamiento de los centros del país	Ward con 55 centros completos; $k = 2$ por silueta (0.450). Descartado $k = 7$ (0.317)
DataTur mide menos que SITUR-Q	Lo declaramos, sin ajustar: Cozumel –14.5, Isla Mujeres –19.3, Cancún –1.6 puntos. El error es conservador (el norte se ve menos lleno). Descartado calibrar, que volvería estimación la ocupación del norte
El sesgo del modelo	Medido y declarado (decisión 4.7)

Cifras vigentes: cortes del índice comparable 0.186 y 0.756; en julio de 2026 los 5 lugares

están tranquilos y Cancún (0.193) concurrido.

Lo que salió mal y cómo lo corregimos

- **La “ocupación” de 2,560,068:** SITUR-Q trae tres renglones por mes (cuartos disponibles, ocupados y el porcentaje) y el panel los sumaba. Ahora se recalcula ocupados entre disponibles (Chetumal 2024: 58.0%) y el panel se detiene si una variable trae dos renglones el mismo mes.
- **Visitantes contados dos veces:** la serie “zonas arqueológicas” de SITUR-Q es el INAH sumado por destino (Chetumal 2025: $39,459 = 11,017 + 21,850 + 6,592$). Se usa solo el INAH, zona por zona.

CAPÍTULO 6

Fase 5: el Pronóstico, ¿cuándo conviene ir?

Fechas: 30 de septiembre y 1 de octubre de 2026. **Notas:** 11-pronostico.md, 12-planeador.md, 15-norte-en-planeador.md.

Qué buscábamos: cuántos visitantes se esperan en cada lugar los próximos 12 meses, con un rango; la probabilidad de tormenta; escenarios malo, probable y bueno; y el riesgo de rebasar lo que cada lugar puede recibir.

5.1 · Qué se pronostica: “Medidas + norte” · 30-sep-2026

Opción	Por qué sí o por qué no
Medidas + norte (elegida)	Visitantes INAH de la Bahía y de la Ruta (127 meses), cruces de Belice por Chetumal (90) y la ocupación de Cancún como referencia (55): solo series medidas que llegan a 2026
Solo INAH	Chetumal se quedaría sin serie y no se sabría cuándo se llena el norte
Estimar la ocupación del sur	Contradice la decisión 3.4 y solo hay 36 meses de Chetumal

Huecos declarados: Maya Ka'an y la Laguna no tienen serie; el Tren Maya tiene solo 20–23 meses (para aprender la temporada hacen falta 24), así que se usa como variable, no se pronostica.

5.2 · Los meses que no deben enseñar: “Hueco + forma del año” · 30-sep-2026

La pregunta: un mes cerrado no es “cero demanda”. Si el modelo aprende de esos ceros, creerá que en abril puede no llegar nadie por temporada.

Elegida: los meses de cierre, los meses parciales (justo antes de cerrar o después de reabrir) y la pandemia se marcan y **no entrenan**, pero su valor se conserva. La forma del año se aprende de todos los años abiertos y el nivel, de los meses posteriores a la reapertura.

Descartados: entrenar solo desde la reapertura (19 meses, menos de los 24 necesarios) y tomar los ceros como dato (enseña una temporada falsa).

Evidencia: Kohunlich tuvo 21,850 visitantes en 2025 contra 42,813 en 2019: reabrió a la mitad. Una región toma el motivo de su zona más afectada (en enero de 2025 Kohunlich ya abría pero Dzibanché no: sumar solo las abiertas bajaría el total de forma artificial).

5.3 · La forma del año: clásica y no STL · 30-sep-2026

Decisión técnica: descomposición clásica multiplicativa sobre años completos. El plan decía STL, pero STL necesita una serie continua y tiraría los años posteriores a los huecos. STL quedó como segunda opinión (coincide entre 0.85 y 0.97). Es multiplicativa porque la temporada escala con el nivel.

Resultado: la Ruta recibe en enero 61 % más que un mes promedio (1.606) y en septiembre la mitad (0.496). Las zonas del sur se mueven con Cancún (parecido 0.83 y 0.72); Belice, no (0.26).

5.4 · Hasta cuándo dura la pandemia en Belice · 30-sep-2026

Lo que pasó: con la pandemia terminando en febrero de 2022, STL confundía la recuperación de la frontera con temporada (ponía marzo en 0.73, cuando los años completos lo ponen entre 0.92 y 1.18; parecido de solo 0.446). De marzo a junio de 2022 los cruces iban en 65.1, 69.5, 80.2 y 82.2 % de 2019; desde julio, nunca bajaron de 86 %.

Lo que decidimos: la pandemia de Belice termina en **junio de 2022**. El parecido sube a **0.847**. Belice entrena 62 meses en lugar de 66.

Precisión que se dejó escrita: la opción se presentó como “cuando los cruces vuelven a 80 % o más”; mayo ya estaba en 80.2 %, así que por ese criterio literal el corte sería abril. El de junio se sostiene en el salto a 86 % o más desde julio.

5.5 · Cómo elegir el modelo de pronóstico · 30-sep-2026

Contexto: comparamos 5 modelos “viajando al pasado” (origen móvil): la línea base (el mismo mes del año anterior), dos Holt-Winters con la forma del año fija (con y sin tendencia), una regresión con clima y Gradient Boosting. Cada uno con un rango del 90 % conformal y su cobertura medida.

Opción	Por qué sí o por qué no
Menor error con rango ☒ 80 % (elegida)	Un rango “del 90 %” que falla mucho engaña a quien planea
Menor error sin importar el rango	En la Ruta elegiría un modelo cuyo rango acierta solo 72 de cada 100 veces
Un solo modelo para todo	En Cancún la regresión se equivoca 58 % más que la línea base

Resultado: regresión con clima en la Bahía (error 15.7 %, rango cumplido 91.3 %), la Ruta (21.6 %; 80.3 %) y Belice (11.0 %; 94.1 %); línea base en Cancún (3.8 %; 89.3 %). Ejemplo: Bahía, diciembre de 2026, 1,311 visitantes (entre 959 y 1,793).

Decisiones técnicas que se declararon: la forma del año se fija porque desde las reaper-turas solo hay 17 a 20 meses seguidos; la variante sin tendencia se agregó después de ver que la tendencia pronosticaba –240 visitantes. La Ruta no llega a 90 % con ningún modelo (en 2023 cayó 10.7 % sin aviso), y el clima casi no mejora el pronóstico.

5.6 · El golpe de una tormenta: “Supuesto con barrido” · 30-sep-2026

La pregunta: la probabilidad de tormenta sí está medida (31 eventos, Poisson: agosto 13.9 %, al menos una en el año 40.3 %). Pero ¿cuántos visitantes quita? Solo hubo 3 meses con tormenta entre los que entrenan (Earl 2016, Franklin 2017, Lisa 2022).

Elegida: un supuesto con tres valores: 0 %, 25 % y 50 %. **Descartado:** solo mostrar la probabilidad, sin golpe en el escenario malo.

Resultado: con el golpe más duro, el escenario probable del año baja solo 1.2–2.3 %: las tormentas pesan en el mes, no en el año.

5.7 · ¿La campaña entra en los escenarios? · 30-sep-2026

Elegida: no, se ve en la Fase 6. Los escenarios son “lo que pasaría de todos modos”. **Descartado:** meter un efecto supuesto de +5 % o +10 %, que mezclaría un pronóstico medido con un número sin fuente.

5.8 · La capacidad de cada lugar: “Capacidad probada” · 30-sep-2026

Elegida: el mes más alto que cada lugar ya recibió: Ruta 10,465 (enero de 2018), Bahía 1,639 (abril de 2017) y Belice 65,792 (agosto de 2025).

Descartados: cuartos de hotel (se pronostican visitantes a zonas y cruces, no noches; habría que suponer cuántos se hospedan) y dejarlo para la Fase 6.

Resultado del Monte Carlo (10,000 futuros): riesgo de rebasar la capacidad en algún mes del año: Ruta 30.9 %, Bahía 24.2 %, Belice 38.3 %; concentrado en diciembre y enero.

El planeador de viaje (en la página)

Queríamos que la página sirviera para planear un viaje: que alguien elija lugar y mes, vea cómo va a estar y, si hay mucha gente o es temporada alta, reciba la recomendación de otra parte del sur; además, recomendar dónde hospedarse y dónde comer cerca, con un clasificador de texto y Google Maps.

5.9 · De dónde salen los lugares que se recomiendan · 1-oct-2026

Opción	Por qué sí o por qué no
DENUE + botón de Google Maps (elegida)	Negocios oficiales con coordenadas; el botón es un enlace público que abre Google Maps en otra pestaña. Sin scraping, sin llave, funciona sin internet
Scraping de Google Maps	Prohibido por sus términos y por la regla 4
API de Google Places	Llave con tarjeta, deja de funcionar sin internet y la llave quedaría expuesta en un repositorio público
Solo el mapa propio	100 % sin internet, pero menos útil para llegar

5.10 · Qué hace el NLP · 1-oct-2026

Elegido: un clasificador por **léxico** sobre nombres y giros (tipo de lugar, grupo y momento del día). **Por qué:** no hay etiquetas para entrenar un modelo estadístico; un léxico es honesto y se explica regla por regla.

Resultado: 1,587 de 2,042 negocios clasificados; **39 de 40** correctos en una muestra nueva revisada a mano.

5.11 · Cuándo es temporada alta · 1-oct-2026

Elegida: forma del año ≥ 1.20 o riesgo de rebasar la capacidad $\geq 10\%$. **Descartado:** el semáforo del Radar (es del mes actual, y los 5 lugares salen siempre tranquilos).

Ajuste al probarlo: sin una condición de lluvia, el mes sugerido casi siempre era junio, el más lluvioso (195 mm). Se agregó que llueva menos que la mediana.

5.12 · Cancún y Riviera Maya en el planeador · 1-oct-2026

Lo que decidimos: en el planeador, cambiar Maya Ka'an y la Laguna (que no tienen serie) por Cancún y la Riviera Maya, para quien pensaba ir al norte. Pueden aparecer, pero si su mes está lleno, la página recomienda un lugar del sur de forma visible, que no se pierda al bajar; así no rompemos la regla de promover solo el sur.

Temporada alta del norte: su ocupación cambia poco (Cancún, de 64.5 % a 80.7 %), así que con la regla del sur nunca sería temporada alta (su índice máximo es 1.08). **Elegido:** los **cortes del Radar** (ocupación $\geq 71.2\%$): Cancún queda en temporada alta de noviembre a abril. **Descartados:** la regla del sur (nunca recomendaría el sur) y solo "saturado" $\geq 85.9\%$ (ningún mes llega).

Consecuencia: la regla de oro 9 se ajustó. El norte aparece con la etiqueta "Referencia: la campaña no lo promueve" y, si está lleno, el planeador **siempre** recomienda un lugar del sur. La Riviera Maya entró al Pronóstico con el mismo método (Holt-Winters sin tendencia: el único con rango $\geq 80\%$, aunque con 72 % más error que la línea base; se declara).

CAPÍTULO 7

Fase 6: repartir el presupuesto

Fecha: 2 de octubre de 2026. **Nota:** 19-presupuesto.md.

Qué buscábamos: cuánto dinero va a cada lugar, mes y canal para traer el máximo de visitantes sin anunciar donde está lleno. Responde al incidente de Investigación de Operaciones: qué es “óptimo”, qué priorizar si los objetivos chocan, qué restricciones son indispensables y qué pasa si se cambian.

6.1 · Qué maximizar · 2-oct-2026

Opción	Por qué sí o por qué no
Visitantes esperados al sur (elegida)	Se mide directo con las tasas de conversión
Derrama económica	La de SITUR-Q no dice su unidad y termina en marzo de 2024: habría que suponer el gasto por persona
Visitantes con castigo por presión	Habría que inventar cuánto pesa el castigo

6.2 · El presupuesto · 2-oct-2026

Elegido: un solo monto, \$250,000 MXN al año, como supuesto (no hay un presupuesto real). Para los 9 meses con pronóstico (octubre de 2026 a junio de 2027): $250,000 \times 9/12 = \$187,500$.

Descartados: un barrido de tres montos y el rendimiento por cada \$10,000. (La sensibilidad igual prueba \$500,000 y \$1,000,000.)

6.3 · La conversión de Facebook, que no está publicada · 2-oct-2026

Elegida: barrido de 3 %, 5.75 % y 6.38 %. El caso base usa la de Google Travel (5.75 %); 6.38 % es la mediana de Facebook en todas las industrias.

Descartados: usar Facebook solo para alcance (sin conversiones) y una sola tasa supuesta.

Consecuencia: con el dólar a 17.06, Google trae 1.59 visitantes por cada \$1,000 y Facebook 6.61.

6.4 · Las restricciones · 2-oct-2026

Elegimos las cuatro: cero anuncio en temporada alta; tope de capacidad probada; piso de equidad de 15 % por lugar; tope de 70 % por canal.

Cómo se modeló: programación estocástica de dos etapas. Hoy se decide el dinero (x); en cada escenario del Monte Carlo (malo, probable, bueno, con pesos 30/40/30), una variable binaria (y) pausa el anuncio si el escenario más la campaña rebasa la capacidad. Se resuelve con PuLP y CBC en 0.3 segundos.

6.5 · El desempate · 2-oct-2026

Lo que pasó: como todos los lugares convierten igual (no hay dato de respuesta por lugar), había muchísimas soluciones con el mismo máximo. La computadora entregaba una esquina cualquiera: **los \$131,250 de la Ruta, todos en junio.**

Opción	Por qué sí o por qué no
Proporcional al espacio libre (elegida)	Entre las soluciones con el máximo de visitantes, la que reparte el dinero según el espacio que sobra cada mes
Tope de 25 % por mes	Es una regla nueva sin fuente
Dejarlo concentrado	Óptimo en papel, absurdo en la práctica

Ejemplo: la Ruta en octubre de 2026 tiene libre $1 - 3,688/10,465 = 0.648$ de su capacidad; le toca el 8.1 % de cada canal: \$10,624 de Facebook y \$4,553 de Google.

Resultado

- **957 visitantes esperados** con \$187,500, unos **\$196 por visitante**. Ruta 41.5 %, Bahía 36.9 %, Chetumal 21.6 %. Facebook 70 % y Google 30 % en cada mes.
- **Sin anuncio:** diciembre en los tres lugares, enero en la Ruta y la Bahía, marzo en la Ruta y abril en la Bahía (20 de 27 combinaciones quedan permitidas).
- **Las reglas de cuidado cuestan 0 visitantes;** el tope por canal cuesta 282 (29.5 %) y se mantiene por riesgo.
- **Precios sombra:** \$1,000 más de presupuesto traen 1.59 visitantes; \$1,000 más permitidos a Facebook, 5.02.
- **Frontera de Pareto:** hasta 40 % de la capacidad probada no se pierde ningún visitante (con 35 %, 537; con 30 %, ninguno).
- **Sensibilidad:** el número de visitantes cambia (542 con 3 % de conversión; 3,827 con \$1,000,000), pero el reparto casi no.

Consecuencia: el plan mensual pasa a la Torre (Fase 7), que ejecuta la etapa 2 semana a semana, y a la campaña (Fase 8), que pone el mensaje y el público de cada anuncio.

CAPÍTULO 8

Fase 7: la Torre en vivo

Fecha: 2 de octubre de 2026. **Nota:** 20-torre-en-vivo.md.

Qué buscábamos: que la campaña se ajuste cada semana mientras corre. Responde a dos incidentes: el de Big Data (arquitectura de baja latencia para ajustar la campaña durante su ejecución) y el de Mercadotecnia (qué hacer si la afluencia rebasa la capacidad).

7.1 · Qué señales vigila · 2-oct-2026

Elegidas, las cuatro: ocupación del norte (DataTur semanal), tormentas cerca (HURDAT2, con la regla de la Fase 2), clima raro (Isolation Forest) y llegadas mensuales del sur contra lo esperado (el rango del 90 % del Pronóstico).

Detalle: llegadas *por debajo* del rango no pausan, porque eso es espacio, lo que la campaña busca.

7.2 · Qué hacer en el sur con una mala semana · 2-oct-2026

Opción	Por qué sí o por qué no
Pausar esa semana y guardar el dinero (elegida)	El dinero pasa a la siguiente semana permitida del mismo lugar; no se pierde
Bajar a la mitad	Se seguiría anunciando con mal clima
Solo avisar	No cuida nada

7.3 · Qué hacer si el norte se llena · 2-oct-2026

Elegida: encender “¿Ibas al norte?” si Cancún o la Riviera Maya llegan a 85.92 % (el corte de “saturado” del Radar), hacia el lugar del sur encendido con más espacio ese mes. **Descartado:** solo marcarlo.

7.4 · Cómo mostrarlo · 2-oct-2026

Elegida: reproducción grabada en la página, porque GitHub Pages es estático y no puede transmitir. **Descartado en ese momento:** además, transmisión en vivo con un servidor local. (Se agregó después, en la Fase 9.)

Cómo funciona: cada semana real se escribe como un archivo, y **Spark Structured Streaming** los lee de uno en uno (`maxFilesPerTrigger=1`), en orden, como si llegaran. En cada lote, el motor de reglas decide. Cambiar la carpeta por una fuente real no cambia el motor.

7.5 · Qué es “clima raro” · 2-oct-2026

Lo que pasó: el corte automático de Isolation Forest marcaba como raras el **47 %** de las semanas de Chetumal (e incluso 13–26 % dentro de su propio entrenamiento). Con 156 semanas no distinguía, y desde 2022 llueve más y hace más calor que en 2019–2021. Pausaría media campaña.

Opción	Por qué sí o por qué no
Más raro que el 95 % de las semanas que el bosque ya conoce (elegida)	Con un bosque por año que aprende de todos los años anteriores: 21 semanas raras en Chetumal (8.8 %) y 17 en Kohunlich (7.1 %)
Más raro que el 99 %	Casi nunca pausa
Quitar la señal	Se pierde la vigilancia del clima

Resultado: 239 semanas reales

- **239 lotes de Spark, en orden**, del 3 de enero de 2022 al 27 de julio de 2026.
- **48 pausas** de lugar-semana: 44 con clima raro, 9 con tormenta cerca (Lisa 2022, Nadine y Sara 2024) y 5 porque llegó más gente de la esperada a Chetumal en mayo de 2025 (algunas con más de un motivo).
- **No se perdió dinero:** los \$876,901 planeados se gastaron todos.
- **“¿Ibas al norte?” se encendió 6 semanas**, todas hacia la Bahía. El norte casi nunca se satura en una semana suelta (Cancún 1, Riviera Maya 9): su señal fuerte es la temporada.
- **Validación independiente:** el bosque marcó las tres semanas de tormenta sin saber que hubo tormenta.

Limitaciones declaradas: el sur no tiene ningún dato semanal oficial; las tormentas de 2026 todavía no se publican (“sin dato”, no “sin tormenta”); se supone que el dato del mes se conoce al empezar el siguiente (en realidad tarda 1–2 meses); el plan de dinero se aplicó a años pasados.

PARTE III

La campaña y el cierre

Fase 8: la campaña “El sur tiene espacio”

Fecha: 2 de octubre de 2026. **Nota:** 21-campana.md.

Qué buscábamos: a quién le habla la campaña, con qué palabras, en qué canal, cuándo y cómo se mide. Cubre los elementos obligatorios del Problema Prototípico (buyer persona, branding, medios, piezas, implementación e indicadores) y el incidente de mercadotecnia: promover sin provocar un nuevo colapso.

8.1 · Cuántas personas · 2-oct-2026

Opción	Por qué sí o por qué no
Dos: “La que vuelve al sur” y “La que baja del norte” (elegida)	Cada una con su mensaje y su canal
Solo la nacional	Deja fuera al extranjero que ya está a 334 km, en Cancún
Solo la extranjera	La Bahía es 95 % nacional

Evidencia: Oxtankah 94.8 % nacionales y la Ruta 63.3 % (INAH 2025); de los 9,408,423 extranjeros en Cancún, 56.3 % de Estados Unidos y 17.1 % de Canadá; solo 250 extranjeros llegaron en avión a Chetumal. Cada rasgo de cada persona lleva su etiqueta: *dato, derivado, supuesto o hueco* (estado de origen, edad e ingreso del nacional).

8.2 · El nombre de la campaña · 2-oct-2026

Elegido: “El sur tiene espacio” (“The south has room”): dice el dato y la promesa a la vez.

Descartados: “Sur sin prisa” (no dice dónde) y “Del Caribe al sur” (solo le sirve a la extranjera).

8.3 · El tono · 2-oct-2026

Opciones presentadas: cercano y tranquilo; orgullo cultural maya y mexicano; aventura.

Lo que decidimos: combinar los tres, porque para nosotros es un orgullo ser mexicanos.

De dónde salió el mensaje: las reseñas

De 85,987 reseñas de Quintana Roo (Tulum, Isla Mujeres y Bacalar), el riesgo de que una reseña sea mala sube con el **ruido** (2.76 veces), la **suciedad** (1.89), el **precio** (1.66) y las **multitudes** (1.52), y baja con la **cultura** (0.48) y la **calma** (0.41). Lo que hunde una reseña es lo que sobra en los destinos llenos; lo que la protege es lo que el sur ofrece. Esa es la promesa de la marca.

8.4 · Decisiones técnicas de la minería de texto

- **Temas con un léxico a la vista, no LDA:** así cada tema se define antes y se defiende palabra por palabra.
- **Riesgo relativo** como medida (la de la epidemiología): fácil de leer (“2.76 veces más seguido”).
- **Reglas de asociación (Apriori)** para combinaciones: ruido + servicio $\Rightarrow$ reseña mala, lift 2.82.
- **Log-odds con prior de Dirichlet** para las palabras que distinguen a las reseñas de 5 estrellas (*excelente, increíble, hermoso, deliciosa, amable*): evita que las palabras raras salgan por azar.
- **Límite declarado:** ninguna reseña es de los cinco lugares.

8.5 · Reglas de los anuncios

- Cada anuncio lleva **el dato que lo respalda** (por ejemplo, “Pirámides mayas con espacio”: Tulum 1,031,443 visitantes, la Ruta 66,628).
- **Sin precios ni horas de viaje**, porque no hay dato oficial.
- El largo se revisa contra los límites de cada plataforma (Google: título ≤ 30 y descripción ≤ 90 ; Meta: título ≤ 40 y texto ≤ 125).
- “La que baja del norte” se activa solo cuando Cancún está en temporada alta y el sur tiene espacio, y la Torre la enciende por semana.

Resultado: 2 personas, la marca completa (nombre, lema, personalidad, propuesta de valor, posicionamiento y elementos visuales), 5 anuncios, el plan de medios (Facebook 70 %, Google 30 %, WhatsApp sin costo, la página como destino), el calendario de 9 meses y 10 indicadores (alcance, interacción, conversión, costo por visitante $\leq$ \$196, afluencia +957, presupuesto, económico [hueco], social, ambiental y capacidad ≤ 40 %).

Lo que salió mal y cómo lo corregimos

- **Un dominio inventado:** las maquetas de los anuncios mostraban una dirección web que no existe. Se cambió por la dirección real de la página, y una prueba lo vigila.
- **El calendario** decía que había anuncio para el norte en un mes sin anuncios. Se corri-

gió.

Fases 9, 10 y 11: servidor, página final y cierre

Fecha: 2 de octubre de 2026. **Notas:** 22-backend.md, 23-pagina-final.md, 24-cierre.md.

10.1 Fase 9: el servidor que conecta la página con los modelos

Qué buscábamos: el plan pide una web real con un backend que *calcula*, no un tablero con archivos fijos, y que el optimizador responda en menos de 2 segundos.

9.1 · Qué servidor · 2-oct-2026

Opción	Por qué sí o por qué no
FastAPI, solo en la computadora del proyecto (elegida)	Valida tipos y publica su propia documentación; 8 direcciones de consulta
Flask	No valida tipos ni se documenta solo
Un servidor en la nube	El proyecto debe correr sin internet y no hay presupuesto de alojamiento

Tres reglas de diseño: (1) en GitHub Pages la página sigue estática y sin llamadas a otros sitios; con el servidor encendido aparecen “Pruébalo tú” y “Escuchar en vivo”; (2) el servidor solo escucha en la propia computadora (127.0.0.1); (3) la consulta a la base es de **solo lectura** y rechaza todo lo que no sea SELECT, y cualquier función que lea archivos o cambie la base (6 intentos probados).

Resultado: el modelo de presupuesto se resolvió en **274 milisegundos** desde la página; con \$500,000, en 220 ms (1,914 visitantes).

10.2 Fase 10: la página final

10.1 · ¿Prueba con personas? · 2-oct-2026

La pregunta: el plan pedía una “prueba de 5 segundos con una persona no técnica por sección”.

Lo que decidimos: solo la revisión automática, y declarar que no hubo prueba con personas.

Descartado: dejar un guion para que el equipo hiciera la prueba con 3 a 5 personas; la fase quedaba abierta hasta tener las respuestas.

Resultado de la revisión (axe-core, normas WCAG 2.1 A y AA, en escritorio y celular, de día y de noche): de **67 fallas a 0**. La mayoría eran textos con poco contraste en las fichas de “Los lugares”; además, el botón del chat no tenía nombre en celular y las tablas no se podían recorrer con el teclado. Teclado: 40 de 40 tabulaciones con marca visible.

10.2 · El equipo · 2-oct-2026

Quiénes somos: Brandon Uriel García Sánchez, Maribel Mondragón Mercado, Jesús Ramírez Isidro y Enrique González Ortega. Aparecen en “Quiénes somos”.

10.3 Fase 11: cierre y coloquio

Qué quedó: la trazabilidad de cada cifra clave (archivo crudo → función → salida → prueba), el mapa del informe técnico (las 23 secciones del Entregable B, cada una con su archivo), el diccionario de 56 tablas, el guion del coloquio de 15 minutos y estas tres guías.

11.1 · El orden del coloquio · 2-oct-2026

Propuesta: por **la historia de la campaña**, no por materia, porque las reglas del coloquio piden que la campaña sea el centro y que no se presente cada UCA aislada.

Tiempo	Quién	Parte
0:00–0:45	Enrique	Apertura
0:45–4:15	Brandon	Problema y datos
4:15–7:45	Maribel	Dónde y cuándo
7:45–11:15	Jesús	Cuánto y cómo se cuida
11:15–14:15	Enrique	Campaña e indicadores
14:15–15:00	Maribel	Cierre

Es una propuesta: el equipo la ajusta.

11.2 · Revisión completa y las tres guías · 2-oct-2026

Lo que buscábamos: poder responder cualquier pregunta de los profesores (“¿de dónde salió esto?”, “¿cómo hicieron lo de Spark?”). Para eso hacía falta un documento con todas las fórmulas resueltas a mano, otro con lo mismo sin tecnicismos y otro con las decisiones de las 11 fases, los tres en LaTeX y bien fundamentados.

Consecuencia: la *Guía técnica*, la *Guía sencilla* y este documento, escritos en $\text{\LaTeX}$. Una prueba automática revisa que sus cifras clave sigan coincidiendo con los datos.

Revisión: volvimos a correr los notebooks y las 276 pruebas. Corregimos conteos desactualizados (44 → 56 tablas, 7 → 6 notebooks) y se restauró una imagen del documento ejecutivo que había desaparecido del disco.

11.3 · La carpeta Entregable · 3-oct-2026

Lo que buscábamos: una carpeta solo para entregar, sin archivos .py sueltos que haya que correr, con pocos notebooks, con los datos y sin los archivos de trabajo del proyecto.

Pregunta y opción	Por qué sí o por qué no
Cuatro notebooks autosuficientes (elegida)	Datos; dónde y cuándo; presupuesto y Torre; campaña. Cada uno trae dentro el código que usa y se entrega ya ejecutado
Seis, uno por materia	Fácil de repartir, pero más largos en total
Tres	Lo más compacto, pero cada notebook queda muy largo
Datos limpios + resultados, 370 MB (elegida)	Alcanzan para correr los cuatro notebooks; del crudo va el manifiesto con huellas y direcciones para volver a bajarlo
Todo, con el crudo (1.2 GB)	Permite rehacer la limpieza, pero es pesado para subir o mandar
Ligero, menos de 60 MB	El notebook de Spark trabajaría con una muestra

Cómo se logró sin archivos .py: cada celda que empieza con `%%modulo` trae completo un archivo del paquete y, al correrla, queda registrada como ese módulo. El notebook usa el mismo código que el proyecto y da las mismas cifras (956.8 visitantes, 239 lotes de Spark).

Descartado: reescribir el código a mano dentro de los notebooks, que crearía dos versiones que se separan con el primer cambio.

Consecuencia: la carpeta no lleva `OBJETIVO.md`, `CLAUDE.md` ni el `README.md` (son herramientas de trabajo del proyecto, no de la entrega). Se genera con un comando desde el proyecto, y los cambios se hacen siempre en el proyecto. El uso del asistente de IA sigue declarado en las guías.

Pendientes que no dependen del código

- Que el equipo ensaye y ajuste el guion del coloquio.

- Que una persona hablante revise el maya yucateco antes de publicarlo.
- Fotos y reseñas propias del equipo, si se consiguen.

La página web, en paralelo a todas las fases

Fechas: del 28 de septiembre al 2 de octubre de 2026. **Notas:** 06-pagina.md, 07-diseno.md y de la 12 a la 17.

La página se construyó junto con los datos (decisión 2.1). Estas son las decisiones que la fueron formando, en orden.

P.1 · Para gente no técnica · 28-sep-2026

Lo que decidimos: enfocarnos en la página, pensada para gente no técnica.

Decisiones: una sola idea por sección, cifras medidas y en palabras (“de cada 10 cuartos, 6 ocupados”). **Descartado:** destacar en la portada a Kohunlich (+13.5 %) y Dzibanché (+69.2 %), porque la Ruta completa bajó 8.2 % (escoger datos a conveniencia), y una gráfica de “ocupación hotelera” de cuatro centros que pedía conocimientos técnicos.

Ubicación comprobada: los 11 pueblos están en el Censo de Quintana Roo, las 4 zonas tienen “Quintana Roo” en el INAH y cada coordenada cae en el polígono de su municipio. No basta el nombre: hay un “Xul-Ha” en Puerto Morelos y un “Felipe Carrillo Puerto” en Solidaridad.

P.2 · El sistema visual “Sur mexicano” · 28-sep-2026

Por qué: la primera versión se veía genérica, como hecha por inteligencia artificial, con mucho texto y poco visual. Queríamos calidad de primer nivel, una tipografía de viaje y de mar, colores vibrantes y una identidad mexicana real.

Elegido: rosa mexicano, amarillo cempasúchil, turquesa y añil en bloques de color completo; letras Bricolage Grotesque y Figtree guardadas en la propia página (funcionan sin internet); la greca escalonada con el perfil de las pirámides del sur; fotos grandes y unos 70 % menos de texto.

Descartados: el estilo del primer diseño (genérico, “de IA”); imitar literalmente a Apple (tomamos sus principios, no su diseño); el papel picado (cliché nacional; la greca es propia del sur de Quintana Roo).

P.3 · La comida, y por qué se retiró · 1-oct-2026

Lo que buscábamos: muchas fotos de comida, porque de la vista nace el amor.

Lo que hicimos: una galería de 24 platillos de la península con fotos de Wikimedia Com-

mons, con licencia libre y crédito. Las revisamos a ojo y rechazamos, por ejemplo, alfajores argentinos que salieron buscando “relleno negro”.

El error: solo se había revisado que las fotos no mencionaran lugares excluidos. Eran de **Mérida, Campeche y otros lugares fuera de Quintana Roo**.

P.4 · Fotos comprobadas y una página que empieza por el viaje · 1-oct-2026

Lo que detectamos: las fotos tenían que ser de lugares de Quintana Roo, cambiar según el lugar elegido, y la página tenía que empezar por el plan de viaje.

Decisiones:

- La galería de platillos se **retiró completa**.
- **Toda foto debe tener coordenada GPS dentro del municipio de su lugar;** si no, el programa se detiene. De 331 fotos con coordenada elegimos 28, revisadas a ojo.
- La foto de la portada cambia con el lugar elegido.
- Nuevo orden: el planeador arriba, “Así va a estar”, “Qué hacer”, los lugares, y “Los datos” al final.

Huecos declarados: en Commons no hay fotos de platillos tomadas en los 5 lugares (0 de 331), y Rest-Mex no tiene reseñas de ellos. Mostrarlas sería inventarlas.

P.5 · Una página que convence · 2-oct-2026

Lo que buscábamos: más fotos de comida, reseñas reales, las estrellas de los hoteles, preguntas frecuentes, secciones para vender, una barra de imágenes, 10 idiomas y versión de día y de noche, sin saturar la página.

Pedido	Lo que existe	Lo que decidimos
Reseñas reales	Rest-Mex no cubre los 5 lugares; copiar las de Google está prohibido	Botón “Reseñas en Google” en cada negocio + reseñas del equipo
Estrellas	DataTur las publica solo para 70 centros, ninguno del sur	Estrellas oficiales donde existen; hueco declarado en el sur
Secciones para vender	No hay precios oficiales	Experiencias reales, rutas de 2 y 3 días y llamados, sin precios
10 idiomas	—	9 publicados; el maya yucateco espera la revisión de un hablante; “Los datos” en español
Día y noche	—	Botón animado de sol a luna; la página se abre como un círculo

P.6 · Cancún y Riviera Maya en toda la parte del viajero · 2-oct-2026

Lo que detectamos: la parte del viajero seguía mostrando lugares sin datos (Maya Ka'an y la Laguna) en lugar de Cancún y la Riviera Maya, y el modo noche no funcionaba bien.

Decisiones: en el mapa, las fichas, las experiencias, las rutas y las preguntas, los lugares del viajero son Chetumal, Calderitas–Oxtankah, la Ruta, Cancún y la Riviera Maya (estos dos siempre con su etiqueta de referencia). “Los datos” no cambia: sigue siendo el análisis de las 5 regiones. El modo noche se rehízo: cada bloque de color tiene su versión oscura. Las estrellas oficiales del norte (Cancún: 67.8% de sus cuartos son de 5 estrellas) y 8 fotos de comida con coordenada comprobada en Cancún y Playa del Carmen.

Lo que estas decisiones tienen en común

Leídas juntas, las decisiones de las 12 fases siguen cinco reglas. Son las que conviene defender en el coloquio, porque explican *cómo* se trabajó y no solo *qué* salió.

12.1 1. Ninguna cifra se inventó

Cada vez que faltó un dato, se eligió entre declararlo hueco o probarlo como supuesto con varios valores. Nunca se rellenó.

Dato que faltaba	Cómo se trató
Ocupación del sur desde 2025	Hueco; el sur se mide con presión de llegada (3.4)
Conversión de Facebook para turismo	Supuesto con barrido: 3, 5.75 y 6.38 % (6.3)
Golpe de una tormenta	Supuesto con barrido: 0, 25 y 50 % (5.6)
Efecto de la campaña en los escenarios	No se metió un número sin fuente (5.7)
Feriados sin tipo de cambio	Vacíos, sin copiar el día anterior (2.7)
Reseñas y fotos de platillos del sur	No se muestran; las aportará el equipo (P.4)

12.2 2. Cada modelo se comparó contra una regla simple

El Radar contra “igual que este mes” (130 contra 126); el pronóstico contra “el mismo mes del año pasado” (en Cancún ganó la regla simple, y se usa); Markov contra la persistencia (mejor puntaje a 1, 4 y 8 semanas). Siempre se dice cuánto le gana cada modelo, aunque sea poco.

12.3 3. Fijamos los criterios antes de ver al ganador

Primero decidimos *cómo* elegir (“el que más acierta y más cambios anticipa”, “menor error con rango $\geq 80\%$ ”) y el código aplica el criterio solo. Cuando la auditoría cambió los datos, el modelo ganador del Radar cambió de Random Forest a regresión logística, y respetamos el criterio, no el nombre.

12.4 4. Cuando algo falló, se contó

- El índice que daba a Cancún como tranquilo en julio (4.5).
- La “ocupación” de 2,560,068 y los visitantes contados dos veces (Fase 4).
- Los conteos inflados del DENUe y del Censo (Fase 1).
- El corte de clima raro que marcaba el 47 % de las semanas (7.5).
- Todo el dinero de la Ruta en junio (6.5).
- Junio como mes recomendado, siendo el más lluvioso (5.11).
- Las fotos de Mérida y Campeche (P.3).

Cada uno se corrigió con datos y quedó escrito. Varios se convirtieron en pruebas automáticas para que no vuelvan a pasar.

12.5 5. La redistribución tiene reglas que no se pueden romper

La campaña no anuncia en temporada alta, no rebasa la capacidad probada, reparte entre los tres lugares, no depende de una sola plataforma, se pausa con mal clima y manda al sur a quien iba al norte lleno. Y se midió el precio de cuidar: **cero visitantes**.