Gobierno de México | Ciencia y Tecnología, Secretaría de Ciencia, Humanidades, Tecnología e Innovación | UNRC Universidad Nacional Rosario Castellanos

UNIVERSIDAD NACIONAL ROSARIO CASTELLANOS

LICENCIATURA EN CIENCIA DE DATOS PARA NEGOCIOS

TORRE DEL CARIBE: CAMPAÑA PUBLICITARIA INTELIGENTE PARA REDISTRIBUIR EL TURISMO HACIA EL SUR DE QUINTANA ROO

Documento técnico: cómo funciona cada modelo, fórmula por fórmula, con ejemplos resueltos con nuestros datos

EQUIPO - 2

Tutor:	Carlos Orozco Rocha
Alumnos	Brandon Uriel García Sánchez Enrique González Ortega Jesús Ramírez Isidro Maribel Mondragón Mercado
Grupo	PHLCDN-503-UST
Unidad Académica	Unidad Santo Tomás
Fecha de Entrega	Octubre de 2026

Contenido

Profesores y materias del proyecto 4

Cómo leer las fórmulas de este documento 4
Tres palabras que se usan en todo el documento 5

1. El problema y nuestra respuesta 6

1.1 La pregunta que nos pide responder el Problema Prototípico 6
1.2 El diagnóstico, con datos 6
1.3 Nuestra respuesta 7
1.4 Tres módulos que no se enciman 7
1.5 Las siete preguntas secundarias y dónde se responden 8
1.6 Cómo trabajamos 8

2. Los datos: de dónde sale cada cifra 9

2.1 La regla: solo fuentes oficiales, descargadas con código 9
2.2 Las fuentes 10
2.3 Lo que no existe (huecos declarados) 11

3. Grandes volúmenes de datos 12

3.1 La arquitectura medallón: Bronze, Silver y Gold 12
3.2 Spark: qué es y qué hace aquí 13
3.3 Reglas de limpieza: un cero no es lo mismo que un hueco 14
3.4 Cuando dos fuentes cuentan lo mismo (conciliación) 15
3.5 El almacén DuckDB y el modelo estrella 15
3.6 Streaming: la Torre en vivo 16
3.7 Privacidad 17

4. Planteamiento: el problema medido 18

4.1 ¿Qué tan concentrado está el turismo? El índice de Herfindahl-Hirschman 18
4.2 ¿Por qué estos cinco lugares? La tabla de criterios 20
4.3 Variables, actores y relaciones 21

5. Minería de datos: encontrar patrones 22

5.1 El índice de presión turística (IPT) 22
5.2 Agrupamiento de los centros turísticos del país (método de Ward) 24
5.3 La forma del año (estacionalidad) 26
5.4 Clima raro con Isolation Forest (detección de anomalías) 27
5.5 Minería de texto de las reseñas 29
5.6 Qué hacer, dónde comer y dónde dormir: clasificación por léxico 32

6. Aprendizaje de máquina: predecir 33

6.1 Clasificación: ¿qué estado tendrá cada lugar el mes siguiente? 33
6.2 Pronóstico de visitantes: series de tiempo 37

7. Modelos estocásticos: la incertidumbre 42

7.1 Cadena de Markov semanal del norte 42
7.2 Tormentas: definición y distancia 45
7.3 Poisson: la probabilidad de tormenta en cada mes 45
7.4 Monte Carlo: escenarios malo, probable y bueno 46
7.5 Sensibilidad: ¿qué variable mueve más? 48

8. Investigación de Operaciones: repartir el presupuesto 49

8.1 La pregunta 49
8.2 Los parámetros: cuánto rinde un peso en cada canal 49
8.3 El modelo de dos variables, resuelto con el método gráfico 50
8.4 El modelo completo 52
8.5 Cómo lo resuelve la computadora 53
8.6 ¿Cuánto cuesta cada regla? Precios sombra 55
8.7 Sensibilidad: ¿y si los supuestos están mal? 56
8.8 La etapa 2 en la práctica: el motor de la Torre 56

9. Mercadotecnia digital: la campaña 57

9.1 Segmentar: lo que dicen los datos 57
9.2 Elegir: dos viajeras ideales (buyer persona) 57
9.3 Posicionar: la marca 58
9.4 Los mensajes: cada promesa con su dato 58
9.5 Los medios 59
9.6 Cómo se mide: el embudo y los indicadores 59
9.7 La regla anti-colapso 61

10. Integración y propuesta final 62

10.1 La estafeta: la salida de una materia es la entrada de la siguiente 62
10.2 Comparación de escenarios y propuesta 63
10.3 La página y el servidor 63

11. Lo que no se pudo medir y lo que se supuso 64

11.1 Supuestos 64
11.2 Lo que los modelos no pueden afirmar 64

12. Preguntas difíciles y su respuesta 65

Referencias 66

Profesores y materias del proyecto

Este documento acompaña al Problema Prototípico del 5.º semestre, *Turismo inteligente sustentable para México*. El proyecto integra las seis Unidades de Competencia Académica (UCA) del semestre. La tabla indica qué capítulo corresponde a cada materia y qué criterio de la rúbrica atiende.

Materia (UCA)	Profesor	Capítulo	Criterio de la rúbrica
Herramientas para el Almacenamiento de Grandes Volúmenes de Datos	Víctor Gabriel Cruz Arrona	3	2. Gestión y almacenamiento (12 %)
Minería de Datos	Luis Becerril Espinosa	4 y 5	1. Planteamiento (8 %) y 3. Minería de datos (12 %)
Aprendizaje de Máquina	Raúl Jorge Domínguez Vilchis	6	4. Aprendizaje de máquina (12 %)
Modelos Estocásticos para la Toma de Decisiones	René Chablé García	7	5. Modelos estocásticos (10 %)
Investigación de Operaciones	Carlos Orozco Rocha (tutor del equipo)	8	6. Investigación de Operaciones (12 %)
Mercadotecnia Digital	Víctor Hugo Reyes Anselmo	9	7. Mercadotecnia digital (8 %)

Los criterios 8 (integración, 10 %) y 9 (propuesta e impacto, 8 %) se cubren en el capítulo 10, y el criterio 10 (informe técnico, 4 %) en todo el documento.

Cómo leer las fórmulas de este documento

Cada fórmula aparece siempre con la misma secuencia de cinco pasos, para que se entienda sin abrir el código:

Paso	Qué contiene
1. La idea en palabras	Lo que hace el método, explicado con un ejemplo de la vida diaria y sin símbolos (caja gris).
2. La fórmula	La expresión matemática completa, tal como la calcula el programa.
3. Qué es cada símbolo	Una tabla que traduce cada letra a lo que significa en el proyecto.
4. Paso a paso con nuestros datos	El cálculo resuelto a mano con cifras reales del proyecto; el resultado coincide con el que da el código (caja dorada).
5. Qué significa	Cómo se lee el resultado y a qué decisión de la campaña alimenta.

Además, cada capítulo incluye un recuadro de conexión con la materia:

> **Conexión con la materia.** Qué tema de la UCA se aplica y cómo se relaciona con el incidente crítico que el profesor planteó en el Problema Prototípico.

Tres palabras que se usan en todo el documento

Medido es lo que sale directo de una fuente oficial (INEGI, SECTUR, INAH, Sedetur). **Estimado** es lo que sale de un modelo; en las tablas del proyecto lleva el sufijo `_est` y siempre va acompañado de su error. **Hueco** es un dato que no existe: nunca lo rellenamos con ceros ni con promedios, lo declaramos y decimos qué no se puede afirmar por su culpa. Las cifras se recalcularon el 2 de octubre de 2026 con los datos del proyecto.

1. El problema y nuestra respuesta

1.1 La pregunta que nos pide responder el Problema Prototípico

> ¿Cómo diseñar una campaña publicitaria basada en Ciencia de Datos que permita promover estratégicamente un destino turístico del estado seleccionado, atraer segmentos de visitantes de manera responsable y contribuir a una distribución más equilibrada de los flujos turísticos, aprovechando la capacidad disponible y reduciendo los impactos económicos, sociales y ambientales asociados con la saturación turística? (UNRC, 2026)

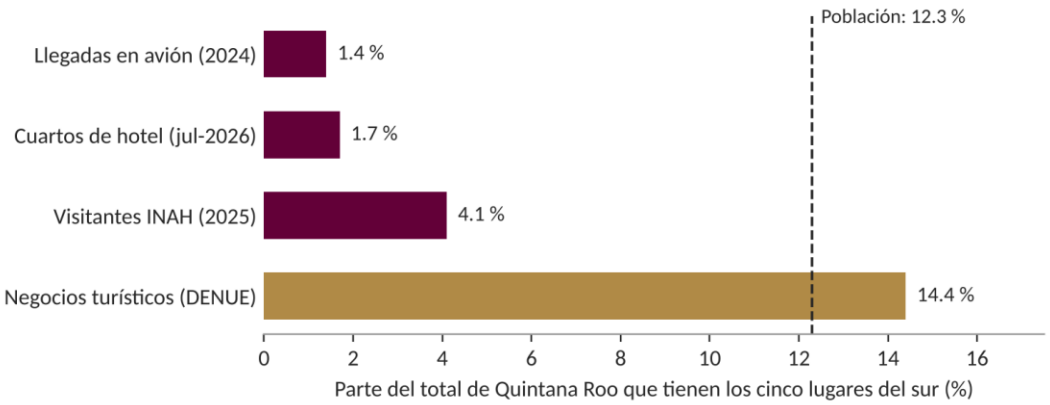
Leímos la pregunta como cuatro exigencias, y cada parte del sistema responde a una:

Exigencia de la pregunta	Qué tenemos que saber	Quién lo responde
Promover estratégicamente	Dónde hay espacio y cuándo conviene ir	Radar y Pronóstico
De manera responsable	No llevar gente a donde ya está lleno ni con mal clima	Reglas del presupuesto y Torre en vivo
Distribución más equilibrada	Cuánto está concentrado el turismo y hacia dónde moverlo	Planteamiento y campaña
Aprovechar la capacidad disponible	Cuánto puede recibir cada lugar sin rebasarse	Capacidad probada, Monte Carlo y optimización

1.2 El diagnóstico, con datos

Elegimos **Quintana Roo** porque concentra el contraste más fuerte del país dentro de un mismo estado. El norte (Cancún, la Riviera Maya y Tulum) recibe casi todo: el aeropuerto de Cancún concentra el 92.5 % de los pasajeros de avión del estado. En 2026 la franja de Tulum a Xcalak tuvo sargazo récord (56 de 140 playas en rojo en agosto) y la zona arqueológica de Tulum perdió el 31.3 % de sus visitas entre enero y julio.

El sur, en cambio, tiene espacio: los cinco lugares de la campaña tienen el **12.3 % de la población** del estado, pero reciben solo el **1.4 % de los pasajeros de avión**.



Parte del total del estado que tienen los cinco lugares del sur. La línea punteada marca su parte de la población: los negocios están donde está la gente, pero los visitantes no.

1.3 Nuestra respuesta

Los cinco lugares que promueve la campaña se eligieron con una tabla de criterios (capítulo 4):

1. **Chetumal**, la capital del estado.
2. **La Bahía de Calderitas y la zona arqueológica de Oxtankah.**
3. **La Ruta arqueológica del sur**: Kohunlich, Dzibanché e Ichkabal.
4. **Maya Ka'an con Kantemó.**
5. **La Laguna Milagros con Xul-Ha.**

Cancún, la Riviera Maya y Tulum aparecen solo como **referencia etiquetada**: sirven para medir desde dónde se redistribuye, pero la campaña no los promueve.

La campaña se llama **"El sur tiene espacio"** y tiene tres reglas que la vuelven responsable: nunca anuncia un lugar en su temporada alta; se pausa sola con mal clima o si llega más gente de la esperada; y a quien iba al norte le ofrece el lugar del sur que tenga más espacio.

1.4 Tres módulos que no se enciman

Una regla de diseño fue que ninguna técnica contestara la pregunta de otro módulo, para que nunca hubiera dos respuestas distintas a lo mismo.

Módulo	Pregunta	Horizonte	Técnicas principales
Radar	¿Dónde hay presión y dónde hay espacio?	Hoy (semanas y meses)	Índice de presión, agrupamiento, clasificador, cadena de Markov
Pronóstico	¿Cuándo conviene ir y cuánto invertir?	1 a 12 meses	Forma del año, cinco modelos de series de tiempo, intervalo conformal, Poisson, Monte Carlo, optimización
Torre en vivo	¿Qué hace la campaña esta semana?	Semana a semana	Spark Structured Streaming, Isolation Forest, motor de reglas
Campaña	¿A quién, con qué mensaje y por qué canal?	Todo el plan	Minería de texto, buyer persona, indicadores

El Radar predice un **estado** (tranquilo, concurrido o saturado) a un mes; el Pronóstico predice un **nivel** (cuántos visitantes) de 1 a 12 meses. La cadena de Markov trabaja en semanas y el Monte Carlo en meses. La Torre no entrena modelos propios: observa la semana real y ejecuta las reglas que el presupuesto dejó previstas.

1.5 Las siete preguntas secundarias y dónde se responden

Pregunta del Problema Prototípico	Se responde en
1. Patrones temporales, espaciales y de comportamiento de la concentración	Cap. 4 (HHI), 5 (forma del año, reseñas) y 9
2. Variables relacionadas con la saturación	Cap. 5 (índice de presión) y 6 (clasificador)
3. Demanda futura con incertidumbre	Cap. 6 (pronóstico) y 7 (Monte Carlo)
4. Escenarios de redistribución sin perder actividad económica	Cap. 8 (presupuesto)
5. Características para recomendar destinos alternativos	Cap. 5 (minería de texto) y 9 (buyer persona)
6. Impacto en comunidades y destinos saturados	Cap. 4 (presión por habitante) y 10 (Torre)
7. Cómo evaluar si la propuesta es viable, sustentable y efectiva	Cap. 8 (escenarios) y 9 (indicadores)

1.6 Cómo trabajamos

Trabajamos en doce fases (de la 0 a la 11), una a la vez: plan y entorno; descarga de 14 fuentes oficiales; limpieza y almacén; elección de los cinco lugares; Radar; Pronóstico; presupuesto; Torre en vivo; campaña; servidor; página final; y cierre. El paquete de código tiene 59 archivos en 7 carpetas, con una regla: **una pieza, un archivo**. Cada archivo hace una sola cosa y empieza con un encabezado que dice qué hace, por qué así, de qué datos sale y a qué decisión alimenta. Así cada pieza se puede probar, explicar y reemplazar sin romper las demás.

Para programar usamos un asistente de programación con inteligencia artificial (Claude Code) como herramienta. Las reglas, las decisiones y la revisión fueron del equipo, y están documentadas en más de 40 registros de decisión, cada uno con las opciones descartadas y su evidencia. Hay 316 pruebas automáticas: unas revisan la forma de los datos (sin duplicados, columnas completas) y otras revisan cifras conocidas (por ejemplo, que Tulum haya tenido 1,031,443 visitantes en 2025). Todo lo aleatorio usa semilla fija, así que volver a correr el proyecto da exactamente las mismas cifras.

2. Los datos: de dónde sale cada cifra

2.1 La regla: solo fuentes oficiales, descargadas con código

Todas las fuentes se descargaron con programas, nunca a mano, y se guardaron sin modificarse en `datos/bronze/<fuente>/<fecha>/`. Cada archivo quedó registrado en un manifiesto con su huella SHA-256, su tamaño, su dirección de origen, la fecha de descarga y su número de registros. El resultado de la fase de descarga fue **353 archivos, 8,134,802 registros y 824 MB**.

No usamos TripAdvisor ni Google Maps, porque sus términos de uso prohíben extraer sus datos; tampoco el semáforo estatal de sargazo, porque solo se publica en Facebook, cuyos términos también lo prohíben. Esta decisión responde directamente al incidente ético de Minería de Datos.

2.2 Las fuentes

Clave	Fuente	Qué trae	Registros	Para qué se usa
D1	SITUR-Q (Sedetur Quintana Roo)	Ocupación, cuartos, Tren Maya, cruceristas, cruces desde Belice, llegadas por avión	6,607	Radar del sur, pronóstico de Chetumal
D2	DataTur, ocupación hotelera (SECTUR)	66 centros del país; 7 de Quintana Roo con 239 semanas (ene-2022 a jul-2026)	166 archivos	Radar del norte, Markov, Torre
D3	DataTur, llegadas por nacionalidad	Extranjeros por aeropuerto, país y sexo, 2012–2026	521,363	Buyer persona
D4	DataTur: INAH, AFAC, cruceros y Compendio	Visitantes por zona arqueológica 2016–2026, pasajeros, cruceros, cuartos por categoría	390,228	Base del pronóstico del sur
D5	Rest-Mex 2025	Reseñas de turistas con calificación de 1 a 5	208,051	Minería de texto
D6	DENUE (INEGI), los 32 estados	Negocios con giro, tamaño y coordenadas	6,138,075	Oferta turística
D7	Censo 2020, ITER (INEGI)	Población de 2,243 localidades de Quintana Roo	2,243	Presión por habitante
D8	Open-Meteo (reanálisis ERA5)	Clima diario desde 1950 y horario desde 2019 en 8 puntos	767,016	Clima de los modelos y anomalías
D9	HURDAT2 (NOAA)	Trayectoria de todas las tormentas del Atlántico, 1851–2025	55,524	Probabilidad de tormenta
D10	FRED (Reserva Federal de St. Louis)	Pesos por dólar diario desde 1993	8,575	Sensibilidad y costos
D11–D15	ENDUTIH 2025, polígonos municipales, benchmarks de anuncios, fotos de Wikimedia Commons	Uso de internet, geografía, costo por clic, imágenes con licencia libre	—	Campaña y página

Clave	Fuente	Qué trae	Registros	Para qué se usa
D18	Normales climatológicas 1991–2020 (SMN-CONAGUA)	Lluvia y temperatura máxima normales de 3 estaciones: Chetumal, Nicolás Bravo y Cancún	36	Clima que ve el viajero

Tres hallazgos de esta etapa marcaron todo el proyecto: SITUR-Q **no publica ocupación hotelera de 2025–2026** para ningún destino (viene en ceros); las llegadas por avión de 2025 vienen en cero en los cuatro aeropuertos; y DataTur corrigió 2,804 cifras entre una publicación y otra (conservamos siempre la más reciente).

2.3 Lo que no existe (huecos declarados)

Hueco	Qué no se puede afirmar por su culpa
Ocupación hotelera del sur 2025–2026	Cuántos cuartos se llenan hoy en Chetumal; por eso el sur se mide con llegadas reales
Estado de origen, edad e ingreso del visitante nacional	Una persona nacional más detallada
Conversión de Facebook para turismo	El rendimiento exacto de Facebook; se prueba con tres valores
Tormentas de 2026	Si hubo tormentas este año; la Torre dice “sin dato”
Reseñas de los cinco lugares	Qué opinan los turistas del sur; las reseñas son de destinos llenos
Derrama económica por lugar	Cuánto dinero deja la campaña; la de SITUR-Q no trae unidad y termina en 2024

3. Grandes volúmenes de datos

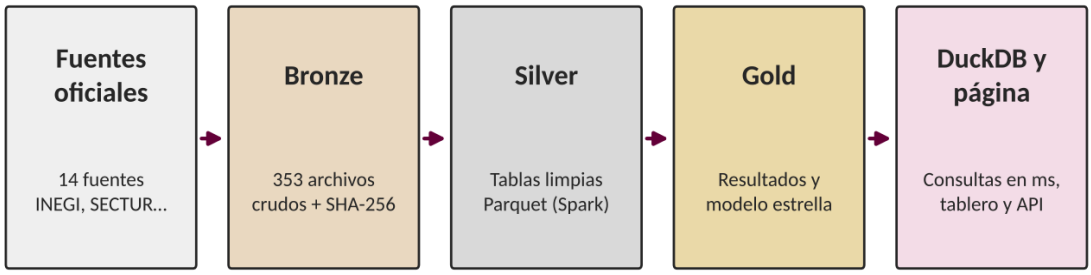
Materia: Herramientas para el Almacenamiento de Grandes Volúmenes de Datos · **Profesor:** Víctor Gabriel Cruz Arrona · **Criterio 2 de la rúbrica (12 %):** integra diversas fuentes; estructura, documenta, transforma y almacena considerando calidad y arquitectura.

Conexión con la materia. El incidente crítico de esta UCA se titula *"Cuando los datos del turismo no caben en una sola computadora"* y plantea cuatro problemas que nos tocaron de verdad: archivos con millones de registros en formatos distintos, fuentes que no coinciden entre sí, la necesidad de datos que llegan de forma continua (baja latencia) y la pregunta ética de si conviene guardar todo solo porque se puede. Este capítulo responde a cada uno: arquitectura medallón (3.1), procesamiento distribuido con Spark (3.2), reglas de calidad (3.3), conciliación de fuentes (3.4), almacén con modelo estrella (3.5), streaming (3.6) y privacidad (3.7).

3.1 La arquitectura medallón: Bronze, Silver y Gold

La idea en palabras

Pensemos en una planta potabilizadora. El agua cruda (Bronze) se guarda tal como llega, para poder volver a ella. Después se filtra y se limpia (Silver). Al final se embotella lista para beber (Gold). Si alguien duda del agua embotellada, se puede revisar cada paso hasta la toma original.



Arquitectura de datos del proyecto, de la fuente oficial a la página.

Capa	Carpeta	Contenido y regla
Bronze	`datos/bronze/`	Los archivos tal como los publica la fuente (zip, Excel, JSON, CSV). Nunca se modifican; cada uno tiene su huella SHA-256.
Silver	`datos/silver/`	Una tabla limpia por fuente, en Parquet, con nombres en español, tipos correctos y banderas de calidad (`_flag`). La escribe Spark.
Gold	`datos/gold/`	Salidas de los modelos y el modelo estrella; es lo que usan la página y los documentos.

Por qué así. Si una cifra de Gold parece rara, se puede repetir el camino desde el archivo crudo, que no se tocó. La alternativa descartada fue limpiar mientras se descarga: Bronze dejaría de ser idéntico a la fuente y ya no habría contra qué comparar.

La huella SHA-256. Es la "huella digital" de un archivo: una cadena de 64 caracteres que se calcula con todo su contenido. Si cambia un solo byte, la huella cambia por completo. Una prueba automática vuelve a calcular las 353 huellas y falla si alguna no coincide con el manifiesto; así se demuestra que Bronze no se alteró.

3.2 Spark: qué es y qué hace aquí

> **La idea en palabras**
>
> Limpiar una lista de 6 millones de negocios es como calificar 6 millones de exámenes. Una persona sola tardaría mucho; doce personas, cada una con su montón, terminan mucho antes. Spark reparte la tabla en montones (particiones) y pone a trabajar a la vez a todos los núcleos de la computadora.

Las cinco ideas de Spark que usamos:

1. **Driver y ejecutores.** El *driver* planea el trabajo y los *ejecutores* lo hacen. Aquí Spark corre en modo local (`local[*]`) con los 12 núcleos de la computadora y 4 GB de memoria. Es el mismo programa que correría en un clúster; solo cambia la dirección del "maestro".
2. **DataFrame y particiones.** Un DataFrame de Spark es una tabla repartida en particiones, y cada partición la procesa un núcleo.
3. **Evaluación perezosa.** Las transformaciones (`withColumn`, `filter`) no se ejecutan al escribirlas: Spark arma un plan completo, lo optimiza y lo ejecuta solo cuando se pide una acción (`count`, `write`).
4. **Barajeo (*shuffle*).** Quitar duplicados obliga a juntar en el mismo núcleo todos los renglones con el mismo identificador. Es la parte cara del trabajo y por eso se hace una sola vez.
5. **Parquet particionado.** Spark guarda por columnas y comprime. Además separa la tabla en carpetas por estado (`cve_ent=23/` es Quintana Roo), así que leer un estado no obliga a leer los otros 31.

El trabajo más grande fue el DENUE nacional (6.1 millones de negocios):

```
crudo = (spark.read.option("header", True).option("encoding", "ISO-8859-1")
         .csv("temporal/*.csv"))                  # 33 CSV como UNA sola tabla
silver = (crudo.select(*COLUMNAS)                 # sin datos personales
          .dropDuplicates(["id"])                 # un negocio, una fila (barajeo)
          .withColumn("scian_3", F.substring("codigo_act", 1, 3))
          .withColumn("categoria_turistica", categoria)   # 721 alojamiento, 722 alimentos
          .withColumn("coordenadas_flag",
                      ~(lat.between(14, 33) & lon.between(-119, -86)) | lat.isNull())
          .withColumn("es_qroo", F.col("cve_ent") == "23"))
silver.write.mode("overwrite").partitionBy("cve_ent").parquet("datos/silver/denue")
```

Resultado: 0 duplicados, ninguna coordenada fuera de México, y la razón social, el teléfono y el correo nunca entran a Silver. Tarda cerca de minuto y medio. Del total nacional, el 14.3 % de los negocios son turísticos; en Quintana Roo, el 19.7 %.

3.3 Reglas de limpieza: un cero no es lo mismo que un hueco

La regla más importante de Silver: **un cero físicamente imposible es un hueco; un cero posible se conserva.**

Caso	Por qué	Regla
Ocupación con 0 cuartos disponibles	No se pueden ocupar cuartos que no existen	Hueco
Los 4 aeropuertos en 0 todo 2025	Cancún no pudo recibir cero pasajeros: la fuente dejó de publicar	Hueco
Cruceristas en 0 en 2020	Real: los puertos cerraron por la pandemia	Se conserva
Zona arqueológica con 0 visitantes	Suele ser un cierre por obras	Se conserva y se marca
Feriado sin tipo de cambio	No hubo cotización ese día	Vacío; no se copia el día anterior

La ocupación se calcula sumando antes de dividir

> **La idea en palabras**
>
> Si en un mes había muchos cuartos y en otro pocos, no es justo que los dos pesen igual. Por eso primero se suman todos los cuartos ocupados del año, luego todos los disponibles, y al final se divide una vez. Así cada cuarto-noche cuenta exactamente una vez.

$$O = \frac{\text{cuartos-noche ocupados en todos los meses}}{\text{cuartos-noche disponibles en todos los meses}} \times 100$$

Símbolo	Qué significa
O	Ocupación del periodo, en porcentaje
cuarto-noche	Un cuarto durante una noche; un hotel de 10 cuartos tiene 300 cuartos-noche en un mes de 30 días

> **Paso a paso con nuestros datos: ocupación de Chetumal en 2024**
>
> **Paso 1.** Sumamos los cuartos-noche ocupados de los 12 meses: 458,696.
>
> **Paso 2.** Sumamos los cuartos-noche disponibles de los 12 meses: 791,016.
>
> **Paso 3.** Dividimos y multiplicamos por 100:

$$O = \frac{458{,}696}{791{,}016} \times 100 = 0.5799 \times 100 = 57.99 \approx 58.0\ \%$$

> **Qué significa:** de cada 10 cuartos, 4 se quedaron vacíos. Es capacidad ociosa, justo lo que la campaña puede aprovechar.

Por qué no promediar porcentajes. Con números redondos, para que se vea el problema: un mes con 50,000 cuartos al 90 % (45,000 ocupados) y otro con 10,000 al 10 % (1,000 ocupados). El promedio simple da (90 + 10) ÷ 2 = 50 %, pero en realidad se ocuparon 46,000 de 60,000 cuartos: 76.7 %. El promedio simple le da al mes chico el mismo peso que al grande.

Un error real que lo demuestra. SITUR-Q publica tres renglones por mes para la ocupación (disponibles, ocupados y porcentaje). La primera versión de nuestro panel los sumaba y la "ocupación" llegó a 2,560,068. Ahora se recalcula ocupados ÷ disponibles, y una prueba automática lo vigila.

3.4 Cuando dos fuentes cuentan lo mismo (conciliación)

El incidente de esta materia pregunta qué hacer cuando "un destino puede aparecer como altamente visitado en una fuente, mientras que otra muestra una menor actividad" (UNRC, 2026). Medimos cuánto difieren:

$$\Delta\% = \left(\frac{S}{D} - 1\right) \times 100$$

Símbolo	Qué significa
S	La cifra de SITUR-Q (fuente estatal)
D	La cifra de DataTur (fuente federal)
$\Delta\%$	Cuánto más (si es positivo) o menos (si es negativo) cuenta la fuente estatal

> **Paso a paso con nuestros datos: cruceristas en 2025**
>
> **Cozumel.** SITUR-Q cuenta 4,915,242 y DataTur 4,724,255. Primero dividimos: 4,915,242 ÷ 4,724,255 = 1.0404. Le restamos 1: 0.0404. Por 100: **+4.04 %**.
>
> **Mahahual.** 2,641,695 ÷ 2,379,422 = 1.1102, menos 1 y por 100: **+11.02 %**. En Mahahual SITUR-Q cuenta siempre más: entre 11 % y 35 % según el año.

En la ocupación pasa lo mismo: DataTur marca menos que SITUR-Q (Cancún −1.6 puntos, Cozumel −14.5, Isla Mujeres −19.3), aunque las dos se mueven juntas (correlación entre 0.68 y 0.97). Nuestra regla tiene tres partes:

1. Cada lugar usa **una sola fuente en toda su historia**, para que sus cambios en el tiempo sean reales.
2. La diferencia **se declara** y no se "ajusta".
3. Se revisa en qué sentido va. Aquí el norte se ve menos lleno con DataTur, así que la conclusión "el sur tiene espacio" se sostiene con más fuerza: la diferencia es conservadora.

3.5 El almacén DuckDB y el modelo estrella

DuckDB es una base de datos analítica que vive en un solo archivo (`datos/gold/torre.duckdb`) y lee los Parquet de Silver y Gold sin copiarlos. Responde en milisegundos sin levantar Spark. Tiene una vista por cada tabla (14 de Silver y 39 de Gold) y un **modelo estrella** (Kimball y Ross, 2013): una tabla de hechos en el centro, con las medidas, rodeada de tablas de dimensiones con las descripciones.

Tabla	Tipo	Contenido
`dim_lugar`	Dimensión	15 lugares con su papel: 5 promovidos, 3 de referencia y 7 de comparación
`dim_tiempo`	Dimensión	Un renglón por mes, de 2012 a 2027
`hechos_mes`	Hechos	3,287 renglones: lugar × mes × variable, con su fuente

El **grano** (qué representa un renglón de hechos) es "una medida de un lugar en un mes". Un hueco no tiene renglón: nunca se guarda un cero inventado. Ejemplo de consulta:

```
SELECT anio, SUM(valor) FROM hechos_mes JOIN dim_tiempo USING (periodo)
WHERE lugar = 'Chetumal' AND variable = 'llegadas_extranjeros_avion'
GROUP BY anio;      -- 2025: 250 extranjeros (Cancún: 9,408,423)
```

El **diccionario de datos** se genera solo desde el almacén: 58 tablas, cada columna con su tipo, su porcentaje de vacíos, un ejemplo real y su significado. Si una columna no tiene significado escrito, el programa se detiene; así el diccionario no puede quedar desactualizado. Descartamos PostgreSQL porque exige instalar y levantar un servidor, y el proyecto debe correr sin internet en cualquier computadora.

3.6 Streaming: la Torre en vivo

> **La idea en palabras**
>
> Una banda transportadora: cada semana llega una caja con los datos de esa semana. La Torre abre una caja a la vez, en el orden en que llegaron, decide qué hacer con la campaña y pasa a la siguiente.

Así funciona con Spark Structured Streaming:

1. Cada una de las 239 semanas reales (enero de 2022 a julio de 2026) se escribe como un archivo JSON en una carpeta.
2. Spark escucha la carpeta con `readStream`. La opción `maxFilesPerTrigger=1` hace que cada micro-lote sea exactamente un archivo, es decir, una semana.
3. En cada micro-lote, `foreachBatch` le pasa la semana al motor de reglas, que decide qué anuncio se enciende o se pausa.
4. Un punto de control (*checkpoint*) registra qué archivos ya se procesaron: si el programa se cae, no procesa dos veces la misma semana.
5. Al final se comprueba que llegaron 239 lotes, en orden.

Esta es exactamente la arquitectura que recibiría datos reales cada semana: una carpeta a la que llega un archivo nuevo. Cambiar la fuente por una real no cambia el motor. En la página se presenta como "reproducción de datos históricos reales", porque GitHub Pages no puede transmitir en vivo.

La ventana deslizante de cuatro semanas

> **La idea en palabras**
>
> Una semana rara (un puente, un evento) puede engañar. Por eso la Torre mira el promedio de las últimas cuatro semanas. Cada semana entra la nueva y sale la más vieja: la ventana "se desliza".

$$\bar{o}_w = \frac{o_w + o_{w-1} + o_{w-2} + o_{w-3}}{4}$$

Símbolo	Qué significa
o_w	Ocupación de la semana w (la más reciente)
$o_{w-1}, o_{w-2}, o_{w-3}$	Ocupación de una, dos y tres semanas antes
$\bar{o}_w$	Promedio móvil que usa la Torre para decidir

Es la misma fórmula que en notación de sumatoria se escribe $\bar{o}_w = \frac{1}{4}\sum_{k=0}^{3} o_{w-k}$: "suma las cuatro semanas más recientes y divide entre cuatro". Spark la calcula con una función de ventana sobre cada centro turístico.

3.7 Privacidad

No guardamos ningún dato personal. El DENUE entra sin razón social, teléfono ni correo; las reseñas no tienen identificadores; las nacionalidades y los visitantes vienen agregados por mes. Ninguna tabla permite identificar a una persona. Con esto respondemos a la pregunta del incidente: *"¿Qué riesgos pueden surgir al almacenar información que permita identificar patrones de movilidad o comportamiento de los turistas?"*: guardamos solo lo agregado y lo necesario para una decisión.

4. Planteamiento: el problema medido

> **Materia que lo encabeza:** Minería de Datos (Luis Becerril Espinosa), con la tutoría de Carlos Orozco Rocha · **Criterio 1 de la rúbrica (8 %):** delimita el problema e identifica variables, actores y relaciones.

4.1 ¿Qué tan concentrado está el turismo? El índice de Herfindahl-Hirschman

Pregunta. Si el problema es la concentración, hay que medirla. ¿Qué parte de los visitantes, cuartos y negocios del estado tienen los cinco lugares, y qué tan concentrada está cada dimensión?

> **La idea en palabras**
>
> Imaginemos un pastel repartido entre varias personas. Si una se lleva casi todo, el reparto está concentrado. El índice de Herfindahl-Hirschman (HHI) resume en un solo número qué tan desigual es el reparto: vale casi 1 si uno se lleva todo y vale poco si todos reciben parecido. Es el mismo índice que usan las autoridades de competencia para saber si un mercado está dominado por una sola empresa.

El cálculo se hace en tres pasos.

Paso A: la cuota de cada unidad (qué parte del pastel le toca):

$$s_i = \frac{x_i}{x_1 + x_2 + \cdots + x_N}$$

Paso B: el índice (se elevan las cuotas al cuadrado y se suman):

$$\text{HHI} = s_1^2 + s_2^2 + \cdots + s_N^2 = \sum_{i=1}^{N} s_i^2$$

Paso C: el índice normalizado (para que siempre vaya de 0 a 1):

$$\text{HHI}^* = \frac{\text{HHI} - \frac{1}{N}}{1 - \frac{1}{N}}$$

Símbolo	Qué significa
x_i	Lo que tiene la unidad i (pasajeros de un aeropuerto, cuartos de un destino…)
N	Cuántas unidades hay (4 aeropuertos, 11 municipios…)
s_i	Cuota de la unidad i; todas las cuotas suman 1
$\sum$	"Suma de": $\sum_{i=1}^{N} s_i^2$ se lee "suma los cuadrados de las cuotas, desde la unidad 1 hasta la N"
HHI^*	Índice normalizado: 0 = reparto parejo, 1 = todo en una sola unidad

¿Por qué elevar al cuadrado? Para que las unidades grandes pesen mucho más que las chicas. Una cuota de 0.9 aporta $0.9^2 = 0.81$; nueve cuotas de 0.01 juntas apenas aportan $9 \times 0.01^2 = 0.0009$. Así el índice "ve" la dominancia.

¿Por qué normalizar? El valor más bajo posible del HHI depende de cuántas unidades haya. Si todas pesan igual, cada cuota es $1/N$ y el índice vale $N \times (1/N)^2 = 1/N$: con 4 aeropuertos el mínimo es 0.25; con 11 municipios, 0.09. Para comparar dimensiones con distinto N se resta ese mínimo y se divide entre el rango posible.

Paso a paso con nuestros datos: llegadas en avión, 2024

Paso 1. Cuotas. El total es 14,769,302 + 620,384 + 352,067 + 217,524 = 15,959,277 pasajeros. La cuota de Cancún es 14,769,302 ÷ 15,959,277 = 0.92544.

Paso 2. Cuadrados. Cancún: $0.92544^2 = 0.856433$; Tulum: $0.03887^2 = 0.001511$; Cozumel: $0.02206^2 = 0.000487$; Chetumal: $0.01363^2 = 0.000186$.

Paso 3. Suma. HHI = 0.856433 + 0.001511 + 0.000487 + 0.000186 = 0.858617.

Paso 4. Normalizar. Con $N = 4$ aeropuertos, el mínimo es $1/4 = 0.25$:

$$\text{HHI}^* = \frac{0.8586 - 0.25}{1 - 0.25} = \frac{0.6086}{0.75} = 0.811$$

Qué significa: en una escala de 0 a 1, el tráfico aéreo está en 0.81: casi todo entra por una sola puerta.

La razón contra la población

Para saber si los cinco lugares reciben "poco" o "mucho", comparamos su parte de cada cosa con su parte de la gente:

$$\rho = \frac{\text{parte de la dimensión que tienen los 5 lugares}}{\text{parte de la población que tienen los 5 lugares}}$$

Si $\rho = 1$, tienen de visitantes lo mismo que de habitantes; si $\rho < 1$, reciben menos de lo que "les tocaría" por su población. Con avión: $\rho = 1.4/12.3 = 0.11$, la novena parte. Ojo: ρ es una comparación, no una meta; nada dice que el turismo deba repartirse según la población.

Dimensión	HHI*	Parte de los 5 lugares	ρ
Llegadas en avión (2024)	0.811	1.4 %	0.11
Cuartos de hotel (jul-2026)	0.219	1.7 %	0.14
Visitantes INAH (2025)	0.276	4.1 %	0.33
Negocios turísticos (DENUE)	0.133	14.4 %	1.17
Población (2020)	0.225	12.3 %	1.00

La lectura central del proyecto: los negocios están donde está la gente ($\rho = 1.17$), pero los visitantes no (ρ entre 0.11 y 0.33). El sur tiene la infraestructura de una región habitada y recibe una fracción de los visitantes. Eso es **capacidad ociosa**.

4.2 ¿Por qué estos cinco lugares? La tabla de criterios

Usamos cinco criterios: sin sargazo en rojo, sin cierres recientes, sin saturación, sin fragilidad grave y con datos para medirlos. Tres de ellos se miden con fórmulas sencillas.

Visitantes por residente (presión sobre la comunidad):

$$R_d = \frac{\text{visitantes del lugar } d \text{ en 2025}}{\text{habitantes de las localidades de acceso}}$$

Variación de un sitio (se comparan los mismos meses para que la temporada no distorsione):

$$\Delta\% = \left(\frac{\text{visitantes enero–julio 2026}}{\text{visitantes enero–julio 2025}} - 1\right) \times 100$$

Meses seguidos abierta: se cuenta hacia atrás desde el último mes con dato hasta el último mes en cero. La regla: pasa si son al menos 12 y no hubo cierres en 2026.

> **Paso a paso con nuestros datos**
>
> **Tulum, enero a julio.** 476,247 ÷ 692,946 = 0.6873; menos 1 = −0.3127; por 100 = **−31.3 %**.
>
> **Presión en la Ruta del sur.** Visitantes de Kohunlich + Dzibanché + Ichkabal = 21,850 + 6,592 + 38,186 = 66,628. Habitantes de los pueblos de acceso = 3,699 + 1,436 + 963 = 6,098. Entonces $R = 66{,}628/6{,}098 = 10.93$ visitantes por habitante.
>
> **Presión en Tulum.** $R = 1{,}031{,}443/33{,}374 = 30.91$. La Ruta recibe un tercio de la presión de Tulum: no es poco, y por eso la campaña también le pone tope.
>
> **Dzibanché.** Su último mes en cero fue enero de 2025; de febrero de 2025 a julio de 2026 son 11 + 7 = 18 meses ≥ 12: pasa. Muyil reabrió en febrero de 2026: solo 6 meses, no pasaría.

Por qué por localidad y no por municipio. Cuatro de los cinco lugares están en el municipio Othón P. Blanco (233,648 habitantes). Con la cifra municipal, Chetumal, Calderitas, la Laguna y la Ruta tendrían el mismo denominador y no se podrían comparar.

Un hallazgo que reportamos aunque no nos conviene: Kohunlich (+13.5 %) y Dzibanché (+69.2 %) crecen en 2026, pero la Ruta completa bajó 8.2 % porque Ichkabal cayó 27.5 %. Nunca destacamos solo las zonas que suben: sería escoger datos a conveniencia.

4.3 Variables, actores y relaciones

- **17 variables** con su fuente, periodo y porcentaje de huecos: 9 miden presión (llegadas por tren, crucero, frontera y avión; visitantes INAH; ocupación), 3 miden capacidad (cuartos, hoteles, negocios), 2 miden comunidad (población, servicios de vivienda) y 3 son huecos declarados (afluencia y las dos derramas).
- **Actores:** las comunidades de los cinco lugares (229,247 habitantes), los negocios turísticos de sus localidades (1,966), el Tren Maya (58,086 personas bajaron en Chetumal y Maya Ka’an en 2025), la frontera con Belice (653,306 cruces en 2025), el INAH (77,645 visitantes en las cuatro zonas) y las fuentes SITUR-Q y DataTur.
- **Relación central:** la concentración medida con el HHI.

5. Minería de datos: encontrar patrones

Materia: Minería de Datos · **Profesor:** Luis Becerril Espinosa · **Criterio 3 de la rúbrica (12 %):** identifica patrones, tendencias y relaciones con técnicas pertinentes y los interpreta en función del problema.

Conexión con la materia. El incidente crítico de esta UCA, *"Cuando los datos no mienten, pero los patrones sí importan"*, pide descubrir los patrones que explican por qué los turistas eligen destinos saturados, y menciona por nombre las técnicas que usamos: **reglas de asociación**, **análisis de sentimiento** y detección de eventos raros como huracanes. También advierte sobre la capacidad de carga, la interpretabilidad para tomadores de decisiones no técnicos y la privacidad. En este capítulo aplicamos: normalización y construcción de un índice (5.1), agrupamiento jerárquico con validación por silueta (5.2), descomposición estacional (5.3), detección de anomalías (5.4), minería de texto y reglas de asociación con Apriori (5.5) y clasificación por léxico (5.6).

5.1 El índice de presión turística (IPT)

Pregunta. ¿Qué lugar está más presionado, si cada uno se mide con cosas distintas? Chetumal tiene Tren Maya y cruces desde Belice; la Ruta tiene visitantes a zonas arqueológicas; Cancún tiene ocupación hotelera semanal. Hace falta una sola escala.

La idea en palabras

Es como calificar a alumnos de grupos distintos con exámenes distintos. Primero se pasa cada examen a la misma escala, de 0 a 1 (0 = la peor calificación de todo el estado, 1 = la mejor). Después se promedian los exámenes que presentó cada alumno. Al final se dice quién está en la mitad baja, quién en el 10 % más alto y quién en medio.

Los datos. Una tabla de 15 lugares × 55 meses (enero de 2022 a julio de 2026) = 825 renglones, con: personas que bajan del Tren Maya, cruceristas y visitantes INAH por cada mil habitantes, llegadas por cuarto de hotel y ocupación. Los diez destinos del resto del estado dan la escala común; sin ellos, "tranquilo" no significaría nada.

Paso 1. Llevar todo a la misma escala (normalización mín–máx):

$$z = \frac{x - \text{mín}}{\text{máx} - \text{mín}}$$

Paso 2. Promediar lo que cada lugar tiene:

$$\text{IPT} = \frac{z_1 + z_2 + \cdots + z_n}{n}$$

Paso 3. Clasificar con percentiles comunes:

$$\text{estado} = \begin{cases} \text{tranquilo} & \text{si IPT} < u_{50} \\ \text{concurrido} & \text{si } u_{50} \le \text{IPT} \le u_{90} \\ \text{saturado} & \text{si IPT} > u_{90} \end{cases}$$

Símbolo	Qué significa
x	El valor medido de un componente (por ejemplo, 68.78 % de ocupación)
mín, máx	El valor más bajo y más alto de ese componente en todos los lugares y meses juntos
z	El valor ya en escala de 0 a 1
n	Cuántos componentes tiene ese lugar en ese mes (no todos los lugares tienen los mismos)
u_{50}, u_{90}	Percentiles 50 y 90 del índice: la mitad de los casos queda abajo de u_{50} y el 90 % abajo de u_{90}

Por qué mín–máx. La transformación es una línea recta, así que conserva el orden y las proporciones, y el 0 y el 1 tienen significado ("lo más bajo" y "lo más alto registrado en el estado"). Estandarizar ($z = (x - \bar{x})/\sigma$) da números negativos y sin límite, más difíciles de explicar; usar percentiles pierde las proporciones.

Un componente entra al índice solo si lo tienen al menos dos lugares; si no, ese lugar se compararía contra sí mismo. Así salió Belice, que solo tiene Chetumal.

Paso a paso con nuestros datos: Cancún, julio de 2026

Componente	Valor x	mín	máx	z
Tren Maya (por mil habitantes)	25.1081	0	505.2287	0.0497
INAH, zona El Rey (por mil)	0.9608	0	6,451.8787	0.0001
Llegadas por cuarto	0.4709	0	432.0230	0.0011
Ocupación (DataTur)	68.78 %	17.97	88.40	0.7214

Paso 1, Tren Maya: $z = (25.1081 - 0)/(505.2287 - 0) = 0.0497$.

Paso 1, ocupación: $z = (68.78 - 17.97)/(88.40 - 17.97) = 50.81/70.43 = 0.7214$.

Paso 2, promedio de los cuatro:

$$\text{IPT} = \frac{0.0497 + 0.0001 + 0.0011 + 0.7214}{4} = \frac{0.7723}{4} = 0.1931$$

Paso 3: con los cortes del índice comparable ($u_{50} = 0.186$, $u_{90} = 0.756$), 0.193 queda entre los dos: Cancún está **concurrido**.

La prueba de validez que falló, y por qué la contamos

La primera versión (solo con SITUR-Q) calificaba a Cancún como "tranquilo" en julio de 2026, con 0.025. La razón: SITUR-Q dejó de publicar la ocupación en 2025 y, sin ella, Cancún solo tenía componentes casi

en cero; para ese mes DataTur marcaba 68.8 %. Un índice que dice que Cancún está tranquilo en julio no es válido. Comparamos cuatro variantes:

Variante	Cancún	Isla Mujeres	Chetumal	Ruta	Problema
A. Mín–máx, solo SITUR-Q	0.02	—	0.39	0.14	El norte “desaparece”
B. A + ocupación DataTur	0.28	0.45	0.39	0.14	Chetumal arriba de Cancún
C. Percentil + DataTur	0.44	0.25	0.48	0.71	La Ruta arriba de Cancún
D. B sin componentes de un solo lugar (elegida)	0.28	0.45	0.05	0.14	Quiebre de 2025

Dos índices. El quiebre de 2025 (Chetumal “cayó” de 0.54 a 0.05 sin que llegara menos gente) fue un cambio en los datos, no en la realidad, y un modelo entrenado con eso aprendería cambios falsos. Por eso el Radar publica un **índice comparable**: cada lugar usa solo las medidas que tiene hoy, y solo en los meses en que las tiene todas. Con él, en julio de 2026 estaban concurridos Mahahual (0.731), Isla Mujeres (0.510), Bacalar (0.314), Holbox (0.228), Cancún (0.193) y Cozumel (0.191); los cinco lugares de la campaña estaban tranquilos (Ruta 0.129, Chetumal 0.025, Oxtankah 0.020, Maya Ka’an 0.009). La Laguna Milagros no tiene ninguna serie: aparece como “sin dato oficial”, nunca como “tranquila”.

Sensibilidad. Movimos cada peso a 0.5 y a 1.5 (con los demás en 1) y contamos cuántos lugar-mes cambian de estado: entre el 0.6 % y el 6.0 %. La elección de pesos iguales no decide el resultado.

5.2 Agrupamiento de los centros turísticos del país (método de Ward)

Pregunta. ¿A qué se parece el norte de Quintana Roo dentro del país? Si está en el grupo de los destinos más llenos de México, la saturación no es una impresión.

> **La idea en palabras**
>
> Cada centro turístico tiene una “huella” de 12 números: qué tan lleno está cada mes del año. El agrupamiento junta los centros cuyas huellas se parecen. Empieza con cada centro solo y va uniendo, de dos en dos, los grupos que menos “desordenan” el conjunto, hasta formar un árbol.

La huella de cada centro (su ocupación en cada mes del año, sumando los cuartos de todos los años):

$$p_{c,m} = 100 \times \frac{\text{cuartos ocupados del centro } c \text{ en el mes } m\text{, todos los años}}{\text{cuartos disponibles del centro } c \text{ en el mes } m\text{, todos los años}}$$

Qué tan distintos son dos centros (distancia euclidiana, el “teorema de Pitágoras” con 12 dimensiones):

$$d(c, c') = \sqrt{\left(p_{c,1} - p_{c',1}\right)^2 + \left(p_{c,2} - p_{c',2}\right)^2 + \cdots + \left(p_{c,12} - p_{c',12}\right)^2}$$

El costo de unir dos grupos A y B según Ward (1963):

$$\Delta(A,B) = \frac{|A| \cdot |B|}{|A| + |B|} \parallel \bar{p}_A - \bar{p}_B \parallel^2$$

Símbolo	Qué significa
$\|A\|$	Cuántos centros tiene el grupo A
$\bar{p}_A$	La huella promedio del grupo A
$\parallel \bar{p}_A - \bar{p}_B \parallel^2$	La distancia al cuadrado entre las dos huellas promedio
$\Delta(A,B)$	Cuánto aumenta el "desorden" (la varianza dentro de los grupos) si se unen A y B

En cada paso, Ward une los dos grupos con el menor Δ: la unión más "barata". El resultado son grupos compactos.

¿Cuántos grupos? Se mide con la **silueta** de cada centro (Rousseeuw, 1987):

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i),\, b(i)\}}$$

donde $a(i)$ es la distancia promedio del centro a los de su propio grupo y $b(i)$ la distancia promedio al grupo vecino más cercano. Va de −1 (mal asignado) a 1 (perfectamente asignado). Se elige el número de grupos con la mayor silueta promedio:

Número de grupos k	2	3	4	5	6	7	8
Silueta promedio	**0.450**	0.380	0.365	0.300	0.283	0.317	0.306

Paso a paso con nuestros datos: silueta de Cancún

Paso 1. Distancia promedio de Cancún a los otros 22 centros de su grupo: $a = 43.84$.

Paso 2. Distancia promedio a los 32 centros del otro grupo: $b = 116.21$.

Paso 3.

$$s = \frac{116.21 - 43.84}{\max\{43.84,\ 116.21\}} = \frac{72.37}{116.21} = 0.623$$

Qué significa: 0.623 está cerca de 1: Cancún está bien asignado a su grupo.

Resultado ($k = 2$). Grupo 1, playas y destinos muy ocupados: 23 centros con 64.5 % de ocupación promedio (Cancún, Riviera Maya, Playacar, Akumal, Playa del Carmen, Los Cabos). Grupo 2, el resto del país: 32 centros con 41.1 % (incluye a Cozumel e Isla Mujeres). Solo entran centros con sus 55 meses completos: los incompletos no se rellenan, se excluyen.

Segunda opinión. Con k-means y el mismo número de grupos, el índice de Rand ajustado es 0.49: la frontera entre grupos depende del método (k-means pasa al grupo alto 8 centros intermedios, entre ellos Cozumel e Isla Mujeres), pero los 23 centros del grupo alto de Ward quedan también en el grupo alto de k-means. La conclusión que usamos, que el norte de Quintana Roo está en el grupo de ocupación más alta del país, no depende del método.

5.3 La forma del año (estacionalidad)

Pregunta. ¿Qué meses se llenan y cuáles se vacían en cada lugar? Es la base de la temporada alta, del pronóstico y del calendario de la campaña.

> **La idea en palabras**
>
> Para saber si enero es “alto”, se compara enero con el promedio de su propio año. Si un año tuvo 5,000 visitantes al mes en promedio y enero tuvo 8,000, enero fue 1.6 veces un mes normal. Se repite con varios años y se promedia: lo que queda es la “forma” del año.

Paso 1. La razón de cada mes contra su año:

$$r_{a,m} = \frac{y_{a,m}}{\bar{y}_a}, \qquad \bar{y}_a = \frac{y_{a,1} + y_{a,2} + \cdots + y_{a,12}}{12}$$

Paso 2. El índice del mes (promedio de las razones de ese mes en todos los años A disponibles):

$$\tilde{S}_m = \frac{1}{|A|} \sum_{a \in A} r_{a,m}$$

Paso 3. Reescalar para que los 12 índices promedien exactamente 1: $S_m = \tilde{S}_m / \left(1/12 \sum_{k=1}^{12} \tilde{S}_k\right)$.

Símbolo	Qué significa
$y_{a,m}$	Visitantes del año a en el mes m
$\bar{y}_a$	Promedio mensual del año a
$r_{a,m}$	Cuántas veces un mes normal fue ese mes en ese año
S_m	Índice estacional del mes m: 1.6 = “60 % más que un mes normal”; 0.5 = “la mitad”

¿Multiplicativa o aditiva? Aditiva diría “enero tiene 2,000 visitantes más”; multiplicativa, “enero tiene 61 % más”. Kohunlich reabrió en 2025 con la mitad de su nivel de 2019: “+2,000” ya no vale, pero “+61 %” sí. La temporada crece con el nivel, así que es multiplicativa.

Fuerza de la temporada (Wang et al., 2006). Mide qué parte de los cambios de un mes a otro explica la temporada:

$$F_S = \max\left(0,\ 1 - \frac{\mathrm{Var}(e)}{\mathrm{Var}(s+e)}\right)$$

donde $s + e$ es toda la variación de un mes a otro (en logaritmos) y e es la parte que la temporada no explica. Si la temporada lo explica todo, $\mathrm{Var}(e) = 0$ y $F_S = 1$.

> **Paso a paso con nuestros datos: Ruta arqueológica del sur**
>
> **Paso 1, una razón.** En 2019, Kohunlich + Dzibanché sumaron 64,139 visitantes: $\bar{y}_{2019} = 64{,}139/12 = 5{,}344.92$. En enero hubo 7,935: $r_{2019,1} = 7{,}935/5{,}344.92 = 1.4846$.
>
> **Paso 2, el índice de enero.** Las seis razones de enero (2016–2019, 2022 y 2023) son 1.5459, 1.7075, 1.8266, 1.4846, 1.2540 y 1.8173. Suman 9.6359; entre 6: $\tilde{S}_1 = 1.606$.

Paso 3. El promedio de los 12 índices ya es 1.0000, así que $S_1 = 1.606$: en enero llega **61 % más gente** que en un mes promedio. En septiembre, $S_9 = 0.496$: la mitad.

Fuerza: $\text{Var}(e) = 0.03152$ y $\text{Var}(s + e) = 0.15230$:

$$F_S = 1 - \frac{0.03152}{0.15230} = 1 - 0.2070 = 0.793$$

El 79 % de la variación de un mes a otro en la Ruta es temporada.

Serie	Fuerza F	Mes más alto	Mes más bajo
Ruta arqueológica del sur	0.793	enero (1.606)	septiembre (0.496)
Bahía Calderitas–Oxtankah	0.684	diciembre (1.402)	septiembre (0.647)
Chetumal (cruces de Belice)	0.655	diciembre (1.172)	febrero (0.865)
Cancún (referencia)	0.714	marzo (1.084)	septiembre (0.867)

¿Por qué no STL? La descomposición STL necesita una serie continua, y estas tienen huecos (pandemia, cierres por obras). STL solo podría usar el tramo continuo más largo. La usamos como segunda opinión en ese tramo: su índice coincide con el nuestro entre 0.85 y 0.97.

5.4 Clima raro con Isolation Forest (detección de anomalías)

Pregunta. ¿Esta semana tuvo un clima tan raro que conviene pausar el anuncio? Necesitamos detectar “lo raro” sin que alguien lo defina a mano.

La idea en palabras

Imaginemos que separamos puntos en un plano con cortes al azar. Un punto alejado de todos se queda solo con muy pocos cortes; un punto en medio de la multitud necesita muchísimos. Isolation Forest (Liu et al., 2008) hace eso con 300 árboles de cortes al azar y mide cuántos cortes tarda, en promedio, en aislar cada semana. Las semanas raras se aíslan rápido.

$$s(x) = 2^{-E[h(x)]\,/\,c(n)}, \qquad c(n) = 2\,H(n-1) - \frac{2(n-1)}{n}, \qquad H(k) \approx \ln k + 0.5772$$

Símbolo	Qué significa
$h(x)$	Número de cortes que tardó en aislarse la semana x en un árbol
$E[h(x)]$	El promedio de esos cortes en los 300 árboles
n	Semanas que usa cada árbol (hasta 256)
$c(n)$	Los cortes que tarda, en promedio, una semana cualquiera; sirve para comparar
$H(k)$	Número armónico: $1 + 1/2 + 1/3 + \cdots + 1/k$, que se aproxima con $\ln k + 0.5772$
$s(x)$	Puntaje de rareza: cerca de 0.5 es normal; cerca de 1, muy raro

Cómo leer la fórmula. Si una semana tarda lo mismo que cualquier otra ($E[h] = c(n)$), el exponente vale −1 y $s = 2^{-1} = 0.5$: normal. Si se aísla mucho más rápido ($E[h]$ mucho menor que $c(n)$), el exponente se acerca a 0 y s se acerca a $2^0 = 1$: muy rara.

Las variables son la lluvia de la semana, la lluvia del peor día, el viento máximo, la temperatura máxima y la época del año (como seno y coseno de la semana). La época entra para que un aguacero de septiembre no salga raro solo por ser septiembre.

Paso a paso con nuestros datos: Chetumal, semana del 14 de octubre de 2024 (tormenta Nadine)

Llovieron 148.7 mm (65.4 mm el peor día). Había 260 semanas de entrenamiento, así que cada árbol usa $n = 256$.

Paso 1, el número de referencia:

$$c(256) = 2(\ln 255 + 0.5772) - \frac{2 \times 255}{256} = 2(5.5413 + 0.5772) - 1.9922 = 12.237 - 1.992 = 10.245$$

Paso 2. El bosque calcula $s = 0.712$. El corte que elegimos (percentil 95 de las semanas de entrenamiento) es 0.543. Como 0.712 > 0.543, **la semana es rara**.

Paso 3, ¿cuántos cortes tardó? Despejando la fórmula: $E[h] = -c(n) \times \log_2 s = -10.245 \times \log_2 0.712 = -10.245 \times (-0.489) = 5.0$ cortes, contra unos 10 de una semana normal.

Lo que decidimos. El corte automático del método (marcar raro si $s > 0.5$) señalaba el 47 % de las semanas de Chetumal en el primer intento, entrenado solo con 2019–2021 (con la ventana creciente todavía marcaría el 36 %): con pocas semanas el bosque no distinguía, y desde 2022 llueve más y hace más calor que en 2019–2021. Elegimos “más raro que el 95 % de las semanas que el bosque ya conoce”, con un bosque por año entrenado con todos los años anteriores. Resultado: 21 semanas raras en Chetumal y 17 en Kohunlich.

Validación independiente: el bosque marcó como raras las tres semanas en que pasaron tormentas (Lisa en 2022, Nadine y Sara en 2024) sin saber que hubo tormenta. Es evidencia de que "raro" significa algo real.

Comparación con otros detectores. Con la misma ventana creciente y el mismo corte (percentil 95), probamos también la regla de 3 desviaciones, Local Outlier Factor y One-Class SVM. Los cuatro encuentran las tres semanas de tormenta, así que la diferencia está en las falsas alarmas, porque cada semana rara pausa los anuncios del sur: Isolation Forest es el que menos semanas marca (21 en Chetumal y 17 en Kohunlich, de 247), contra 23 y 20 de la regla de 3 desviaciones, 26 y 30 de Local Outlier Factor y 71 y 33 de One-Class SVM. Además mira las seis variables juntas y no supone que la lluvia siga una curva normal.

5.5 Minería de texto de las reseñas

Pregunta. ¿Qué molesta y qué enamora al turista? Es lo que define la promesa de la campaña y sus palabras.

Datos: 85,987 reseñas de Quintana Roo (Rest-Mex 2025, sin duplicados) de Tulum, Isla Mujeres y Bacalar; 3,597 son malas (1–2 estrellas) y 60,082 de 5 estrellas. Ninguna es de los cinco lugares, así que sirven para saber qué molesta en los destinos llenos, no para opinar del sur.

Temas y riesgo relativo

Cada tema es una lista de raíces de palabras que cuentan solo al inicio de una palabra. Por ejemplo, "ruido" incluye *ruido, ruidos, escándalo, música alta, fiesta*; "calma" incluye *tranquil-, paz, relaj-, silencio*. Para saber si un tema "aleja" o "protege", usamos el **riesgo relativo**, la medida que usa la epidemiología:

$$RR = \frac{P(\text{mala} \mid \text{la reseña habla del tema})}{P(\text{mala})}$$

Se lee: "¿cuántas veces más seguido es mala una reseña que habla de este tema, comparada con una reseña cualquiera?". $RR = 1$: el tema no cambia nada; $RR = 2$: es mala el doble de seguido; $RR < 1$: el tema protege.

Paso a paso con nuestros datos: el ruido

Paso 1. Probabilidad de que una reseña cualquiera sea mala: $P(\text{mala}) = 3{,}597/85{,}987 = 0.04183$ (4.2 %).

Paso 2. De las 2,038 reseñas que hablan de ruido, 235 son malas: $P(\text{mala} \mid \text{ruido}) = 235/2{,}038 = 0.11531$ (11.5 %).

Paso 3.

$$RR_{\text{ruido}} = \frac{0.11531}{0.04183} = 2.76$$

Qué significa: una reseña que habla de ruido es mala casi tres veces más seguido que una reseña cualquiera.

Tema	RR	Lectura	Tema	RR	Lectura
Ruido	2.76	Aleja	Comida	0.81	Protege un poco
Suciedad	1.89	Aleja	Naturaleza	0.73	Protege
Precio	1.66	Aleja	Cultura	0.48	Protege
Multitudes	1.52	Aleja	Calma	0.41	Protege
Servicio	1.18	Neutro			

Por qué léxico y no un modelo de temas (LDA). Con LDA cada tema es una lista de palabras que hay que interpretar. Con un léxico, cada tema se define antes y se defiende palabra por palabra. Para una campaña que tiene que explicar por qué promete calma, lo segundo es más defendible.

Reglas de asociación (algoritmo Apriori)

> **La idea en palabras**
>
> Es el análisis de la "canasta del súper": si quien compra pan suele comprar leche, hay una regla pan ⇒ leche. Aquí cada reseña es una canasta con sus temas y su calificación, y buscamos qué temas aparecen juntos con las reseñas malas o con las de 5 estrellas.

$$\text{soporte}(A) = \frac{\text{reseñas que contienen } A}{N}, \qquad \text{confianza}(A \Rightarrow B) = \frac{\text{soporte}(A \text{ y } B)}{\text{soporte}(A)}, \qquad \text{lift} = \frac{\text{confianza}(A \Rightarrow B)}{\text{soporte}(B)}$$

Medida	Pregunta que responde
Soporte	¿Qué tan frecuente es la combinación en todo el conjunto?
Confianza	Cuando aparece A, ¿qué tan seguido aparece también B?
Lift	¿Cuántas veces más probable es B cuando aparece A, comparado con lo normal? Si vale 1, no hay relación

El truco de Apriori (Agrawal y Srikant, 1994): si una combinación es rara, todas las combinaciones más grandes que la contienen también lo son. Así no tiene que revisar todas las combinaciones posibles. Usamos soporte mínimo de 0.1 % y combinaciones de hasta tres elementos.

> **Paso a paso con nuestros datos: ruido + mal servicio ⇒ reseña mala**
>
> 1,204 reseñas hablan de ruido y de servicio a la vez; 142 de ellas son malas.
>
> **Soporte** = 142 ÷ 85,987 = 0.00165. **Confianza** = 142 ÷ 1,204 = 0.1179. **Lift** = 0.1179 ÷ 0.04183 = **2.82**.
>
> **Qué significa:** una reseña que se queja de ruido y de servicio es mala 2.8 veces más seguido de lo normal. Otras reglas: suciedad + multitudes (lift 2.59), suciedad + precio (2.54). Hacia 5 estrellas: comida + servicio (1.12) y calma + naturaleza (1.10).

Las palabras que distinguen a las reseñas buenas

Contar palabras no basta: una palabra rara que aparece dos veces en las buenas y nunca en las malas daría un cociente enorme por pura casualidad. El método de Monroe et al. (2008) agrega un "colchón" proporcional a lo común que es la palabra y entrega un puntaje z, que se lee como "cuántas desviaciones estándar se aleja la palabra de lo esperado":

$$\delta_w = \ln\frac{y_w^A + \alpha_w}{n^A + \alpha_0 - y_w^A - \alpha_w} - \ln\frac{y_w^B + \alpha_w}{n^B + \alpha_0 - y_w^B - \alpha_w}, \qquad z_w = \frac{\delta_w}{\sqrt{\frac{1}{y_w^A + \alpha_w} + \frac{1}{y_w^B + \alpha_w}}}$$

Símbolo	Qué significa
A, B	Reseñas de 5 estrellas y reseñas malas
y_w^A	Veces que aparece la palabra w en las reseñas de 5 estrellas
n^A	Total de palabras en las reseñas de 5 estrellas
α_w	El colchón: 0.01 × veces que aparece la palabra en todo el corpus
δ_w	Diferencia de "momios" (en logaritmo) entre buenas y malas
z_w	Puntaje final: positivo = palabra de reseña buena; negativo = de reseña mala

Paso a paso con nuestros datos: la palabra "excelente"

Datos: $y^A = 18{,}952$, $y^B = 144$, $\alpha = 190.96$, $n^A = 1{,}879{,}868$, $n^B = 162{,}035$, $\alpha_0 = 20{,}419.0$.

Paso 1, momios en las buenas: $(18{,}952 + 190.96)/(1{,}879{,}868 + 20{,}419 - 18{,}952 - 190.96) = 19{,}142.96/1{,}881{,}144.04$; su logaritmo es −4.5878.

Paso 2, momios en las malas: $334.96/182{,}119.04$; su logaritmo es −6.2985.

Paso 3, diferencia: $\delta = -4.5878 - (-6.2985) = 1.7107$.

Paso 4, puntaje:

$$z = \frac{1.7107}{\sqrt{1/19{,}142.96 + 1/334.96}} = \frac{1.7107}{0.05512} = 31.04$$

"Excelente" es de las palabras que más distinguen a las reseñas de 5 estrellas. En el otro extremo, "sucia" tiene $z = -18.76$.

Palabras de 5 estrellas: *excelente, increíble, hermoso, deliciosa, amable, ruinas, ambiente*. Palabras de reseñas malas: *peor, horrible, dinero, caro, sucia, grosero*. Con ellas se escribieron los mensajes de la campaña (capítulo 9).

5.6 Qué hacer, dónde comer y dónde dormir: clasificación por léxico

De los negocios del DENUE, ¿cuáles recomendar en cada lugar? Usamos un clasificador por léxico que lee el nombre del negocio y, si el nombre no dice nada, su giro oficial (SCIAN). No entrenamos un

modelo estadístico porque no hay etiquetas con qué entrenarlo; un léxico es lo honesto y se explica regla por regla. Las reglas salieron de errores reales: “MICHELADAS” contiene “HELAD” y salía como heladería, y “BARBACOA” contiene “BAR”; por eso la raíz cuenta solo al inicio de una palabra. **Precisión medida:** revisamos a mano dos muestras al azar: 38 de 40 y, tras corregir, 39 de 40 en una muestra nueva.

6. Aprendizaje de máquina: predecir

Materia: Aprendizaje de Máquina · **Profesor:** Raúl Jorge Domínguez Vilchis · **Criterio 4 de la rúbrica (12 %):** construye, valida, compara e interpreta modelos con métricas adecuadas y justifica la selección.

Conexión con la materia. El incidente crítico de esta UCA pide desarrollar "modelos de predicción, clasificación o agrupamiento" para detectar patrones de saturación e identificar temporadas, pero advierte que "un modelo con alta precisión no necesariamente produce una solución sustentable" y que los modelos pueden "favorecer a los lugares más conocidos". Por eso este capítulo tiene las dos tareas clásicas del curso (**clasificación** y **regresión**), compara cada modelo contra una línea base, valida sin dejar que el modelo "vea el futuro" y reporta el sesgo hacia los lugares con más datos.

El proyecto tiene dos problemas de aprendizaje de máquina distintos, y conviene no confundirlos:

	Clasificación (Radar)	Regresión de series de tiempo (Pronóstico)
Qué predice	Un estado: tranquilo, concurrido o saturado	Un número: cuántos visitantes
Horizonte	El mes siguiente	De 1 a 12 meses
Modelos	Regresión logística, Random Forest, Gradient Boosting	Línea base, Holt-Winters (2), regresión con clima, Gradient Boosting
Contra qué se compara	"Igual que este mes"	"El mismo mes del año pasado"
Métricas	Aciertos, cambios anticipados, F1	MAE, MAPE, cobertura del rango

6.1 Clasificación: ¿qué estado tendrá cada lugar el mes siguiente?

Unidad de análisis: un lugar en un mes. **Variable objetivo (y):** el estado del índice comparable el mes siguiente. **Variables de entrada (x, lo que el modelo ve):**

1. El índice de este mes y de los dos anteriores (IPT_t, IPT_{t-1}, IPT_{t-2}) y el cambio ($\text{IPT}_t - \text{IPT}_{t-1}$).
2. El mes del año como un punto en un círculo: $\sin\left(\frac{2\pi m}{12}\right)$ y $\cos\left(\frac{2\pi m}{12}\right)$.
3. Si es uno de los cinco lugares de la campaña (1 o 0).

¿Por qué el mes en un círculo? Si el mes entrara como el número 1 a 12, el modelo creería que diciembre (12) está lejos de enero (1), cuando son vecinos. Al ponerlo en un círculo, como las horas de un reloj, diciembre y enero quedan juntos.

Datos: 468 casos para el modelo final: 234 tranquilos, 185 concurridos y 49 saturados.

Los modelos

Línea base (persistencia): $\hat{y}_{t+1} = y_t$, es decir, "el mes que entra será igual que este". Un modelo que no le gane a esto no sirve.

Regresión logística multiclase.

La idea en palabras

El modelo le pone un puntaje a cada estado (tranquilo, concurrido, saturado) sumando las variables, cada una multiplicada por su peso. Después convierte los tres puntajes en probabilidades que suman 100 %, con una función llamada *softmax*: el estado con más puntaje se lleva la mayor probabilidad.

Paso 1, el puntaje de cada clase:

$$z_k = b_k + \beta_{k,1}x_1 + \beta_{k,2}x_2 + \cdots + \beta_{k,7}x_7$$

Paso 2, convertir puntajes en probabilidades (softmax):

$$P(y = k \mid x) = \frac{e^{z_k}}{e^{z_{\text{tranq}}} + e^{z_{\text{conc}}} + e^{z_{\text{sat}}}}$$

Símbolo	Qué significa
k	Una de las tres clases: tranquilo, concurrido o saturado
$x_1, \ldots, x_7$	Las siete variables de entrada, ya estandarizadas
$\beta_{k,j}$	Peso de la variable j para la clase k: cuánto la empuja hacia esa clase
b_k	Término independiente (el puntaje “de partida” de la clase)
e^z	El número $e \approx 2.718$ elevado al puntaje; siempre es positivo

Por qué funciona. Como e^z siempre es positivo y se divide entre la suma de los tres, las probabilidades quedan entre 0 y 1 y suman exactamente 1. Los pesos β se estiman por **máxima verosimilitud**: se buscan los que hacen más probables los estados que de verdad ocurrieron. Dos detalles: las variables se estandarizan ($(x - \bar{x})/\sigma$) para que los pesos sean comparables entre sí, y se usan **pesos de clase balanceados**, porque “saturado” es raro (49 de 468) y sin ellos el modelo casi nunca lo predeciría.

Paso a paso con nuestros datos: Mahahual, predicción para agosto de 2026

Paso 1, estandarizar. El índice de julio fue 0.731; la media de entrenamiento es 0.2762 y la desviación estándar 0.2799:

$$x_{\text{std}} = \frac{0.731 - 0.2762}{0.2799} = 1.625$$

Así con las siete variables: (1.625, 1.362, 1.623, 0.871, −0.803, −1.158, −0.657).

Paso 2, puntaje de “saturado”. Pesos β = (1.462, 1.291, 1.560, 0.567, −0.158, 1.195, −0.016) y $b = -3.255$. Multiplicamos cada variable por su peso y sumamos:

$$z_{\text{sat}} = -3.255 + 2.376 + 1.758 + 2.532 + 0.494 + 0.127 - 1.384 + 0.011 = 2.659$$

De la misma manera: $z_{\text{conc}} = 3.068$ y $z_{\text{tranq}} = -5.728$.

Paso 3, softmax. Para que la calculadora no se desborde, a todos los puntajes se les resta el mayor (3.068); el resultado no cambia:

$$e^{0} = 1, \qquad e^{2.659-3.068} = e^{-0.409} = 0.664, \qquad e^{-5.728-3.068} = e^{-8.796} = 0.00015$$

La suma es 1 + 0.664 + 0.00015 = 1.664. Entonces:

$$P(\text{concurrido}) = \frac{1}{1.664} = 0.601, \qquad P(\text{saturado}) = \frac{0.664}{1.664} = 0.399, \qquad P(\text{tranquilo}) \approx 0$$

Qué significa: con la regresión logística, Mahahual seguiría concurrido, con 40 % de probabilidad de saturarse. Random Forest, el modelo elegido (abajo), da 55 % de probabilidad de saturarse, y eso es lo que muestra la página.

Qué variable pesa más (promedio del tamaño de β en las tres clases): el índice del mes (1.07), el de dos meses antes (1.04), el del mes anterior (0.95), la temporada como coseno (0.80), el cambio (0.40) y ser uno de los cinco lugares (0.35).

Random Forest (Breiman, 2001): 400 árboles de decisión; cada uno se entrena con una muestra al azar de los casos y mira un subconjunto al azar de variables en cada corte. La predicción promedia lo que dicen los 400. Promediar muchos árboles distintos reduce los errores de un árbol solo, como cuando se pregunta a muchas personas en lugar de a una.

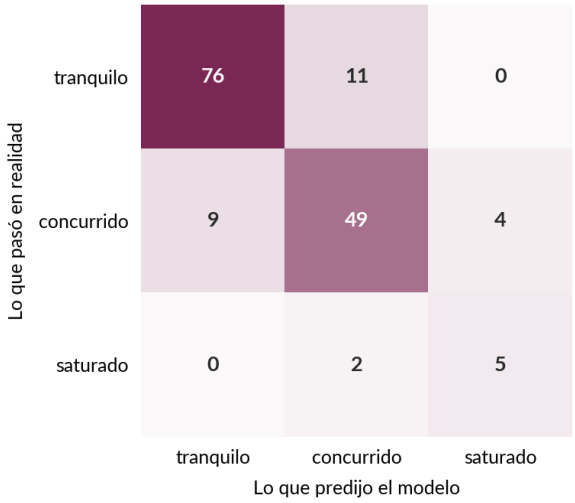
Gradient Boosting (Friedman, 2001): suma árboles pequeños uno tras otro; cada árbol nuevo se dedica a corregir los errores que dejaron los anteriores. Usamos 100 árboles con tasa de aprendizaje 0.1: $F_M(x) = \nu h_1(x) + \nu h_2(x) + \cdots + \nu h_M(x)$.

Cómo se validó: origen móvil

Por qué no revolver al azar. La forma escolar de validar (80 % para entrenar y 20 % al azar para probar) aquí sería trampa: el modelo podría entrenar con agosto y probarse con julio, es decir, ver el futuro. En series de tiempo se valida como se usaría en la vida real.

Origen móvil: para cada mes se reentrena cada modelo solo con lo anterior y se predice ese mes, en dos años distintos. Con el año de validación (agosto de 2024 a julio de 2025, 136 casos) se elige el modelo; con el año de prueba (agosto de 2025 a julio de 2026: 156 predicciones y 30 cambios reales de estado) solo se mide. Elegir con los mismos meses con que se mide premiaría al modelo que tuvo suerte en esos meses.

Las métricas



Matriz de confusión de Random Forest, el modelo elegido, en las 156 predicciones de prueba.

$$\text{Precisión} = \frac{VP}{VP + FP}, \qquad \text{Sensibilidad} = \frac{VP}{VP + FN}, \qquad F1 = \frac{2 \times \text{Precisión} \times \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

Término	Qué significa (con la clase “saturado” como ejemplo)
VP, verdaderos positivos	Dijo “saturado” y sí era saturado
FP, falsos positivos	Dijo “saturado” y no lo era (falsa alarma)
FN, falsos negativos	Era saturado y no lo dijo (se le escapó)
Precisión	De lo que el modelo dijo que era esta clase, ¿cuánto sí lo era?
Sensibilidad (*recall*)	De lo que de verdad era esta clase, ¿cuánto encontró?
F1	Media armónica de las dos: un solo número que castiga si cualquiera es baja
F1 macro	El promedio del F1 de las tres clases, con el mismo peso aunque “saturado” sea rara

Paso a paso con nuestros datos: F1 de Random Forest

En la matriz, cada renglón es lo que pasó y cada columna lo que predijo el modelo.

Tranquilo. Precisión: el modelo dijo “tranquilo” 76 + 9 + 0 = 85 veces y acertó 76: $P = 76/85 = 0.894$. Sensibilidad: hubo 76 + 11 + 0 = 87 meses tranquilos y encontró 76: $R = 76/87 = 0.874$.

$$F1 = \frac{2 \times 0.894 \times 0.874}{0.894 + 0.874} = \frac{1.5627}{1.768} = 0.884$$

Concurrido. $P = 49/62 = 0.790$, $R = 49/62 = 0.790$, $F1 = 0.790$. **Saturado.** $P = 5/9 = 0.556$, $R = 5/7 = 0.714$, $F1 = 0.625$.

F1 macro = (0.884 + 0.790 + 0.625) ÷ 3 = 0.766. Aciertos totales: 76 + 49 + 5 = 130 de 156 (83 %).

Modelo	Aciertos en la validación (de 136)	Aciertos en la prueba (de 156)	Cambios anticipados (de 30)	Falsas alarmas	F1 macro
Persistencia (línea base)	119	126	0	0	0.774
Regresión logística	112	130	8	4	0.793
Random Forest (elegido)	**122**	**130**	**6**	**2**	**0.766**
Gradient Boosting	111	128	7	5	0.731

Lo que decidimos. El criterio es “el modelo que más acierta y, a igualdad, el que más cambios anticipa”, porque la regla anti-colapso necesita anticipar. Lo aplicamos en el año de validación, y el de prueba solo mide. En la validación, Random Forest es el único que le gana a la persistencia (122 contra 119 de 136); en la prueba acierta 130 de 156, anticipa 6 de los 30 cambios y da solo 2 falsas alarmas. Antes elegíamos con los mismos meses de la prueba y ganaba la regresión logística, que en la validación queda en 112, debajo de la persistencia: elegir con la prueba premia al modelo con suerte (una máquina de vectores de soporte habría ganado en la prueba con 133, pero en la validación acierta 114). Los hiperparámetros se fijaron antes y no se buscaron en rejilla: con 136 casos, probar muchas combinaciones también sería elegir por suerte. Se respeta el criterio, no el nombre del modelo: el código elige solo.

6.2 Pronóstico de visitantes: series de tiempo

Qué series se pronostican

Serie	Fuente	Meses	Meses que entrenan
Visitantes a Oxtankah (Bahía)	DataTur, base del INAH	127	90
Kohunlich + Dzibanché + Ichkabal (Ruta)	DataTur, base del INAH	127	91
Cruces desde Belice (Chetumal)	API de SITUR-Q	90	62
Ocupación de Cancún (referencia)	DataTur semanal	55	55

El sur no tiene ocupación oficial en 2025–2026, así que se pronostica solo lo medido que llega a 2026. Maya Ka’an y la Laguna no tienen serie mensual propia: hueco declarado.

Meses que no entrenan. Un mes cerrado no es “cero demanda”. Si el modelo aprendiera de esos ceros, creería que en abril puede haber 0 visitantes por temporada. Quedan fuera del entrenamiento (pero se conservan): los cierres (la zona reportó 0), los meses parciales (justo antes de cerrar o después de reabrir) y la pandemia (INAH de marzo de 2020 a diciembre de 2021; Belice de marzo de 2020 a junio de 2022). Cada reapertura inicia un **tramo** con su propio nivel.

Los cinco modelos

Notación común: y_t = valor del mes t; o = el último mes conocido (el "origen"); h = cuántos meses hacia adelante; S_m = forma del año del capítulo 5, calculada solo con años anteriores al origen.

1. Línea base (ingenuo estacional): $\hat{y}_{o+h}$ = el último valor del mismo mes del año. "Este diciembre será como el diciembre pasado."

2 y 3. Holt-Winters con la forma del año fija.

> **La idea en palabras**
>
> Primero se le quita la temporada a la serie (cada mes se divide entre su índice), y queda el "nivel de fondo". Ese nivel se actualiza cada mes mezclando el dato nuevo con lo que ya se creía. Para pronosticar, al nivel se le vuelve a poner la temporada.

$$z_t = \frac{y_t}{S_{m(t)}}, \qquad \ell_t = \alpha\, z_t + (1-\alpha)\,\ell_{t-1}, \qquad \hat{y}_{o+h} = \ell_o \times S_{m(o+h)}$$

Símbolo	Qué significa
z_t	El dato del mes sin temporada ("desestacionalizado")
ℓ_t	El nivel de fondo después de ver el mes t
α	Cuánto se cree en el dato nuevo (entre 0 y 1): cerca de 1, el nivel sigue cada dato; cerca de 0, cambia lento
$\hat{y}_{o+h}$	El pronóstico: el último nivel por el índice del mes que se quiere pronosticar

La fórmula del nivel es un **promedio ponderado**: si $\alpha = 0.12$, el nivel nuevo es 12 % el dato nuevo y 88 % lo que ya se creía. α se estima minimizando el error de pronóstico a un paso. La variante con tendencia agrega una pendiente que se va apagando. Usamos la forma del año fija porque el Holt-Winters clásico necesita al menos 24 meses seguidos para estimar la temporada, y desde las reaperturas solo hay de 17 a 20.

> **Paso a paso con nuestros datos: Ruta, origen julio de 2026**
>
> El programa estimó $\alpha = 0.1183$.
>
> **Paso 1, quitar la temporada.** Julio tuvo 5,057 visitantes y su índice es 0.953: $z = 5{,}057/0.953 = 5{,}306.6$.
>
> **Paso 2, actualizar el nivel.** El nivel de junio era 5,332.5:
>
> $$\ell_{\text{jul}} = 0.1183 \times 5{,}306.6 + 0.8817 \times 5{,}332.5 = 627.8 + 4{,}701.7 = 5{,}329.4$$
>
> **Paso 3, pronosticar enero de 2027.** Se vuelve a poner la temporada de enero:
>
> $$\hat{y} = 5{,}329.4 \times 1.606 = 8{,}559 \text{ visitantes}$$
>
> El código da 8,559.

4. Regresión con clima (mínimos cuadrados sobre el logaritmo):

$$\ln y_t = \tau_{k(t)} + \mu_{m(t)} + \beta \cdot \frac{L_t - \bar{L}_{m(t)}}{100} + \gamma\, T_t + \varepsilon_t$$

Símbolo	Qué significa
$\ln y_t$	Logaritmo natural de los visitantes; con logaritmos los efectos se leen como porcentajes
τ_k	Nivel del tramo k (antes de 2020, después de la pandemia, desde la reapertura)
μ_m	Efecto del mes m (enero es la referencia: $\mu_1 = 0$)
$L_t - \bar{L}_m$	Lluvia del mes menos la lluvia normal de ese mes, en cientos de milímetros
T_t	1 si empezó una tormenta que afecta al sur; 0 si no
β, γ	Efecto de la lluvia y de la tormenta
ε_t	Error: lo que el modelo no explica

Los coeficientes se estiman por **mínimos cuadrados ordinarios**: se buscan los que hacen más pequeña la suma de los errores al cuadrado. En forma matricial, $\hat{\theta} = (X^\top X)^{-1} X^\top y$. Para el futuro el clima no se conoce, así que se usa el normal: lluvia anómala = 0 y tormenta = su frecuencia histórica en ese mes.

Paso a paso con nuestros datos: Bahía, diciembre de 2026

Paso 1. El tramo actual (desde la reapertura de 2024) tiene $\hat{\tau} = 7.0382$; es decir, un enero típico tiene $e^{7.0382} = 1{,}139$ visitantes.

Paso 2. El efecto de diciembre es $\hat{\mu}_{12} = 0.1404$: diciembre es $e^{0.1404} = 1.151$ veces un enero.

Paso 3. Nunca hubo tormenta en diciembre ($\hat{p} = 0$) y la lluvia se supone normal. Se suman los logaritmos y se regresa con la exponencial:

$$\hat{y} = e^{7.0382 + 0.1404} = e^{7.1786} = 1{,}311 \text{ visitantes}$$

El código da 1,311.13. Además, el coeficiente de la lluvia, $\hat{\beta} = -0.115$, dice que cada 100 mm de lluvia sobre lo normal se asocian a $e^{-0.115} - 1 = -10.9\,\%$ de visitantes (valor $p = 0.027$).

5. Gradient Boosting con rezagos: 150 árboles que aprenden de todos los pares pasados (origen, destino) con: meses hacia adelante, mes del año, logaritmo del último valor, del promedio de los últimos 3 meses y del mismo mes del año anterior.

Cómo se midió el error

Para cada mes del pasado (desde enero de 2019 en el INAH) se pronostican los 12 siguientes **usando solo lo que se sabía entonces** y se compara con lo que pasó. Solo cuentan los pares que los cinco modelos pudieron pronosticar (366 en la Bahía, 378 en la Ruta, 366 en Belice y 438 en Cancún), para que la comparación sea justa.

$$\text{MAE} = \frac{1}{n}\sum|y - \hat{y}|, \qquad \text{MAPE} = \frac{100}{n}\sum\left|\frac{y - \hat{y}}{y}\right|, \qquad \text{error relativo} = \frac{\text{MAE del modelo}}{\text{MAE de la línea base}}$$

Medida	Cómo se lee
MAE	En promedio, ¿por cuántos visitantes se equivoca?
MAPE	En promedio, ¿por qué porcentaje se equivoca?
Error relativo	Menor que 1: el modelo le gana a “el mismo mes del año pasado”

El rango del 90 %: intervalo conformal

La idea en palabras

Revisamos los errores que el modelo cometió en el pasado en pronósticos parecidos. Si 9 de cada 10 fueron menores que cierto tamaño, lo razonable es decir que el próximo tampoco se equivocará más que eso, con 90 % de confianza. No suponemos que los errores sigan una campana normal: usamos los errores reales (Angelopoulos y Bates, 2023).

$$k = \lceil (n+1) \times 0.9 \rceil, \qquad \hat{q} = \text{el } k\text{-ésimo error más chico}, \qquad \text{rango} = \left[\, \hat{y}\, e^{-\hat{q}},\ \ \hat{y}\, e^{\hat{q}} \,\right]$$

Símbolo	Qué significa
n	Cuántos errores pasados hay del mismo modelo y del mismo plazo (1–3, 4–6 o 7–12 meses)
$\lceil\ \rceil$	Redondear hacia arriba
$\hat{q}$	El tamaño de error que cubre al 90 % de los casos (en logaritmo)
$e^{\pm\hat{q}}$	Convierte ese error en un factor: el rango va de “tantas veces menos” a “tantas veces más”

La garantía: si los errores futuros se parecen a los pasados, el dato real cae dentro del rango al menos $k/(n+1)$ de las veces. El “+1” y el redondeo hacia arriba son la corrección que vuelve la garantía exacta con muestras chicas. Trabajamos en logaritmos porque los errores son proporcionales al nivel (equivocarse por 100 no es lo mismo con 1,000 visitantes que con 10,000).

Paso a paso con nuestros datos: Bahía, diciembre de 2026 (5 meses adelante)

Paso 1. Hay $n = 105$ errores pasados: $k = \lceil 106 \times 0.9 \rceil = \lceil 95.4 \rceil = 96$.

Paso 2. Se ordenan los 105 errores de menor a mayor; el número 96 es $\hat{q} = 0.3132$. Garantía: 96/106 = 90.6 %.

Paso 3. Con el pronóstico de 1,311.13:

$$\text{mínimo} = 1{,}311.13 \times e^{-0.3132} = 1{,}311.13 \times 0.7311 = 959$$

$$\text{máximo} = 1{,}311.13 \times e^{0.3132} = 1{,}311.13 \times 1.3678 = 1{,}793$$

Comprobación: diciembre de 2025 tuvo 1,224 visitantes, dentro del rango.

La elección y los resultados

Regla: por serie, el modelo de menor error entre los que tienen un rango que se cumple al menos 80 de cada 100 veces. Descartamos “el menor error sin importar el rango” (en la Ruta elegiría un modelo cuyo rango acierta 72 de cada 100) y “un solo modelo para todo” (en Cancún la regresión comete 58 % más error que la línea base).

Serie	Modelo	MAPE	Error vs. base	Cobertura	Rango típico
Bahía	**Regresión con clima**	15.7 %	0.898	91.3 %	±43 %
	Holt-Winters sin tendencia	19.4 %	1.078	96.5 %	±63 %
	Holt-Winters con tendencia	27.6 %	1.524	87.8 %	±108 %
	Gradient Boosting	28.7 %	1.405	85.8 %	±83 %
	Línea base	19.8 %	1.000	85.4 %	±77 %
Ruta	**Regresión con clima**	21.6 %	0.737	80.3 %	±51 %
	Holt-Winters sin tendencia	20.1 %	0.639	72.3 %	±45 %
	Línea base	27.9 %	1.000	74.3 %	±63 %
Belice	**Regresión con clima**	11.0 %	0.820	94.1 %	±26 %
Cancún	**Línea base**	3.8 %	1.000	89.3 %	±10 %

El valor comercial que pide el incidente. El incidente de esta UCA pide pensar cómo la solución predictiva puede volverse un producto de negocio. El Radar y el Pronóstico ya funcionan como un servicio: cualquier hotelero o autoridad puede consultar el estado de un lugar el mes siguiente y su rango de visitantes a 12 meses. Y la predicción también decide **cuándo activar la campaña**: solo en los meses que el pronóstico marca con espacio.

7. Modelos estocásticos: la incertidumbre

Materia: Modelos Estocásticos para la Toma de Decisiones · **Profesor:** René Chablé García · **Criterio 5 de la rúbrica (10 %):** incorpora la incertidumbre, genera escenarios pertinentes y analiza sus implicaciones para decidir.

Conexión con la materia. El incidente crítico de esta UCA pregunta: *"¿Qué pasaría si la campaña funciona mejor o peor de lo esperado?"*. Pide intervalos de confianza para la demanda, escenarios optimista, moderado y pesimista con su probabilidad, simulación de **Monte Carlo** para el riesgo de rebasar la capacidad de carga, análisis de sensibilidad y comunicar la incertidumbre a personas no técnicas. Aplicamos tres procesos estocásticos del curso: una **cadena de Markov** (cómo cambia de estado la ocupación del norte semana a semana), un **proceso de Poisson** (cuántas tormentas llegan cada mes) y una **simulación de Monte Carlo** (cuántos visitantes podrían llegar en los próximos 12 meses).

Un **proceso estocástico** es algo que evoluciona en el tiempo con una parte de azar. No sabemos exactamente qué va a pasar, pero sí con qué probabilidad puede pasar cada cosa.

7.1 Cadena de Markov semanal del norte

Pregunta. Si Cancún está concurrido esta semana, ¿qué probabilidad hay de que se sature en las próximas semanas? Cuando el norte se va a saturar es el momento de ofrecerle el sur a quien iba allá.

La idea en palabras

Una cadena de Markov es como un juego de tablero en el que la siguiente casilla depende solo de la casilla donde estás, no de cómo llegaste. Aquí las casillas son tranquilo, concurrido y saturado, y las probabilidades de moverse de una a otra se cuentan con lo que pasó en 239 semanas reales.

Datos. 7 centros de DataTur (Cancún, Riviera Maya, Playa del Carmen, Playacar, Akumal, Cozumel e Isla Mujeres) × 239 semanas. Cada semana se clasifica con los percentiles de la ocupación de todas las semanas de los 7 centros: tranquilo por debajo de 71.16 %, saturado por encima de 85.92 %.

La propiedad de Markov ("solo importa el presente"):

$$P(X_{t+1} = j \mid X_t = i,\ X_{t-1},\ \ldots) = P(X_{t+1} = j \mid X_t = i) = p_{ij}$$

Cómo se estima cada probabilidad (contar y dividir):

$$\hat{p}_{ij} = \frac{n_{ij}}{n_{i,\text{tranq}} + n_{i,\text{conc}} + n_{i,\text{sat}}}$$

Símbolo	Qué significa
X_t	El estado del centro turístico en la semana t
p_{ij}	Probabilidad de pasar del estado i (esta semana) al estado j (la siguiente)
n_{ij}	Cuántas veces, en los datos, un centro pasó de i a j entre dos semanas seguidas
P	La matriz de transición: una tabla de 3 × 3 con todas las p_{ij}; cada renglón suma 1

Por qué "contar y dividir" es lo correcto. Es el estimador de máxima verosimilitud: de todas las matrices posibles, es la que hace más probable haber observado exactamente las transiciones que vimos, con la condición de que cada renglón sume 1.

Paso a paso con nuestros datos: la matriz de transición

Esta semana	Conteo → tranq.	→ conc.	→ sat.	Prob. → tranq.	→ conc.	→ sat.
Tranquilo	765	65	0	0.922	0.078	0.000
Concurrido	67	555	46	0.100	0.831	0.069
Saturado	2	44	122	0.012	0.262	0.726

Un renglón. Desde "tranquilo" hubo 765 + 65 + 0 = 830 transiciones; 765 se quedaron en tranquilo: 765 ÷ 830 = 0.922.

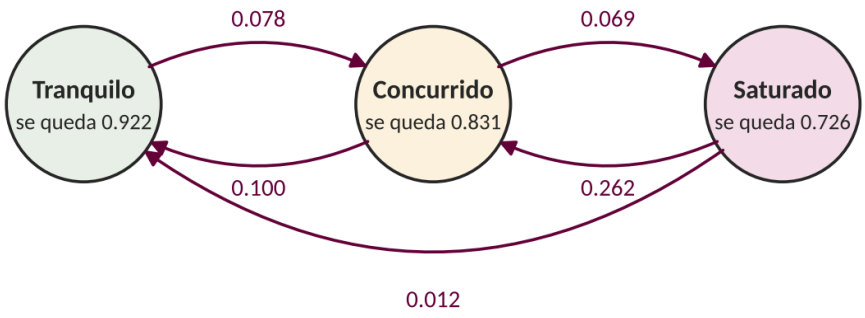


Diagrama de la cadena: cada flecha es la probabilidad de pasar de un estado a otro en una semana.

Varias semanas adelante (Chapman-Kolmogorov)

Para saber qué pasa en dos semanas, hay que considerar **todos los caminos** posibles por la semana intermedia y sumarlos. Eso es exactamente multiplicar la matriz por sí misma: la matriz a k semanas es P^k.

$$p^{(2)}_{\text{conc, sat}} = p_{\text{conc,tranq}}\, p_{\text{tranq,sat}} + p_{\text{conc,conc}}\, p_{\text{conc,sat}} + p_{\text{conc,sat}}\, p_{\text{sat,sat}}$$

Paso a paso con nuestros datos: de concurrido a saturado en dos semanas

Hay tres caminos por la semana intermedia:

Camino 1, concurrido → tranquilo → saturado: $0.100 \times 0.000 = 0$.

Camino 2, concurrido → concurrido → saturado: $0.831 \times 0.069 = 0.057$.

Camino 3, concurrido → saturado → saturado: $0.069 \times 0.726 = 0.050$.

Suma: $0 + 0.057 + 0.050 = 0.107$. Un centro concurrido tiene **10.7 %** de probabilidad de estar saturado dentro de dos semanas. Desde tranquilo, a 8 semanas (P^8), es 5.4 %.

A largo plazo: la distribución estacionaria

Si se deja correr la cadena muchas semanas, la proporción de tiempo en cada estado se estabiliza en un vector π que ya no cambia al multiplicarlo por la matriz:

$$\pi = \pi P, \qquad \pi_{\text{tranq}} + \pi_{\text{conc}} + \pi_{\text{sat}} = 1$$

Paso a paso con nuestros datos: comprobación de la estacionaria

Resolviendo el sistema se obtiene $\pi = (0.513,\ 0.389,\ 0.098)$. Comprobamos la primera componente de πP:

$$0.513 \times 0.922 + 0.389 \times 0.100 + 0.098 \times 0.012 = 0.473 + 0.039 + 0.001 = 0.513 ✓$$

Qué significa: a la larga, el norte pasa el **9.8 % de las semanas saturado**.

Cuánto dura una racha. El número de semanas seguidas en un estado sigue una distribución geométrica con media $1/(1 - p_{ii})$. Una racha saturada dura en promedio $1/(1 - 0.726) = 1/0.274 = 3.65$ semanas.

¿Sirve? El puntaje de Brier

Para evaluar probabilidades (no solo aciertos) se usa el puntaje de Brier (1950): el error al cuadrado entre la probabilidad que se dio y lo que pasó.

$$B = \frac{1}{N}\sum_{n=1}^{N}\sum_{j}\left(p_{n,j} - o_{n,j}\right)^2$$

donde $p_{n,j}$ es la probabilidad que el modelo le dio al estado j en el caso n, y $o_{n,j}$ vale 1 si ese fue el estado real y 0 si no. Cero es perfecto; más bajo es mejor. Por ejemplo, si un centro está concurrido, la cadena da (0.100, 0.831, 0.069); si la semana siguiente resultó saturada, el puntaje de ese caso es $(0.100 - 0)^2 + (0.831 - 0)^2 + (0.069 - 1)^2 = 0.010 + 0.691 + 0.867 = 1.567$, un error grande porque le dio poca probabilidad a lo que pasó.

Lo probamos en las últimas 52 semanas, estimando la matriz cada semana solo con las transiciones anteriores:

Horizonte	Brier, Markov	Brier, persistencia	Brier, frecuencia simple
1 semana	**0.200**	0.225	0.544
4 semanas	**0.389**	0.484	0.549
8 semanas	**0.490**	0.676	0.555

La cadena da mejores probabilidades en los tres horizontes. Su valor está en la probabilidad (“14 % de riesgo de saturarse”), no en una etiqueta.

7.2 Tormentas: definición y distancia

Una tormenta “afecta al sur” si un punto de su trayectoria pasa a 200 km o menos de Chetumal, con viento de al menos 34 nudos (tormenta tropical o huracán), de 1966 en adelante (era satelital). Probamos alternativas: 100 km daba 13 eventos (muy pocos para estimar una tasa por mes) y 300 km daba 59 (incluye tormentas que no traen viento fuerte al sur).

La distancia sobre la Tierra se calcula con la **fórmula de haversine**, que mide la distancia por la superficie de una esfera (no en línea recta a través de ella):

$$d = 2R\arcsin\sqrt{\sin^2\left(\frac{\Delta\varphi}{2}\right) + \cos\varphi_1\cos\varphi_2\sin^2\left(\frac{\Delta\lambda}{2}\right)}$$

donde $R = 6{,}371$ km es el radio de la Tierra, φ la latitud y λ la longitud, en radianes. Ejemplo: el huracán Carmen pasó el 2 de septiembre de 1974 por (18.6°, −88.2°); Chetumal está en (18.5°, −88.3°). Con $\Delta\varphi = \Delta\lambda = 0.1°$ la fórmula da **15.3 km**: con 125 nudos, es evento. En total hubo **31 eventos en 60 temporadas** (1966–2025).

7.3 Poisson: la probabilidad de tormenta en cada mes

> **La idea en palabras**
>
> Las tormentas son eventos raros que llegan sin aviso, y una no depende de la otra. La distribución de Poisson es la que describe cuántos eventos así ocurren en un periodo, y solo necesita un número: cuántos llegan en promedio.

$$P(N_m = k) = \frac{e^{-\lambda_m}\lambda_m^k}{k!}, \qquad \hat{\lambda}_m = \frac{\text{eventos que empezaron en el mes } m}{60 \text{ temporadas}}, \qquad P(N_m \geq 1) = 1 - e^{-\hat{\lambda}_m}$$

Símbolo	Qué significa
N_m	Número de tormentas en el mes m (variable aleatoria)
λ_m	Promedio de tormentas en el mes m por temporada
$k!$	Factorial: $3! = 3 \times 2 \times 1 = 6$
$P(N_m \geq 1)$	Probabilidad de que haya al menos una tormenta en el mes

Por qué “1 menos ninguna”. Es más fácil calcular la probabilidad de que no haya ninguna tormenta: con $k = 0$, la fórmula da $e^{-\lambda}\lambda^0/0! = e^{-\lambda}$. “Al menos una” es todo lo demás: $1 - e^{-\lambda}$.

Por qué Poisson. Si un mes se divide en muchísimos instantes muy cortos y en cada uno puede empezar una tormenta con una probabilidad muy pequeña e independiente, el total sigue una binomial que, en el límite, es una Poisson (Ross, 2019).

¿Se vale usar Poisson? Lo comprobamos con los datos. En una Poisson la varianza es igual al promedio. En los 60 años el promedio es 0.517 tormentas por año y la varianza 0.559: el índice de dispersión es 1.08 y la prueba con la ji cuadrada (63.8 con 59 grados de libertad) da p = 0.31, así que no hay evidencia de que la varianza supere al promedio. Los años con 0, 1, 2 y 3 tormentas fueron 36, 19, 3 y 2; Poisson esperaría 35.8, 18.5, 4.8 y 0.8. Por eso no hizo falta una binomial negativa.

¿Y el cambio climático? En 1966–1995 hubo 10 eventos y en 1996–2025, 21. Si la tasa fuera la misma, cada evento caería en cualquiera de las dos mitades con 50 % de probabilidad; la prueba binomial da p = 0.071, que no es significativa al 5 %. Nos quedamos con los 60 años y lo declaramos como límite: con solo los últimos 30, la probabilidad de agosto subiría de 13.9 % a 23.4 %.

¿Qué tan precisa es cada probabilidad? Con pocos eventos por mes, cada promedio tiene incertidumbre. Su intervalo exacto al 90 % (método de Garwood, con la ji cuadrada) da para agosto entre 7.5 % y 23.0 %. En los meses sin ningún evento el modelo da 0 %, pero no haber visto tormentas en 60 años no prueba que nunca haya: el límite superior es 3/60 (la regla del 3), hasta 4.9 %. El cálculo completo está en el notebook 5 y en el Excel 5_Poisson_tormentas.xlsx, con fórmulas.

Paso a paso con nuestros datos: agosto y el año completo

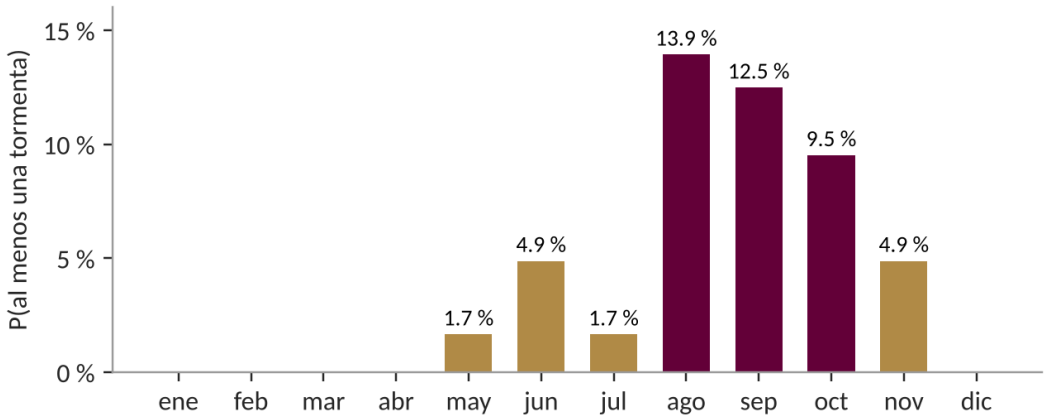
Paso 1. Agosto tuvo 9 eventos en 60 temporadas: $\hat{\lambda}_8 = 9/60 = 0.15$ tormentas por agosto.

Paso 2. Probabilidad de ninguna: $e^{-0.15} = 0.8607$.

Paso 3. Al menos una: $1 - 0.8607 = 0.139$, es decir, **13.9 %**.

Septiembre: $8/60 = 0.1333$; $1 - e^{-0.1333} = 12.5\ \%$.

Todo el año: la suma de procesos de Poisson independientes también es Poisson, así que se suman los promedios: $\lambda = 31/60 = 0.5167$ y $1 - e^{-0.5167} = 1 - 0.5965 = 40.3\ \%$.



Probabilidad de al menos una tormenta que afecte al sur, por mes.

7.4 Monte Carlo: escenarios malo, probable y bueno

Pregunta del incidente: ¿y si el año sale mejor o peor de lo pronosticado? ¿Qué tan probable es rebasar lo que un lugar ha podido recibir?

> **La idea en palabras**
>
> En lugar de un solo pronóstico, la computadora imagina 10,000 años posibles. En cada uno toma el pronóstico, le aplica un año de errores reales del pasado y le sortea tormentas. Con esos 10,000 años se ve qué tan malo puede ser un año malo y qué tan probable es pasarse de la capacidad.

Para cada futuro simulado $r = 1, \ldots, 10{,}000$ y cada mes $j = 1, \ldots, 12$:

$$D_j^{(r)} = \hat{y}_j \times e^{\varepsilon_j^{(r)}} \times \left(1 - \delta \cdot \mathbf{1}\left[N_j^{(r)} \geq 1\right]\right)$$

Símbolo	Qué significa
$D_j^{(r)}$	Visitantes del mes j en el futuro simulado número r
$\hat{y}_j$	El pronóstico del modelo elegido (capítulo 6)
$\varepsilon_j^{(r)}$	Un error real del pasado, $\ln(\text{real}/\text{pronóstico})$, sorteado al azar
$N_j^{(r)}$	Tormentas sorteadas con la Poisson del mes
$\mathbf{1}[\cdot]$	Vale 1 si lo de adentro es cierto (hubo tormenta) y 0 si no
δ	Cuánto quita una tormenta: 0, 25 % o 50 % (supuesto que se prueba)

Los tres factores, en palabras: el pronóstico, por un "golpe de suerte" del pasado, por un posible golpe de tormenta.

Errores en bloque. Se copian los 12 errores de un mismo origen del pasado juntos, no mes por mes. Los meses flojos vienen juntos (si un año sale bajo, sale bajo varios meses); sortear cada mes por separado haría los años demasiado parejos y subestimaría el riesgo.

El golpe de tormenta (δ) es un supuesto. Solo hubo 3 meses con tormenta entre los meses que entrenan (Earl 2016, Franklin 2017, Lisa 2022), muy pocos para medirlo. Por eso se prueban tres valores.

Escenarios: malo, probable y bueno son los percentiles 10, 50 y 90 de los 10,000 valores de cada mes. **Riesgo de capacidad:** la proporción de futuros en los que el mes rebasa la **capacidad probada** C (el mes más alto que el lugar ya recibió):

$$\hat{p}_j = \frac{\text{futuros en los que } D_j > C}{10{,}000}$$

¿Por qué 10,000 simulaciones? El error de un riesgo estimado con R simulaciones es $\sqrt{p(1-p)/R}$. Con el riesgo de la Ruta en enero ($p = 0.3035$): $\sqrt{0.3035 \times 0.6965/10{,}000} = 0.0046$, menos de

medio punto porcentual. Más simulaciones no cambiarían ninguna decisión. Lo comprobamos con 1,000, 5,000, 10,000 y 20,000 futuros y diez semillas distintas: desde 5,000 el escenario malo del año ya no cambia. Lo que limita la precisión no es el número de futuros sino los años de errores reales que tenemos (48 orígenes en la Ruta), y así lo declaramos.

> **Paso a paso con nuestros datos: dos futuros de la Bahía en agosto de 2026**
>
> El pronóstico es 879 visitantes.
>
> **Futuro A:** sorteó un error de −0.20 y una tormenta con $\delta = 0.5$: $879 \times e^{-0.20} \times (1 - 0.5) = 879 \times 0.8187 \times 0.5 = 360$ visitantes.
>
> **Futuro B:** sorteó un error de +0.10 y no hubo tormenta: $879 \times e^{0.10} \times 1 = 879 \times 1.105 = 971$ visitantes.
>
> **Con los 10,000 futuros**, los percentiles 10, 50 y 90 son **684 / 930 / 1,202**: el escenario malo, el probable y el bueno.
>
> **Por qué el probable (930) no es el pronóstico (879):** los errores reales de la Bahía tienen sesgo (el modelo se quedó corto 6 % en la mediana) y el Monte Carlo lo hereda. Es más honesto que suponer errores centrados en cero.

Lugar (12 meses)	Malo / probable / bueno, sin golpe	Con golpe de 50 %	Riesgo de capacidad
Ruta del sur	55,811 / 62,212 / 73,884	54,751 / 61,440 / 72,628	30.9 % (cap. 10,465 al mes)
Bahía	10,106 / 11,217 / 13,085	9,915 / 11,019 / 12,777	24.2 % (cap. 1,639 al mes)
Chetumal (Belice)	551,986 / 620,304 / 671,956	535,346 / 606,138 / 660,162	38.3 % (cap. 65,792 al mes)

Lectura para decidir. Primero, las tormentas pesan en el mes, no en el año: con el golpe más duro el escenario probable del año baja solo 1–2 %, así que la reserva para tormentas es por mes (agosto a octubre), no un recorte anual. Segundo, el riesgo de capacidad está en los meses pico: diciembre de 2026 en Chetumal (29 %) y en la Bahía (14 %), y enero de 2027 en la Ruta (30 %). Empujar la campaña en esos meses podría llevar a esos lugares a recibir más de lo que nunca han recibido. Por eso el modelo de presupuesto (capítulo 8) prohíbe anunciar ahí.

7.5 Sensibilidad: ¿qué variable mueve más?

Se agrega una variable v a la misma regresión del capítulo 6, $\ln y_t = \tau_{k(t)} + \mu_{m(t)} + \theta v_t$. El efecto en porcentaje es $e^{\widehat{\theta}} - 1$, y el **valor** p dice qué tan probable sería ver un efecto así de grande si en realidad no hubiera ninguno (por debajo de 0.05 se considera que hay evidencia).

Lugar	+100 mm de lluvia sobre lo normal	+1 peso por dólar
Bahía	−9.7 % ($p = 0.039$)	−0.2 % ($p = 0.92$)
Ruta	−0.6 % ($p = 0.92$)	+6.8 % ($p = 0.011$)
Chetumal (Belice)	−4.7 % ($p = 0.031$)	+1.2 % ($p = 0.36$)

Ejemplo, lluvia en la Bahía: $\hat{\theta} = -0.1017$, entonces $e^{-0.1017} - 1 = 0.9033 - 1 = -9.7\ \%$ de visitantes por cada 100 mm sobre lo normal. Son asociaciones, no causas probadas. Por ejemplo, la hipótesis de que un peso barato atrae más cruces desde Belice no se sostiene con estos datos ($p = 0.36$).

8. Investigación de Operaciones: repartir el presupuesto

Materia: Investigación de Operaciones · **Profesor:** Carlos Orozco Rocha (tutor del equipo) · **Criterio 6 de la rúbrica (12 %):** formula variables de decisión, función objetivo y restricciones; la solución es justificable.

Conexión con la materia. En clase formulamos y resolvimos problemas de **programación lineal** con el **método gráfico**, a mano y en Excel: definir variables de decisión, escribir la función objetivo y las restricciones, dibujar la región factible y evaluar sus vértices. El incidente crítico de esta UCA, *"Optimización de los flujos turísticos para un desarrollo sustentable"*, pregunta qué significa que una distribución sea óptima, qué restricciones son indispensables, qué tan sensible es la solución y, en concreto, cómo asignar el presupuesto de la campaña "sin rebasar la capacidad de carga de ningún destino y sin generar desigualdades entre comunidades". Por eso este capítulo empieza con la versión de dos variables del modelo, resuelta con el método gráfico (8.3), y después la extiende al modelo completo (8.4).

8.1 La pregunta

¿Cuánto dinero de la campaña va a cada lugar del sur, en qué mes y por qué canal, para traer el mayor número de visitantes **sin anunciar donde ya está lleno** y **sin rebasar la capacidad de nadie**?

8.2 Los parámetros: cuánto rinde un peso en cada canal

La idea en palabras

Un anuncio funciona como un embudo: muchas personas lo ven, algunas le dan clic y, de esas, algunas planean el viaje (conversión). Se paga por cada clic. Lo que importa para decidir es cuántos visitantes trae cada peso.

$$\text{clics} = \frac{\text{pesos}}{\text{costo por clic}}, \qquad \text{visitantes} = \text{clics} \times \text{tasa de conversión}$$

Juntando las dos, el rendimiento de un peso en el canal c es:

$$r_c = \frac{\text{tasa de conversión}_c}{\text{costo por clic}_c \text{ (dólares)} \times \text{pesos por dólar}}$$

Datos (categoría viajes, WordStream by LocaliQ, 2025; promedios de anunciantes de Estados Unidos, usados como supuesto etiquetado): Google, clic de 2.12 dólares y conversión de 5.75 %; Facebook, clic de 0.51 dólares. El dólar es el promedio de agosto de 2026 en FRED: 17.0609 pesos.

Paso a paso con nuestros datos: visitantes por peso

Google. Un clic cuesta $2.12 \times 17.0609 = 36.17$ pesos.

$$r_G = \frac{0.0575}{36.169} = 0.001590 \text{ visitantes por peso} = 1.59 \text{ por cada mil pesos}$$

Facebook. Un clic cuesta $0.51 \times 17.0609 = 8.70$ pesos.

$$r_F = \frac{0.0575}{8.701} = 0.006608 \text{ visitantes por peso} = 6.61 \text{ por cada mil pesos}$$

Qué significa: Facebook rinde cuatro veces más por peso porque su clic es cuatro veces más barato (con la misma conversión supuesta).

Hueco declarado: la conversión de Facebook para turismo no está publicada. El caso base usa la de Google viajes (5.75 %) y la sensibilidad prueba 3 % y 6.38 %. Además suponemos que cada conversión es un visitante; es una cota alta: si llegan menos, la capacidad queda aún más protegida.

8.3 El modelo de dos variables, resuelto con el método gráfico

Antes del modelo completo, conviene ver el corazón del problema con solo dos variables, como en clase.

Variables de decisión (en miles de pesos):

- x_1 = dinero en Facebook / Instagram.
- x_2 = dinero en Google.

Función objetivo (maximizar visitantes):

$$\max Z = 6.608\, x_1 + 1.590\, x_2$$

Restricciones:

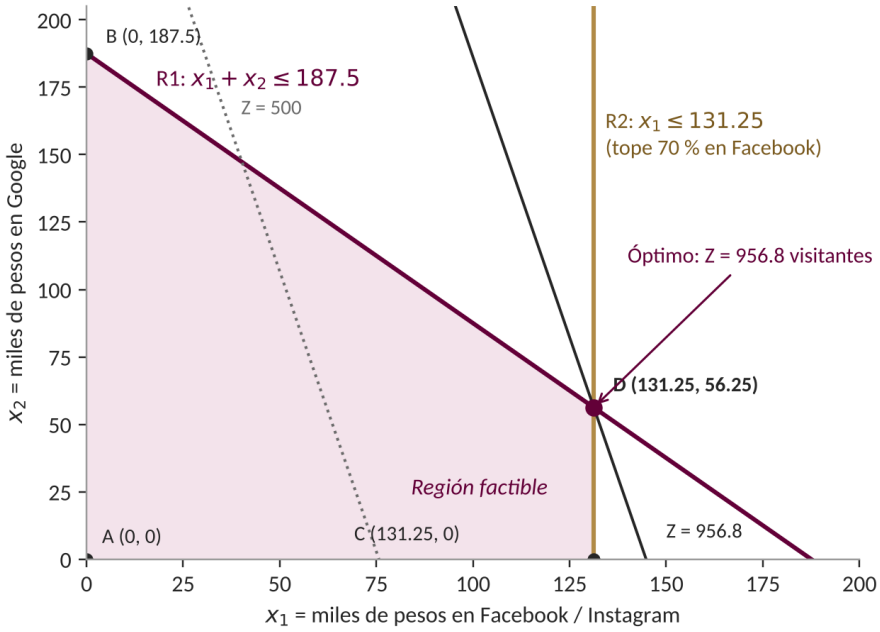
R1, presupuesto: $x_1 + x_2 \leq 187.5$

R2, tope de 70 % en Facebook: $x_1 \leq 131.25$

No negatividad: $x_1 \geq 0, x_2 \geq 0$

Elemento	De dónde sale
6.608 y 1.590	Visitantes por cada mil pesos en Facebook y en Google (8.2)
187.5	El presupuesto de 250 mil pesos al año, prorrateado a los 9 meses del plan: $250 \times 9/12 = 187.5$
131.25	El 70 % del presupuesto: $0.70 \times 187.5 = 131.25$. Es un tope para no depender de una sola plataforma

Paso 1. Graficar las restricciones. R1 es la recta $x_1 + x_2 = 187.5$, que corta los ejes en (187.5, 0) y (0, 187.5); la región que la cumple está debajo de la recta. R2 es la recta vertical $x_1 = 131.25$; la región está a su izquierda. Con la no negatividad, la **región factible** es el polígono sombreado de la figura.



Método gráfico: la región factible es el área sombreada; la recta negra continua es la función objetivo en su valor máximo, que toca la región solo en el vértice D.

Paso 2. Encontrar los vértices. El óptimo de un problema lineal siempre está en un vértice de la región factible. El vértice D es el cruce de R1 y R2: si $x_1 = 131.25$, entonces $x_2 = 187.5 - 131.25 = 56.25$.

Paso 3. Evaluar la función objetivo en cada vértice:

Vértice	x_1 (Facebook)	x_2 (Google)	$Z = 6.608\ x_1 + 1.590\ x_2$
A	0	0	0
B	0	187.5	1.590 × 187.5 = 298.1
C	131.25	0	6.608 × 131.25 = 867.3
D	**131.25**	**56.25**	867.3 + 89.4 = **956.8**

Paso 4. Conclusión. El óptimo es el vértice D: **131,250 pesos en Facebook y 56,250 en Google, que traen 956.8 visitantes** (unos 196 pesos por visitante). En la gráfica se ve también con las rectas de nivel: la recta $Z = 500$ (punteada) cruza la región; al moverla hacia arriba y a la derecha sin cambiar su inclinación, el último punto que toca es D.

La lógica, sin gráfica: Facebook rinde más por peso, así que se lleva todo lo que el tope le permite (70 %); lo que sobra va a Google, porque gastarlo rinde más que dejarlo sin usar.

Este mismo resultado lo da el programa. El modelo completo de 8.4 tiene 216 variables y no se puede dibujar, pero su respuesta total es la misma: 956.8 visitantes. Lo que agrega el modelo completo es **cómo repartir** ese dinero entre 3 lugares y 9 meses sin rebasar ninguna capacidad. El modelo chico se puede resolver también en Excel (con la herramienta Solver), como en las prácticas de la materia.

8.4 El modelo completo

Conjuntos

- **Meses m:** de octubre de 2026 a junio de 2027, los 9 que tienen calendario y escenarios para los tres lugares. Después no hay pronóstico, y no se extrapola.
- **Lugares l:** Chetumal, Bahía, Ruta.
- **Canales c:** Google, Facebook.
- **Escenarios s:** malo, probable y bueno (percentiles 10, 50 y 90 del Monte Carlo), con probabilidades p_s = 0.3, 0.4 y 0.3 (regla de Swanson para resumir una distribución con tres percentiles).

Variables de decisión

Variable	Tipo	Qué decide	Cuándo se decide
$x_{m,l,c} \geq 0$	Continua	Pesos en el mes m, lugar l, canal c	Hoy (“etapa 1”)
$y_{s,m,l} \in \{0,1\}$	Binaria	Si el anuncio sigue encendido (1) o se pausa (0)	Cuando se ve el escenario (“etapa 2”)
$w_{s,m,l} \geq 0$	Continua	Visitantes que sí llegan por la campaña	Cuando se ve el escenario

Visitantes que trae la campaña en cada mes y lugar: $v_{m,l} = r_G\, x_{m,l,G} + r_F\, x_{m,l,F}$.

Función objetivo

$$\max \sum_{s} p_s \sum_{m,l} w_{s,m,l}$$

En palabras: **maximizar los visitantes esperados**, es decir, el promedio (ponderado por la probabilidad de cada escenario) de los visitantes que sí llegan.

Restricciones

#	Restricción	En palabras
R1	$\sum_{m,l,c} x_{m,l,c} \leq 187{,}500$	No gastar más del presupuesto
R2	$x_{m,l,c} = 0$ si (m, l) es temporada alta	Cero anuncio en temporada alta
R3	$D_{m,l}^{p50} + v_{m,l} \leq C_l$	En el escenario probable, los visitantes esperados más los de la campaña no pasan de la capacidad probada
R4	$\sum_{m,c} x_{m,l,c} \geq 0.15 \times 187{,}500$ para cada lugar	Piso de equidad: cada lugar recibe al menos 15 %
R5	$\sum_{m,l} x_{m,l,c} \leq 0.70 \times 187{,}500$ para cada canal	Tope por canal: ninguno pasa de 70 %
R6	$D_{s,m,l} + v_{m,l} \leq C_l + M_{s,m,l}\,(1 - y_{s,m,l})$	Si en un escenario se rebasaría la capacidad, el anuncio se pausa
R7	$w_{s,m,l} \leq v_{m,l}$ y $w_{s,m,l} \leq U\, y_{s,m,l}$	Solo cuentan los visitantes de anuncios encendidos

Cómo funciona la “M grande” (R6 y R7)

La restricción R6 tiene dos modos, como un interruptor:

- **Si el anuncio sigue ($y = 1$):** el término $M(1 - y)$ vale 0 y queda $D + v \leq C$. La capacidad debe respetarse en ese escenario.
- **Si se pausa ($y = 0$):** el término suma M, un número suficientemente grande para que la restricción ya no obligue. Pero entonces R7 dice $w \leq U \times 0 = 0$: esos visitantes se pierden.

El valor de M es el más chico que logra eso, $M_{s,m,l} = \max\left(D_{s,m,l} + U - C_l,\ 0\right)$, porque una M demasiado grande vuelve lento al solucionador. $U = \max_c r_c \times 187{,}500$ es lo más que podría traer una celda.

Por qué se llama “estocástico de dos etapas”. La decisión de hoy (x) se toma sin saber qué escenario va a ocurrir; la reacción (y) depende del escenario. Al maximizar el promedio sobre escenarios, el modelo aprende, desde hoy, a no gastar en meses en los que un año bueno llenaría el lugar: ese dinero se perdería con probabilidad $p_{\text{bueno}} = 0.3$. Aquí se juntan las dos materias: la incertidumbre de Modelos Estocásticos entra a la optimización de Investigación de Operaciones.

8.5 Cómo lo resuelve la computadora

El modelo se escribe con PuLP y lo resuelve el solucionador CBC. Tiene 54 variables x, 81 binarias y y 81 variables w, y tarda 0.3 segundos.

- **Simplex.** Si todas las variables fueran continuas, las restricciones formarían un poliedro (la versión en muchas dimensiones del polígono del método gráfico) y el óptimo estaría en un vértice. El método simplex salta de vértice en vértice, mejorando cada vez, hasta que ningún

vecino mejora. Es exactamente la idea del Paso 3 del método gráfico, pero sin tener que revisar todos los vértices.

- **Ramificación y acotamiento.** Como y solo puede valer 0 o 1, CBC resuelve primero la versión con y continua (una cota optimista). Si alguna y sale fraccionaria, crea dos subproblemas ($y = 0$ y $y = 1$) y descarta las ramas que ya no pueden superar la mejor solución entera encontrada.

Desempate en dos pasos

Como todos los lugares convierten igual (no hay dato de respuesta por lugar), hay muchísimas soluciones con los mismos 956.8 visitantes. El solucionador entregaba una cualquiera: todo el dinero de cada lugar en un solo mes. Decidimos desempatar en dos pasos:

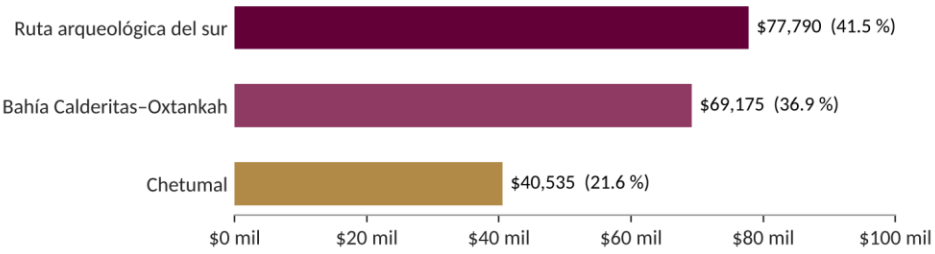
Paso 1: encontrar el máximo de visitantes, $z^* = 956.8$.

Paso 2: exigir al menos z^* y, entre esas soluciones, quedarse con la que reparte cada canal **en proporción al espacio libre** de cada mes y lugar:

$$\text{libre}_{m,l} = 1 - \frac{D_{m,l}^{p50}}{C_l}, \qquad \pi_{m,l} = \frac{\text{libre}_{m,l}}{\text{suma de los espacios libres de las celdas permitidas}}$$

y se minimiza la distancia entre lo que recibe cada celda y su meta $\pi_{m,l} \times$ (dinero del canal). El valor absoluto se vuelve lineal con un truco clásico: se agrega $d \geq 0$ con $d \geq x - \text{meta}$ y $d \geq \text{meta} - x$, y se minimiza d.

> **Paso a paso con nuestros datos: la Ruta en octubre de 2026**
>
> **Paso 1, espacio libre.** Se esperan 3,688 visitantes y la capacidad probada es 10,465: $\text{libre} = 1 - 3{,}688/10{,}465 = 1 - 0.3524 = 0.6476$.
>
> **Paso 2, su proporción.** Hay 20 combinaciones de mes y lugar permitidas (las otras 7 son temporada alta) y sus espacios libres suman 8.0004: $\pi = 0.6476/8.0004 = 0.0809$.
>
> **Paso 3, el dinero.** Facebook: $0.0809 \times 131{,}250 = 10{,}624$ pesos. Google: $0.0809 \times 56{,}250 = 4{,}553$ pesos. El código da lo mismo.



Reparto final del presupuesto de nueve meses por lugar.

Reparto final: Ruta 41.5 % ($77,790), Bahía 36.9 % ($69,175) y Chetumal 21.6 % ($40,535). Diciembre queda sin anuncio en los tres lugares porque es temporada alta.

8.6 ¿Cuánto cuesta cada regla? Precios sombra

El costo de cada regla se mide resolviendo el modelo sin ella y comparando:

Regla	Visitantes que cuesta	%
Cero anuncio en temporada alta	0	0 %
Tope de capacidad probada	0	0 %
Piso de equidad de 15 %	0	0 %
Tope de 70 % por canal	282	29.5 %

Precio sombra. Para cada restricción, cuánto mejoraría el objetivo si se aflojara una unidad: $\lambda_i = \partial z^* / \partial b_i$. En la gráfica de 8.3 se ve directo: si el presupuesto sube un peso, la recta R1 se mueve un poquito hacia afuera y el vértice D se desliza hacia arriba (más Google), porque Facebook ya está en su tope.

- **Presupuesto:** 0.00159 visitantes por peso (1.59 por cada mil pesos), justo el rendimiento de Google, porque un peso extra iría a Google.
- **Tope de Facebook:** $0.006608 - 0.001590 = 0.005019$ por peso. Cada peso que pasa de Google a Facebook suma 0.005 visitantes. Quitar el tope suma $0.30 \times 187{,}500 \times 0.005019 = 282.3$: exactamente el costo de la tabla.
- **Equidad y capacidad: precio sombra 0.** Por la **holgura complementaria**, una restricción que no "aprieta" no tiene precio: aflojarla no trae ningún visitante. Con este presupuesto, la regla ambiental (no rebasar la capacidad) no le cuesta nada a la campaña.

Frontera de Pareto: visitantes contra espacio libre

Cuando hay dos objetivos que chocan (más visitantes contra menos presión), no hay un solo óptimo, sino una frontera de soluciones en la que no se puede mejorar uno sin empeorar el otro. Se traza con el método de la ε-restricción: se pide que ningún mes con anuncio pase de ε veces su capacidad en el escenario probable ($D^{p50} + v \leq \varepsilon\, C$) y se maximizan los visitantes para varios valores de ε.

Tope ε	100 %	90 %	80 %	70 %	60 %	50 %	45 %	40 %	35 %	30 %
Visitantes	957	957	957	957	957	957	957	957	537	0

Qué significa: hasta 40 % no se pierde ningún visitante. La campaña puede prometer que **ningún mes con anuncio pasará del 40 % de su capacidad probada**, sin costo.

8.7 Sensibilidad: ¿y si los supuestos están mal?

Si cambia…	Visitantes
Nada (caso base)	957
Conversión de Facebook de 3 %	542
Conversión de Facebook de 6.38 %	1,052
Clic de Facebook a 0.42 dólares	1,143
Golpe de tormenta de 25 % o 50 %	957
Presupuesto de 500 mil pesos al año	1,914
Presupuesto de 1 millón de pesos al año	3,827

Los visitantes son proporcionales al presupuesto porque el modelo es lineal y la capacidad no se alcanza. El reparto entre lugares y canales casi no cambia en ningún caso: **la recomendación es estable**.

¿Por qué un piso de 15 % y un tope de 70 %? Son reglas de política, no datos, así que las probamos con varios valores. Cualquier piso de equidad hasta un tercio cuesta cero visitantes; elegimos 15 %, la mitad de un reparto igual, para que ninguna comunidad quede fuera si cambian los datos. El tope por canal sí cuesta: con 50 % llegan 769 visitantes, con 70 % llegan 957 y sin tope, 1,239. Nos quedamos con 70 % porque deja a Facebook como canal principal sin que toda la campaña dependa de su conversión, que es el supuesto menos seguro del modelo.

8.8 La etapa 2 en la práctica: el motor de la Torre

Cada semana, para cada lugar, el motor decide: temporada alta (no se gasta), fuera del plan, pausado (tormenta cerca, clima raro o llegó más gente de la esperada) o encendido. El dinero pausado no se pierde: pasa a la siguiente semana permitida.

$$b = \frac{\text{pesos del mes}}{\text{lunes del mes}}, \qquad \text{gasto}_w = (b + A_{w-1}) \text{ si está encendido; } 0 \text{ si no}$$

donde A_w es el dinero acumulado: sube b cuando la semana se pausa y vuelve a 0 cuando se enciende (se gasta todo).

> **Paso a paso: el arrastre del dinero**
>
> Octubre tiene 4 lunes; con 4,000 pesos en el mes, $b = 1{,}000$. **Semana 1 pausada:** no se gasta y $A = 1{,}000$. **Semana 2 encendida:** se gastan $1{,}000 + 1{,}000 = 2{,}000$ y A vuelve a 0.

En las 239 semanas reales hubo 48 pausas (lugar-semana), todo el dinero pausado se gastó después y la opción “¿Ibas al norte?” se encendió 6 semanas.

9. Mercadotecnia digital: la campaña

Materia: Mercadotecnia Digital · **Profesor:** Víctor Hugo Reyes Anselmo · **Criterio 7 de la rúbrica (8 %):** estrategia integral sustentada en datos; plan mercadológico, branding, buyer persona y medios digitales.

Conexión con la materia. El incidente crítico de esta UCA, *"Estrategias digitales para la redistribución del turismo"*, exige que "todas las decisiones sobre el buyer persona, los mensajes, los canales y el presupuesto" estén justificadas con los resultados de las otras cinco materias, y pregunta qué hacer "si la campaña genera una afluencia turística mayor a la capacidad del destino". Aplicamos el esquema clásico **STP** (segmentar, elegir y posicionar; Kotler y Keller, 2016), el **buyer persona**, la **propuesta de valor**, la selección de **medios**, el **embudo de conversión** con sus **KPI** y una regla anti-colapso programada. Cada rasgo de la campaña dice si es dato, cálculo o supuesto.

9.1 Segmentar: lo que dicen los datos

- **Quién visita el sur** (INAH 2025): Oxtankah, 94.8 % nacionales; la Ruta, 63.3 % nacionales y 36.7 % extranjeros.
- **Quién llega al estado en avión** (Unidad de Política Migratoria, 2025): 9,408,423 extranjeros a Cancún; Estados Unidos 56.3 % y Canadá 17.1 %; 53.4 % mujeres; más llegadas en marzo y menos en septiembre.
- **El hallazgo que define todo:** al aeropuerto de Chetumal llegaron **250 extranjeros** en 2025. El extranjero no llega al sur por avión: entra por Cancún y baja por carretera, en Tren Maya, desde Belice o en crucero.
- **Cómo se informan** (ENDUTIH 2025, INEGI): 92.1 % de la población de Quintana Roo usa internet (tercer lugar nacional); de quienes tienen teléfono inteligente, 90.6 % usa mensajería y 80.4 % redes sociales.
- **Qué valoran y qué los aleja** (capítulo 5): el ruido (2.76×), la suciedad (1.89×), el precio (1.66×) y las multitudes (1.52×) hunden una reseña; la calma (0.41×) y la cultura (0.48×) la protegen.

9.2 Elegir: dos viajeras ideales (buyer persona)

Elegimos dos personas: **"La que vuelve al sur"** (nacional) y **"La que baja del norte"** (Estados Unidos o Canadá, ya en Cancún o la Riviera). Descartamos solo la nacional (deja fuera al extranjero que ya está a 334 km) y solo la extranjera (la Bahía es 95 % nacional).

Persona	Rasgo	Valor y fuente	Tipo
La que vuelve al sur	Origen	Nacional: 94.8 % de Oxtankah y 63.3 % de la Ruta (INAH 2025)	Dato
	Cuándo viaja	De diciembre a abril; se le invita en los meses con espacio	Derivado

Persona	Rasgo	Valor y fuente	Tipo
	Qué valora	Calma (0.41×) y cultura (0.48×) en las reseñas	Derivado
	Qué la aleja	Ruido, suciedad, precio y multitudes	Derivado
	Cómo se informa	Mensajería 90.6 %, redes 80.4 % (ENDUTIH 2025)	Dato
	Estado de origen, edad, ingreso	No hay dato oficial por destino	Hueco
La que baja del norte	Origen	EE. UU. 56.3 % y Canadá 17.1 % de 9,408,423 extranjeros en Cancún	Dato
	Sexo	53.4 % mujeres	Dato
	Por qué no llega sola	250 extranjeros en el aeropuerto de Chetumal	Dato
	Cuándo está	Más en marzo, menos en septiembre; Cancún en temporada alta de noviembre a abril	Dato
	Cómo se informa	Busca en Google y usa redes desde el destino	Supuesto
	Idioma	Inglés y español	Derivado

9.3 Posicionar: la marca

- **Nombre:** “El sur tiene espacio” (*The south has room*). Dice el dato (capacidad ociosa) y la promesa (sin multitudes) a la vez.
- **Lema:** “Pirámides, bahía y sabor del sur, con espacio para disfrutarlos”.
- **Personalidad:** cercana y tranquila; orgullosa de lo maya y lo mexicano; con espíritu de aventura.
- **Propuesta de valor:** el Caribe mexicano que todavía tiene espacio: zonas mayas con 15.5 veces menos visitantes que Tulum (INAH 2025), una bahía tranquila y la comida del sur.
- **Declaración de posicionamiento:** para quien quiere el Caribe mexicano sin multitudes, el sur de Quintana Roo es la opción cultural y tranquila; a diferencia de Tulum o Cancún, aquí hay espacio, y la campaña lo cuida.
- **Identidad visual:** el sistema “Sur mexicano”: rosa, amarillo, turquesa y añil en bloques; tipografías Bricolage y Figtree; greca maya; fotos reales con coordenada comprobada.

9.4 Los mensajes: cada promesa con su dato

Reglas: cada anuncio lleva el dato que lo respalda; no se mencionan precios ni horas de viaje (no hay dato oficial); el lenguaje sale de las reseñas de 5 estrellas; y el largo se revisa contra los límites de cada

plataforma (Google: título de hasta 30 caracteres y descripción de hasta 90; Meta: título de hasta 40 y texto de hasta 125).

Persona	Canal	Mensaje	Dato que lo respalda
Vuelve	Google (es)	“Pirámides mayas con espacio”	Tulum 1,031,443 visitantes; Ruta 66,628 (15.5 veces menos)
Vuelve	Facebook (es)	“La bahía que te esperaba”	Oxtankah: 11,017 visitantes en 2025, 94.8 % mexicanos
Vuelve	WhatsApp	“¿Y si este puente nos vamos al sur?”	90.6 % usa mensajería; sin costo
Baja	Google (en)	“Mayan pyramids, with room”	El mismo 15.5; Cancún en temporada alta
Baja	Facebook (en)	“Your Caribbean trip, one stop south”	Tren Maya con estación en Chetumal; solo se muestra si la Torre marca el norte lleno

9.5 Los medios

Medio	Peso	Justificación con datos
Facebook / Instagram	70 %	6.61 visitantes por cada mil pesos; 80.4 % usa redes. Tope de 70 % para no depender de una plataforma (capítulo 8)
Google búsqueda	30 %	Llega a quien ya busca viajar; conversión de 5.75 % en viajes
WhatsApp (orgánico)	Sin costo	90.6 % usa mensajería; el botón de compartir viaja entre familia y amigos
La página	Destino	Planeador por lugar y mes en 10 idiomas, sin llamadas a otros sitios

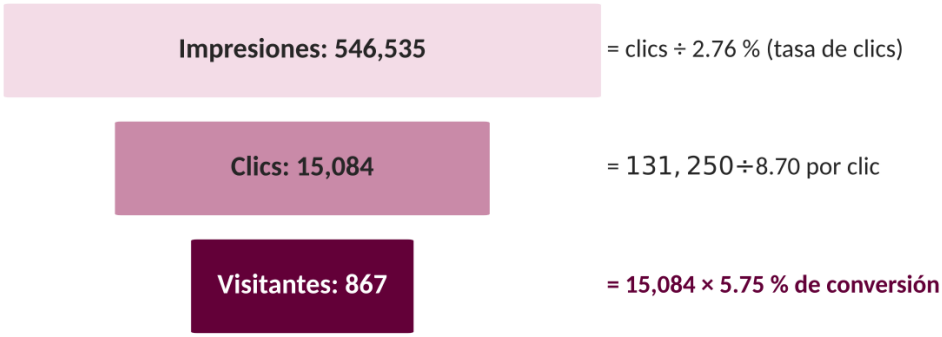
Calendario: los 9 meses del plan (octubre de 2026 a junio de 2027) con el dinero del capítulo 8. “La que baja del norte” se activa solo en los meses en que Cancún está en temporada alta y el sur tiene espacio; además, la Torre la enciende por semana cuando el norte se satura.

9.6 Cómo se mide: el embudo y los indicadores

> **La idea en palabras**
>
> El embudo se recorre al revés de como se paga: con el dinero se compran clics; para conseguir esos clics, cierta cantidad de personas tuvo que ver el anuncio; y de los clics, una parte se convierte en visitantes.

$$\text{clics} = \frac{\text{pesos}}{\text{costo por clic}}, \qquad \text{impresiones} = \frac{\text{clics}}{\text{CTR}}, \qquad \text{visitantes} = \text{clics} \times \text{tasa de conversión}$$

Indicador	Fórmula	Qué mide
CTR (tasa de clics)	clics ÷ impresiones	Qué tan atractivo es el anuncio
Tasa de conversión	planes de viaje ÷ clics	Qué tan convincente es la página
CPA (costo por visitante)	pesos gastados ÷ conversiones	Qué tan eficiente es el gasto



El embudo de Facebook con el reparto del capítulo 8.

Paso a paso con nuestros datos: el embudo esperado

Facebook. Clics: 131,250 ÷ 8.70 = 15,084. Con una tasa de clics de 2.76 %, eso supone 15,084 ÷ 0.0276 = 546,535 impresiones. Visitantes: 15,084 × 0.0575 = 867.

Google. Clics: 56,250 ÷ 36.17 = 1,555. Con una tasa de clics de 8.73 %, 1,555 ÷ 0.0873 = 17,814 impresiones. Visitantes: 1,555 × 0.0575 = 89.

Costo por visitante: 187,500 ÷ 956 = 196 pesos.

Son estimaciones con promedios de EE. UU.: las metas reales se fijan con el primer mes de campaña.

Indicador	Fórmula	Meta
Alcance	Personas únicas que vieron un anuncio	Se fija con el primer mes real
Interacción (CTR)	clics ÷ impresiones	Google ≥ 8.73 %; Facebook ≥ 2.76 %
Conversión	planes de viaje ÷ clics	≥ 5.75 %
Costo por visitante	pesos gastados ÷ conversiones	≤ 196 pesos
Afluencia	visitantes reales − escenario probable	+957 en 9 meses
Presupuesto	pesos gastados ÷ pesos planeados	100 % (lo pausado se gasta después)
Económico	ocupación hotelera de Chetumal	Hueco: no se publica desde 2025
Social	visitantes por cada mil habitantes (Radar)	Nunca “saturado”
Ambiental	semanas con anuncio en temporada alta o con mal clima	0
Capacidad	(esperados + campaña) ÷ capacidad probada	≤ 40 % en meses con anuncio

9.7 La regla anti-colapso

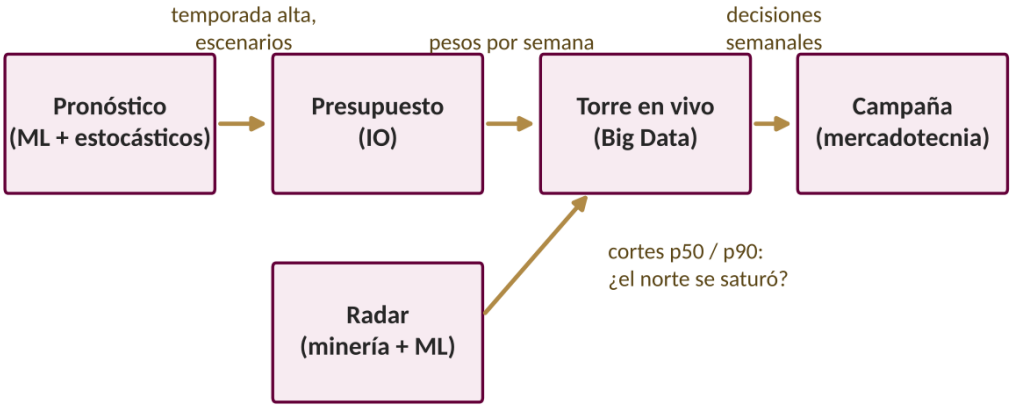
El incidente pregunta qué hacer si la afluencia rebasa la capacidad. La campaña tiene la respuesta programada, no solo escrita:

1. Nunca anuncia un lugar en su temporada alta (restricción R2 del presupuesto).
2. No permite que los visitantes esperados más los de la campaña pasen de la capacidad probada (R3).
3. La Torre pausa el anuncio si hay tormenta, clima raro o llegó más gente de la esperada.
4. A quien iba al norte lleno le ofrece el lugar del sur con más espacio, nunca otro lugar lleno.

10. Integración y propuesta final

Criterios 8 y 9 de la rúbrica (10 % y 8 %): articula los seis componentes; compara escenarios y propone una alternativa viable y equilibrada entre beneficio económico, distribución turística e impacto ambiental.

10.1 La estafeta: la salida de una materia es la entrada de la siguiente



Cómo se pasan los resultados entre los módulos del sistema.

Paso	Sale de (materia)	Archivo	Lo usa
1	Forma del año y Monte Carlo (Aprendizaje de Máquina y Estocásticos)	`pronostico_calendario`, `pronostico_escenarios`	El presupuesto: qué meses son temporada alta y cuánta capacidad queda
2	Presupuesto (Investigación de Operaciones)	`presupuesto_plan`	La Torre: cuánto gastar cada semana
3	Radar (Minería y Aprendizaje de Máquina)	Cortes p50/p90 de la ocupación semanal	La Torre: cuándo el norte está saturado
4	Torre en vivo (Grandes Volúmenes)	`envivo_decisiones`	La campaña: indicador ambiental y “¿Ibas al norte?”
5	Campaña (Mercadotecnia Digital)	`campana.json`	La página y el coloquio

10.2 Comparación de escenarios y propuesta

Escenario	Qué pasa	Decisión de la campaña
Año malo (percentil 10)	Llegan menos visitantes de lo esperado	La campaña trae su +957; no hay riesgo de capacidad
Año probable (percentil 50)	Lo pronosticado	Se gasta el plan completo; ningún mes con anuncio pasa del 40 % de su capacidad
Año bueno (percentil 90)	Llegan más visitantes	La Torre pausa el anuncio en los meses que se llenarían y el dinero pasa a semanas con espacio
Tormenta (agosto a octubre)	Hasta −50 % en el mes	Pausa semanal; el año cambia solo 1–2 %

Propuesta final: una campaña de 187,500 pesos en nueve meses (70 % Facebook/Instagram y 30 % Google, más WhatsApp orgánico), repartida Ruta 41.5 %, Bahía 36.9 % y Chetumal 21.6 %, sin anuncio en diciembre, que trae en el escenario esperado unos **957 visitantes adicionales a 196 pesos cada uno**, sin que ningún mes con anuncio pase del 40 % de su capacidad probada. Equilibra los tres objetivos del Problema Prototípico: más actividad económica en el sur, menos presión relativa en el norte y cero anuncios en temporada alta o con mal clima.

10.3 La página y el servidor

La página (https://catoxp.github.io/torre-del-caribe-unrc-2026/) es HTML, CSS y JavaScript sin framework y funciona sin internet. Todas sus cifras salen de un solo archivo generado desde Silver y Gold. La parte del viajero (planeador, qué hacer, lugares) está en 10 idiomas; la parte de los datos (Radar, presupuesto, Torre, campaña) va en español. El servidor FastAPI tiene 8 servicios; entre ellos, `/api/optimizar` resuelve en vivo el modelo del capítulo 8 en 0.3 segundos con los supuestos que manda la página, y `/api/stream` transmite la Torre semana a semana. La auditoría de accesibilidad con axe-core (normas WCAG 2.1, niveles A y AA) pasó de 67 fallas a 0 en cuatro vistas. No hicimos prueba con personas, y lo declaramos.

El clima que ve el viajero. La página muestra la lluvia y la temperatura máxima normales 1991–2020 medidas en las estaciones del Servicio Meteorológico Nacional (Chetumal, Nicolás Bravo y Cancún; en la Riviera Maya no hay estación con normales y se usa ERA5). Los modelos siguen con el reanálisis ERA5, porque necesitan la lluvia de cada mes de cada año. Comparados en 1991–2020, ERA5 reproduce la forma de la lluvia (correlación de 0.96 a 0.99, de 3 % a 9 % menos al año), pero marca de 2 a 3 °C menos de temperatura máxima, y eso para un viajero sí importa.

La entrega. Además de este documento entregamos siete notebooks, uno por materia, ya ejecutados. Cada uno rehace los cálculos de su capítulo a la vista, explica cada paso, justifica cada hiperparámetro con las alternativas que descartamos y compara cada cifra con la del proyecto: si una no coincidiera, el notebook se detendría. Los cálculos de Poisson (7.3) y del método gráfico (8.3) también están en Excel, con fórmulas.

11. Lo que no se pudo medir y lo que se supuso

11.1 Supuestos

Supuesto	Dónde	Cómo se protegió
Costos por clic y conversiones de EE. UU.	Presupuesto	Se etiquetan como supuesto y se prueba la sensibilidad
Cada conversión es un visitante	Presupuesto	Es una cota alta: protege la capacidad
Golpe de una tormenta (0, 25 o 50 %)	Monte Carlo	Se prueban los tres valores; el año cambia 1–2 %
Capacidad = el mes más alto ya recibido	Monte Carlo y presupuesto	Se aclara que no es la capacidad física oficial
El futuro se parece al pasado	Rango conformal	Se mide la cobertura real; en la Ruta 2023 falló y se dice
La misma matriz de Markov para 7 centros	Radar semanal	Se declara como simplificación
El dato mensual se conoce al mes siguiente	Torre	En la realidad tarda 1–2 meses; se declara
Pesos iguales en el índice	Radar	Sensibilidad: cambia el estado del 0.6–6.0 % de los casos

11.2 Lo que los modelos no pueden afirmar

- Que el clasificador anticipe saturaciones del sur: en los cinco lugares casi no hubo cambios con qué probarlo.
- Que el clima cause cambios en los visitantes: las sensibilidades son asociaciones.
- Que la tasa de tormentas no esté subiendo: en 1996–2025 hubo el doble que en 1966–1995; con tan pocos casos no es significativo ($p = 0.071$), pero podría serlo con más años.
- El rendimiento real de la campaña: los indicadores tienen metas, pero solo se medirán cuando corra.

Los huecos de datos están en la sección 2.3.

12. Preguntas difíciles y su respuesta

Pregunta	Respuesta corta
¿Inventaron algún dato?	No. Lo que no existe es hueco; lo estimado lleva `_est`; cada cifra se rastrea hasta su archivo oficial y las pruebas automáticas recalculan las cifras de los documentos.
¿Por qué aparece Claude en el repositorio?	Usamos un asistente de programación con inteligencia artificial como herramienta. Las decisiones son del equipo, están documentadas y podemos explicar cada método (este documento).
¿Por qué el sur y no Bacalar o Tulum?	Sargazo récord de Tulum a Xcalak, caída de 31.3 % en Tulum y la laguna de Bacalar en deterioro. El sur tiene 12.3 % de la población y 1.4 % de los pasajeros de avión.
¿Por qué no promediaron porcentajes de ocupación?	Porque los meses con pocos cuartos pesarían igual que los grandes. Se suman cuartos y luego se divide.
¿Por qué validaron con origen móvil y no 80/20 al azar?	Porque en series de tiempo revolver al azar deja que el modelo vea el futuro.
¿Sirve su clasificador?	Le gana a “igual que este mes” por 4 aciertos de 156 y anticipa 6 de 30 cambios con 2 falsas alarmas; lo elegimos con un año de validación y lo medimos con otro. En el sur casi no hubo cambios con qué probarlo, y así lo decimos.
¿Qué garantiza el rango del 90 %?	Si los errores futuros se parecen a los pasados, el dato cae dentro al menos 90 de cada 100 veces. La cobertura real medida fue de 80 % a 97 %.
¿Por qué Poisson para las tormentas?	Son eventos raros e independientes en un periodo, y los datos lo confirman: la varianza de los conteos por año es casi igual a su promedio (índice de dispersión 1.08, p = 0.31).
¿Por qué 70 % en Facebook?	Rinde 6.61 visitantes por cada mil pesos contra 1.59 de Google; sin tope se iría el 100 % a una sola plataforma.
¿Qué significa el precio sombra?	Cuánto mejora el objetivo si se afloja una restricción una unidad. El del presupuesto es 1.59 visitantes por cada mil pesos.
¿Qué pasa si la campaña funciona demasiado bien?	La capacidad y la temporada alta son restricciones del modelo y la Torre pausa cada semana. Además se puede prometer no pasar del 40 % de la capacidad sin perder visitantes.

Referencias

Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules. En *Proceedings of the 20th International Conference on Very Large Data Bases* (pp. 487–499). Morgan Kaufmann.

Álvarez-Carmona, M. Á., et al. (2025). *Rest-Mex 2025* [Conjunto de datos]. IberLEF 2025. https://portal.odesia.uned.es/en/dataset/rest-mex-2025

Angelopoulos, A. N., & Bates, S. (2023). Conformal prediction: A gentle introduction. *Foundations and Trends in Machine Learning, 16*(4), 494–591. https://doi.org/10.1561/2200000101

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review, 78*(1), 1–3.

Canca Ortiz, J. D., & Villa Caro, G. (2021). *Introducción a la investigación de operaciones*. Editorial Universidad de Sevilla.

Chang, W. L., Boyd, D., & Levin, O. (2019). *NIST Big Data Interoperability Framework: Volume 6, Big Data Reference Architecture* (Version 2) (NIST Special Publication 1500-6r2). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.1500-6r2

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Gretzel, U., Sigala, M., Xiang, Z., & Koo, C. (2015). Smart tourism: Foundations and developments. *Electronic Markets, 25*(3), 179–188. https://doi.org/10.1007/s12525-015-0196-8

Hersbach, H., et al. (2020). The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society, 146*(730), 1999–2049. https://doi.org/10.1002/qj.3803

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Instituto Nacional de Estadística y Geografía. (2021). *Censo de Población y Vivienda 2020: Principales resultados por localidad (ITER)*. INEGI. https://www.inegi.org.mx/programas/ccpv/2020/

Instituto Nacional de Estadística y Geografía. (2025). *Cuenta satélite del turismo de México 2024*. INEGI. https://www.inegi.org.mx/temas/turismosat/

Instituto Nacional de Estadística y Geografía. (2026). *Directorio Estadístico Nacional de Unidades Económicas (DENUE)*. INEGI. https://www.inegi.org.mx/app/mapa/denue/

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3.ª ed.). Wiley.

Kotler, P., & Keller, K. L. (2016). *Marketing management* (15.ª ed.). Pearson.

Landsea, C. W., & Franklin, J. L. (2013). Atlantic hurricane database uncertainty and presentation of a new database format. *Monthly Weather Review, 141*(10), 3576–3592. https://doi.org/10.1175/MWR-D-12-00254.1

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. En *2008 Eighth IEEE International Conference on Data Mining* (pp. 413–422). IEEE. https://doi.org/10.1109/ICDM.2008.17

Monroe, B. L., Colaresi, M. P., & Quinn, K. M. (2008). Fightin' words: Lexical feature selection and evaluation for identifying the content of political conflict. *Political Analysis, 16*(4), 372–403. https://doi.org/10.1093/pan/mpn018

Organización Mundial del Turismo. (2005). *Indicadores de desarrollo sostenible para los destinos turísticos: Guía práctica*. OMT.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Ross, S. M. (2019). *Introduction to probability models* (12.ª ed.). Academic Press.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Secretaría de Turismo. (2025). *Compendio estadístico del turismo en México 2024*. Gobierno de México. https://www.datatur.sectur.gob.mx/SitePages/CompendioEstadistico.aspx

Secretaría de Turismo. (2026). *DataTur: Sistema Nacional de la Información Estadística del Sector Turismo de México*. Gobierno de México. https://www.datatur.sectur.gob.mx/

Secretaría de Turismo del Estado de Quintana Roo. (2026). *SITUR-Q: Sistema de Información Turística de Quintana Roo*. Gobierno de Quintana Roo.

Taha, H. A. (2024). *Investigación de operaciones* (11.ª ed.). Pearson Educación.

Universidad Nacional Rosario Castellanos. (2026). *Problema Prototípico e Incidentes Críticos, semestre 2026-2: Turismo inteligente sustentable para México*. Licenciatura en Ciencias de Datos para Negocios, 5.º semestre.

Wang, X., Smith, K., & Hyndman, R. (2006). Characteristic-based clustering for time series data. *Data Mining and Knowledge Discovery, 13*(3), 335–364. https://doi.org/10.1007/s10618-005-0039-x

Ward, J. H., Jr. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845

WordStream by LocaliQ. (2025). *Google Ads benchmarks 2025*. https://www.wordstream.com/blog/2025-google-ads-benchmarks

World Tourism Organization. (2018). *'Overtourism'? Understanding and managing urban tourism growth beyond perceptions*. UNWTO. https://doi.org/10.18111/9789284420070