

UNIVERSIDAD NACIONAL ROSARIO CASTELLANOS

Torre del Caribe

Hoja de ruta del proyecto

Licenciatura en Ciencias de Datos para Negocios · 5° semestre, 2026-2

Problema Prototípico: *Turismo inteligente sustentable para México*

Responsable técnico: **Brandon Uriel García Sánchez**

1. Dónde está el proyecto (28 de septiembre de 2026, actualizado)

Fase	Qué es	Estado
Plan y regiones	Plan aprobado; 5 regiones a promover (sur y Maya Ka'an); Cancún, Riviera Maya y Tulum solo como referencia	✅ Terminado (revisado el 28-sep)
Fase 0 — Preparación	Computadora lista para procesar datos grandes (PySpark, Java 17)	✅ Terminado
Fase 1 — Recolección de datos	353 archivos oficiales, 8,134,802 registros, costos publicitarios y evidencia de sargazo	✅ Terminado
Fase 2 — Limpieza y orden de datos	Convertir los datos crudos en tablas limpias (Silver) y tablas finales (Gold)	🔄 En curso (SITUR-Q, ocupación SECTUR 2022–2026, DENUÉ, INAH y Censo listos; faltan clima, huracanes, tipo de cambio, nacionalidades, reseñas, vuelos, cruceros, catálogo de datos y DuckDB; se terminan antes de la Fase 5)
Página web	Sistema "Sur mexicano": los 5 lugares en mapa 3D, cómo llega la gente, dónde se queda el dinero, las 12 fases, quiénes somos y preguntas rápidas	🔄 En curso
Fase 3 — Planteamiento con datos	Tabla de criterios de las 5 regiones, variables y actores	✅ Lista para revisión (las 5 regiones pasan los criterios; notebook 01 con variables, actores y concentración: los 5 lugares tienen el 12.3 % de la población pero el 1.4 % de las llegadas en avión)
Fase 4 — Radar	Índice de presión y estados tranquilo / concurrido / saturado, con predicción del mes siguiente	✅ Auditada y lista para revisión (índice de presión con llegadas por cuarto, predicción del mes siguiente con regresión logística, cadena de Markov del norte, clustering de 55 centros del país, notebook 02 y sección del Radar en la página; los 5 lugares, tranquilos en jul-2026)
Fases 5 a 11	Pronóstico, presupuesto, torre en vivo, campaña, backend y cierre	🕒 Pendiente

Cómo se trabaja cada fase: primero se explica qué se hará y con qué dato; si hay una decisión real, Brandon elige entre 2 o 3 opciones; se programa en piezas pequeñas; se prueba con cifras

oficiales conocidas; se agrega el capítulo correspondiente al documento ejecutivo en PDF.

2. Dos frentes que avanzan juntos

La campaña necesita dos cosas: **evidencia** (datos y modelos) y **una página web** que la muestre de forma atractiva a cualquier persona. Por decisión del responsable técnico, ambos frentes avanzan al mismo tiempo:

Frente de datos y modelos	Frente de la página web
Limpia los datos, construye los modelos y calcula los resultados	Muestra esos resultados con el sistema visual "Sur mexicano" (colores mexicanos en bloques, greca maya, fotos grandes; docs/decisiones/07-diseno.md)
Cada resultado queda en una tabla final (Gold)	La página lee esas tablas; cada vez que un modelo termina, su sección se "enciende" con datos reales

3. Qué sigue, fase por fase

Fase 2 — Limpieza y orden de los datos (en curso)

- **Qué se hace:** PySpark convierte los 8 millones de registros en tablas uniformes. Pone nombres claros, corrige tipos de dato, marca los huecos y suma las estaciones del Tren Maya. Después arma las tablas finales por destino y mes (Gold).
- **Avance:** listos SITUR-Q (12 indicadores) y la ocupación hotelera de SECTUR, que cubre **de 2022 a 2026** (239 semanas por centro de Quintana Roo), y el directorio de negocios DENUÉ completo (6,138,075 negocios; 13,663 turísticos en Quintana Roo). Siguen nacionalidades, zonas arqueológicas, vuelos, cruceros, clima, huracanes, reseñas y población.
- **Se entrega:** tablas limpias, diccionario de datos, reporte de calidad y comparación entre las dos fuentes que miden lo mismo (SITUR-Q contra DataTur en Cancún y Riviera Maya).

Página web (en paralelo; pensada para público no técnico)

1. **Portada:** "El sur tiene espacio." Teléfono con los 5 lugares y tarjetas con cifras reales de esos lugares (por ejemplo, "4 de cada 10 cuartos vacíos en Chetumal durante 2024"). Nada del norte en la portada.

2. **"Conoce los 5 lugares":** mapa con los lugares numerados y una ficha de cada uno: lugares para comer y para dormir, cuánta gente vive ahí, cuántos llegaron en tren o visitaron sus pirámides, y un aviso de cuidado. Si un dato no existe, la ficha dice "sin dato". Después se conectará al Radar (Fase 4).
3. **"¿Por qué el sur?":** Cancún y la Riviera Maya solo como referencia ("de cada 10 cuartos, 7 ocupados").
4. **Así llega la gente:** mapa de todo el estado con las llegadas por avión, Tren Maya, crucero y frontera.
5. **Dónde se queda el dinero:** tamaño de los hoteles por destino y hospedajes chicos, medianos y grandes.
6. **Las 12 fases:** tarjetas que se llenan conforme avanza el proyecto.
7. **Quiénes somos y fuentes,** con nombres completos y botón para descargar el documento del proyecto.
8. **Preguntas rápidas:** asistente con respuestas fijas sacadas de los datos, cada una con su fuente.

Todo funciona sin internet, en la computadora, y se ve bien en celular.

Fase 3 — Planteamiento con datos

- Tabla que califica las 5 regiones con los 5 criterios de selección, con Cancún, Riviera Maya y Tulum como referencia.
- **Decisión de Brandon:** cómo medir la presión turística en 2025–2026, cuando no hay ocupación oficial. Las opciones son usar llegadas medidas (Tren Maya, cruceros, Belice, habitaciones) o estimar la ocupación, marcándola como estimada.

Fase 4 — Radar (¿dónde hay espacio?)

- Índice de presión turística por destino y semana; un modelo que clasifica cada destino como tranquilo, concurrido o saturado; y la probabilidad de que cambie en las próximas semanas (cadena de Markov).
- **Decisión de Brandon:** cuánto pesa cada factor del índice y dónde van los cortes entre tranquilo, concurrido y saturado.
- **Página:** la sección "¿Dónde hay espacio hoy?" pasa a datos del modelo.

Fase 5 — Pronóstico (¿cuándo conviene ir?)

- Pronóstico de visitantes por mes con rango de confianza del 90 %, probabilidad de huracán por mes (175 años de registros) y escenarios malo, probable y bueno.

- **Página:** calendario de 12 meses tipo aplicación del clima, y la pestaña de escenarios.

Fase 6 — Reparto del presupuesto

- Modelo de optimización que decide cuánto invertir por mes, destino y canal, sin rebasar la capacidad y con un piso mínimo para cada comunidad. Usa los costos publicitarios ya reunidos.
- **Decisión de Brandon:** qué se maximiza (visitantes o derrama) y cuáles restricciones son indispensables.
- **Página:** pestaña "Presupuesto" con controles que recalculan en vivo.

Fase 7 — Torre en vivo (¿qué hace la campaña esta semana?)

- Reproduce semana a semana los datos reales de 2024 a 2026, detecta semanas anómalas y aplica las reglas de pausa (por ejemplo, sargazo en la Bahía de Chetumal).
- **Página:** pestaña "En vivo" con las decisiones que aparecen semana a semana.

Fase 8 — La campaña

- Minería de 85,993 reseñas de Quintana Roo, buyer persona con datos reales (origen, sexo y aeropuerto de llegada), marca, mensajes, piezas publicitarias e indicadores.
- **Decisión de Brandon:** nombre de la campaña, tono y mensajes.
- **Página:** sección "La campaña".

Fase 9 — Conexión de la página con el sistema

- Un servidor local que calcula en vivo (optimización y escenarios) y entrega los datos a la página.

Fase 10 — Pulido final de la página

- Revisión en celular y escritorio, capturas para el documento y una prueba con una persona no técnica.

Fase 11 — Cierre

- Documento ejecutivo completo, notebooks por materia, ensayo del coloquio de 15 minutos con reparto entre los integrantes.

4. Decisiones ya tomadas

Decisión	Motivo principal
Estado: Quintana Roo	Es donde hay datos oficiales confirmados de todas las fuentes
Se promueve una ruta de cultura, bahía, lagunas y comunidad, no playa	Sargazo récord en 2026 y crisis de Tulum (-31.3 % de visitantes)
5 regiones: Chetumal, Bahía Calderitas-Oxtankah, Ruta arqueológica del sur, Maya Ka'an + Kantemó y Laguna Milagros-Xul-Ha	Sin sargazo en su costa, sin cierres y sin saturación (datos del INAH y noticias de 2026)
Cancún, Riviera Maya y Tulum solo como referencia	Ahí está el turista al que se le habla, y ahí está la única ocupación hotelera medida en 2025-2026
Sistema de tres horizontes: hoy, próximos meses y esta semana	Cada módulo responde una sola pregunta y no se enciman
Todo se construye desde cero, sin el proyecto anterior	Decisión del responsable técnico
La página se construye en paralelo	Lo visual es la prioridad del proyecto
DENUE se procesa completo (6.1 millones de negocios)	Volumen real para el criterio de Big Data
Oferta turística = giros característicos del turismo (SECTUR/INEGI)	Criterio oficial y defendible

5. Riesgos y datos que no existen

Tema	Situación	Cómo se maneja
Ocupación hotelera 2025–2026	No existe en SITUR-Q para ningún destino; SECTUR sí la tiene para los 7 centros del norte	Decisión en la Fase 3
Isla Mujeres	Las noticias decían 93.5–95 % de ocupación; SECTUR registra 74.7 % y 43.2 % (feb y abr 2026)	Queda fuera por el foco en 5 regiones; se conserva como ejemplo de fuentes que no coinciden
Sargazo en la Bahía de Chetumal	En los canales de entrada, no en la costa (28-sep)	Vigilancia; pausa automática si llega a la costa
Conversión en Facebook para turismo	No está publicada	Supuesto declarado en la Fase 6
Costos publicitarios	Son promedios de EE. UU.	Se usan como referencia, no como medición de México
Laguna Milagros–Xul-Ha	Sin estadística turística propia	Se mide con población y directorio de negocios; se declara